UVOD

- Predavanja: prof. dr. Bojan Stopar (605)
- Vaje: doc. dr. Oskar Sterle (607) (računalniška učilnica)
- Dva kolokvija; pozitivna ocena obeh – pozitivna ocena pisnega dela izpita
- Izpit: sestavljeni, pogoj za pristop na ustni izpit je pozitivna ocena pisnega dela izpita
- 3 izpitni roki: 2 pozimi, 1 jeseni
- Literatura: zapiski, gradivo v spletni učilnici

OSNOVNI POJMI VERJETNOSTI

Slučajni dogodek in verjetnost

Eden od osnovnih pojmov v teoriji verjetnosti je slučajni dogodek.

Slučajni dogodek je tisti, katerega relativna frekvenca se približuje konstantni limiti, ko število ponovitev poskuša narašča v neskončnost.

Limita relativne frekvence pojava slučajnega dogodka je verjetnost dogodka.

Verjetnost slučajnega dogodka je število med 0 in 1.

Če je verjetnost slučajnega dogodka 0, se dogodek ne bo nikoli zgodil, če je verjetnost slučajnega dogodka 1 se bo dogodek vedno zgodil.

Če je verjetnost sl. dogodka med 0 in 1, se dogodek lahko ali pa ne dogodi, možnost pojava sl. dogodka je dana z verjetnostjo.

Če je A slučajni dogodek in $P(A)$ verjetnost pojava slučajnega dogodka, zapišemo verjetnost pojava slučajnega dogodka v matematični obliki:

$0 \leq P(A) \leq 1$

Neodvisnost slučajnih dogodkov

Dva slučajna dogodka sta neodvisna, če pojav enega nima vpliva na drugega.

Če sta dva slučajna dogodka neodvisna, je verjetnost, da se dogodita skupaj enaka produktu verjetnosti pojavov posameznih dogodkov. V matematičnem jeziku:

$$P(A \cap B) = P(A) \cdot P(B)$$

Slučajna spremenljivka

Verjetnost pojava slučajnega dogodka običajno podajamo glede na populacijo, to je množico vseh možnih izidov slučajnega dogodka.

Slučajne dogodke obravnavamo kot elemente populacije.

V mnogih primerih pa je bolj primerno in pregledno definirati verjetnost slučajnega dogodka kot funkcijo slučajne spremenljivke.

Primer:

Opravili smo meritve dolžine in izmerjene vrednosti zaokroževali na 0,01 m.

Kot slučajni dogodek A obravnavamo dogodek, da je zaokrožena vrednost izmerjene dolžine enaka 123,55 m ali manj, slučajni dogodek B, da je izmerjena vrednost enaka 123,56 m, dogodek C da je vrednost dolžine 123,57 m, dogodek D, da znaša dolžine 123,58 m in dogodek E da je dolžina 123,59 m ali več.

Za posamezen slučajni dogodek ugotovimo število pojavov (ponovitev) slučajnega dogodka.

Slučajni dogodek, da je zaokrožena vrednost enaka 123,55 ali manj (slučajni dogodek A) se je tako zgodil $n(A)$–krat, slučajni dogodek B se je zgodil $n(B)$–krat in tako dalje.

Očitno ja število pojavov vseh slučajnih dogodkov $n(A)\ldots n(E)$ enako skupnemu številu vseh slučajnih dogodkov n:

$$n = n(A) + n(B) + n(C) + n(D) + n(E)$$

Ker imamo na voljo veliko število meritev, lahko izračunamo relativne frekvence pojava posameznih slučajnih dogodkov.

$$f_r(A) = \frac{n(A)}{n},\ f_r(B) = \frac{n(B)}{n},\ f_r(C) = \frac{n(C)}{n},\ f_r(D) = \frac{n(D)}{n},\ f_r(E) = \frac{n(E)}{n},$$

Ker smo sprejeli relativno frekvenco pojava slučajnega dogodka za verjetnost pojava slučajnega dogodka imamo:

$$P(A) = f_r(A),\ P(B) = f_r(B),\ P(C) = f_r(C), P(D) = f_r(D), P(E) = f_r(E)$$

Če lahko relativne frekvence f_r aproksimiramo s primerno funkcijo $p(x)$, ki je funkcija x– a (v našem primeru je x zaokrožena vrednost izmerjene dolžine), nam taka funkcija predstavlja primerno osnovo za izračunavanje verjetnosti.

V povezavi s slučajnimi dogodki lahko definiramo kot slučajni dogodek tisti dogodek, da dolžina pridobi določeno vrednost x, vrednost $p(x)$ pa predstavlja verjetnost pojava tega slučajnega dogodka.

X predstavlja vrednost dolžine.

Slučajni dogodek, je dogodek v katerem slučajna spremenljivka X pridobi določeno numerično vrednost x.

To zapišemo v matematični obliki:

$X = x$

Verjetnost pojava slučajnega dogodka $(X = x)$ matematično zapišemo:

$P(X = x)$

Verjetnost pojava slučajnega dogodka $(X = x)$ podaja verjetnostna funkcija $p(x)$.

Zapišemo torej:

$p(x) = P(X = x)$

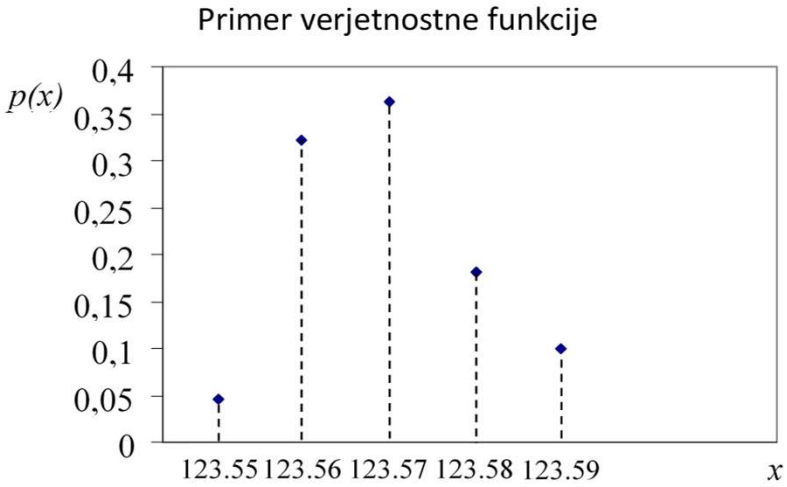

Tu je X <u>slučajna spremenljivka</u> in $p(x)$ pripadajoča <u>verjetnostna funkcija</u>.

Slučajna spremenljivka in njena verjetnostna funkcija sestavljata skupaj <u>verjetnostni model</u> <u>(stohastični model)</u>, to je matematični model, ki podaja razporeditev verjetnosti posameznim slučajnim dogodkom.

Slučajno spremenljivko bomo označevali z veliko črko (X), numerično vrednost, ki jo ta pridobi pa z majhno črko x oziroma z realnim številom.

Obravnavani primer si predstavljamo kot ilustracijo kaj je <u>verjetnostna funkcija</u> $\rightarrow$ matematični model dejanske razporeditve verjetnosti posameznim zaokroženim vrednostim merjene dolžine.

Naloga verjetnostne funkcije je torej razporeditev celotne razpoložljive verjetnosti med vse vrednosti slučajne spremenljivke, ki jih je ta pridobila.

Veljati pa mora, tako kot v gornjem primeru, da je vsota vseh vrednosti verjetnostne funkcije $\sum_{i=1}^{n} p_i(x_i) = 1$.

Verjetnostna funkcija $p(x)$ ni edina funkcija, ki je dodeljena slučajni spremenljivki.

Druga funkcija je funkcija porazdelitve verjetnosti $F(x)$ slučajne spremenljivke X.

Včasih jo imenujemo tudi porazdelitvena funkcija $F(x)$.

Definirana je:

$F(x) = P(X \leq x)$ za $\forall x$

Lahko jo interpretiramo kot verjetnost slučajnega dogodka, da slučajna spremenljivka pridobi vrednost, ki je manjša ali enaka vrednosti x.

Za porazdelitveno funkcijo $F(x)$ velja:

1. $P(a < X \leq b) = F(b) - F(a)$
2. $0 \leq F(x) \leq 1$, za $\forall x$
3. $F(a) \leq F(b)$, za $a < b$
4. $F(-\infty) = 0$
5. $F(\infty) = 1$
6. $\lim_{x \to a^+} F(x) = F(a)$

Primer porazdelitvene funkcije

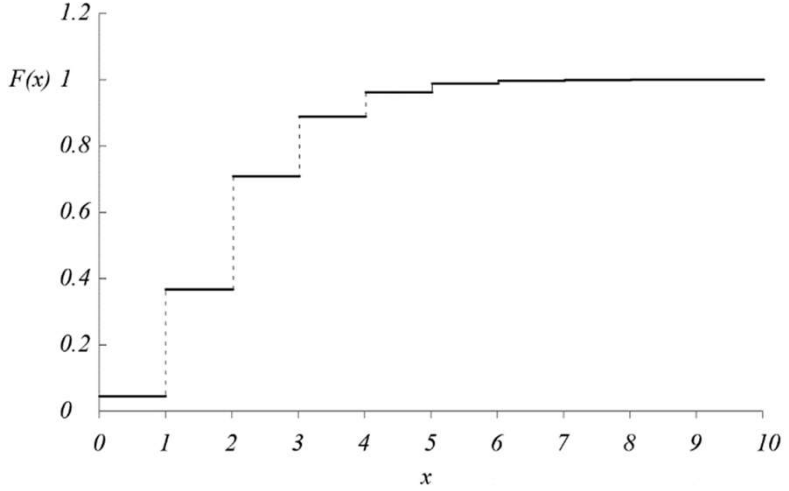

Enačba $0 \leq F(x) \leq 1$ zagotavlja, da bodo vse vrednosti $F(x)$ ležale med vključno 0 in vključno 1.

To mora biti izpolnjeno, ker so vrednosti $F(x)$ verjetnosti pojava slučajnih dogodkov, verjetnosti pa so števila med 0 in 1.

Enačba $F(a) \leq F(b)$, za $a < b$, določa porazdelitveno funkcijo kot nepadajočo, kar pomeni, da $F(x)$ ne more zmanjšati svoje vrednosti, ko x narašča.

Enačbi $F(-\infty) = 0$ in $F(\infty) = 1$ podajata skrajni vrednosti za porazdelitveno funkcijo $F(x)$.

Omenili smo že, da slučajna spremenljivka X in njej pripadajoča verjetnostna funkcija $p(x)$ sestavljata verjetnostni model.

Verjetnostni model pa je podan tudi s slučajno spremenljivko X in njej pripadajočo porazdelitveno funkcijo $F(x)$.

V obeh primerih je verjetnostni model definiran kot porazdelitev verjetnosti slučajne spremenljivke X.

Obravnavani primer predstavlja primer diskretne porazdelitve verjetnosti.

Značilnost diskretne porazdelitve verjetnosti je v tem, da je vrednost verjetnostne funkcije $p(x) \neq 0$, samo za določeno množico vrednosti x, za vse ostale vrednosti x, je $p(x) = 0$.

V našem primeru je $p(x) \neq 0$, samo za vrednosti na katere smo zaokrožili izmerjeno dolžino.

Iz tega izhaja, da mora biti porazdelitvena funkcija $F(x)$ diskretne porazdelitve verjetnosti stopničasta, kar pomeni, da funkcija $F(x)$ narašča v končnih skokih.

Velja pa tudi, da je vrednost $p(x)$ natanko enaka skoku $F(x)$ za $\forall\ x$, za katerega je $p(x) \neq 0$.

Skoki $F(x)$ so enaki vrednostim $p(x) \neq 0$ le za točno določene vrednosti x.

ZVEZNA PORAZDELITEV VERJETNOSTI

V gornjem primeru smo vrednosti meritev dolžine zaokrožili na najbližji .

Dejstvo, da smo imeli opravka le s končnim številom vrednosti, ki jih je lahko pridobila slučajna spremenljivka, je vodilo do opisa obnašanja pogreškov izmerjene dolžine v smislu diskretne porazdelitve verjetnosti.

Če gledamo na opazovanja in njihove pogreške splošno, v nezaokroženi obliki, je bolj praktično uporabljati verjetnostne porazdelitve, ki so zvezne.

Zvezna porazdelitev verjetnosti je verjetnostni model, ki ima zvezno porazdelitveno funkcijo $F(x)$, to je funkcijo brez skokov.

Če porazdelitvena funkcija $F(x)$ nima skokov, ima odgovarjajoča verjetnostna funkcija $p(x)$ vrednost enako 0 za $\forall\ x$ in je kot taka neuporabna.

Na njenem mestu je za zvezne porazdelitve verjetnosti uporabljena funkcija gostote verjetnosti $f(x)$.

To funkcijo smo že omenili v uvodu v predmet.

Funkcija gostote verjetnosti $f(x)$ je matematično definirana kot prvi odvod porazdelitvene funkcije $F(x)$:

$$f(x) = F'(x) = \frac{d}{dx} F(x)$$

Ker je $F(x)$ ne-padajoča funkcija je njen naklon (določa ga odvod) nenegativen.

Zato velja:

$$f\left(x\right) \geq 0$$

Imamo torej:

$$\int_a^b f(x)\, dx = F(b) - F(a)$$

Skupaj z enačbo $P\left(a < X \leq b\right) = F\left(b\right) - F\left(a\right)$ vidimo, da velja:

$$P\left(a < X \leq b\right) = F\left(b\right) - F\left(a\right) = \int_a^b f(x)\, dx$$

kar predstavlja verjetnost, da slučajna spremenljivka X pridobi vrednost med a in b.

Slučajni dogodek je $(a < X \leq b)$.

Verjetnost pojava tega slučajnega dogodka je definirana kot določeni integral funkcije gostote verjetnosti $f(x)$ na intervalu med a in b.

Verjetnost pojava tega slučajnega dogodka predstavlja površina pod funkcijo gostote verjetnosti $f(x)$ na intervalu med a in b.

Pri uporabi funkcije gostote verjetnosti $f(x)$ je pomembno vedeti, da le-ta ne zagotavlja verjetnosti, kot jo zagotavlja verjetnostna funkcija $p(x)$.

Verjetnost je v primeru zvezne porazdelitve in funkcije gostote verjetnosti $f(x)$ določena s površino pod funkcijo gostote verjetnosti na intervalu med a in b.

Za diskretno porazdelitev je verjetnost določena z vrednostjo verjetnostne funkcije $p(x)$, ki predstavlja ordinato za točno določeno vrednost x slučajne spremenljivke X.

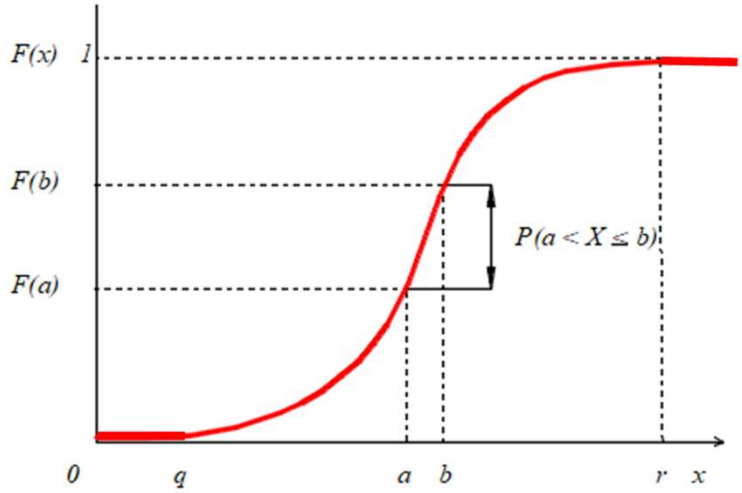

Porazdelitvena funkcija

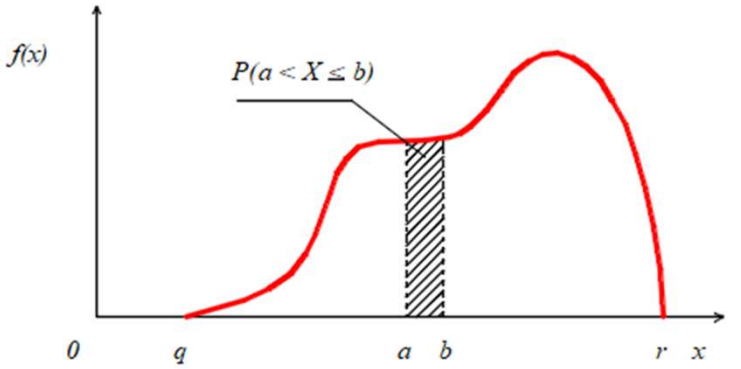

Funkcija gostote verjetnosti

Na osnovi dveh posebnih primerov enačbe:

$$P\left(a < X \leq b\right) = F\left(b\right) - F\left(a\right) = \int_{a}^{b} f(x)\ dx$$

lahko pridobimo dve pomembni in uporabni zvezi:

1.) Če postavimo vrednosti za $a = -\infty$ in $b = \infty$ ter z upoštevanjem $F(-\infty) = 0$ in $F(\infty) = 1$, dobimo:

$$\int_{-\infty}^{\infty} f(x)dx = P(-\infty < X \leq \infty) = F(\infty) - F(-\infty) = 1 - 0 = 1$$

kar pomeni, da je celotna površina pod funkcijo gostote verjetnosti $f(x)$ enaka 1.

2.) Postavimo vrednost za $a = -\infty$ in $b = x$ ter ob upoštevanju, da velja $F(-\infty) = 0$ in dejstva, da je slučajni dogodek $\left(X \leq x\right)$ enak slučajnemu dogodku $\left(-\infty < X \leq x\right)$, dobimo:

$$F\left(x\right) = P\left(X \leq x\right) = P(-\infty \leq X < x\ ) = F\left(x\right) - F(-\infty) = \int_{-\infty}^{x} f(u)\ du$$

Spremenljivko x v funkciji gostote verjetnosti $f(x)$ smo zamenjali s spremenljivko u $x \to u;\ u = x$ oz. $f(u) = f(x)$, ker je x ena od meja določenega integrala.

Gornja enačba pomeni, da v primeru, ko poznamo funkcijo gostote verjetnosti $f(x)$ lahko pridobimo porazdelitveno funkcijo $F(x)$.

Najpreprostejši primer zvezne porazdelitve verjetnosti je konstantna oz. enakomerna porazdelitev.

Slučajna spremenljivka X ima enakomerno porazdelitev verjetnosti, če je ne-ničelni del funkcije gostote verjetnosti konstanta.

To zapišemo:

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & \text{za } a<x<b\\ 0, & \text{drugje}\end{cases}$$

Števili a in b sta parametra porazdelitve.

Odgovarjajoča porazdelitvena funkcija je:

$$F(x)=\begin{cases}0, & \text{za } x\le a\\ \displaystyle\int_a^x \frac{1}{b-a}\,du=\frac{x-a}{b-a}, & \text{za } a<x<b\\ 1, & \text{za } x\ge b\end{cases}$$

Verjetnost, da je vrednost slučajne spremenljivke X manjša ali enaka vrednosti c je dana s šrafirano površino pod funkcijo gostote verjetnosti $f(x)$ in z ordinato $F(c)$, ki pripada vrednosti abscise c.

Neničelni del funkcije gostote mora biti enak $\dfrac{1}{b-a}$, da bo celotna površina pod funkcijo gostote enaka 1.

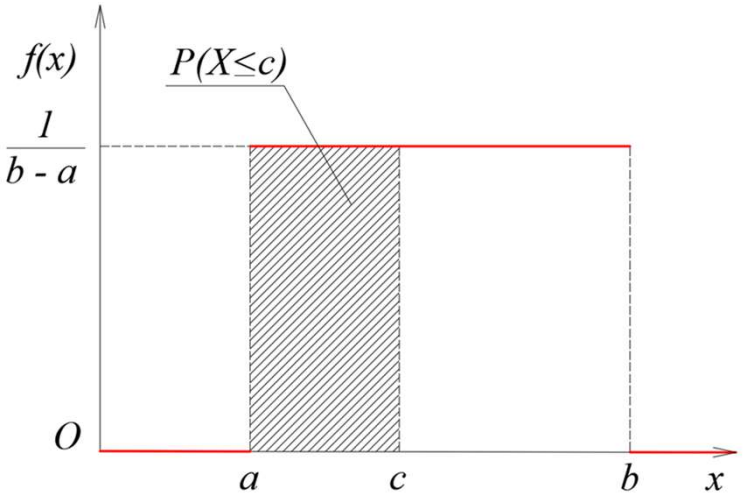

Funkcija gostote verjetnosti

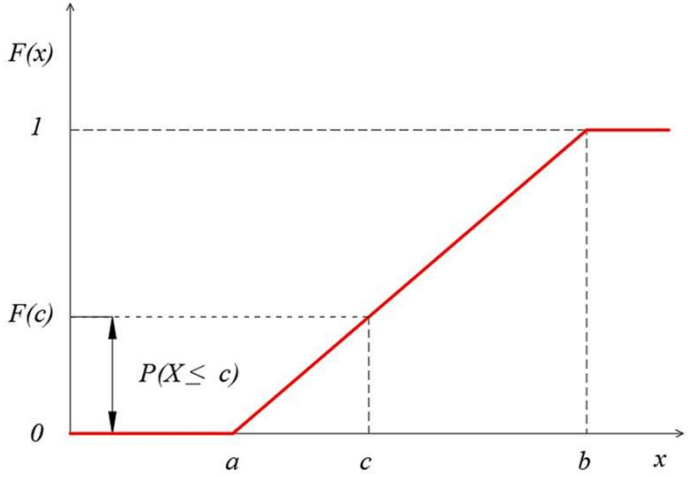

Porazdelitvena funkcija

NORMALNA PORAZDELITEV VERJETNOSTI

Najpomembnejša porazdelitev verjetnosti je normalna porazdelitev verjetnosti.

Velik pomen normalne porazdelitve verjetnosti izhaja iz dejstva, da predstavlja osnovni verjetnostni model vseh fizičnih meritev (fizičnih opazovanj), vključno z meritvami v geodeziji.

Funkcija gostote verjetnosti normalne porazdelitve je:

$$f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}\text{, za } -\infty<x<\infty$$

Količini μ in σ sta parametra porazdelitve in ju imenujemo μ –srednja vrednost in σ –standardni odklon.

Porazdelitvena funkcija normalne porazdelitve je:

$$F(x)=\int_{-\infty}^{x} f(u)\,du=\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{x} e^{-\frac{(u-\mu)^2}{2\sigma^2}}\,du$$

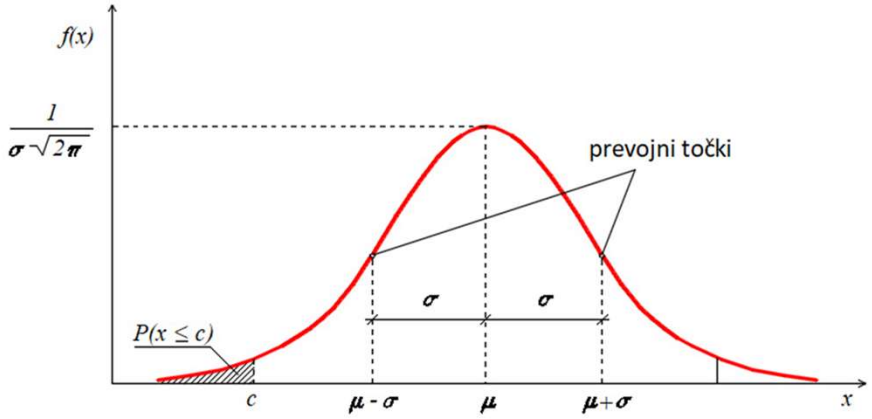

Funkcija gostote verjetnosti

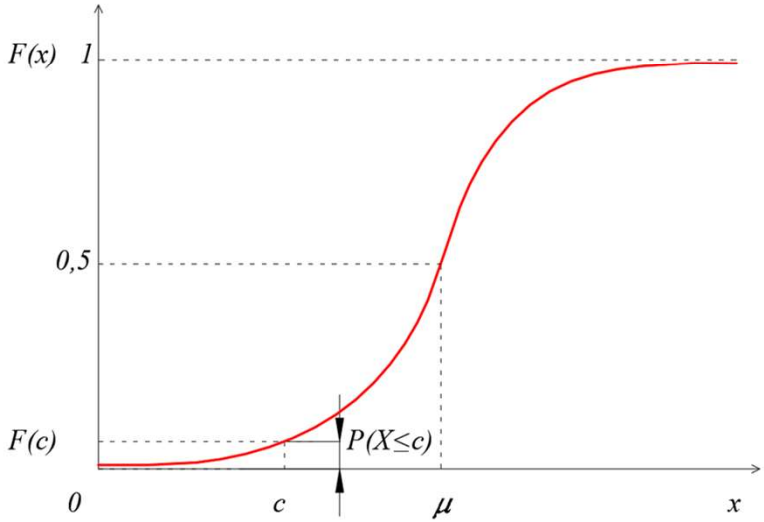

Porazdelitvena funkcija

Normalna porazdelitev je simetrična okrog srednje vrednosti μ .

Največja gostota (verjetnosti) je pri vrednosti abscise $x = \mu$.

Prevojni točki funkcije gostote sta pri vrednostih abscise $x = \mu - \sigma$ in $x = \mu + \sigma$.

Če je X slučajna spremenljivka z normalno porazdelitvijo, potem je na sliki porazdelitvene funkcije $F(x)$ vrednost $P(X \leq c)$ verjetnost, da je X manjši ali enak c, predstavljena s šrafirano površino pod funkcijo gostote verjetnosti $f(x)$ in z ordinato $F(c)$.

Primer:

Grafična predstavitev verjetnosti za zvezno porazdelitev verjetnosti in sicer verjetnost, da je X manjši ali enak 10 je $P(X \leq 10)$, verjetnost, da bo X med 11 in 15 $P(10 < X \leq 15)$ in verjetnost, da bo X večji od 16 $P(X > 16)$ je razvidna iz spodnjih slik.

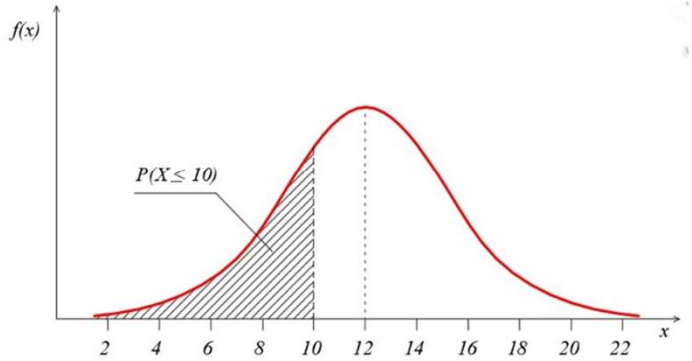

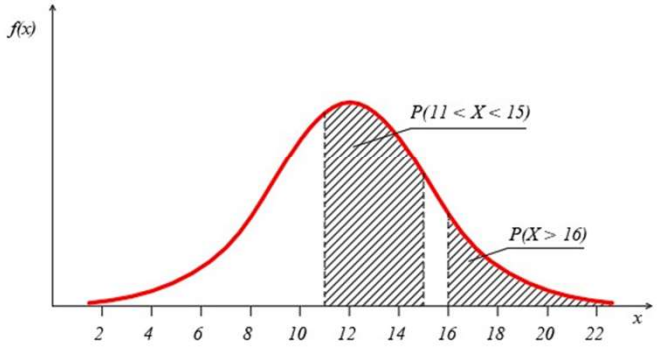

Verjetnost, da bo X natanko 10 je 0 $P(X = 10)$, ker je v tem primeru površina pod funkcijo gostote verjetnosti (na intervalu med 10 in 10) enaka 0.

Standardna-standardizirana normalna porazdelitev

Slučajna spremenljivka ima standardno normalno oz. standardizirano normalno porazdelitev, če je njena funkcija gostote verjetnosti:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}, \text{ za } -\infty < z < \infty$$

Standardna normalna porazdelitev je normalna porazdelitev z $\mu = 0$ in $\sigma = 1$.

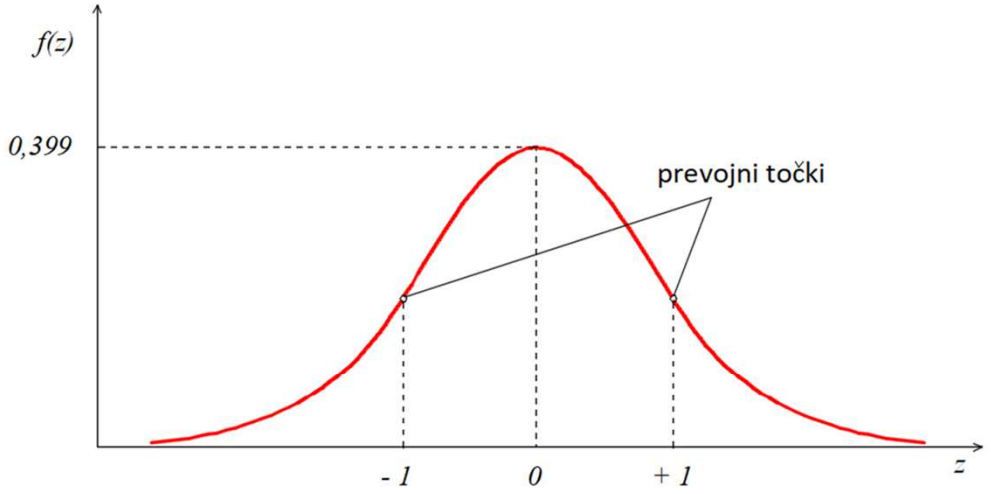

Standardna normalna porazdelitev je pomemben poseben primer normalne porazdelitve, ker zagotavlja udoben način določanja verjetnosti za katero koli normalno porazdelitev.

Funkcije gostote normalne porazdelitve ne moremo analitično integrirati, kar je lahko včasih težava, ko računamo verjetnosti za konkretne vrednosti μ in σ.

Težavo z integriranjem lahko rešimo s transformiranjem normalno porazdeljene slučajne spremenljivke X v standardno normalno porazdeljeno slučajno spremenljivko Z, za katero nato določamo odgovarjajoče verjetnosti.

Transformacija – standardizacija je dana z izrazom:

$$Z = \frac{X - \mu}{\sigma}$$

Prav tako kakor $f(x)$ (funkcija gostote verjetnosti normalne porazdelitve) je nemogoče analitično integrirati tudi $f(z)$ (funkcija gostote verjetnosti standardizirane normalne porazdelitve).

Rezultat standardizacije je porazdelitvena funkcija $\Phi(z)$ standardizirane normalne slučajne spremenljivke Z:

$$P(Z \le z) = \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-\frac{u^2}{2}} du \text{, za } -\infty < u < \infty$$

Ta integral rešimo numerično in tabeliramo pridobljene vrednosti $\Phi(z)$.

Normalna porazdelitev kot verjetnostni model meritev

Primernost izbire normalne porazdelitve za verjetnostni model meritev temelji na obnašanju dejanskih meritev–model je tako izbran, da se prilega meritvam.

Izbira normalne porazdelitve za verjetnostni model meritev pa ima tudi teoretično osnovo.

Če je (slučajni) pogrešek meritve vsota več komponent pogreška, od katerih ima vsaka svojo (drugačno) porazdelitev verjetnosti, se lahko pokaže, da ima celoten (skupen) pogrešek približno normalno porazdelitev, ne glede na to, ali so pogreški komponent tudi sami normalno porazdeljeni.

Za ilustracijo te zanimive lastnosti si oglejmo tri neodvisne enakomerno porazdeljene slučajne spremenljivke (komponente pogreška), vsako s parametroma $a=-1$ in $b=1$.

Funkcija gostote verjetnosti za vsako od treh slučajnih spremenljivk je dana s spodnjim grafom.

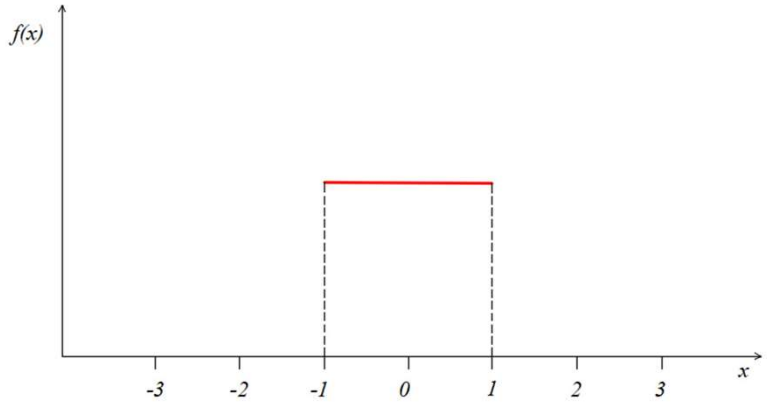

Vsota dveh enakomerno porazdeljenih slučajnih spremenljivk bo imela funkcijo gostote verjetnosti, dano z grafom:

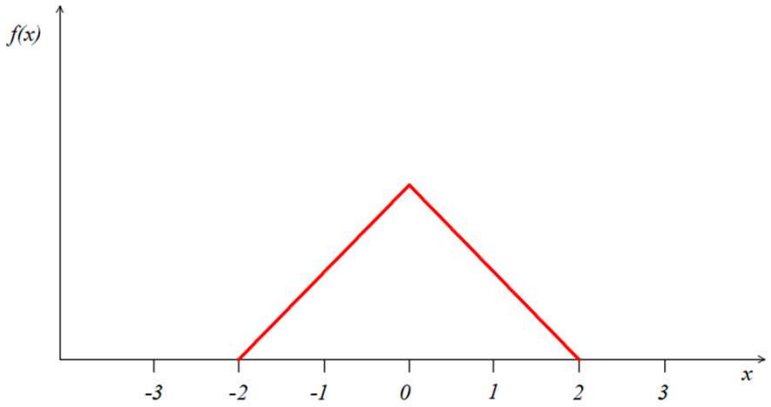

Vsota treh enakomerno porazdeljenih slučajnih spremenljivk bo imela funkcijo gostote verjetnosti:

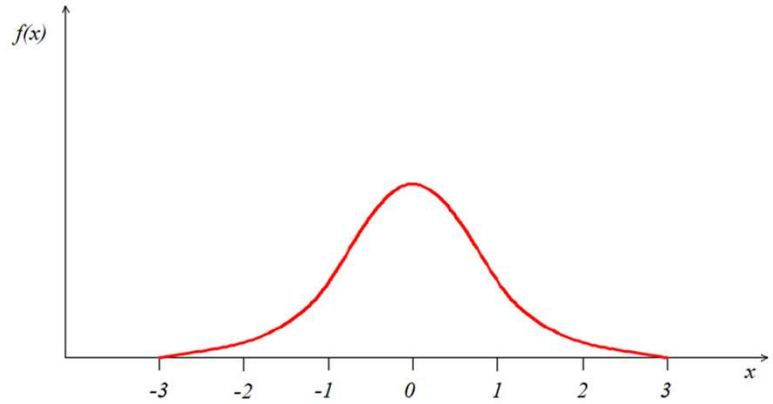

S slike vidimo, da je vsota treh enakomerno porazdeljenih slučajnih spremenljivk že podobna funkciji gostote verjetnosti normalne porazdelitve.

Vsota štirih enakomerno porazdeljenih slučajnih spremenljivk bo imela porazdelitev, ki bo še bliže normalni porazdelitvi in tako naprej.

Ko se število slučajnih spremenljivk (vplivov, ki vplivajo na izmerjeno vrednost; komponent, katerih skupni vpliv na merjeno vrednost je predstavljen kot slučajni pogrešek izmerjene vrednosti) povečuje, se porazdelitev verjetnosti njihovih vsot vse bolj približuje normalni porazdelitvi (dokaz podaja centralni limitni izrek).

Za meritve, za katere predpostavljamo, da vsebujejo veliko število komponent (na merjeno vrednost vpliva veliko vplivov) je kot verjetnostni model smiselno uporabljati normalno porazdelitev.

PRIČAKOVANA VREDNOST

Naj bo X diskretno porazdeljena slučajna spremenljivka, ki lahko pridobi vrednosti $x_1, x_2, ..., x_n,\ i = 1, ..., n$ in pripadajoča verjetnostna funkcija $p(x_i),\ \ i = 1, 2, ..., n$.

Uteženo vsoto vseh možnih vrednosti slučajne spremenljivke $x_1, x_2, ..., x_n$, kjer so $p(x_i),\ i = 1, 2, ..., n$ uteži odgovarjajoče vrednosti verjetnostne funkcije, imenujemo pričakovana vrednost $E(X)$ slučajne spremenljivke X :

$$E(X) = \sum_{i=1}^{n} x_i p(x_i) = x_1 p(x_1) + x_2 p(x_2) + ... + x_n p(x_n)$$

Pričakovana vrednost $E(X)$ slučajne spremenljivke X je tudi njena srednja vrednost μ :

$$\mu = E(X)$$

$E(X)$ oz. μ predstavlja absciso težišča porazdelitve verjetnosti sl. spremenljivke X .

μ je lahko negativna, pozitivna ali enaka 0.

Če obravnavamo funkcijo $g(X)$ slučajne spremenljivke X , je pričakovana vrednost te funkcije:

$$E(g(X)) = \sum_{i=1}^{n} g(x_i) p(x_i)$$

Če je, na primer, $g\left(X\right)=(X-\mu)^2$, imamo:

$$E\left((X-\mu)^2\right)=\sum_{i=1}^{n}(x_i-\mu)^2\,p(x_i)$$

Izraz $E\left((X-\mu)^2\right)$ imenujemo varianca slučajne spremenljivke X in jo označimo s σ^2:

$$\sigma^2=E\left((X-\mu)^2\right)$$

Kot vemo, je varianca mera razpršenosti slučajne spremenljivke oz. pripadajoče porazdelitve verjetnosti.

Pozitivni kvadratni koren variance σ^2 je standardni odklon oz. standardna deviacija σ.

Standardni odklon σ je, kakor tudi varianca σ^2, mera razpršenosti (spremenljivosti vrednosti) slučajne spremenljivke.

Velja:

$$\sigma=+\sqrt{\sigma^2}$$

Za zvezne porazdelitve verjetnosti sta srednja vrednost μ in varianca σ^2 definirani z integralom, ne z vsoto.

Za slučajno spremenljivko X z zvezno porazdelitvijo verjetnosti imamo tako:

$$\mu=E(X)=\int_{-\infty}^{\infty}x\cdot f(x)dx$$

$$\sigma^2=E\left((X-\mu)^2\right)=\int_{-\infty}^{\infty}(x-\mu)^2\,f(x)\,dx$$

Za simetrične porazdelitve verjetnosti je sredina μ (centralna) vrednost okrog katere obstaja simetrija.

Če je slučajna spremenljivka X normalno porazdeljena je:

$$E(x)=\int_{-\infty}^{\infty} x\cdot\left(\frac{1}{\sigma\sqrt{2\pi}}\right)\cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,dx=\mu$$

Parameter σ v funkciji gostote verjetnosti $f(x)$ normalne porazdelitve je standardni odklon σ oziroma njegov kvadrat varianca σ^2:

$$E\left((X-\mu)^2\right)=\int_{-\infty}^{\infty}(x-\mu)^2\cdot\left(\frac{1}{\sigma\sqrt{2\pi}}\right)\cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,dx=\sigma^2$$

Lastnosti pričakovane vrednosti so:

1. $E(a)=a$, a je konstanta
2. $E(a\cdot X)=a\cdot E(X)$
3. $E(a\cdot X+b)=a\cdot E(X)+b$
4. $E\left(g(X)\pm h(X)\right)=E\left(g(X)\right)\pm E\left(h(X)\right)$
5. $E\left(g(X,Y)\pm h(X,Y)\right)=E\left(g(X,Y)\right)\pm E\left(h(X,Y)\right)$

Lastnosti pričakovane vrednosti lahko uporabimo za izpeljavo pomembne zveze:

$$\begin{aligned}\sigma^2 &= E\left((X-\mu)^2\right)\\ &= E\left(X^2 - 2\mu X + \mu^2\right)\\ &= E\left(X^2\right) - 2\mu \underbrace{E(X)}_{=\mu} + \mu^2\\ &= E\left(X^2\right) - \mu^2\\ &= E\left(X^2\right) - \left(E(X)\right)^2\end{aligned}$$

Primer:

Če je X slučajna spremenljivka, a in b konstanti ter Y slučajna spremenljivka, določena z zvezo:

$Y = a\,X + b$

dokaži z uporabo lastnosti pričakovane vrednosti, da velja:

$\mu_y = a\mu_x + b$

in

$\sigma_y^2 = a^2\sigma_x^2$

kjer sta μ_x in μ_y srednji vrednosti ter σ_x^2 in σ_y^2 varianci slučajnih spremenljivk X in Y.

Imamo:

$$\begin{aligned}\mu_y &= E(Y)\\ &= E(aX+b)\\ &= aE(X)+b\end{aligned}$$

$$\mu_y = a\mu_x + b$$

in:

$$\begin{aligned}\sigma_y^2 &= E\left((Y-\mu_y)^2\right)\\ &= E\left((aX+b-a\mu_x-b)^2\right)\\ &= E\left((aX-a\mu_x)^2\right)\\ &= E\left(a^2(X-\mu_x)^2\right)\\ &= a^2\underbrace{E\left((X-\mu_x)^2\right)}_{=\sigma_x^2}\end{aligned}$$

$$\sigma_y^2 = a^2\sigma_x^2$$

Ob dani srednji vrednosti μ_x in varianci σ_x^2 slučajne spremenljivke X lahko, z uporabo lastnosti pričakovane vrednosti, določimo srednjo vrednost μ_y in varianco σ_y^2 linearne funkcije Y slučajne spremenljivke X.

Naloge:

1.) Za gornji primer ugotovi/preveri ali je srednja vrednost μ_y odvisna od variance σ_y^2 in ali je varianca σ_y^2 odvisna od srednje vrednosti μ_y.

2.) Premisli ali lahko uporabiš pričakovano vrednost za izračun srednje vrednosti μ_y in variance σ_y^2 tudi za nelinearno funkcijo $Y = f(X)$.

MERILA NATANČNOSTI IN TOČNOSTI

Pod predpostavko, da je normalna porazdelitev verjetnosti sprejemljiv verjetnostni model za opazovanja, lahko predstavimo merjeno količino s slučajno spremenljivko X, ki ima funkcijo gostote verjetnosti $f(x)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \text{za } -\infty < x < \infty$$

Če postavimo za srednjo vrednost $\mu = 0$ se gornja enačba preoblikuje v:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}}$$

V tej obliki predstavlja normalna porazdelitev verjetnosti model za slučajne pogreške opazovanj. Slučajni pogreški naj bi imeli srednjo vrednost μ enako 0. Funkcija gostote verjetnosti normalno porazdeljenih slučajnih pogreškov opazovanj je prikazana na sliki.

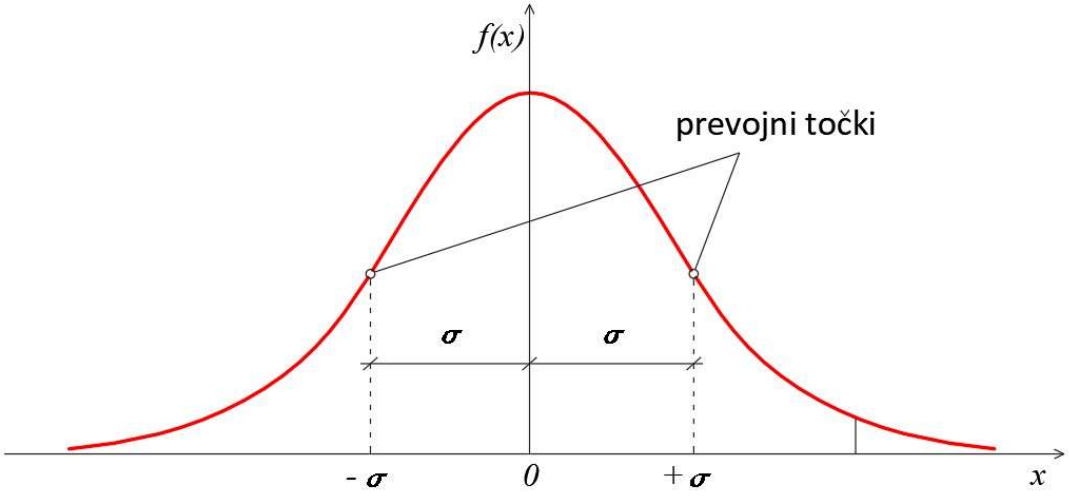

Natančnost opazovanj (kot smo jo definirali lani) je stopnja medsebojne skladnosti oz. bližine ponovljenih opazovanj iste količine.

Glede na to je širina verjetnostne porazdelitve opazovanj oziroma »velikost« slučajnih pogreškov, prisotnih v opazovanjih, merilo natančnosti opazovanj.

Majhna širina kaže visoko natančnost, velika širina majhno natančnost opazovanj.

Za potrebe analiz pa potrebujemo kvantitativno merilo za oceno natančnosti meritev.

Taki merili sta standardni odklon σ in varianca σ^2.

Velja: manjši standardni odklon višja natančnost in obratno.

Enako velja za varianco.

Za primer na sliki je $\sigma_1 < \sigma_2$ kjer je σ_1 standardni odklon natančnejšega niza opazovanj.

Ker mora biti površina pod funkcijo gostote verjetnosti enaka 1 ima funkcija gostote verjetnosti opazovanj višje natančnosti vrh nad funkcijo gostote verjetnosti opazovanj nižje natančnosti.

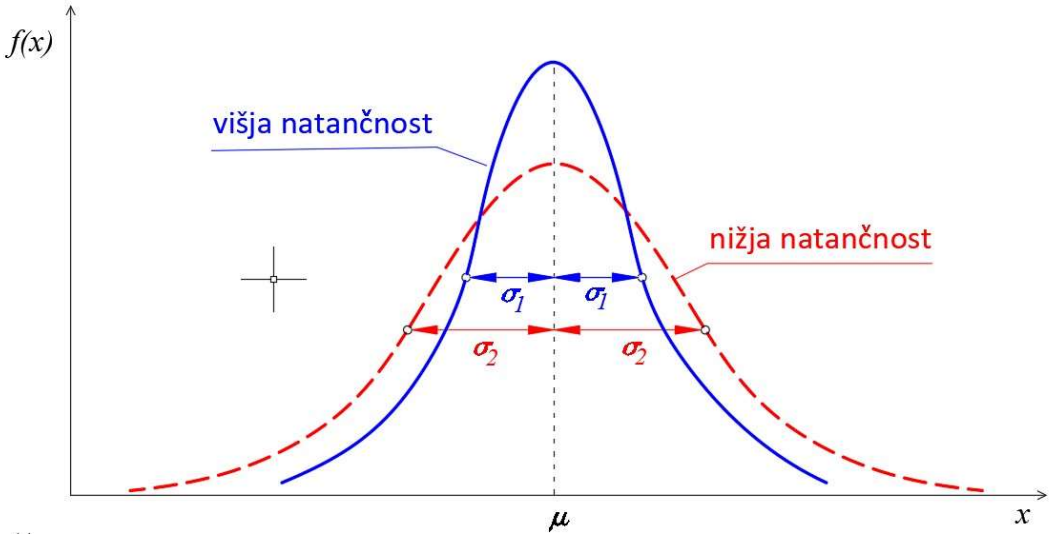

Na osnovi enačbe $P(a < X \leq b) = F(b) - F(a) = \int_a^b f(x) \cdot dx$ lahko določimo verjetnost, da leži opazovanje X med $\mu - \sigma$ in $\mu + \sigma$.

Imamo:

$$P(\mu - \sigma < X < \mu + \sigma) = \int_{\mu-\sigma}^{\mu+\sigma} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

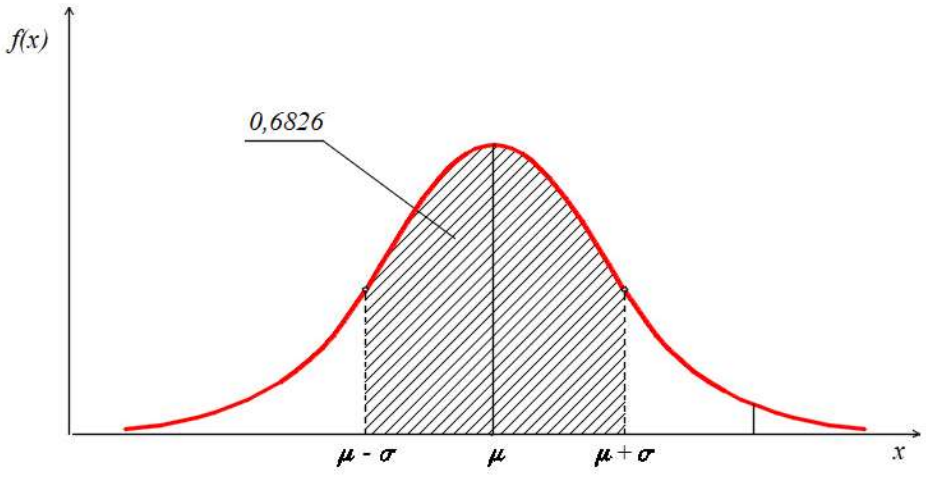

Da določimo to verjetnost, je najbolj prikladno, da slučajno spremenljivko X standardiziramo v skladu z enačbo $Z = \frac{X - \mu}{\sigma}$ in nato uporabimo tabele standardne normalne porazdelitve.

Imamo:

$$\begin{aligned} P(\mu - \sigma < X < \mu + \sigma) &= P\left(\frac{(\mu - \sigma) - \mu}{\sigma} < \frac{X - \mu}{\sigma} < \frac{(\mu + \sigma) - \mu}{\sigma}\right) \\ &= P(-1 < Z < 1) \\ &= \Phi(1) - \Phi(-1) \\ &= 0,8413 - 0,1587 = 0,6826 \text{ (tabela zgoraj)} \end{aligned}$$

kar predstavlja površino šrafiranega območja na sliki.

Mnogokratniki standardnega odklona so tudi merila natančnosti:

Verjetnost, da opazovanje leži v mejah $\mu - k\sigma$ in $\mu + k\sigma$ je dana z:

$$P\left(\mu - k\sigma < X < \mu + k\sigma\right) = \int_{\mu - k\sigma}^{\mu + k\sigma} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Če spet uporabimo postopek standardizacije, dobimo:

$$\begin{aligned} & P\left(\mu - k\sigma < X < \mu + k\sigma\right) \\ & = P\left(-k < Z < k\right) \qquad (*) \\ & = \Phi\left(k\right) - \Phi\left(-k\right) \end{aligned}$$

Če upoštevamo simetrijo normalne porazdelitve, velja:

$$\Phi(k) + \Phi(-k) = 1$$

V tem primeru se enačba (*) zreducira v:

$$P\left(\mu - k\sigma < X < \mu + k\sigma\right) = 2\Phi(k) - 1$$

$$\left(\begin{array}{l} \overset{\text{prištejemo in odštejemo } \Phi(k)}{\Phi(k) - \Phi(-k) + \quad \Phi(k) \quad - \quad \Phi(k)} \\ 2\Phi(k) - \left(\Phi(k) + \Phi(-k)\right) = \\ 2\Phi(k) - 1 \end{array} \right)$$

Vrednost $\Phi(k)$ za odgovarjajočo vrednost k pridobimo v tabelah standarde normalne porazdelitve.

Za nekatere vrednosti k so vrednosti $\Phi\left(k\right)$ in verjetnosti $P\left(\mu - k\sigma < X < \mu + k\sigma\right)$ dane v spodnji tabeli.

k	$\Phi(k)$	$P\left(\mu - k\sigma < X < \mu + k\sigma\right)$
0,674	0,7498	0,500
1,000	0,8413	0,683
1,645	0,9500	0,900
1,960	0,9750	0,950
2,000	0,9772	0,954
2,576	0,9950	0,990
3,000	0,9987	0,997

Glej tudi tabelo vrednosti $\Phi\left(z\right)$ za izbrane vrednosti z (normalna porazdelitev).

Točnost opazovanja smo definirali kot stopnjo skladnosti oz. bližine opazovanj in prave vrednosti τ opazovane količine X.

Na točnost vplivajo poleg slučajnih pogreškov tudi neodstranjeni sistematični pogreški.

Splošna mera točnosti je srednji kvadratni pogrešek M^2, ki je definiran s pričakovano vrednostjo:

$$M^2 = E\left((X-\tau)^2\right)$$

kjer je τ prava vrednost opazovanj.

Vpliv sistematičnih pogreškov predstavlja razlika med srednjo vrednostjo μ in pravo vrednostjo τ opazovane količine X:

$$\beta = \mu - \tau$$

Z uporabo lastnosti pričakovane vrednosti se da dokazati, da je:

$$M^2 = \sigma^2 + \beta^2 \qquad (**)$$

Ravno tako kakor večja varianca σ^2 predstavlja opazovanja manjše natančnosti, predstavlja večji srednji kvadratni pogrešek M^2 manjšo točnost.

Druga mera točnosti je koren srednjega kvadratnega pogreška oziroma količina $r.m.s.$ (angl. root of mean square error), ki je določena kot kvadratni koren srednjega kvadratnega pogreška M^2:

$$\mathrm{r.m.s.} = \pm\sqrt{M^2}$$

Nasprotno kot standardni odklon σ, ki je vedno pozitiven, ker je, po definiciji, določen, kot pozitivni kvadratni koren variance σ^2 predstavlja $\mathrm{r.m.s.}$ interval, vezan na pravo vrednost τ merjene količine.

Iz enačbe (**) izhaja, da visoka natančnost (majhen standardni odklon σ) ne pomeni nujno tudi visoke točnosti.

Če je standardni odklon σ majhen, vpliv neodstranjenih sistematičnih pogreškov β pa velik, imajo opazovanja sicer visoko natančnost, vendar v splošnem nižjo točnost.

Če smo iz opazovanj v celoti odstranili sistematične pogreške, predpostavimo, da je $\beta = 0$.

Brez vpliva sistematičnih pogreškov na točnost opazovanj je srednji kvadratni pogrešek M^2 enak varianci σ^2.

V tem primeru je natančnosti enaka točnosti in varianco σ^2 lahko uporabimo kot merilo točnosti.

Pred uporabo opazovanj je zato pomembno zmanjšati vpliv sistematičnih pogreškov na zanemarljivo majhno raven.

Kot smo omenili, je natančnost mera za razpršenost opazovanj glede na njihovo srednjo vrednost in je eno od meril kakovosti opazovanj.

Točnost je mera kakovosti, ki vključuje tako slučajne vplive (slučajne pogreške) kot tudi neodstranjene sistematične vplive (sistematične pogreške) na opazovanja.

Točnost opazovanj obravnavamo tudi kot sestavljeno mero kakovosti, ki nima enolične interpretacije, kot jo ima natančnost, čeprav sta merili točnosti, to je srednji kvadratni pogrešek M^2 in koren srednjega kvadratnega pogreška $r.m.s.$ enolično določeni.

Uvedemo še pojem pravilnosti opazovanj β, ki podaja stopnjo skladnosti oz. bližine prave vrednosti τ in srednje vrednosti μ opazovanj.

Do sedaj smo količino β obravnavali kot vpliv neodstranjenih sistematičnih pogreškov na opazovanja, ki povzročijo, da se srednja in prava vrednost razlikujeta.

Relacije med natančnostjo, točnostjo in pravilnostjo predstavljata obe sliki.

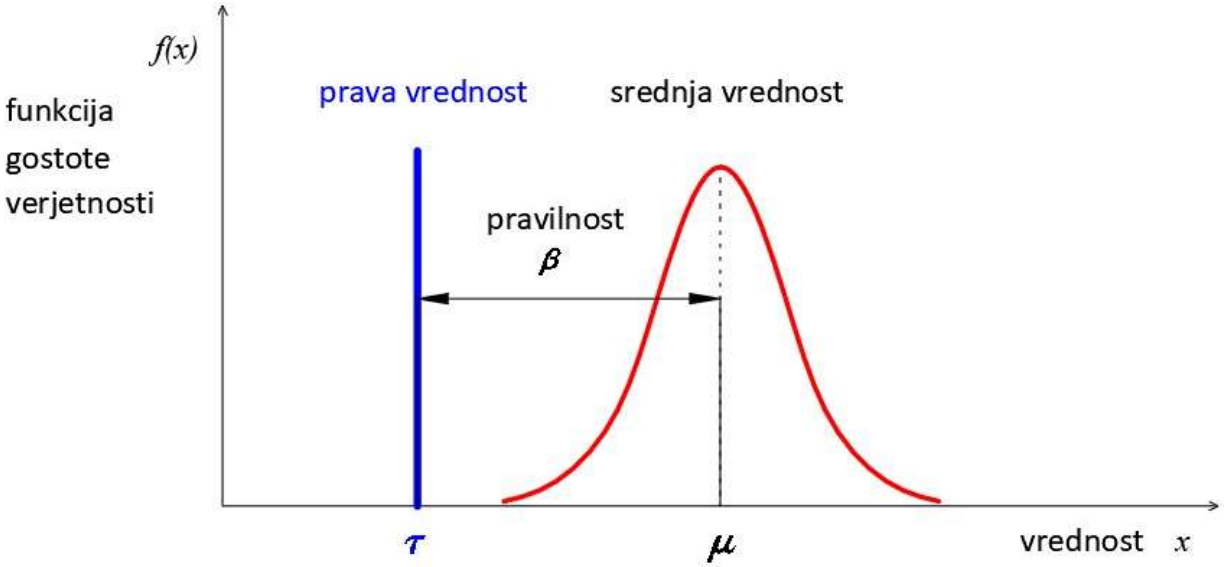

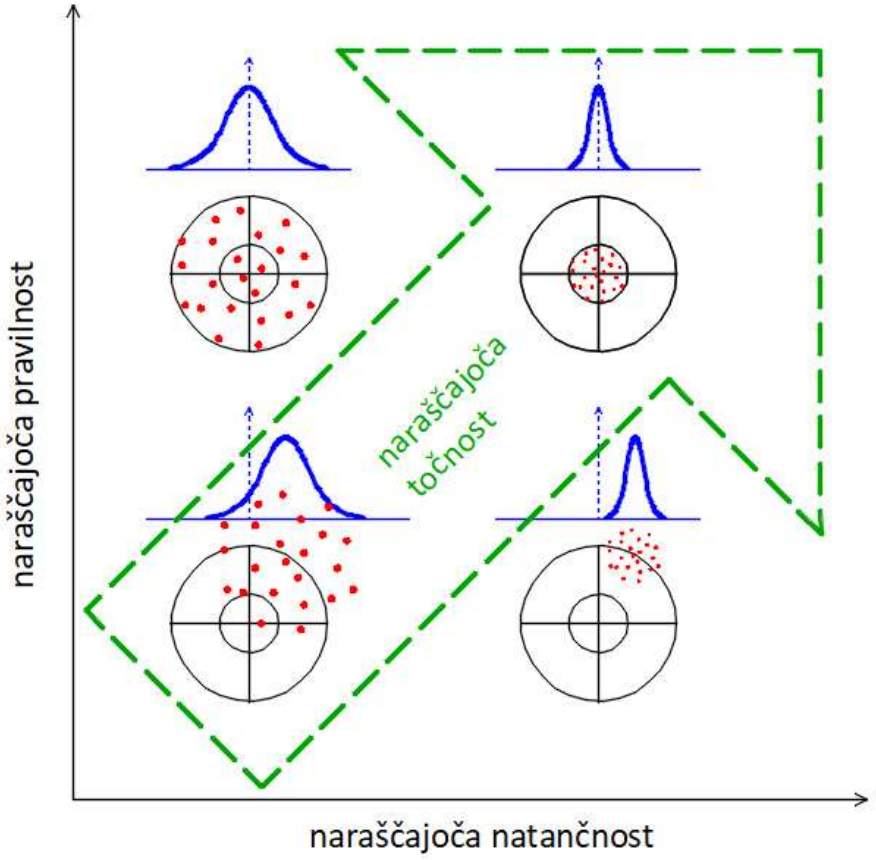

KOVARIANCA IN KORELACIJA

Če sta slučajni spremenljivki X in Y vključeni v isti verjetnostni model, pravimo, da sta skupno porazdeljeni oziroma, da imata skupno porazdelitev verjetnosti.

Njuna skupna porazdelitvena funkcija je:

$$F(x,y) = P(X \leq x, Y \leq y)$$

kar interpretiramo kot verjetnost, da je vrednost slučajne spremenljivke X manjša ali enaka od določene vrednosti x ter ob tem vrednost slučajne spremenljivke Y manjša ali enaka y.

Porazdelitveni funkciji $F(x)$ in $F(y)$ posameznih slučajnih spremenljivk X in Y pridobimo iz skupne porazdelitvene funkcije $F(x,y)$:

$$F(x) = P(X \leq x) = P(X \leq x, Y \leq \infty) = F(x,\infty)$$

in

$$F(y) = P(Y \leq y) = P(X \leq \infty, Y \leq y) = F(\infty, y)$$

Ko pridobimo porazdelitveni funkciji na tak način ju imenujemo delni porazdelitveni funkciji slučajnih spremenljivk X in Y.

Če sta X in Y zvezni slučajni spremenljivki je njuna skupna funkcija gostote verjetnosti $f(x,y)$ dana z:

$$f(x,y)=\frac{\partial^2}{\partial x \partial y}F(x,y)$$

Njuno skupno porazdelitveno funkcijo $F(x,y)$ pa izrazimo kot:

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y} f(u,v)\,du\,dv$$

Kjer je $f(u,v)$ skupna funkcija gostote verjetnosti sl. spremenljivk X in Y.

Lahko se dokaže, da sta delni funkciji gostote verjetnosti slučajnih spremenljivk X in Y določeni z:

$$f(x)=\int_{-\infty}^{\infty} f(x,y)\,dy$$

in

$$f(x)=\int_{-\infty}^{\infty} f(x,y)\,dx$$

Rekli smo, da sta dva slučajna dogodka neodvisna, če pojav enega nima vpliva na pojav drugega.

Na enak način rečemo, da sta dve slučajni spremenljivki neodvisni, če dodelitev vrednosti eni ne vpliva na vrednost dodeljeno drugi.

Zvezo za neodvisne slučajne dogodke pa lahko razširimo na porazdelitvene funkcije, če predpostavljamo, da sta $(X \le x)$ in $(Y \le y)$ slučajna dogodka.

Imamo torej:

$$P(X \le x, Y \le y) = P(X \le x)P(Y \le y)$$

oziroma:

$$F(x,y) = F(x)F(y) \qquad (*)$$

za neodvisni slučajni spremenljivki X in Y.

Če imata sl. spr. X in Y skupno zvezno porazdelitev verjetnosti in sta neodvisni, dobimo z odvajanjem obeh strani enačbe (*):

$$f(x,y) = f(x)f(y)$$

To zvezo lahko naprej razširimo na pričakovane vrednosti.

Lahko se dokaže, da za neodvisni slučajni spremenljivki X in Y velja:

$$E(XY) = E(X)E(Y) = \mu_x \mu_y$$

Delni porazdelitvi slučajnih spremenljivk X in Y imata srednji vrednosti μ_x in μ_y ter varianci σ_x^2 in σ_y^2 .

Dodatno poleg teh štirih parametrov obstaja še peti parameter, ki podaja stopnjo koreliranosti med dvema slučajnima spremenljivkama.

Ta parameter je kovarianca σ_{xy} , ki je določena s pričakovano vrednostjo:

$$\sigma_{xy} = E\Big(\big(X-\mu_x\big)\big(Y-\mu_y\big)\Big)$$

Kovarianca je lahko pozitivna, enaka 0 ali negativna. Ko je $\sigma_{xy} > 0$ sta slučajni spremenljivki X in Y pozitivno korelirani, ko je $\sigma_{xy} = 0$ sta nekorelirani in ko je $\sigma_{xy} < 0$ sta negativno korelirani.

Za zvezen primer imamo:

$$\sigma_{xy} = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\big(x-\mu_x\big)\big(y-\mu_y\big)\,f\left(x,y\right)dxdy$$

Če uporabimo na izrazu $\sigma_{xy} = E\Big((X-\mu_x)(Y-\mu_y)\Big)$ lastnosti pričakovane vrednosti pridemo do uporabnega rezultata:

$$\begin{aligned}
\sigma_{xy} &= E\Big(\big(X-\mu_x\big)\big(Y-\mu_y\big)\Big) \\
&= E\Big(XY-\mu_x Y - X\mu_y + \mu_x\mu_y\Big) \\
&= E(XY) - \mu_x E(Y) - E(X)\mu_y + \mu_x\mu_y \\
&= E(XY) - \mu_x\mu_y - \mu_x\mu_y + \mu_x\mu_y \\
&= E(XY) - \mu_x\mu_y \\
&= E\big(XY\big) - E\big(X\big)E\big(Y\big)
\end{aligned}$$

Če sta X in Y neodvisni sl. spremenljivki, velja, kakor smo že ugotovili $E\big(XY\big) = \mu_x\mu_y = E\big(X\big)E\big(Y\big)$.

Iz česar sledi, da je za neodvisni slučajni spremenljivki X in Y kovarianca $\sigma_{xy} = 0$.

To pomeni, da sta neodvisni slučajni spremenljivki X in Y tudi nekorelirani.

Čeprav neodvisnost sl. spremenljivk zagotavlja, da je njuna kovarianca enaka 0, obratno ne velja.

Kovarianca enaka 0 ne pomeni nujno neodvisnosti.

Vendar, ko sta X in Y skupno normalno porazdeljeni sl. spremenljivki, je kovarianca enaka 0 ($\sigma_{xy} = 0$) zadosten pogoj za neodvisnost.

Torej, za nekorelirane normalno porazdeljene slučajne spremenljivke sta pojma neodvisnosti in nekoreliranosti enakovredna.

Če slučajni spremenljivki X in Y standardiziramo je pričakovana vrednost produkta standardiziranih slučajnih spremenljivk število brez enote, ki ga imenujemo korelacijski koeficient ρ_{xy}.

Imamo tako:

$$\rho_{xy} = E\left(\left(\frac{X-\mu_x}{\sigma_x}\right)\cdot\left(\frac{Y-\mu_y}{\sigma_y}\right)\right)$$

kar zapišemo:

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}$$

Ker sta standardna odklona vedno pozitivna, pridobi korelacijski koeficient ρ_{xy} predznak kovariance σ_{xy}.

Absolutna vrednost korelacijskega koeficienta ρ_{xy} je lahko največ 1:

$$\left|\rho_{xy}\right| \leq 1$$

oziroma vrednost korelacijskega koeficienta ρ_{xy} vedno leži v mejah:

$$-1 \leq \rho_{xy} \leq 1$$

KOVARIANČNA MATRIKA, MATRIKA KOFAKTORJEV, MATRIKA UTEŽI

Predstavili smo že porazdelitev verjetnosti dveh skupno porazdeljenih slučajnih spremenljivk in pojem kovariance.

Kovarianca je v osnovi odnos med samo dvema slučajnima spremenljivkama.

Če imamo opravka s tremi ali več slučajnimi spremenljivkami, ki so skupno porazdeljene, moramo obravnavati kovariance vseh možnih parov slučajnih spremenljivk.

Ko govorimo o kovarianci treh skupno porazdeljenih slučajnih spremenljivk $X,\ Y,\ Z$ se kovariance nanašajo na tri pare slučajnih spremenljivk in sicer za X in $Y \rightarrow \sigma_{xy}$, za Y in $Z \rightarrow \sigma_{yz}$ in za X in $Z \rightarrow \sigma_{xz}$.

Če imamo opravka z m skupno porazdeljenimi slučajnimi spremenljivkami jih združimo v vektor.

Vektor, katerega elementi so skupno porazdeljene slučajne spremenljivke imenujemo slučajni vektor.

Če so $X_1, X_2, ..., X_m$ skupno porazdeljene slučajne spremenljivke je vektor:

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \\ . \\ . \\ . \\ X_m \end{bmatrix}$$

slučajni vektor.

Če definiramo slučajni vektor:

$$\left(\mathbf{x}-\boldsymbol{\mu}\right)=\begin{bmatrix}(X_1-\mu_1)\\(X_2-\mu_2)\\.\\.\\.\\(X_m-\mu_m)\end{bmatrix}$$

kjer so $\mu_1,\ \mu_2,\ldots,\mu_m$ srednje vrednosti slučajnih spremenljivk $X_1, X_2,\ldots,X_m$ lahko sestavimo (diadni) produkt vektorjev:

$$(\mathbf{x}-\boldsymbol{\mu})(\mathbf{x}-\boldsymbol{\mu})^T=\begin{bmatrix}(X_1-\mu_1)\\(X_2-\mu_2)\\.\\.\\.\\(X_m-\mu_m)\end{bmatrix}\begin{bmatrix}(X_1-\mu_1) & (X_2-\mu_2) & . & . & . & (X_m-\mu_m)\end{bmatrix}=$$

$$=\begin{bmatrix}(X_1-\mu_1)^2 & (X_1-\mu_1)(X_2-\mu_2) & . & . & . & (X_1-\mu_1)(X_m-\mu_m)\\(X_2-\mu_2)(X_1-\mu_1) & (X_2-\mu_2)^2 & . & . & . & (X_2-\mu_2)(X_m-\mu_m)\\.&.&.&.&.&.\\.&.&.&.&.&.\\.&.&.&.&.&.\\(X_m-\mu_m)(X_1-\mu_1) & (X_m-\mu_m)(X_2-\mu_2) & . & . & . & (X_m-\mu_m)^2\end{bmatrix}$$

Če vemo, da je $\sigma_i^2 = E\left((X_i - \mu_i)^2\right)$ varianca sl. spremenljivke X_i in če vemo, da je $\sigma_{ij}^2 = E\left((X_i - \mu_i)(X_j - \mu_j)\right)$ kovarianca sl. spremenljivk X_i in X_j, in ker je $\sigma_{ij} = \sigma_{ji}$ lahko zapišemo pričakovano vrednost gornje matrike:

$$\boldsymbol{\Sigma}_{\mathbf{xx}} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & . & . & . & \sigma_{1m} \\ \sigma_{12} & \sigma_2^2 & . & . & . & \sigma_{2m} \\ . & . & . & . & . & . \\ . & . & . & . & . & . \\ . & . & . & . & . & . \\ \sigma_{1m} & \sigma_{2m} & . & . & . & \sigma_m^2 \end{bmatrix}$$

Variance elementov sl. vektorja $\mathbf{x}$ oz. variance slučajnih spremenljivk $X_1, X_2, ..., X_m$ ležijo na glavni diagonali matrike $\boldsymbol{\Sigma}_{\mathbf{xx}}$, kovariance vseh možnih parov slučajnih spremenljivk predstavljajo izven diagonalni členi.

Vsaka kovarianca med dvema slučajnima spremenljivkama se pojavi dvakrat, simetrično, nad in pod glavno diagonalo.

Matriko $\boldsymbol{\Sigma}_{\mathbf{xx}}$ imenujemo variančno-kovariančna matrika ali kar kovariančna matrika slučajnega vektorja $\mathbf{x}$.

Na varianco slučajne spremenljivke gledamo tudi kot na kovarianco slučajne spremenljivke X_i same s seboj $\left(\sigma_i^2 = \sigma_{ii}\right)$.

Včasih se za poimenovanje gornje matrike uporablja tudi ime disperzijska matrika.

Če so slučajne spremenljivke, zbrane v slučajnem vektorju $\mathbf{x}$, nekorelirane, so kovariance (izven diagonalni elementi) kovariančne matrike $\boldsymbol{\Sigma}_{\mathbf{xx}}$ enaki 0, matrika $\boldsymbol{\Sigma}_{\mathbf{xx}}$ je diagonalna, v njej nastopajo le variance elementov sl. vektorja $\mathbf{x}$.

Kljub temu pa $\boldsymbol{\Sigma}_{\mathbf{xx}}$ še vedno imenujemo kovariančna matrika.

PRIMER:

Za slučajni vektor $\mathbf{x}$ je kovariančna matrika $\boldsymbol{\Sigma}_{\mathbf{xx}}$:

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \end{bmatrix} \sim \boldsymbol{\Sigma}_{\mathbf{xx}} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} & \sigma_{14} \\ \sigma_{12} & \sigma_2^2 & \sigma_{23} & \sigma_{24} \\ \sigma_{13} & \sigma_{23} & \sigma_3^2 & \sigma_{34} \\ \sigma_{14} & \sigma_{24} & \sigma_{34} & \sigma_4^2 \end{bmatrix} = \begin{bmatrix} 0.1289 & -0.4536 & -0.0622 & 0.0874 \\ -0.4536 & 1.7674 & -0.1914 & 0.2112 \\ -0.0622 & -0.1914 & 0.0335 & 0.0357 \\ 0.0874 & 0.2112 & 0.0357 & 0.0665 \end{bmatrix}$$

Na osnovi varianc določi standardne odklone vseh elementov sl. vektorja $\mathbf{x}$ ter na osnovi kovarianc in odgovarjajočih standardnih odklonov določi korelacijske koeficiente parov elementov sl. vektorja $\mathbf{x}$.

Variance:

$$\sigma_1^2 = 0.1289;\ \sigma_2^2 = 1.7674;\ \sigma_3^2 = 0.0335;\ \sigma_4^2 = 0.0665$$

Standardni odkloni:

$$\sigma_1 = 0.3590;\ \sigma_2 = 1.3294;\ \sigma_3 = 0.1830;\ \sigma_4 = 0.2579$$

Kovariance:

$$\sigma_{12} = -0.4536;\ \sigma_{13} = -0.0622;\ \sigma_{14} = 0.0874;\ \sigma_{23} = -0.1914;\ \sigma_{24} = 0.2112;\ \sigma_{34} = 0.0357$$

Korelacijski koeficienti:

$$\rho_{12} = \frac{\sigma_{12}}{\sigma_1\sigma_2} = \frac{-0.4536}{0.3590 \cdot 1.3294} = -0.9503;\ \rho_{13} = \frac{\sigma_{13}}{\sigma_1\sigma_3} = \frac{-0.0622}{0.3590 \cdot 0.1830} = -0.9465;\ \rho_{14} = \frac{\sigma_{14}}{\sigma_1\sigma_4} = \frac{0.0874}{0.3590 \cdot 0.2579} = 0.9440$$

$$\rho_{23} = -0.7866;\ \rho_{24} = 0.6160;\ \rho_{34} = 0.7564$$

Matriko uteži $\mathbf{P_{xx}}$ sl. vektorja $\mathbf{x}$ določimo na osnovi odgovarjajoče kovariančne matriko $\mathbf{\Sigma_{xx}}$ z:

$$\mathbf{P_{xx}} = \sigma_0^2 \cdot \mathbf{\Sigma_{xx}^{-1}} \qquad (*)$$

kjer je σ_0^2 referenčna varianca.

Enačba (*) velja splošno, za korelirane in nekorelirane slučajne spremenljivke (ni omejena le na diagonalni matriki $\mathbf{P_{xx}}$ in $\mathbf{\Sigma_{xx}}$).

PRIMER:

Za slučajni vektor $\mathbf{x}$ z gornjo kovariančno matriko $\mathbf{\Sigma_{xx}}$, določi matriko uteži $\mathbf{P_{xx}}$, če je referenčna varianca $\sigma_0^2 = 0.0335$.

$$\mathbf{P_{xx}} = \sigma_0^2 \cdot \mathbf{\Sigma_{xx}^{-1}} = 0.0335 \cdot \begin{bmatrix} 0.1289 & -0.4536 & -0.0622 & 0.0874 \\ -0.4536 & 1.7674 & -0.1914 & 0.2112 \\ -0.0622 & -0.1914 & 0.0335 & 0.0357 \\ 0.0874 & 0.2112 & 0.0357 & 0.0665 \end{bmatrix}^{-1} = 0.0335 \cdot \begin{bmatrix} 1.0956 & 0.6209 & -4.8626 & 3.1426 \\ -0.6209 & 0.1662 & -1.1934 & 0.9290 \\ -4.8626 & -1.1934 & 7.3714 & 6.2237 \\ 3.1426 & 0.9290 & 6.2237 & 4.6157 \end{bmatrix} = \begin{bmatrix} 0.0367 & -0.0208 & -0.1629 & 0.1053 \\ -0.0208 & 0.0056 & -0.0400 & 0.0311 \\ -0.1629 & -0.0400 & 0.2469 & 0.2085 \\ 0.1053 & 0.0311 & 0.2085 & 0.1546 \end{bmatrix}$$

Če imamo opravka s koreliranimi sl. spremenljivkami je kovariančna matrika $\mathbf{\Sigma_{xx}}$ slučajnega vektorja $\mathbf{x}$ ne-diagonalna matrika.

V tem primeru ne smemo računati uteži sl. spremenljivk s pomočjo enačb:

$$p_1 = \frac{\sigma_0^2}{\sigma_1^2},\ p_2 = \frac{\sigma_0^2}{\sigma_2^2},\ \ldots,\ p_m = \frac{\sigma_0^2}{\sigma_m^2}$$

ki smo jih uporabljali, ko smo imeli opravka z nekoreliranimi sl. spremenljivkami oz. z diagonalnima kovariančno matriko $\mathbf{\Sigma_{xx}}$ in matriko uteži $\mathbf{P_{xx}}$.

PRIMER:

Imamo dve sl. spremenljivki oz. dve opazovanji X_1 in X_2, ki sestavljata slučajni vektor $\mathbf{x}$:

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

Varianci sl. spremenljivk sta $X_1 \to \sigma_1^2$ in $X_2 \to \sigma_2^2$, kovarianca med sl. spremenljivkama X_1 in X_2 je σ_{12}

Korelacijski koeficient je ρ_{12}.

Kovariančna matrika $\mathbf{\Sigma_{xx}}$ je tako: $\mathbf{\Sigma_{xx}} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$

Matrika uteži $\mathbf{P_{xx}}$ slučajnega vektorja $\mathbf{x}$ je: $\mathbf{P_{xx}} = \sigma_0^2 \cdot \mathbf{\Sigma_{xx}^{-1}} = \sigma_0^2 \cdot \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}^{-1} = \frac{\sigma_0^2}{\sigma_1^2\sigma_2^2 - \sigma_{12}^2} \cdot \begin{bmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{bmatrix}$

Ker je: $\underbrace{\rho_{12} = \frac{\sigma_{12}}{\sigma_1\sigma_2}}_{\text{def.}} \to \sigma_{12} = \rho_{12}\sigma_1\sigma_2$

je:

$$\sigma_1^2\sigma_2^2 - \sigma_{12}^2 = \sigma_1^2\sigma_2^2(1 - \rho_{12}^2)$$

in tako:

$$\mathbf{P_{xx}} = \frac{\sigma_0^2}{\sigma_1^2\sigma_2^2(1-\rho_{12}^2)} \cdot \begin{bmatrix} \sigma_2^2 & -\rho_{12}\sigma_1\sigma_2 \\ -\rho_{12}\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} = \begin{bmatrix} \frac{\sigma_0^2}{\sigma_1^2(1-\rho_{12}^2)} & -\frac{\sigma_0^2\rho_{12}}{\sigma_1\sigma_2(1-\rho_{12}^2)} \\ -\frac{\sigma_0^2\rho_{12}}{\sigma_1\sigma_2(1-\rho_{12}^2)} & \frac{\sigma_0^2}{\sigma_2^2(1-\rho_{12}^2)} \end{bmatrix}$$

Lahko ugotovimo, da za nekorelirani sl. spremenljivki X_1 in X_2 za izračun odgovarjajočih uteži še vedno velja:

$$p_1 = \frac{\sigma_0^2}{\sigma_1^2},\ p_2 = \frac{\sigma_0^2}{\sigma_2^2}$$

Diagonalna elementa matrike $\mathbf{P_{xx}}$ oziroma uteži p_1 in p_2 lahko torej izračunamo s pomočjo gornjih izrazov le, ko je $\rho_{12} = 0$.

V splošnem torej matriko uteži $\mathbf{P_{xx}}$ slučajnega vektorja $\mathbf{x}$, za katerega je dana kovariančna matrika $\mathbf{\Sigma_{xx}}$ računamo z zvezo:

$$\mathbf{P_{xx}} = \sigma_0^2\mathbf{\Sigma_{xx}^{-1}}$$

Če kovariančno matriko $\mathbf{\Sigma_{xx}}$ delimo z referenčno varianco σ_0^2 dobimo matriko kofaktorjev $\mathbf{Q_{xx}}$ slučajnega vektorja $\mathbf{x}$.

Imamo tako:

$$\mathbf{Q_{xx}} = \frac{1}{\sigma_0^2}\mathbf{\Sigma_{xx}} = \begin{bmatrix} \frac{\sigma_1^2}{\sigma_0^2} & \frac{\sigma_{12}}{\sigma_0^2} & . & . & . & \frac{\sigma_{1m}}{\sigma_0^2} \\ \frac{\sigma_{12}}{\sigma_0^2} & \frac{\sigma_2^2}{\sigma_0^2} & . & . & . & \frac{\sigma_{2m}}{\sigma_0^2} \\ . & . & . & . & . & . \\ . & . & . & . & . & . \\ . & . & . & . & . & . \\ \frac{\sigma_{1m}}{\sigma_0^2} & \frac{\sigma_{2m}}{\sigma_0^2} & . & . & . & \frac{\sigma_m^2}{\sigma_0^2} \end{bmatrix}$$

oziroma: $\mathbf{\Sigma_{xx}} = \sigma_0^2 \cdot \mathbf{Q_{xx}}$

Matriko kofaktorjev $\mathbf{Q_{xx}}$ obravnavamo kot kovariančno matriko, ki nima »merila«, ker ni pomnožena z referenčno varianco σ_0^2.

Matriko kofaktorjev $\mathbf{Q_{xx}}$ zato obravnavamo tudi kot relativno kovariančno matriko.

Ko matriko kofaktorjev $\mathbf{Q_{xx}}$ pomnožimo z referenčno varianco σ_0^2, pridobimo absolutno natančnost, ki jo predstavlja kovariančna matrika $\mathbf{\Sigma_{xx}}$.

Matriko kofaktojrev $\mathbf{Q_{xx}}$ obravnavamo kot matriko, ki predstavlja relativno natančnost, kovariančno matriko $\mathbf{\Sigma_{xx}}$ pa kot matriko, ki predstavlja absolutno natančnost elementov slučajnega vektorja $\mathbf{x}$.

Za gornji primer določi matriko kofaktorjev $\mathbf{Q_{xx}}$.

OSNOVNI POJMI O VZORČENJU

V primeru, ko je porazdelitev verjetnosti slučajne spremenljivke znana smo sposobni sestaviti izraze, ki podajajo verjetno obnašanje slučajne spremenljivke. Izračunamo lahko npr. srednjo vrednost in varianco slučajne spremenljivke.

Ko rečemo, da je porazdelitev verjetnosti znana, to pomeni, da poznamo vrsto (enakomerna, normalna) in parametre porazdelitve verjetnosti slučajne spremenljivke.

V nekaterih primerih je primerno porazdelitev verjetnosti mogoče sestaviti na podlagi teoretičnih predpostavk.

Pogosto pa ne moremo dovolj kakovostno določiti porazdelitve verjetnosti slučajne spremenljivke le na teoretični osnovi.

Tako nam ostane možnost empirične določitve porazdelitve verjetnosti slučajne spremenljivke.

S pojmom določiti imamo v mislih »natančno pridobiti«, zato je v tem primeru primernejši pojem »statistično oceniti«.

Za statistično oceno porazdelitve verjetnosti geodetskih opazovanj se najpogosteje uporablja ponavljanje opazovanj.

Opazovanja pridobivamo iz populacije, ki predstavlja neskončno množico vrednosti, iz katerih pridobivamo opazovanja.

Vrednosti opazovanj predstavljajo vzorec (pridobljen iz populacije).

Če so ponovljena opazovanja neodvisna med seboj in opazovanja opravljena pod enakimi pogoji jih splošno imenujemo slučajni vzorec.

V primeru geodetskih opazovanj je populacija množica vrednosti opazovane količine, ki jih lahko pridobimo z opazovanji.

Pridobljene vrednosti opazovanj opazovane količine sestavljajo vzorec.

Število opazovanj v vzorcu imenujemo velikost vzorca.

V ocenjevanju porazdelitve verjetnosti je pomembna velikost vzorca.

V splošnem velja, da večji vzorec zagotavlja boljšo oceno porazdelitve verjetnosti populacije.

PRENOS VARIANC – KOVARIANC

Na začetku smo se že seznanili s prenosom pravih pogreškov.

V praksi pa pogreške z znano vrednostjo običajno odstranimo (recimo sistematične pogreške), preden izračunamo želeno količino.

Vrednosti slučajnih pogreškov pa niso znane, zato merjenih vrednosti za slučajne poreške ne moremo popravljati.

Zato tudi ne moremo uporabiti postopka prenosa pravih pogreškov za slučajne pogreške.

Čeprav vrednosti slučajnih pogreškov opazovanj niso znane pa je kljub temu mogoče določati njihov vpliv na funkcije opazovanj.

Namesto uporabe dejanskih numeričnih vrednosti slučajnih pogreškov opazovanj, kot je to bilo v primeru prenosa pravih pogreškov, imamo sedaj opravka s porazdelitvijo verjetnosti (slučajna spremenljivka + verjetnostna funkcija slučajne spremenljivke; slučajna spremenljivka + funkcija gostote verjetnosti; slučajna spremenljivka + porazdelitvena funkcija) opazovanj v funkcije opazovanj.

Če slučajni vektor $\mathbf{x}$ predstavlja množico opazovanj in slučajni vektor $\mathbf{y}$ množico funkcij opazovanj, zapišemo:

$$\mathbf{y} = \mathbf{y}(\mathbf{x})$$

Problem prenosa sedaj predstavlja določitev skupne porazdelitve verjetnosti slučajnega vektorja $\mathbf{y}$, ob dani porazdelitvi verjetnosti slučajnega vektorja $\mathbf{x}$.

Izpeljava skupne porazdelitve verjetnosti slučajnega vektorja $\mathbf{y}$ na osnovi znane porazdelitve verjetnosti slučajnega vektorja $\mathbf{x}$ je matematično dokaj težavna, tudi za relativno enostavne funkcije slučajnega vektorja $\mathbf{x}$.

Za naše potrebe (v geodeziji pa tudi drugih strokah) na srečo obstaja učinkovita alternativa, če se pri obravnavi omejimo na linearne funkcije slučajnega vektorja $\mathbf{x}$.

Ta alternativa vključuje samo prenos varianc in kovarianc.

ZAKON O PRENOSU VARIANC IN KOVARIANC

Ker sta varianca in kovarianca pričakovani vrednosti, je običajen način izpeljave zakona o prenosu varianc in kovarianc z uporabo lastnosti pričakovane vrednosti (glej nazaj).

Uporabimo pa lahko tudi drugačen postopek, z definiranjem varianc in kovarianc, izračunanih iz vzorcev neskončnih velikosti.

Naj bo $\mathbf{x}$ slučajni vektor, sestavljen iz dveh skupno porazdeljenih slučajnih spremenljivk X_1 in X_2:

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

in naj bo:

$$\begin{bmatrix} X_{11} \\ X_{21} \end{bmatrix}, \begin{bmatrix} X_{12} \\ X_{22} \end{bmatrix}, \ldots, \begin{bmatrix} X_{1q} \\ X_{2q} \end{bmatrix}$$

vzorec velikosti q, dobljen iz porazdelitve verjetnosti slučajnega vektorja $\mathbf{x}$.

Srednji vrednosti X_1 in X_2 sta μ_{x_1} in μ_{x_2}

Odklon/odstopanje posamezne komponente vektorja vzorca od odgovarjajoče srednje vrednosti je:

$$\begin{aligned} \Delta X_{1k} &= X_{1k} - \mu_{x_1} \\ \Delta X_{2k} &= X_{2k} - \mu_{x_2} \end{aligned} \; ; \; k = 1, 2, \ldots, q .$$

Varianci slučajnih spremenljivk X_1 in X_2 definirajmo:

$$\sigma_{x_1}^2 = \lim_{q\to\infty} \frac{1}{q} \sum_{k=1}^{q} \Delta X_{1k}^2 \text{ in}$$

$$\sigma_{x_2}^2 = \lim_{q\to\infty} \frac{1}{q} \sum_{k=1}^{q} \Delta X_{2k}^2$$

kovarianco med X_1 in X_2 pa:

$$\sigma_{x_1x_2} = \lim_{q\to\infty} \frac{1}{q} \sum_{k=1}^{q} \Delta X_{1k}\ \Delta X_{2k}$$

Varianca, izračunana iz gornjih izrazov, je v skladu z izrazom:

$$E\left(\left(X-\mu\right)^2\right) = \sum_{i=1}^{n} \left(x_i-\mu\right)^2\ p\left(x_i\right)$$

če vemo, da je verjetnost $p\left(x_i\right)$ pojava vrednosti x_i v vzorcu izražena z relativno frekvenco.

Če je vzorec neskončne velikosti, je relativna frekvenca enaka verjetnosti.

Izraz za kovarianco pa je v skladu z izrazom:

$$\sigma_{xy} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left(x-\mu_x\right)\left(y-\mu_y\right) f\left(x,y\right) dxdy$$

Slučajni vektor $\mathbf{y}$ je sestavljen iz dveh skupno porazdeljenih slučajnih spremenljivk Y_1 in Y_2:

$$\mathbf{y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix}$$

Med slučajnima vektorjema $\mathbf{x}$ in $\mathbf{y}$ naj velja zveza:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} \qquad (*)$$

V kateri je $\mathbf{A}$ matrika koeficientov, velikosti $2*2$ in $\mathbf{b}$ vektor (konstant) sestavljen iz dveh konstant b_1 in b_2:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix};\ \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

Če zapišemo enačbo $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$ v celoti, imamo:

$$Y_1 = a_{11}X_1 + a_{12}X_2 + b_1$$
$$Y_2 = a_{21}X_1 + a_{22}X_2 + b_2$$

Če to zvezo zapišemo za k –to komponento vzorca imamo:

$$Y_{1k} = a_{11}X_{1k} + a_{12}X_{2k} + b_1$$
$$Y_{2k} = a_{21}X_{1k} + a_{22}X_{2k} + b_2$$

Srednji vrednosti μ_{y_1} in μ_{y_2} slučajnih spremenljivk Y_1 in Y_2 sta, glede na gornjo zvezo med slučajnima vektorjema $\mathbf{x}$ in $\mathbf{y}$:

$$\mu_{y_1} = a_{11}\mu_{x_1} + a_{12}\mu_{x_2} + b_1$$
$$\mu_{y_2} = a_{21}\mu_{x_1} + a_{22}\mu_{x_2} + b_2$$

Odstopanji vrednosti Y_{1k} in Y_{2k} (vrednosti Y_1 in Y_2 za k –to komponento vzorca) od njunih srednjih vrednosti μ_{y_1} in μ_{y_2} sta določeni na enak način kot za k –ti komponenti vzorca X_{1k} in X_{2k} slučajnih spremenljivk X_1 in X_2:

$$\begin{aligned}\Delta Y_{1k} &= Y_{1k} - \mu_{y_1} \\ \Delta Y_{2k} &= Y_{2k} - \mu_{y_2}\end{aligned} ; k = 1, 2, ..., q$$

Zapišemo lahko torej:

$$\begin{aligned}\Delta Y_{1k} &= Y_{1k} - \mu_{y_1} = a_{11}X_{1k} + a_{12}X_{2k} + b_1 - a_{11}\mu_{x_1} + a_{12}\mu_{x_2} - b_1 \\ \Delta Y_{2k} &= Y_{2k} - \mu_{y_2} = a_{21}X_{1k} + a_{22}X_{2k} + b_2 - a_{21}\mu_{x_1} + a_{22}\mu_{x_2} - b_2\end{aligned} ; k = 1, 2, \ldots, q$$

Oziroma:

$$\begin{aligned}\Delta Y_{1k} &= a_{11}\Delta X_{1k} + a_{12}\Delta X_{2k} \\ \Delta Y_{2k} &= a_{21}\Delta X_{1k} + a_{22}\Delta X_{2k}\end{aligned} ; k = 1, 2, \ldots, q$$

Če tudi varianci in kovarianco med slučajnima spremenljivkama Y_1 in Y_2 definiramo na enak način kot za X_1 in X_2, imamo:

$$\sigma_{y_1}^2 = \lim_{q \to \infty} \frac{1}{q} \sum_{k=1}^{q} \Delta Y_{1k}^2$$

$$\sigma_{y_2}^2 = \lim_{q \to \infty} \frac{1}{q} \sum_{k=1}^{q} \Delta Y_{2k}^2$$

$$\sigma_{y_1 y_2} = \lim_{q \to \infty} \frac{1}{q} \sum_{k=1}^{q} \Delta Y_{1k} \, \Delta Y_{2k}$$

Z upoštevanjem zgornjih izrazov lahko zapišemo:

$$\begin{aligned}
\sigma_{y_1}^2 &= \lim_{q\to\infty}\frac{1}{q}\sum_{k=1}^{q}\left(a_{11}\Delta X_{1k}+a_{12}\Delta X_{2k}\right)^2 \\
&= \lim_{q\to\infty}\frac{1}{q}\sum_{k=1}^{q}\left(a_{11}^2\Delta X_{1k}^2+2a_{11}a_{12}\Delta X_{1k}\Delta X_{2k}+a_{12}^2\Delta X_{2k}^2\right) \\
&= \lim_{q\to\infty}\frac{1}{q}\left[\sum_{k=1}^{q}a_{11}^2\Delta X_{1k}^2+\sum_{k=1}^{q}2a_{11}a_{12}\Delta X_{1k}\Delta X_{2k}+\sum_{k=1}^{q}a_{12}^2\Delta X_{2k}^2\right] \qquad (1) \\
&= a_{11}^2\lim_{q\to\infty}\frac{1}{q}\sum_{k=1}^{q}\Delta X_{1k}^2+2a_{11}a_{12}\lim_{q\to\infty}\frac{1}{q}\sum_{k=1}^{q}\Delta X_{1k}\Delta X_{2k}+a_{12}^2\lim_{q\to\infty}\sum_{k=1}^{q}\Delta X_{2k}^2 \\
&= a_{11}^2\sigma_{x_1}^2+2a_{11}a_{12}\sigma_{x_1x_2}+a_{12}^2\sigma_{x_2}^2
\end{aligned}$$

Enako lahko pokažemo, da velja za varianco $\sigma_{y_2}^2$ slučajne spremenljivke Y_2:

$$\sigma_{y_2}^2 = a_{21}^2\sigma_{x_1}^2+2a_{21}a_{22}\sigma_{x_1x_2}+a_{22}^2\sigma_{x_2}^2 \qquad (2)$$

In za kovarianco $\sigma_{y_1y_2}$ med Y_1 in Y_2:

$$\sigma_{y_1y_2} = a_{11}a_{21}\sigma_{x_1}^2+\left(a_{11}a_{22}+a_{12}a_{21}\right)\sigma_{x_1x_2}+a_{12}a_{22}\sigma_{x_2}^2 \qquad (3)$$

Naj bosta $\boldsymbol{\Sigma}_{\mathbf{xx}}$ in $\boldsymbol{\Sigma}_{\mathbf{yy}}$ kovariančni matriki slučajnih vektorjev $\mathbf{x}$ in $\mathbf{y}$:

$$\mathbf{x} \sim \boldsymbol{\Sigma}_{\mathbf{xx}} = \begin{bmatrix} \sigma_{x_1}^2 & \sigma_{x_1 x_2} \\ \sigma_{x_1 x_2} & \sigma_{x_2}^2 \end{bmatrix} \text{ in } \mathbf{y} \sim \boldsymbol{\Sigma}_{\mathbf{yy}} = \begin{bmatrix} \sigma_{y_1}^2 & \sigma_{y_1 y_2} \\ \sigma_{y_1 y_2} & \sigma_{y_2}^2 \end{bmatrix}$$

Ugotovimo, da lahko enačbe (1), (2) in (3) pridobimo tudi z uporabo zveze:

$$\boldsymbol{\Sigma}_{\mathbf{yy}} = \mathbf{A}\, \boldsymbol{\Sigma}_{\mathbf{xx}} \mathbf{A}^T \qquad (4)$$

kjer je matrika $\mathbf{A}$ (ponovno):

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$$

Enačba (4) ne velja samo za slučajni vektor $\mathbf{x}$ z $n = 2$ komponentama in za slučajni vektor $\mathbf{y}$ z $m = 2$ komponentama ampak za poljubne vrednosti za n in m .

Enačba (4) predstavlja splošni zakon o prenosu varianc in kovarianc za linearno funkcijo oblike:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$$

Nelinearne funkcije $\mathbf{y}$ slučajnih vektorjev $\mathbf{x}$:

$$\mathbf{y} = \mathbf{y}(\mathbf{x})$$

moramo, za uporabo zakona o prenosu varianc in kovarianc, linearizirati.

Jacobijeva matrika $\mathbf{J} = \mathbf{J}_{\mathbf{yx}}$ za nelinearne funkcije $\mathbf{y} = \mathbf{y}(\mathbf{x})$ je:

$$\mathbf{J} = \mathbf{J}_{\mathbf{yx}} = \left[\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right] = \begin{bmatrix} \frac{\partial Y_1}{\partial X_1} & \frac{\partial Y_1}{\partial X_2} & \cdots & \frac{\partial Y_1}{\partial X_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial Y_m}{\partial X_1} & \frac{\partial Y_m}{\partial X_2} & \cdots & \frac{\partial Y_m}{\partial X_n} \end{bmatrix}$$

Matriko koeficientov linearne funkcije $\mathbf{A}$ pri prenosu varianc in kovarianc nadomesti Jacobijeva matrika $\mathbf{J}$.

Zakon o prenosu varianc in kovarianc lahko sedaj zapišemo v splošni obliki:

$$\mathbf{\Sigma}_{\mathbf{yy}} = \mathbf{J}_{\mathbf{yx}}\, \mathbf{\Sigma}_{\mathbf{xx}}\, \mathbf{J}_{\mathbf{yx}}^{T} \qquad (5)$$

Enačbe (1), (2), (3), (4) in (5) veljajo splošno, ne glede na porazdelitev verjetnosti slučajnega vektorja $\mathbf{x}$.

IZPELJAVA ZAKONA O PRENOSU VARIANC IN KOVARIANC Z UPORABO LASTNOSTI PRIČAKOVANE VREDNOSTI

Dan je slučajni vektor $\mathbf{x} = \begin{bmatrix} X_1 & X_2 & \cdots & X_n \end{bmatrix}^T$ s pripadajočima kovariančno matriko $\boldsymbol{\Sigma}_{\mathbf{xx}}$ ter matriko kofaktorjev $\mathbf{Q}_{\mathbf{xx}}$ in slučajni vektor $\mathbf{y} = \begin{bmatrix} y_1 & y_2 & \cdots & Y_n \end{bmatrix}$ je linearna funkcija slučajnega vektorja $\mathbf{x}$:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{a}$$

Slučajnemu vektorju $\mathbf{y}$ pripadajoča kovariančna matrika $\boldsymbol{\Sigma}_{\mathbf{yy}}$ ter matrika kofaktorjev je $\mathbf{Q}_{\mathbf{yy}}$ sta:

$$\boldsymbol{\Sigma}_{\mathbf{yy}} = \mathbf{A}\,\boldsymbol{\Sigma}_{\mathbf{xx}}\mathbf{A}^T, \mathbf{Q}_{\mathbf{yy}} = \mathbf{A}\,\mathbf{Q}_{\mathbf{xx}}\mathbf{A}^T$$

Kjer je $\mathbf{A}$ matrika koeficientov in $\mathbf{b}$ vektor konstant.

Z uporabo lastnosti pričakovane vrednosti določimo $\boldsymbol{\mu}_{\mathbf{y}}$ in $\boldsymbol{\Sigma}_{\mathbf{yy}}$:

$$\begin{aligned}
\boldsymbol{\mu}_{\mathbf{y}} &= E(\mathbf{y}) \\
&= E(\mathbf{A}\mathbf{x} + \mathbf{b}) \\
&= E(\mathbf{A}\mathbf{x}) + E(\mathbf{b}) \\
&= \mathbf{A}E(\mathbf{x}) + \mathbf{b} \\
&= \mathbf{A}\boldsymbol{\mu}_{\mathbf{x}} + \mathbf{b}
\end{aligned}$$

$$\begin{aligned}
\boldsymbol{\Sigma}_{\mathbf{yy}} &= E\left((\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}})(\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}})^T\right) \\
&= E\left((\mathbf{A}\mathbf{x} + \mathbf{b} - \mathbf{A}\boldsymbol{\mu}_{\mathbf{x}} - \mathbf{b})(\mathbf{A}\mathbf{x} + \mathbf{b} - \mathbf{A}\boldsymbol{\mu}_{\mathbf{x}} - \mathbf{b})^T\right) \\
&= E\left((\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu}_{\mathbf{x}})(\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu}_{\mathbf{x}})^T\right) \\
&= E\left((\mathbf{A}(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}}))(\mathbf{A}(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}}))^T\right) \\
&= E\left(\mathbf{A}(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})^T\,\mathbf{A}^T\right) \\
&= \mathbf{A}E\left((\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})^T\right)\mathbf{A}^T \\
&= \mathbf{A}\boldsymbol{\Sigma}_{\mathbf{xx}}\mathbf{A}^T
\end{aligned}$$

IZPELJAVA ZAKONA O PRENOSU VARIANC IN KOVARIANC Z UPORABO LASTNOSTI PRIČAKOVANE VREDNOSTI ZA NELINEARNO FUNKCIJO

Imamo nelinearno funkcijo slučajne spremenljivke x:

$$y = y(x)$$

Nelinearno funkcijo $y = y(x)$ linearizirамо z razvojem v Taylorjevo vrsto v okolici vrednosti $x = x_0$:

$$y(x) = y(x_0) + \left(\frac{dy}{dx}\right)_{x_0}(x - x_0) + \left(\frac{d^2y}{dx^2}\right)_{x_0}\frac{(x - x_0)^2}{2!} + \left(\frac{d^3y}{dx^3}\right)_{x_0}\frac{(x - x_0)^3}{3!} + \cdots + \left(\frac{d^{n-1}y}{dx^{n-1}}\right)_{x_0}\frac{(x - x_0)^{n-1}}{(n-1)!}$$

Vse številske vrednosti odvodov so izračunane za vrednosti $x = x_0$.

Nelinearno funkcijo $z = z(x, y)$ dveh slučajnih spremenljivk linearizirамо z razvojem v Taylorjevo vrsto v okolici vrednosti

$x = x_0$ in $y = y_0$:

$$z(x) = z(x_0, y_0) + \left(\frac{\partial z}{\partial x}\right)_{(x_0,y_0)}(x - x_0) + \left(\frac{\partial z}{\partial y}\right)_{(x_0,y_0)}(y - y_0) +$$

$$+\frac{1}{2!}\left(\left(\frac{\partial^2 z}{\partial x^2}\right)_{(x_0,y_0)}(x - x_0)^2 + \left(\frac{\partial^2 z}{\partial y^2}\right)_{(x_0,y_0)}(y - y_0)^2 + \left(\frac{\partial z}{dx}\right)_{(x_0,y_0)}\left(\frac{\partial z}{dy}\right)_{(x_0,y_0)}(x - x_0)(y - y_0)\right) + \cdots$$

Vsi parcialni odvodi so izračunani za vrednosti $x = x_0$ in $y = y_0$.

Za n slučajnih spremenljivk, združenih v slučajnem vektorju $\mathbf{x}$ lahko zapišemo vektorsko (matrično) enačbo za slučajni vektor $\mathbf{y}$:

$$\mathbf{y} = \mathbf{y}(\mathbf{x})$$

Taylorjevo vrsto lahko zdaj zapišemo:

$$\mathbf{y} = \mathbf{y}(\mathbf{x}) = \mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{\mathbf{x}_0} (\mathbf{x} - \mathbf{x}_0) + \text{členi višjih stopenj}$$

Vse številske vrednosti parcialnih odvodov so ponovno izračunane za vrednosti $\mathbf{x} = \mathbf{x}_0$.

Z uporabo lastnosti pričakovane vrednosti dobimo:

$$\begin{aligned}
\boldsymbol{\mu}_{\mathbf{y}} &= E(\mathbf{y}) \\
&= E\left(\mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{(\mathbf{x}_0)} (\mathbf{x} - \mathbf{x}_0)\right) \\
&= E(\mathbf{y}(\mathbf{x}_0)) + E\left(\left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{(\mathbf{x}_0)} (\mathbf{x} - \mathbf{x}_0)\right) \\
&= \mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{(\mathbf{x}_0)} E(\mathbf{x} - \mathbf{x}_0) \\
&= \mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{(\mathbf{x}_0)} (E(\mathbf{x}) - E(\mathbf{x}_0)) \\
&= \mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)_{(\mathbf{x}_0)} (\boldsymbol{\mu}_{\mathbf{x}} - \mathbf{x}_0)
\end{aligned}$$

Kovariančna matrika $\mathbf{\Sigma_{yy}}$ slučajnega vektorja $\mathbf{y}$ je dana z:

$$\mathbf{\Sigma_{yy}} = E\left(\left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{y} \right) \left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{y} \right)^T \right)$$

Zanima nas torej izraz $\left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{y} \right)$ za linearizirano nelinearno funkcijo:

$$\begin{aligned} \mathbf{y} - \boldsymbol{\mu}_\mathbf{y} &= \left(\mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)_{(\mathbf{x}_0)} (\mathbf{x} - \mathbf{x}_0) \right) - \left(\mathbf{y}(\mathbf{x}_0) + \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)_{(\mathbf{x}_0)} (\boldsymbol{\mu}_\mathbf{x} - \mathbf{x}_0) \right) \\ &= \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)_{(\mathbf{x}_0)} (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) \\ &= \left(\mathbf{J_{yx}} \right)_{(\mathbf{x}_0)} (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) \end{aligned}$$

Kjer je $\mathbf{J_{yx}}$ Jacobijeva matrika parcialnih odvodov m funkcij y po n spremenljivkah x oziroma $\dim(\mathbf{x}) = n$ in $\dim(\mathbf{y}) = m$:

$$\mathbf{J_{yx}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \cdots & \frac{\partial y_n}{\partial x_m} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \frac{\partial y_m}{\partial x_2} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}$$

Kovariančno matriko $\mathbf{\Sigma_{yy}}$ slučajnega vektorja $\mathbf{y}$ določimo za linearizirano funkcijo z uporabo gornjih izrazov:

$$\begin{aligned} \mathbf{\Sigma_{yy}} &= E\left(\left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{y} \right) \left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{y} \right)^T \right) \\ &= E\left(\left(\mathbf{J_{yx}} (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) \right) \left(\mathbf{J_{yx}} (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) \right)^T \right) \\ &= E\left(\mathbf{J_{yx}} (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x})^T \mathbf{J}_\mathbf{yx}^T \right) \\ &= \mathbf{J_{yx}} E\left((\mathbf{x} - \boldsymbol{\mu}_\mathbf{x}) (\mathbf{x} - \boldsymbol{\mu}_\mathbf{x})^T \right) \mathbf{J}_\mathbf{yx}^T \\ &= \mathbf{J_{yx}} \mathbf{\Sigma_{xx}} \mathbf{J}_\mathbf{yx}^T \end{aligned}$$

PRIMER 1:

Imamo linearno funkcijo $Y = a_1 X_1 + a_2 X_2 + \cdots + a_n X_n$, ki jo lahko zapišemo:

$$Y = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}$$

Slučani vektor $\mathbf{y}$ je funkcija slučajnega vektorja $\mathbf{x} \rightarrow \mathbf{y} = \mathbf{A}\mathbf{x}$

Komponente slučajnega vektorja $\mathbf{x}$ so neodvisne (nekorelirane), kovariančna matrika $\boldsymbol{\Sigma}_{\mathbf{xx}}$ je diagonalna matrika.

Določi kovariančno matriko $\boldsymbol{\Sigma}_{\mathbf{yy}}$ slučajnega vektorja $\mathbf{y}$.

Kovariančno matriko $\boldsymbol{\Sigma}_{\mathbf{yy}}$ slučajnega vektorja $\mathbf{y}$ dobimo z uporabo enačbe $\boldsymbol{\Sigma}_{\mathbf{yy}} = \mathbf{A}\,\boldsymbol{\Sigma}_{\mathbf{xx}}\mathbf{A}^T$ (4):

$$\begin{bmatrix} \sigma_y^2 \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \end{bmatrix} \cdot \begin{bmatrix} \sigma_{x_1}^2 & 0 & \cdots & 0 \\ 0 & \sigma_{x_2}^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{x_n}^2 \end{bmatrix} \cdot \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}$$

oziroma:

$$\sigma_y^2 = a_1^2 \sigma_{x_1}^2 + a_2^2 \sigma_{x_2}^2 + \ldots + a_n^2 \sigma_{x_n}^2 \qquad \text{(a)}$$

Za nelinearno funkcijo oblike $\mathbf{y} = \mathbf{y}(\mathbf{x})$:

$$Y = Y(X_1, X_2, ..., X_n)$$

kjer so $X_1, X_2, ..., X_n$ nekorelirane slučajne spremenljivke pa dobimo z uporabo enačbe $\mathbf{\Sigma_{yy}} = \mathbf{J_{yx}}\ \mathbf{\Sigma_{xx}}\ \mathbf{J_{yx}^T}$ (5):

$$\left[\sigma_y^2\right] = \left[\begin{array}{cccc} \frac{\partial Y}{\partial X_1} & \frac{\partial Y}{\partial X_2} & \cdots & \frac{\partial Y}{\partial X_n} \end{array}\right] \cdot \left[\begin{array}{cccc} \sigma_{x_1}^2 & 0 & \cdots & 0 \\ 0 & \sigma_{x_2}^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \sigma_{x_n}^2 \end{array}\right] \cdot \left[\begin{array}{c} \frac{\partial Y}{\partial X_1} \\ \frac{\partial Y}{\partial X_2} \\ \vdots \\ \frac{\partial Y}{\partial X_n} \end{array}\right]$$

oziroma:

$$\sigma_y^2 = \left(\frac{\partial Y}{\partial X_1}\right)^2 \sigma_{x_1}^2 + \left(\frac{\partial Y}{\partial X_2}\right)^2 \sigma_{x_2}^2 + ... + \left(\frac{\partial Y}{\partial X_n}\right)^2 \sigma_{x_n}^2 \qquad \text{(b)}$$

<u>PRIMER 2</u>:

S pomočjo gornje rešitve izračunaj varianco aritmetične sredine 4 nekoreliranih slučajnih spremenljivk X_1, X_2, X_3, X_4, ki jo izračunaš z izrazom: $\overline{X} = \frac{X_1 + X_2 + X_3 + X_4}{4}$.

Variance vseh štirih slučjanih spremenljivk X_1, X_2, X_3, X_4 so enake σ_x^2.

PRIMER 3:

V pravokotniku smo izmerili stranici $a = 60\text{m}$ in $b = 40\text{m}$ s standardnima odklonoma $\sigma_a = 2\text{cm}$ in $\sigma_b = 1.5\text{cm}$

Izračunaj obseg in ploščino pravokotnika ter pripadajoča standardna odklona.

Na osnovi standardnih odklonov izmerjenih dolžin stranic sestavimo kovariančno matriko: $\mathbf{\Sigma_{ab}} = \begin{bmatrix} \sigma_a^2 & \sigma_{ab} \\ \sigma_{ab} & \sigma_b^2 \end{bmatrix} = \begin{bmatrix} 0.0004 & 0 \\ 0 & 0.000225 \end{bmatrix}$

1. Obseg je linearna funkcija dolžin stranic:

$O = 2 \cdot a + 2 \cdot b$

V matrični obliki lahko izraz za obseg zapišemo:

$$O = \begin{bmatrix} 2 & 2 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \mathbf{Ab}$$

$$\mathbf{\Sigma_{OO}} = \mathbf{A\Sigma_{ab}A}^T = \begin{bmatrix} 2 & 2 \end{bmatrix} \begin{bmatrix} 0.0004 & 0 \\ 0 & 0.000225 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} =$$

$$= \begin{bmatrix} 0.0025 \end{bmatrix} = \begin{bmatrix} \sigma_o^2 \end{bmatrix}$$

Element kovariančne matrike $\mathbf{\Sigma_{OO}}$ je varianca obsega:

$\sigma_o^2 = 0.0025\text{m}^2$

Standardni odklon obsega pravokotnika pa je: $\sigma_O = 0.05\text{m} = 5\text{cm}$

2. Ploščina je nelinearna funkcija dolžin stranic:

$P = a \cdot b$

Sestavimo Jacobijevo matriko:

$$\mathbf{J}_{\left(\frac{P}{ab}\right)} = \begin{bmatrix} \frac{\partial P}{\partial a} & \frac{\partial P}{\partial b} \end{bmatrix} = \begin{bmatrix} b & a \end{bmatrix}$$

Številska vrednost elementov Jacobijeve matrike je določena za vrednosti dolžin opazovanih stranic:

$$\mathbf{J}_{\left(\frac{P}{ab}\right)\binom{a=60}{b=40}} = \begin{bmatrix} \frac{\partial P}{\partial a} & \frac{\partial P}{\partial b} \end{bmatrix}_{\binom{a=60}{b=40}} = \begin{bmatrix} b & a \end{bmatrix}_{\binom{a=60}{b=40}} = \begin{bmatrix} 40 & 60 \end{bmatrix}$$

Kovariančna matrika ploščine je:

$$\mathbf{\Sigma_{PP}} = \mathbf{J}_{\left(\frac{P}{ab}\right)\binom{a=60}{b=40}} \mathbf{\Sigma_{ab}} \mathbf{J}_{\left(\frac{P}{ab}\right)\binom{a=60}{b=40}}^T =$$

$$= \begin{bmatrix} 40 & 60 \end{bmatrix} \begin{bmatrix} 0.0004 & 0 \\ 0 & 0.000225 \end{bmatrix} \begin{bmatrix} 40 \\ 60 \end{bmatrix} =$$

$$= \begin{bmatrix} 1.4500 \end{bmatrix} = \begin{bmatrix} \sigma_P^2 \end{bmatrix}$$

Standardni odklon ploščine je: $\sigma_P = 1.2042\text{m}$

PRIMER 4:

V geometričnem nivelmanu je višinska razlika med točkama A in B določena z nivelmanom iz sredine.

Odčitek na lati na točki A je r_A in odčitek na lati na točki B je r_B. Standardna odklona odčitkov sta σ_{rA} in σ_{rB}.

Višinska razlika med točkama je $\Delta h_{AB} = r_B - r_A$ in njena varianca $\sigma^2_{\Delta h_{AB}} = \sigma^2_{rA} + \sigma^2_{rB}$.

Če sta standardna odklona odčitkov na lati enaka $\sigma_{rA} = \sigma_{rA} = \sigma_r$ je varianca višinske razlike med točkama A in B:

$\sigma^2_{\Delta h_{AB}} = 2\sigma^2_r$ in standardni odklon $\sigma_{\Delta h_{AB}} = \sqrt{2}\sigma_r$.

Višinska razlika med točkama P in Q, določena z geometričnim nivelmanom je določena kot vsota višinskih razlik med posameznimi postavitvami nivelirja (višinskimi razlikami med lato zadaj in lato spredaj).

Če je število postavitev nivelirja enako n in je z vsako postavitvijo nivelirja določena višinska razlika $\Delta h_i;\ i = 1,...,n$, je višinska razlika med točkama P in Q:

$$\Delta H_{PQ} = \Delta h_1 + \Delta h_2 + \cdots + \Delta h_n$$

Varianca vseh višinskih razlik med lato zadaj in lato spredaj je enaka in znaša $\sigma^2_{\Delta h_i} = \sigma^2_{\Delta h}$

Varianca višinske razlike med točkama P in Q (skupaj imamo n višinskih razlik) je:

$$\sigma^2_{\Delta H_{PQ}} = \sigma^2_{\Delta h_1} + \sigma^2_{\Delta h_2} + \cdots + \sigma^2_{\Delta h_n} = n \cdot \sigma^2_{\Delta h}$$

Višinsko razliko med točkama običajno določimo v nivelmanu »tja in nazaj«:

$$\Delta H_{sr} = \frac{\Delta H_{PQ} + \Delta H_{QP}}{2}$$

Varianca sredine višinske razlike med točkama P in Q, določena z geometričnim nivelmanom je tako:

$$\sigma^2_{\Delta H_{sr}} = \frac{1}{4}\sigma^2_{\Delta H_{PQ}} + \frac{1}{4}\sigma^2_{\Delta H_{QP}} = \frac{1}{2}\sigma^2_{\Delta H} = \frac{n}{2} \cdot \sigma^2_{\Delta h} = n \cdot \sigma^2_r$$

Ob čemer smo upoštevali enakost:

$$\sigma^2_{\Delta h} = 2\sigma^2_r$$

ZAKON O PRENOSU KOFAKTORJEV

Med kovariančno matriko $\mathbf{\Sigma_{xx}}$ in odgovarjajočo matriko kofaktorjev $\mathbf{Q_{xx}}$ slučajnega vektorja $\mathbf{x}$ velja zveza:

$\mathbf{\Sigma_{xx}} = \sigma_0^2\ \mathbf{Q_{xx}}$ (σ_0^2 je referenčna varianca) (6)

Za slučajni vektor $\mathbf{y}$ velja identična relacija med kovariančno matriko $\mathbf{\Sigma_{yy}}$ in matriko kofaktorjev $\mathbf{Q_{yy}}$:

$\mathbf{\Sigma_{yy}} = \sigma_0^2\ \mathbf{Q_{yy}}$ (7)

V enačbah (4) in (5) lahko uporabimo desne strani enačb (6) in (7) in pridobljene izraze nato delimo z referenčno varianco σ_0^2.

Tako dobimo:

- za linearen primer $\mathbf{Q_{yy}} = \mathbf{A}\,\mathbf{Q_{xx}}\mathbf{A}^T$ in
- za nelinearen primer $\mathbf{Q_{yy}} = \mathbf{J_{yx}}\ \mathbf{Q_{xx}}\ \mathbf{J_{yx}^T}$.

V povezavi s prenosom varianc in kovarianc, ob uporabi matrik kofaktorjev na mestu kovariančnih matrik, govorimo o prenosu kofaktorjev.

ZAPOREDNI PRENOS VARIANC IN KOVARIANC, ZAPOREDNI PRENOS KOFAKTORJEV

Dan je slučajni vektor $\mathbf{x}$ s pripadajočima kovariančno matriko $\boldsymbol{\Sigma}_{\mathbf{xx}}$ ter matriko kofaktorjev $\mathbf{Q}_{\mathbf{xx}}$.

Slučajni vektor $\mathbf{y}$ je funkcija slučajnega vektorja $\mathbf{x}$:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{a}$$

Slučajnemu vektorju $\mathbf{y}$ pripadajoča matrika kofaktorjev je $\mathbf{Q}_{\mathbf{yy}}$ je:

$$\mathbf{Q}_{\mathbf{yy}} = \mathbf{A}\,\mathbf{Q}_{\mathbf{xx}}\mathbf{A}^T$$

Imamo še slučajna vektorja $\mathbf{z}$ in $\mathbf{t}$, ki sta dana z zvezama:

$$\mathbf{z} = \mathbf{B}\mathbf{y} + \mathbf{b}$$
$$\mathbf{r} = \mathbf{C}\mathbf{z} + \mathbf{c}$$

Zanimata nas matriki kofaktorjev $\mathbf{Q}_{\mathbf{zz}}$ in $\mathbf{Q}_{\mathbf{rr}}$.

Določimo ju na običajen način, z uporabo zakona o prenosu kofaktorjev za linenarno funkcijo.

$$\mathbf{Q}_{\mathbf{zz}} = \mathbf{B}\,\mathbf{Q}_{\mathbf{yy}}\mathbf{B}^T = \mathbf{B}\,\mathbf{A}\,\mathbf{Q}_{\mathbf{xx}}\mathbf{A}^T\mathbf{B}^T$$

$$\mathbf{Q}_{\mathbf{rr}} = \mathbf{C}\,\mathbf{Q}_{\mathbf{zz}}\mathbf{C}^T = \mathbf{C}\,\mathbf{B}\,\mathbf{A}\,\mathbf{Q}_{\mathbf{xx}}\mathbf{A}^T\mathbf{B}^T\mathbf{C}^T$$

Gornje enačbe veljajo tudi za linearizirane oblike nelinearnih funkcij.

V tem primeru namesto matrik $\mathbf{A}, \mathbf{B}$ in $\mathbf{C}$ uporabimo odgovarjajoče Jacobijeve matrike.

PRENOS VARIANC IN KOVARIANC PRI POSREDNI IZRAVNAVI PO METODI NAJMANJŠIH KVADRATOV

Enačbe popravkov so oblike:

$$\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$$

kjer je $\mathbf{v}$ je vektor popravkov opazovanj, $\boldsymbol{\Delta}$ vektor neznank, $\mathbf{B}$ matrika koeficientov neznank, vektor $\mathbf{f} = \mathbf{d} - \mathbf{l}$, kjer je $\mathbf{l}$ vektor opazovanj in $\mathbf{d}$ vektor numeričnih konstant.

Vektorju opazovanj $\mathbf{l}$ dodelimo kovariančno matriko $\boldsymbol{\Sigma}_{\mathbf{ll}}$, matriko kofaktorjev $\mathbf{Q}_{\mathbf{ll}}$ in matriko uteži $\mathbf{P}_{\mathbf{ll}}$.

V primeru, ko se kovariančna matrika, matrika kofaktorjev in matrika uteži nanašajo na slučajni vektor opazovanj $\mathbf{l}$ izpustimo navajanje indeksa "$_{\mathbf{ll}}$".

Tako je za vektor opazovanj $\mathbf{l}$ kovariančna matrika $\boldsymbol{\Sigma}$, matrika kofaktorjev $\mathbf{Q}$ in matrika uteži $\mathbf{P}$.

Pri izravnavi po metodi najmanjših kvadratov uporabljamo za prenos (varianc in kovarianc) matrike kofaktorjev.

Posredna izravnava → dan je vektor opazovanj $\mathbf{l}$ in pripadajoča matrika uteži $\mathbf{P}$, ki določa tudi matriko kofaktorjev opazovanj $\mathbf{Q}$:

$$\mathbf{Q} = \mathbf{P}^{-1}$$

Zanimajo nas matrike kofaktorjev:

- vektorja neznank $\boldsymbol{\Delta} \rightarrow \mathbf{Q}_{\boldsymbol{\Delta\Delta}}$
- vektorja popravkov opazovanj $\mathbf{v} \rightarrow \mathbf{Q}_{\mathbf{vv}}$
- vektorja izravnanih opazovanj $\hat{\mathbf{l}} \rightarrow \mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$

Ponovimo:

Imamo linearno funkcijo $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$.

Dana je matrika kofaktorjev $\mathbf{Q_{xx}}$ sl. vektorja $\mathbf{x}$

Matriko kofaktorjev $\mathbf{Q_{yy}}$ sl. vektorja $\mathbf{y}$ izračunamo z:

$$\mathbf{Q_{yy}} = \mathbf{A}\,\mathbf{Q_{xx}}\,\mathbf{A}^T$$

<u>Izpeljava prenosa kofaktorjev za posredno izravnavo</u>

Enačbe za rešitev posredne izravnave prepišemo v obliko $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$, nato za te enačbe uporabimo gornjo enačbo prenosa kofaktorjev.

Najprej zapišemo enačbo $\mathbf{f} = \mathbf{d} - \mathbf{l}$ v obliki $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$ in dobimo:

$$\mathbf{f} = \left(-\mathbf{I}\right)\mathbf{l} + \mathbf{d}$$

z uporabo zakona o prenosu kofaktorjev za to enačbo dobimo:

$$\mathbf{Q_{ff}} = (-\mathbf{I})\mathbf{Q}(-\mathbf{I})^T = \mathbf{Q}$$

Vidimo, da je matrika kofaktorjev $\mathbf{Q_{ff}}$ vektorja $\mathbf{f}$ enaka matriki kofaktorjev $\mathbf{Q}$ vektorja opazovanj $\mathbf{l}$.

Enačbe rešitve posredne izravnave so:

$$\mathbf{N} = \mathbf{B}^T \mathbf{P} \mathbf{B}$$

$$\mathbf{t} = \mathbf{B}^T \mathbf{P}\, \mathbf{f}$$

$$\boldsymbol{\Delta} = \mathbf{N}^{-1} \mathbf{t}$$

$$\mathbf{v} = \mathbf{f} - \mathbf{B}\boldsymbol{\Delta}$$

$$\hat{\mathbf{l}} = \mathbf{l} + \mathbf{v}$$

Gornje enačbe zapišemo v obliki $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$:

$$\mathbf{t} = \left(\mathbf{B}^T \mathbf{P}\right)\mathbf{f} \tag{1}$$

$$\boldsymbol{\Delta} = \left(\mathbf{N}^{-1}\right)\mathbf{t} \tag{2}$$

$$\begin{aligned} \mathbf{v} &= \mathbf{f} - \mathbf{B}\boldsymbol{\Delta} \\ &= \mathbf{f} - \mathbf{B}\mathbf{N}^{-1}\mathbf{t} \\ &= \mathbf{f} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}\mathbf{f} \\ \mathbf{v} &= \left(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}\right)\mathbf{f} \end{aligned} \tag{3}$$

$$\begin{aligned} \hat{\mathbf{l}} &= \mathbf{l} + \mathbf{v} \\ &= \mathbf{l} + \mathbf{f} - \mathbf{B}\boldsymbol{\Delta} \\ \hat{\mathbf{l}} &= \left(-\mathbf{B}\right)\boldsymbol{\Delta} + \mathbf{d} \end{aligned} \tag{4}$$

V gornjih enačbah predstavljajo izrazi v oklepajih $\left(\ \right)$ matriko $\mathbf{A}$ enačbe $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$.

Z uporabo zakona o prenosu kofaktorjev za enačbe (1) do (4) dobimo:

$$\mathbf{Q_{tt}} = \mathbf{B}^T \underbrace{\mathbf{P}\underbrace{\mathbf{Q_{ff}}}_{=\mathbf{Q}}}_{\mathbf{PQ=I}} \left(\mathbf{B}^T\mathbf{P}\right)^T = \mathbf{N} \tag{5}$$

$$\mathbf{Q_{\Delta\Delta}} = \left(\mathbf{N}^{-1}\right)\mathbf{Q_{tt}}\left(\mathbf{N}^{-1}\right)^T = \mathbf{N}^{-1} \tag{6}$$

$$\begin{aligned}\mathbf{Q_{vv}} &= \left(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}\right)\mathbf{Q_{ff}}\left(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}\right)^T \\ &= \mathbf{Q} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\end{aligned} \tag{7}$$

$$\mathbf{Q_{\hat{l}\hat{l}}} = \left(-\mathbf{B}\right)\mathbf{Q_{\Delta\Delta}}\left(-\mathbf{B}\right)^T = \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T \tag{8}$$

Iz enačb (7) in (8) vidimo, da je:

$$\mathbf{Q_{\hat{l}\hat{l}}} = \mathbf{Q} - \mathbf{Q_{vv}}$$

Kovariančne matrike $\mathbf{\Sigma_{tt}}$, $\mathbf{\Sigma_{\Delta\Delta}}$ in $\mathbf{\Sigma_{\hat{l}\hat{l}}}$ slučajnih vektorjev $\mathbf{t}$, $\mathbf{\Delta}$ in $\hat{\mathbf{l}}$ dobimo z množenjem odgovarjajočih matrik kofaktorjev z referenčno varianco σ_0^2.

PRENOS VARIANC IN KOVARIANC PRI POGOJNI IZRAVNAVI PO METODI NAJMANJŠIH KVADRATOV

Pogojne enačbe so oblike:

$$\mathbf{Av} = \mathbf{f}$$

$\mathbf{v}$ je vektor popravkov, $\mathbf{A}$ je matrika numeričnih koeficientov opazovanj (numeričnih koeficientov popravkov) in $\mathbf{f} = \mathbf{d} - \mathbf{Al}$ vektor odstopanj, kjer je $\mathbf{d}$ vektor numeričnih konstant in $\mathbf{l}$ vektor opazovanj.

Vemo, da vektor $\mathbf{f}$ pri pogojni izravnavi ni enak vektorju $\mathbf{f}$ pri posredni izravnavi.

<u>Izpeljava prenosa kofaktorjev za pogojno izravnavo</u>

Dan je vektor opazovanj $\mathbf{l}$ in pripadajoča matrika kofaktorjev $\mathbf{Q}$.

Spet vse enačbe za rešitev problema izravnave zapišemo v obliki $\mathbf{y} = \mathbf{Ax} + \mathbf{b}$ in nato uporabimo prenos kofaktorjev.

Izraz $\mathbf{f} = \mathbf{d} - \mathbf{Al}$, zapisan v obliki $\mathbf{y} = \mathbf{Ax} + \mathbf{b}$ je:

$$\mathbf{f} = (-\mathbf{A})\mathbf{l} + \mathbf{d}$$

Z uporabo zakona o prenosu kofaktorjev za gornjo enačbo dobimo:

$$\mathbf{Q_{ff}} = (-\mathbf{A})\mathbf{Q}(-\mathbf{A})^T = \mathbf{AQA}^T \qquad (1)$$

Koraki v rešitvi pogojne izravnave so:

$$\mathbf{Q}_e = \mathbf{A}\mathbf{Q}\mathbf{A}^T \tag{2}$$

$$\mathbf{P}_e = \mathbf{Q}_e^{-1} \tag{3}$$

$$\mathbf{k} = \mathbf{P}_e\mathbf{f} \tag{4}$$

$$\mathbf{v} = \mathbf{Q}\mathbf{A}^T\mathbf{k} \tag{5}$$

$$\hat{\mathbf{l}} = \mathbf{l} + \mathbf{v} \tag{6}$$

Iz enačb (1) in (2) je očitno, da je matrika kofaktorjev $\mathbf{Q_{ff}}$ vektorja $\mathbf{f}$ enaka matriki $\mathbf{Q}_e$:

$$\mathbf{Q_{ff}} = \mathbf{Q}_e$$

Z uporabo zakona o prenosu kofaktorjev za enačbi (4) in (5), imamo:

$$\mathbf{Q_{kk}} = \left(\mathbf{P}_e\right)\underbrace{\mathbf{Q_{ff}}}_{=\mathbf{Q}_e}\left(\mathbf{P}_e\right)^T = \mathbf{P}_e \tag{7}$$

In

$$\mathbf{Q_{vv}} = \left(\mathbf{Q}\mathbf{A}^T\right)\underbrace{\mathbf{Q_{kk}}}_{=\mathbf{P}_e}\left(\mathbf{Q}\mathbf{A}^T\right)^T = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\mathbf{Q} \tag{8}$$

ker so vse matrike kofaktorjev in uteži simetrične.

Za določitev matrike kofaktorjev vektorja $\hat{\mathbf{l}}$, moramo $\hat{\mathbf{l}}$ izraziti kot linearno funkcijo opazovanj $\mathbf{l}$:

$$\begin{aligned}\hat{\mathbf{l}} &= \mathbf{l} + \mathbf{v} \\ &= \mathbf{l} + \mathbf{Q}\mathbf{A}^T\mathbf{k} \\ &= \mathbf{l} + \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{f} \\ &= \mathbf{l} + \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\left(\mathbf{d} - \mathbf{A}\mathbf{l}\right)\end{aligned}$$

iz česar sledi:

$$\hat{\mathbf{l}} = \left(\mathbf{I} - \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\right)\mathbf{l} + \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{d}$$

Z uporabo zakona o prenosu kofaktorjev za gornjo enačbo je:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \left(\mathbf{I} - \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\right)\mathbf{Q}\left(\mathbf{I} - \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\right)^T$$

kar vodi do:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{Q} - \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\mathbf{Q} \qquad (9)$$

Iz enačb (8) in (9) je očitno, da je:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{Q} - \mathbf{Q}_{\mathbf{v}\mathbf{v}}$$

kar je enako kot za primer posredne izravnave.

Kovariančne matrike slučajnih vektorjev $\mathbf{k}$, $\mathbf{v}$ in $\hat{\mathbf{l}}$ zopet dobimo z množenjem matrik kofaktorjev z referenčno varianco σ_0^2.

PRIMER:

POSREDNA IZRAVNAVA

Imamo kocko, v kateri smo opazovali dolžino stranice – l_1, dolžino diagonale osnovne ploskve – l_2, dolžino telesne diagonale – l_3, obseg osnovne ploskve – l_4, ploščino odnovne ploskve – l_5 in prostornino – l_6.

<u>1. Opazovanja so nekorelirana in enake natačnosti.</u>

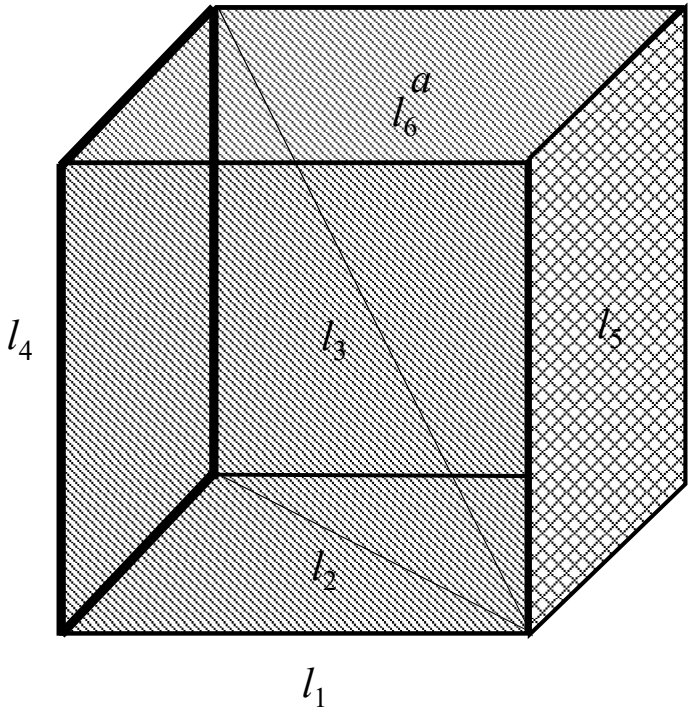

Podatki:

$l_1 = 10\text{m}$
$l_2 = 14.4\text{m}$
$l_3 = 17.3\text{m}$
$l_4 = 40.1\text{m}$
$l_5 = 101\text{m}^2$
$l_6 = 1000\text{m}^3$

Parametri problema:

$n = 6$
$n_0 = 1$
$u = 1$
$r = 5$

Za $u = 1$ neznanko izberemo dolžino stranice kocke a.

Enačbe, ki povezujejo opazovanja $l_1 - l_6$ in dolžino stranice a so:

$$F_1 = l_1 - a = 0$$
$$F_2 = l_2 - a\sqrt{2} = 0$$
$$F_3 = l_3 - a\sqrt{3} = 0$$
$$F_4 = l_4 - 4a = 0$$
$$F_5 = l_5 - a^2 = 0$$
$$F_6 = l_6 - a^3 = 0$$

Enačbe so nelinearne za neznanko $\rightarrow$ linearizacija.

Linearizirane enačbe popravkov opazovanj so:

$$v_1 - 1 \cdot \delta a = a_0 - l_1$$
$$v_2 - \sqrt{2} \cdot \delta a = \sqrt{2} \cdot a_0 - l_2$$
$$v_3 - \sqrt{3} \cdot \delta a = \sqrt{3} \cdot a_0 - l_3$$
$$v_4 - 4 \cdot \delta a = 4 \cdot a_0 - l_4$$
$$v_5 - 2 \cdot a \cdot \delta a = a_0^2 - l_5$$
$$v_6 - 3 \cdot a^2 \cdot \delta a = a_0^3 - l_6$$

Izberemo približno vrednost za a, $a_0 = 10\text{m}$.

Matrika $\mathbf{B}$ in vektor $\mathbf{f}$ sta:

$$\mathbf{B} = \begin{bmatrix} -1 \\ -\sqrt{2} \\ -\sqrt{3} \\ -4 \\ -2 \cdot a_0 \\ -3 \cdot a_0^2 \end{bmatrix}; \quad \mathbf{f} = \begin{bmatrix} 0 \\ -0.2579 \\ 0.0205 \\ -0.1000 \\ -1 \\ 0 \end{bmatrix}$$

Matrika uteži $\mathbf{P}$ je enotska matrika

Sestavi matriko $\boldsymbol{\Sigma}_{\Delta\Delta}$ in določi standardni odklon ocenjene dolžine stranice kocke.

1.1. Matrika $\mathbf{Q}_{\Delta\Delta} = \mathbf{N}^{-1}$ je (vrednosti so zaokrožene na 4 decimalna mesta):

$$\mathbf{Q}_{\Delta\Delta} = \left(\mathbf{B}^T \mathbf{B}\right)^{-1}$$

Ker je $\sigma_0^2 = 1$ je $\boldsymbol{\Sigma}_{\Delta\Delta} = \mathbf{Q}_{\Delta\Delta}$

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[1.1059 \cdot 10^{-5}\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0033\text{m}$$

1.2. Sestavimo matriko $\mathbf{Q}_{\Delta\Delta}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.3333\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.5774\text{m}$$

b.) Opazovanja l_1, l_2 in l_3:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.1667\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.4082\text{m}$$

c.) Opazovanja l_1, l_2, l_3 in l_4:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0455\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.2132\text{m}$$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0024\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0487\text{m}$$

2. Opazovanja so nekorelirana in različne natačnosti

Standardni odkloni opazovanj so sedaj:

$\sigma_1 = 0.2\text{m}$
$\sigma_2 = 0.24\text{m}$
$\sigma_3 = 0.27\text{m}$
$\sigma_4 = 0.5\text{m}$
$\sigma_5 = 1\text{m}^2$
$\sigma_6 = 5\text{m}^3$

Kovariančna matrika opazovanj $\boldsymbol{\Sigma}$ je:

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0.0040 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.0576 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.0729 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.2500 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 25.000 \end{bmatrix}$$

Matrika uteži opazovanj $\mathbf{P}$ je:

$$\mathbf{P} = \begin{bmatrix} 25.0000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 17.3611 & 0 & 0 & 0 & 0 \\ 0 & 0 & 13.7174 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4.0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.0400 \end{bmatrix}$$

Sestavi matriko $\boldsymbol{\Sigma}_{\Delta\Delta}$ in določi standardni odklon ocenjene dolžine stranice kocke.

1.1. Matrika $\mathbf{Q}_{\Delta\Delta} = \mathbf{N}^{-1}$ je (vrednosti so zaokrožene na 4 decimalna mesta):

$$\mathbf{Q}_{\Delta\Delta} = \left(\mathbf{B}^T\mathbf{B}\right)^{-1}$$

Ker je $\sigma_0^2 = 1$ je $\boldsymbol{\Sigma}_{\Delta\Delta}$=$\mathbf{Q}_{\Delta\Delta}$

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[2.4010\cdot 10^{-4}\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0155\text{m}$$

1.2. Sestavimo matriko $\boldsymbol{\Sigma}_{\Delta\Delta}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0167\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.1294\text{m}$$

b.) Opazovanja l_1, l_2 in l_3:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0099\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0996\text{m}$$

c.) Opazovanja l_1, l_2, l_3 in l_4:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0061\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0779\text{m}$$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

$$\boldsymbol{\Sigma}_{\Delta\Delta} = \left[0.0018\right] = \left[\sigma_{\hat{a}}^2\right]$$
$$\sigma_{\hat{a}} = 0.0421\text{m}$$

PRIMER:

POGOJNA IZRAVNAVA

Ista kocka, v kateri smo opazovali dolžino stranice – l_1, dolžino diagonale osnovne ploskve – l_2, dolžino telesne diagonale – l_3, obseg osnovne ploskve – l_4, ploščino odnovne ploskve – l_5 in prostornino – l_6.

<u>1. Opazovanja so nekorelirana in različne natačnosti.</u>

Podatki:

$$l_1 = 10\text{m} \quad \sigma_1 = 0.2\text{m}$$
$$l_2 = 14.4\text{m} \quad \sigma_2 = 0.24\text{m}$$
$$l_3 = 17.3\text{m} \quad \sigma_3 = 0.27\text{m}$$
$$l_4 = 40.1\text{m} \quad \sigma_4 = 0.5\text{m}$$
$$l_5 = 101\text{m}^2 \quad \sigma_5 = 1\text{m}^2$$
$$l_6 = 1000\text{m}^3 \quad \sigma_6 = 5\text{m}^3$$

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0.0040 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.0576 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.0729 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.2500 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 25.000 \end{bmatrix}$$

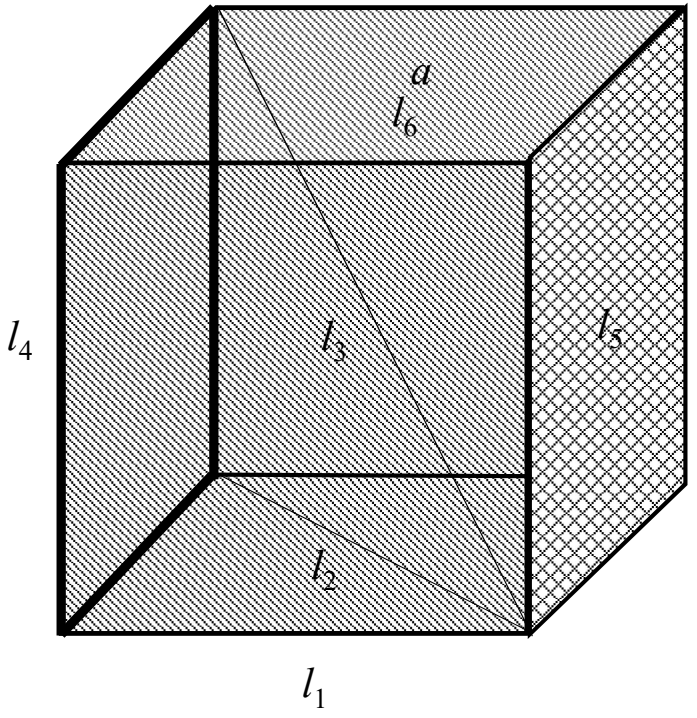

Določi velikost kocke s pripadajočimi informacije o njeni natančnosti.

Parametri problema:

$n = 6$

$n_0 = 1$

$r = n - n_0 = 5$

Pogojne enačbe za vseh 6 opazovanj so:

$$F_1 = l_1 - \frac{l_2}{\sqrt{2}} = 0$$

$$F_2 = l_1 - \frac{l_3}{\sqrt{3}} = 0$$

$$F_3 = l_1 - \frac{l_4}{4} = 0$$

$$F_4 = l_1^2 - l_5 = 0$$

$$F_5 = l_1^3 - l_6 = 0$$

Ker je najmanj ena pogojna enačba nelinearna $\rightarrow$ linearizacija.

Matrika $\mathbf{A}$ in vektor $\mathbf{f}$ sta:

$$\mathbf{A}_{ij} = \frac{\partial F_1}{\partial l_j} = \begin{bmatrix} 1 & -\frac{1}{\sqrt{2}} & 0 & 0 & 0 & 0 \\ 1 & 0 & -\frac{1}{\sqrt{3}} & 0 & 0 & 0 \\ 1 & 0 & 0 & -\frac{1}{4} & 0 & 0 \\ 2 \cdot l_1 & 0 & 0 & 0 & -1 & 0 \\ 3 \cdot l_1^2 & 0 & 0 & 0 & 0 & -1 \end{bmatrix}$$

$$\mathbf{f}_i = -F_i = \begin{bmatrix} -l_1 + \frac{l_2}{\sqrt{2}} \\ -l_1 + \frac{l_3}{\sqrt{3}} \\ -l_1 + \frac{l_4}{4} \\ -l_1^2 + l_5 \\ -l_1^3 + l_6 \end{bmatrix}$$

Določi ocenjeno dolžino stranice kocke, sestavi kovariančno matriko $\mathbf{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$ in določi standardni odklon ocenjene dolžine stranice kocke.

1.1. Matrika $\mathbf{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$ je (vrednosti so zaokrožene na 4 decimalna mesta):

$$\mathbf{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0.0002 & 0.0003 & 0.0004 & 0.0010 & 0.0048 & 0.0720 \\ 0.0003 & 0.0005 & 0.0006 & 0.0014 & 0.0068 & 0.1019 \\ 0.0004 & 0.0006 & 0.0007 & 0.0017 & 0.0083 & 0.1248 \\ 0.0010 & 0.0014 & 0.0017 & 0.0038 & 0.0192 & 0.2881 \\ 0.0048 & 0.0068 & 0.0083 & 0.0192 & 0.0960 & 1.4406 \\ 0.0720 & 0.1019 & 0.1248 & 0.2881 & 1.4406 & 21.6093 \end{bmatrix}$$

Varianca ocenjene dolžine stranice kocke je $\sigma_{\hat{l}_1}^2$

$$\mathbf{\Sigma}_{\hat{l}_1\hat{l}_1} = \left[\sigma_{\hat{l}_1}^2 \right] = \left[2.4010 \cdot 10^{-4} \right] \rightarrow \sigma_{\hat{l}_1} = 0.0155\text{m}$$

1.2. Sestavimo matriko $\boldsymbol{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

$$\boldsymbol{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0.0167 & 0.0237 \\ 0.0237 & 0.0335 \end{bmatrix}$$

b.) Opazovanja l_1, l_2 in l_3:

$$\boldsymbol{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0.0099 & 0.0140 & 0.0172 \\ 0.0140 & 0.0198 & 0.0243 \\ 0.0172 & 0.0243 & 0.0297 \end{bmatrix}$$

c.) Opazovanja l_1, l_2, l_3 in l_4:

$$\boldsymbol{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0.0061 & 0.0086 & 0.0105 & 0.0243 \\ 0.0086 & 0.0121 & 0.0149 & 0.0343 \\ 0.0105 & 0.0149 & 0.0182 & 0.0420 \\ 0.0243 & 0.0343 & 0.0420 & 0.0970 \end{bmatrix}$$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

$$\boldsymbol{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0.0018 & 0.0025 & 0.0031 & 0.0071 & 0.0354 \\ 0.0025 & 0.0035 & 0.0043 & 0.0100 & 0.0501 \\ 0.0031 & 0.0043 & 0.0053 & 0.0123 & 0.0613 \\ 0.0071 & 0.0100 & 0.0123 & 0.0283 & 0.1416 \\ 0.0354 & 0.0501 & 0.0613 & 0.1416 & 0.7081 \end{bmatrix}$$

Za različne kombinacije opazovanj primerjaj izračunane variance istih izravnanih opazovanj in komentiraj rezultate.

PRENOS PRAVIH POGREŠKOV (1. letnik):
PRENOS PRAVEGA POGREŠKA DOLŽINE STRANICE NA PRAVI POGREŠEK POVRŠINE KVADRATA

Izračunati želimo površino parcele kvadratne oblike, s stranico dolžine 50 m.

Prava dolžina stranice (AB, BC, CD, DA) je 50.120 m, izmerili smo dolžino stranice 50.170 m.

Koliko znaša pravi pogrešek površine parcele?

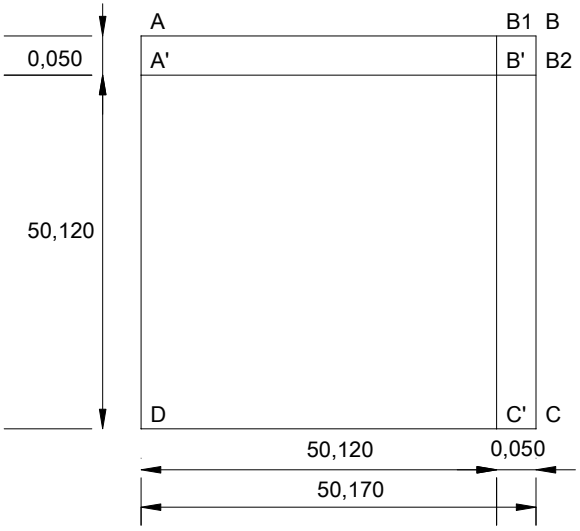

Iz prave vrednosti dolžine stranice kvadrata, izračunana prava površina je:

$$y_T = x_T{}^2 = (50{,}120)^2 = 2512{,}0144\ m^2$$

kar predstavlja na sliki površino kvadrata A‘B‘C‘D.
Pravih vrednosti praviloma ne poznamo.

Površina kvadrata, določena na osnovi izmerjene vrednosti dolžine stranice, je:

$$y = x^2 = (50{,}170)^2 = 2517{,}0289\ m^2$$

Pravi pogrešek površine kvadrata je tako:

$$dy = y - y_T = \ 2517{,}0289 - 2512{,}0144 = 5{,}0145 m^2$$

To površino na sliki predstavlja vsota površin pravokotnikov A B1 B' A' in C B2 B' C' in kvadrata B1 B B2 B'.

POTREBNA NATANČNOST GEODETSKIH MERITEV

Ocena potrebne natančnosti meritev je analiza vpliva natančnosti spremenljivk (meritev) v matematičnem modelu na natančnost funkcij spremenljivk (funkcij meritev).

Oceno potrebne natančnosti meritev opravimo pred pričetkom terenske izmere.

To je pomembna faza pri pripravi projekta izmere, ker predstavlja osnovo za pridobitev informacije o potrebni/optimalni natančnosti meritev, glede na vnaprej postavljene zahteve kakovosti rešitve problema.

To oceno včasih potrebujemo za pridobitev odgovora ali bomo postavljene kriterije natančnosti lahko sploh izpolnili.

Pridobljeni rezultati nam pomagajo pri izbiri instrumentarija in postopkov meritev.

V okviru te ocene predpostavimo, da so vse količine, ki nastopajo v matematičnem modelu proste sistematičnih pogreškov – merila natančnosti so enaka merilom točnosti.

Predpostavimo, da so posamezne komponente matematičnega modela med seboj nekorelirane → uporabimo zakon o prenosu varianc in kovarianc nekoreliranih slučajnih spremenljivk.

Analitični postopki določitve potrebne natančnosti meritev temeljijo na zakonu o prenosu varianc in kovarianc.

Če je Y linearna funkcija nekoreliranih (neodvisnih) opazovanj $X_1, X_2, ..., X_n$:

$$Y = a_1 X_1 + a_2 X_2 + ... + a_n X_n$$

imamo:

$$\sigma_Y{}^2 = a_1^2 \sigma_{X_1}^2 + a_2^2 \sigma_{X_2}^2 + ... + a_n^2 \sigma_{X_n}^2$$

Kjer so $a_1, a_2, ..., a_n$ konstante, $\sigma_{X_1}^2, \sigma_{X_2}^2, ..., \sigma_{X_n}^2$ variance opazovanj, $X_1, X_2, ..., X_n$ in $\sigma_Y{}^2$ varianca slučajne spremenljivke Y.

Če je Y nelinearna funkcija nekoreliranih opazovanj $X_1, X_2, ..., X_n$ je:

$$\sigma_Y^2 = \left(\frac{\partial Y}{\partial X_1}\right)^2 \sigma_{X_1}^2 + \left(\frac{\partial Y}{\partial X_2}\right)^2 \sigma_{X_2}^2 + ... + \left(\frac{\partial Y}{\partial X_n}\right)^2 \sigma_{X_n}^2$$

Pri predhodni oceni natančnosti uporabljamo gornje enačbe v obratnem smislu → zahtevane natančnosti vhodnih opazovanj X_i pridobimo, če imamo predhodno podano potrebno natančnost funkcije opazovanj Y.

Najbolj preprost primer določitve potrebne natančnosti opazovanj temelji na predpostavki da vsako opazovanje prispeva enak delež v skupno natančnost funkcije opazovanj.

Za linearen primer takrat velja:

$$\frac{\sigma_Y{}^2}{n} = a_1^2\sigma_{X_1}^2 = a_2^2\sigma_{X_2}^2 = \ldots = a_n^2\sigma_{X_n}^2$$

Iz česar dobimo:

$$\sigma_{X_i} = \frac{\sigma_Y}{|a_i|\sqrt{n}};\ \ i = 1,2,\ldots,n$$

Če predpostavimo enak prispevek vsakega opazovanja v natančnost nelinearne funkcije opazovanj, imamo:

$$\frac{\sigma_Y^2}{n} = \left(\frac{\partial Y}{\partial X_1}\right)^2 \sigma_{X_1}^2 = \left(\frac{\partial Y}{\partial X_2}\right)^2 \sigma_{X_2}^2 = \ldots = \left(\frac{\partial Y}{\partial X_n}\right)^2 \sigma_{X_n}^2$$

Iz česar dobimo:

$$\sigma_{X_i} = \frac{\sigma_Y}{\left|\frac{\partial Y}{\partial X_i}\right|\sqrt{n}}\ ;\ \ i = 1,2,\ldots,n$$

Ko vsako opazovanje prispeva enak delež v natančnost funkcije opazovanj, pravimo, da so opazovanja uravnotežene natančnosti.

Primer:

Pravokoten kos zemljišča ima stranici dolžin $\sim 85m$ in $\sim 60m$.

Če moramo določiti površino P zemljišča s standardnim odklonom $\sigma_P = 0,6m^2$, določi potrebna standardna odklona dolžin stranic zemljišča pod predpostavko, da sta opazovanji uravnotežene natančnosti.

Površina zemljišča je $P = xy$. Očitno je $n = 2$. Za potrebe analize uporabimo vrednosti $x = 85m$ in $y = 60m$.

Iz enačbe: $\sigma_{X_i} = \dfrac{\sigma_Y}{\left|\dfrac{\partial Y}{\partial X_i}\right|\sqrt{n}}$ imamo:

$$\sigma_x = \frac{\sigma_P}{\left|\dfrac{\partial P}{\partial x}\right|\sqrt{2}} = \frac{\sigma_P}{y\sqrt{2}} = \frac{0,6m^2}{60m\sqrt{2}} = 7mm$$

$$\sigma_y = \frac{\sigma_P}{\left|\dfrac{\partial P}{\partial y}\right|\sqrt{2}} = \frac{\sigma_P}{x\sqrt{2}} = \frac{0,6m^2}{85m\sqrt{2}} = 5mm$$

Če želimo določiti površino pravokotne parcele, s stranicama dolžin $\sim 85m$ in $\sim 60m$, s standardnim odklonom $\sigma_P = 0,6m^2$, naj bi, za primer uravnotežene natančnosti, bili dolžini stranic izmerjeni s standardnima odklonoma $\sigma_x = 7mm$ in $\sigma_y = 5mm$,

VPLIV NATANČNOSTI DOLŽINE STRANICE NA NATANČNOST POVRŠINE KVADRATA

Izračunati želimo površino in standardni odklon površine parcele kvadratne oblike, s stranico dolžine približno 50 m.
Standardni odkloni izmerjenih dolžin stranic znašajo:

$$\sigma_a = \sigma_a = \sigma_a = \sigma_a = 5\ cm$$

Koliko znaša standardni odklon površine kvadrata?

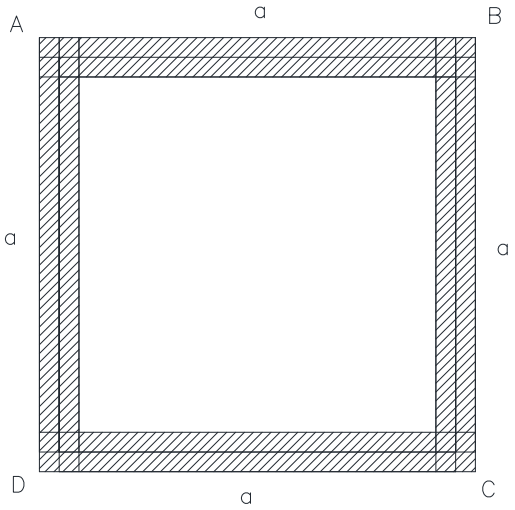

Uporabimo prenos varianc in kovarianc.
Površina kvadrata je:

$$P = a^2$$

Prenos varianc in kovarianc izvedemo s pomočjo izrazov za prenos pri nelinearni funkciji.

$$\frac{\partial P}{\partial a} = 2a$$

$$\sigma_P^2 = \left(\frac{\partial P}{\partial a}\right)^2 {\sigma_a}^2 = (2a)^2 {\sigma_a}^2 = (100m)^2 (0,050m)^2 = 25m^4$$

$$\sigma_P = 5m^2$$

NATANČNOST KOORDINAT OGLIŠČ IN NATANČNOST POVRŠINE KVADRATA 1.

Parcela ima obliko kvadrata. Koordinate oglišč parcele smo določili z geodetsko izmero glede na dve dani točki T_A in T_B. Do vsake točke parcele (T_1, T_2, T_3 in T_4) smo opazovali kot α (dejansko smo opazovali dve smeri β_1 in β_2) in dolžino *s*.

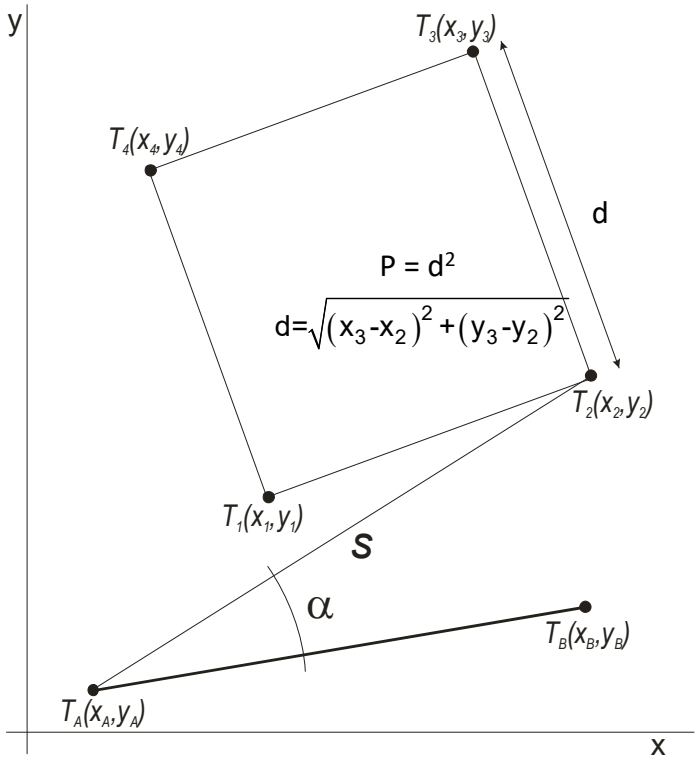

Površino parcele moramo določiti s standardnim odklonom:

$$\sigma_P = 1m^2$$

Površino parcele (kvadrata) dobimo z:

$$P = d^2$$

Kjer d predstavlja izračunano stranico med dvema sosednjima točkama, v našem primeru med točkama T_2 in T_3.

Natančnost površine določimo s prenosom varianc in kovarianc:

$$\sigma_P^2 = \left|\frac{\partial P}{\partial d}\right|^2 \cdot \sigma_d^2 \quad \rightarrow \quad \sigma_P = \left|\frac{\partial P}{\partial d}\right| \cdot \sigma_d \quad \rightarrow \quad \sigma_d = \frac{\sigma_P}{\left|\frac{\partial P}{\partial d}\right|} = \frac{\sigma_P}{2 \cdot d}$$

Za izračun standardnega odklona površine kvadrata potrebujemo podatek o standardnem odklonu dolžine stranice. Dolžino stranice izračunamo z:

$$d = \sqrt{(x_3 - x_2)^2 + (y_3 - y_2)^2}$$

Natančnost stranice izračunamo iz natančnosti koordinat s prenosom varianc in kovarianc:

$$\sigma_d^2 = \left|\frac{\partial d}{\partial x_2}\right|^2 \cdot \sigma_{x2}^2 + \left|\frac{\partial d}{\partial y_2}\right|^2 \cdot \sigma_{y2}^2 + \left|\frac{\partial d}{\partial x_3}\right|^2 \cdot \sigma_{x3}^2 + \left|\frac{\partial d}{\partial y_3}\right|^2 \cdot \sigma_{y3}^2$$

NATANČNOST KOORDINAT OGLIŠČ IN NATANČNOST POVRŠINE KVADRATA 2.

Če predpostavimo, da so koordinate vseh točk določene z enako natančnostjo:

$$\sigma_{xi} = \sigma_{yi} = \sigma_{koo} \quad (i = 1,2,3,4)$$

potem lahko zapišemo:

$$\sigma_d^2 = \sigma_{koo}^2 \cdot \left(\left|\frac{\partial d}{\partial x_2}\right|^2 + \left|\frac{\partial d}{\partial y_2}\right|^2 + \left|\frac{\partial d}{\partial x_3}\right|^2 + \left|\frac{\partial d}{\partial y_3}\right|^2 \right) = \sigma_{koo}^2 \cdot 2$$

Iz česar sledi:

$$\sigma_d = \sigma_{koo} \cdot \sqrt{2} \;\rightarrow \sigma_{koo} = \frac{\sigma_d}{\sqrt{2}} \;\rightarrow \sigma_{koo} = \frac{\sigma_P}{2\sqrt{2} \cdot d}$$

Koordinate točke T_i *(i=1,2,3,4)* so določene na podlagi opazovanj kota *α* in dolžine *s*. Točka T_2 ima koordinate, ki jih dobimo z:

$$x_2 = x_A + s \cdot \sin(\nu_{TA}^{T2} - \alpha)$$

$$y_2 = y_A + s \cdot \cos(\nu_{TA}^{T2} - \alpha)$$

Natančnost koordinate x_2 točke T_2 je odvisna od natančnosti opazovanj za njeno določitev.

Če zapišemo $x_2 = x_{koo}$ in $\sigma_{koo} = \sigma_{x2}$, velja:

$$\sigma_{koo}^2 = \left|\frac{\partial x_2}{\partial s}\right|^2 \cdot \sigma_s^2 + \left|\frac{\partial x_2}{\partial \alpha}\right|^2 \cdot \sigma_\alpha^2$$

$$\sigma_{koo}^2 = \sin^2(\nu_{TA}^{T2} - \alpha) \cdot \sigma_s^2 + \cos^2(\nu_{TA}^{T2} - \alpha) \cdot s^2 \cdot \sigma_\alpha^2$$

Če za vrednosti trigonometričnih funkcij *sin* in *cos* privzamemo njuni ekstremni vrednosti, to je 1, dobimo za gornjo zvezo izraz:

$$\sigma_{koo}^2 = \sigma_s^2 + s^2 \cdot \sigma_\alpha^2$$

Za izmerjen kot *α* in izmerjeno dolžino *s* predpostavimo uravnoteženo natančnost, kar pomeni:

$$\sigma_s^2 = s^2 \cdot \sigma_\alpha^2$$

S tem lahko definiramo natančnosti izmerjenih količin (*α, s*) glede na natančnost koordinat točk:

$$\sigma_s^2 = \frac{\sigma_{koo}^2}{2} \;;\; \sigma_\alpha^2 = \frac{\sigma_{koo}^2}{2 \cdot s^2}$$

NATANČNOST KOORDINAT OGLIŠČ IN NATANČNOST POVRŠINE KVADRATA 3.

Končni rezultat so natančnosti izmerjene dolžine σ_s in izmerjene smeri σ_β oziroma kota σ_α

$$\sigma_\alpha = \sqrt{2}\sigma_\beta$$

kjer velja:

$$\sigma_s = \frac{\sigma_{koo}}{\sqrt{2}}$$

$$\sigma_\beta = \frac{\sigma_\alpha}{\sqrt{2}} = \frac{\sigma_{koo}}{2 \cdot s}$$

POVZETEK:

Natančnost dolžine med točkami (mejniki) parcele:

$$\sigma_d = \frac{\sigma_P}{2 \cdot d}$$

Natančnost koordinat točke (mejnika):

$$\sigma_{koo} = \frac{\sigma_d}{\sqrt{2}} \qquad = \frac{\sigma_P}{2\sqrt{2} \cdot d}$$

Natančnost opazovanj (dolžine in smeri) z dane točke na točke (mejnike) parcele:

$$\sigma_s = \frac{\sigma_{koo}}{\sqrt{2}} = \frac{\sigma_d}{2} = \frac{\sigma_P}{2\sqrt{2} \cdot d}$$

$$\sigma_\beta = \frac{\sigma_\alpha}{\sqrt{2}} = \frac{\sigma_{koo}}{2 \cdot s} = \frac{\sigma_d}{2\sqrt{2} \cdot s} = \frac{\sigma_P}{4\sqrt{2} \cdot d \cdot s}$$

NATANČNOST DOLŽINE STRANICE IN NATANČNOST POVRŠINE KVADRATA 4.

Zveza med natančnostjo dolžine stranice med dvema točkama parcele in površino parcele.

Zahtevana natančnost površine parcele je:

$$\sigma_P = 1m^2$$

Potrebno natančnost dolžine stranice prikazuje sosednja slika.

x- os predstavlja velikost računane dolžine (oddaljenost med sosednjima točkama parcele v metrih).

Potrebna natančnost izmerjene dolžine je podana na y- osi v metrih.

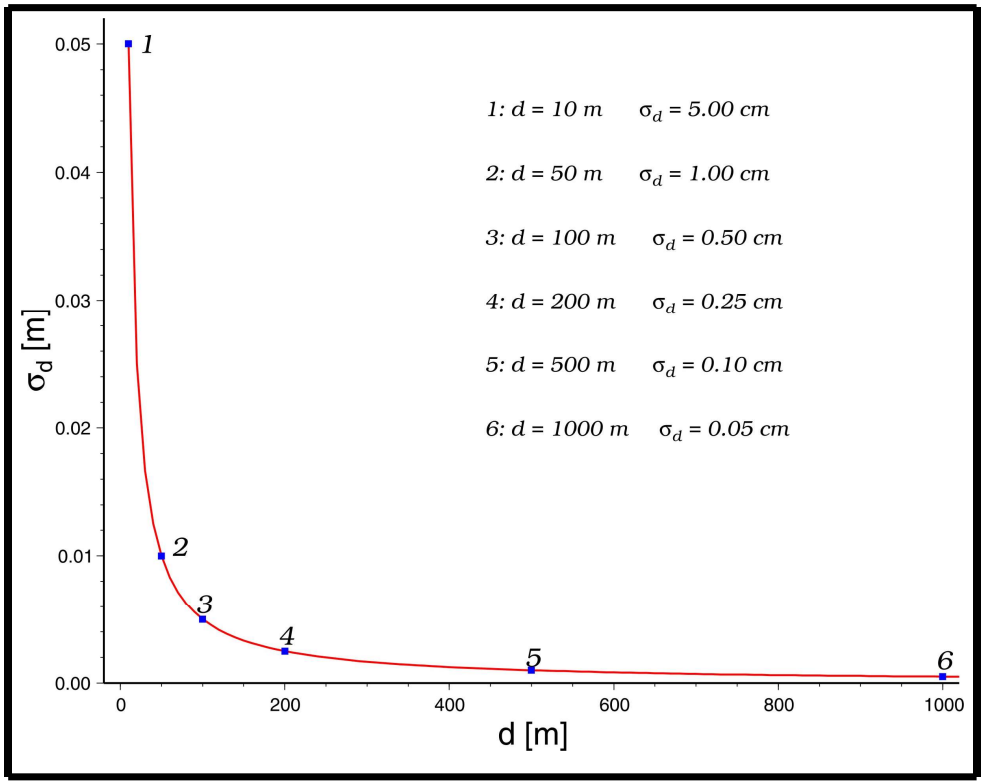

NATANČNOST KOORDINAT IN NATANČNOST POVRŠINE KVADRATA 5.

Zveza med natančnostjo posamezne koordinate oglišča in natančnostjo površine kvadrata.

Natančnost površine parcele je zopet:

$$\sigma_P = 1m^2$$

Potrebna natančnost koordinat je odvisna od razdalje med oglišči kvadrata (dolžine stranice kvadrata).

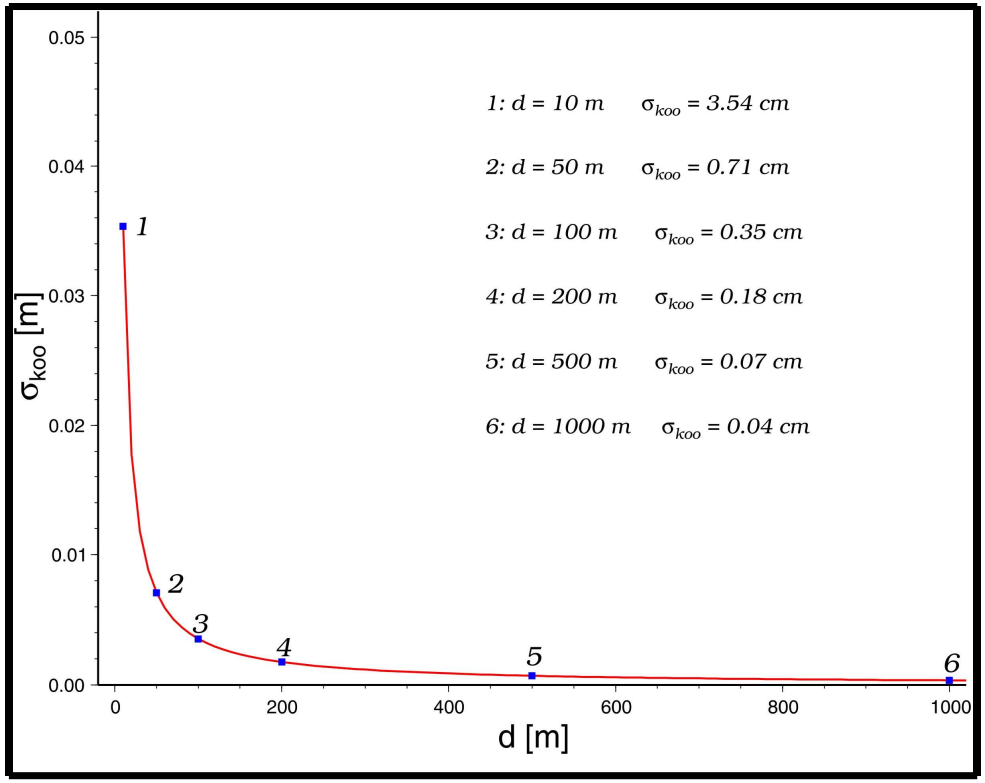

NATANČNOST MERJENIH RAZDALJ IN NATANČNOST POVRŠINE KVADRATA 5.

Potrebna natančnost izmerjene dolžine s **od stojiščne točke do oglišča kvadrata, da zadostimo pogoju potrebne natančnosti površine parcele:**

$$\sigma_P = 1m^2$$

Natančnost izmerjene dolžine je odvisna od te dolžine (x-os v metrih), kjer predpostavimo, da je stojiščna točka oddaljena za dvakratno vrednost dolžine stranice kvadrata.

Potrebna natančnost izmere dolžine s **je podana na y- osi v metrih.**

(+ NASLEDNJA PROSOJNICA)

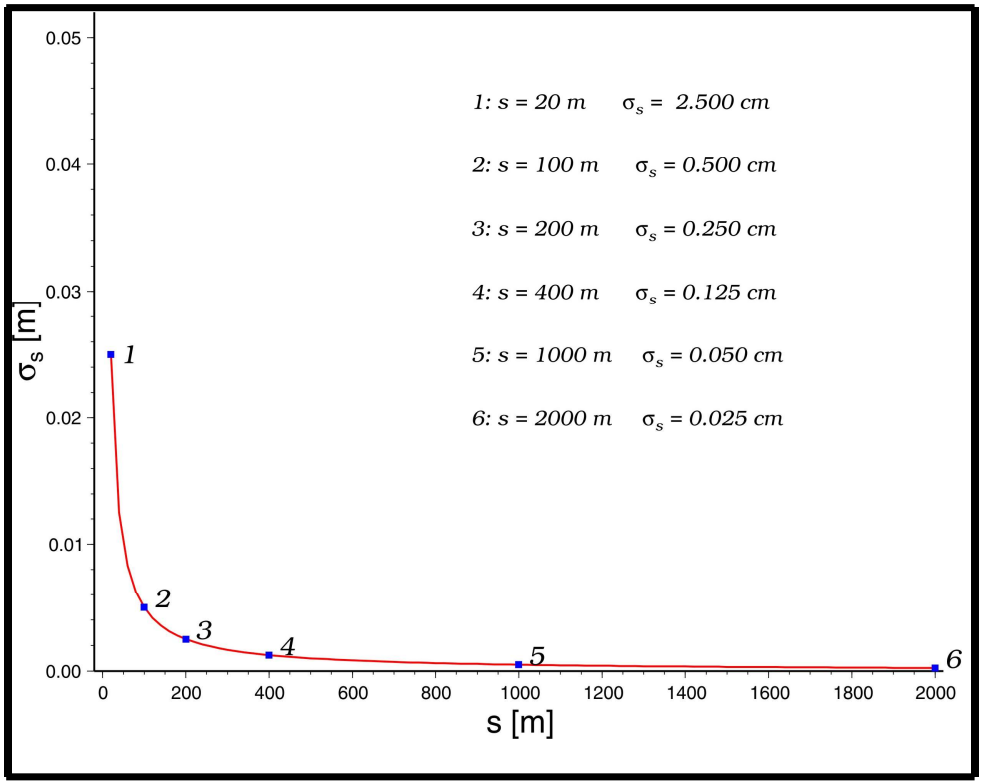

NATANČNOST MERJENIH SMERI IN NATANČNOST POVRŠINE KVADRATA 6.

Potrebna natančnost izmerjene smeri *β* na stojiščni točki proti oglišču parcele, da dosežemo natančnost določitve površine parcele:

$$\sigma_P = 1m^2$$

Natančnost izmerjene smeri je odvisna od oddaljenosti stojiščne točke od posameznega oglišča parcele (x- os v metrih), kjer zopet predpostavimo, da je stojiščna točka oddaljena za približno dvakratno dolžino stranice parcele (kvadrata).

Potrebna natančnost izmerjene smeri je podana na y- osi v sekundah.

(+ PREDHODNA PROSOJNICA)

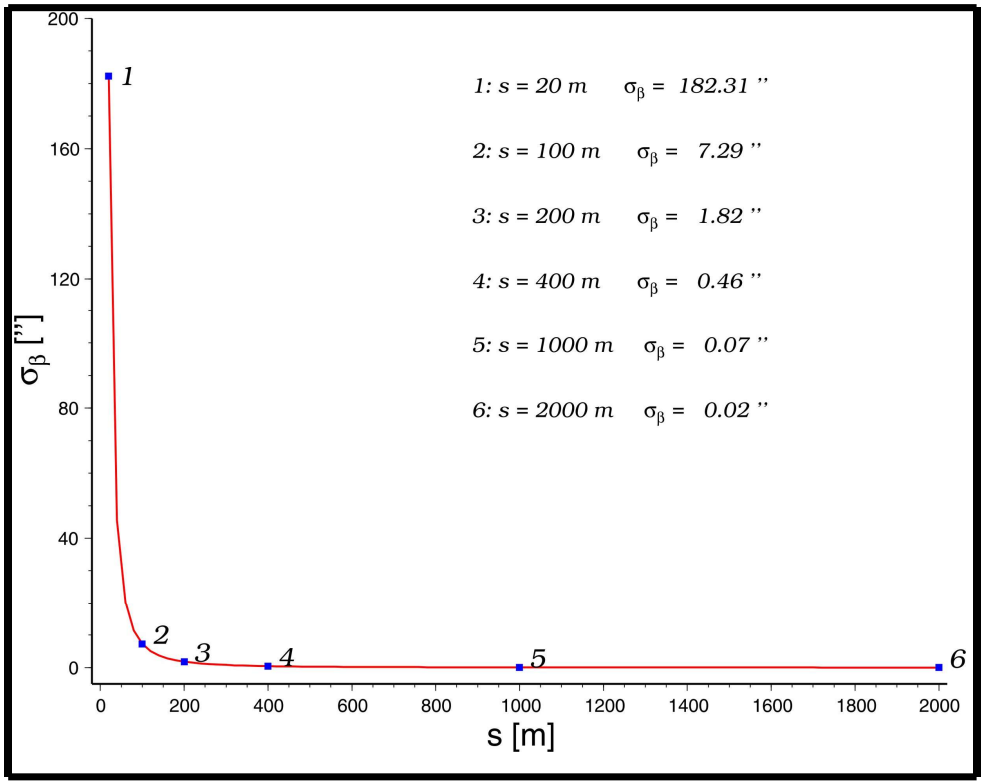

ZAKLJUČEK GLEDE ANALIZE POTREBNE NATANČNOSTI OPAZOVANJ

V praksi je za obsežne matematične modele včasih težko izpolniti predpostavko popolnoma uravnotežene natančnosti opazovanj.

Vzroki so v omejitvi instrumentarija in/ali uporabljenih merskih postopkov.

V takih primerih je potrebno povečati standardni odklon (=zmanjšati natančnost) ene ali več komponent in na ta način upoštevati omejitve uporabljenega instrumentarija ali merskega postopka, standardne odklone ostalih opazovanj pa ustrezno prilagoditi.

V primerih, ko z instrumenti, ki jih imamo na voljo, ne moremo doseči potrebne/zahtevane natančnosti meritev (glede na potrebno natančnost neznank) lahko povečamo formalno natančnost meritev s povečevanjem števila meritev.

Pri tem se postavi vprašanje smiselnosti prevelikega povečanja števila meritev.

Splošno pravilo v geodetski izmeri je, da morajo biti, v primeru meritev raznovrstnih količin, takšnih natančnosti, da zagotavljajo približno enak vpliv na natančnosti neznank.

To pomeni, da morata biti geometrija matematičnega modela in natančnost meritev usklajena.

Na primer v terestrični detajlni geodetski izmeri želimo doseči uravnoteženje vpliva natančnosti kotnih in dolžinskih meritev na natančnost določitve koordinat.

DOVOLJENA ODSTOPANJA OPAZOVANJ

Dovoljeno odstopanje opazovanja je določeno kot največja še sprejemljiva velikost slučajnega pogreška opazovanja.

Slučajne pogreške, ki po velikosti presegajo dovoljena odstopanja obravnavamo kot grobe pogreške.

Z namenom, da bi pridobili rešitev matematičnega modela, ki bo prosta grobih pogreškov, izberemo verjetnost in pripadajoči mnogokratnik standardnega odklona meritev, s katerima določimo mejo med slučajnimi in grobimi pogreški.

V praksi najpogosteje uporabimo stopnjo verjetnosti 99,7 % in pripadajočo vrednost mnogokratnika standardnega odklona 3.

Pod predpostavko normalne porazdelitve opazovanj tako obravnavamo tiste vrednosti meritev, ki se glede na srednjo vrednost meritev μ nahajajo v intervalu $\mu \pm 3\sigma$, kot vrednosti meritev, ki so obremenjena samo s slučajnimi pogreški.

V skladu s tem trdimo, da opazovanje izpolnjuje vnaprej postavljeno zahtevo glede natančnosti t, če je standardni odklon σ opazovanja določen v skladu z:

$3\sigma \leq t$

Za običajne merske postopke v geodeziji so postavljena merila v obliki vrednosti t.

Praviloma so ta merila določena v pravilnikih in tehničnih predpisih.

V stroki je v uporabi je več tehničnih predpisov, odvisno od namena in vrste meritev.

Najbolj podrobno določajo dovoljena odstopanja opazovanj za naloge v geodeziji v inženirstvu t. i. »DIN norme«.

UVOD V STATISTIČNO ANALIZO

Vzorci in statistike

Omenili smo že slučajni vzorec, ki ga sestavlja n neodvisnih identično porazdeljenih opazovanj.

Predstavili smo tudi pojem populacije.

Ko opravimo n neodvisnih opazovanj neke količine pod enakimi pogoji, jih skupno obravnavamo kot slučajni vzorec velikosti n, izbran iz populacije neskončne velikosti.

Iz populacije lahko izberemo več kot en vzorec.

Vzorci v splošnem ne bodo enaki – to je, podatki opazovanj bodo različni od vzorca do vzorca.

Možno je sestaviti nove količine, ki so funkcije opazovanj (slučajnih spremenljivk) $X_1, X_2, ..., X_n$, ki sestavljajo slučajni vzorec velikosti n.

Ker so nove količine funkcije slučajnih spremenljivk so tudi same slučajne spremenljivke, ki imajo svojo lastno porazdelitev verjetnosti.

Te količine imenujemo statistike.

Pomembno vlogo pri ocenjevanju vzorcev, pridobljenih iz normalno porazdeljene populacije, igrajo tudi druge porazdelitve verjetnosti.

Te porazdelitve imenujemo vzorčne porazdelitve.

Med vzorčnimi porazdelitvami sta najpomembnejši χ^2–porazdelitev in Studentova t–porazdelitev.

Najpreprostejša statistika je srednja vrednost vzorca $\bar{X}$:

$$\bar{X} = \frac{X_1 + X_2 + ... + X_n}{n}$$

Če je n –opazovanj $X_1, X_2, ..., X_n$ neodvisnih, identično porazdeljenih slučajnih spremenljivk, vsaka s srednjo vrednostjo μ in varianco σ^2 je srednja vrednost vzorca $\bar{X}$ tudi slučajna spremenljivka, za katero se da dokazati da ima srednjo vrednost μ in varianco $\frac{\sigma^2}{n}$.

Porazdelitev verjetnosti srednje vrednosti vzorca $\bar{X}$ je odvisna od porazdelitve verjetnosti populacije, iz katere je izbran vzorec.

Če je populacija normalno porazdeljena, je tudi srednja vrednost vzorca $\bar{X}$ normalno porazdeljena.

Ker so opazovanja različna od vzorca do vzorca, so tudi srednje vrednosti vzorcev $\bar{X}$ različne od vzorca do vzorca, v skladu s porazdelitvijo verjetnosti $\bar{X}$.

Pod predpostavko, da je normalna porazdelitev osnovni verjetnostni model vseh geodetskih opazovanj, se omejimo na vzorčenje normalno porazdeljene populacije.

Čeprav je srednja vrednost vzorca $\bar{X}$ normalno porazdeljena, tega ne moremo predpostaviti za vse druge statistike, ki jih lahko sestavimo iz slučajnega vzorca, pridobljenega iz normalno porazdeljene populacije.

χ^2 PORAZDELITEV

Če je $Z_1, Z_2, ..., Z_n$ n – neodvisnih slučajnih spremenljivk, vsaka s standardno normalno porazdelitvijo ($\mu = 0,\ \sigma = 1$), se lahko pokaže da je funkcija gostote verjetnosti statistike Y , določene z vsoto kvadratov standardno normalno porazdeljenih slučajnih spremenljivk Z_i :

$$Y = Z_1^2 + Z_2^2 + ... + Z_n^2$$

dana z izrazom:

$$f(y) = \begin{cases} \dfrac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} y^{\left(\frac{n}{2}\right)-1} e^{-\frac{y}{2}};\ \text{za } y > 0 \\ 0;\ \text{za } y \le 0 \end{cases} \qquad (*)$$

Kjer je $\Gamma(\alpha)$ gama funkcija, definirana z integralom:

$$\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-n} d\alpha;\ \text{za } \alpha > 0$$

Za Y rečemo, da ima χ^2 porazdelitev z n –prostostnimi stopnjami.

Parameter porazdelitve je število prostostnih stopenj n , srednja vrednost μ_y in varianca σ_y^2 pa sta:

$$\mu_y = E(Y) = n$$

$$\sigma_y{}^2 = E\left(\left(Y - \mu_y\right)^2\right) = 2n$$

Za majhne vrednosti n je funkcija gostote verjetnosti $f(y)$ χ^2 porazdelitve zelo asimetrična.

Za večje vrednosti n se njena oblika približuje simetrični obliki funkcije gostote verjetnosti normalne porazdelitve s srednjo vrednostjo $\mu = n$ in varianco $\sigma^2 = 2n$.

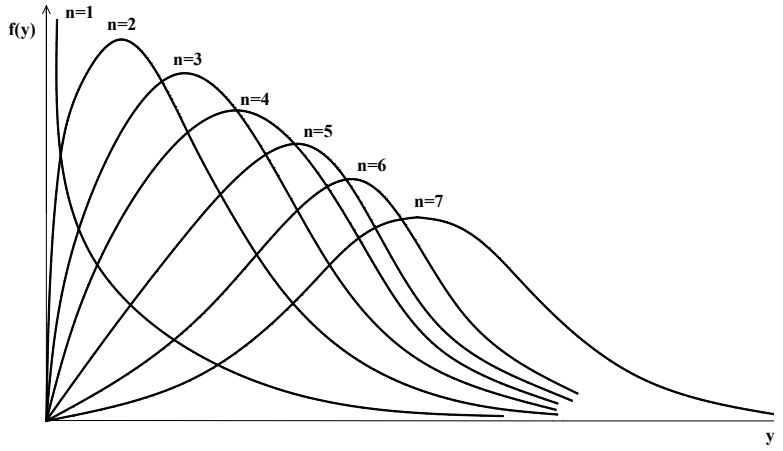

Če ima slučajna spremenljivka Y χ^2–porazdelitev z n prostostnimi stopnjami je njena porazdelitvena funkcija $F(y)$ dana z izrazom:

$$F(y) = P(Y \le y) = \int_0^y f(u)du$$

kjer je $f(u)$ funkcija gostote verjetnosti χ^2–porazdelitve.

Če vemo, da je $F(y)$ verjetnost, je ob določeni vrednosti verjetnosti, ki jo vnaprej določimo $\rightarrow F(y) = p$, odgovarjajoča vrednost za y t. i. p – ti fraktil (centil, decil, kvartil,…).

Za χ^2–porazdelitev z n prostostnimi stopnjami je p – ti centil predstavljen s simbolom $\chi^2_{p,n}$. Vrednosti za $\chi^2_{p,n}$ so dane v tabelah.

Integral $\Gamma(\alpha) = \int_0^\infty n^{\alpha-1}e^{-n}d\alpha;$ za $\alpha > 0$ lahko rešimo analitično za $\alpha \in \mathbf{N}$ (α – naravno število).

Rešimo ga s pomočjo izrazov, ki jih dobimo z rešitvijo gornjega integrala, za $\forall$ $p \in \mathbf{N}$, p – naravno število ($p = 1, 2, \ldots$):

$$\Gamma(p) = (p-1)! = (p-1)(p-2)\ldots(2)(1); \quad \Gamma\left(\frac{2p+1}{2}\right) = \frac{1\cdot 3\cdot 5\cdot \ldots \cdot (2p-1)\sqrt{\pi}}{2^p}$$

STUDENTOVA t – PORAZDELITEV

Če je Z slučajna spremenljivka s standardno normalno porazdelitvijo in Y neodvisna slučajna spremenljivka, ki ima χ^2–porazdelitev z n prostostnimi stopnjami, ima slučajna spremenljivka T:

$$T = \frac{Z}{\sqrt{\frac{Y}{n}}}$$

t–porazdelitev z n prostostnimi stopnjami.

Funkcija gostote verjetnosti t–porazdelitve je:

$$f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi n}\cdot\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{t^2}{n}\right)^{-\frac{(n+1)}{2}} \text{; za } -\infty < t < \infty$$

Parameter t–porazdelitve je n, kjer je $n \in \mathbf{N}$.

Srednja vrednost μ_t in varianca σ_t^2 slučajne spremenljivke T sta:

$$\mu_t = E(T) = 0; \text{ za } n > 1$$

$$\sigma_t{}^2 = E\left((T-\mu_t)^2\right) = \frac{n}{n-2}; \text{ za } n > 2$$

Porazdelitev je simetrična okrog vrednosti $t = 0$.

Ko n narašča, se t–porazdelitev približuje standardni normalni porazdelitvi.

Za velike vrednosti n, lahko uporabimo standardno normalno porazdelitev za približek t–porazdelitve.

Porazdelitvena funkcija t–porazdelitve je:

$$F(t) = P(T \le t) = \int_{-\infty}^{t} f(u)\cdot du$$

Kjer je $f(u)$ funkcija gostote verjetnosti t–porazdelitve (*).

Če je vrednost za verjetnost postavljena na določeno vrednost p $\left(F(t) = P(T \le t) = p\right)$, vrednost za t, za določeni p označimo s $t_{p,n}$, ki predstavlja t. i. p – ti centil, fraktil t– porazdelitve z n prostostnimi stopnjami.

Vrednosti $t_{p,n}$ so dane v tabelah.

SKUPNE STATISTIKE VZORCA

Omenili smo, da je mogoče sestaviti nove slučajne spremenljivke, ki so funkcije slučajnih spremenljivk $X_1, X_2, ..., X_n$, ki sestavljajo slučajni vzorec in jih imenujemo statistike.

Skupne statistike, ki jih uporabljamo za določitev »sredine« vzorca:

1. Srednja vrednost vzorca $\overline{X}$ je definirana kot povprečje vseh vrednosti v vzorcu (nekorelirana opazovanja enake natančnosti):

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}$$

$$\overline{X} = X_a + \frac{\sum_{i=1}^{n} (X_i - X_a)}{n}$$ (X_a je poljubna konstanta)

Druga enačba je primernejša za ročno računanje.

2. Mediana vzorca: Če vrednosti v slučajnem vzorcu razvrstimo po velikosti, je vrednost za mediano vzorca:

- vrednost v sredini urejene množice, če je n – liho število in
- povprečje dveh srednjih vrednosti, če je n – sodo število.

Skupne statistike, ki jih uporabljamo kot mero razpršenosti ali disperzije vzorca:

1. Območje vzorca

To je razlika med najmanjšo in največjo vrednostjo v vzorcu. Včasih jo imenujemo tudi celotna razpršenost vzorca.

2. Odklon srednje vrednosti vzorca

Odklon elementa vzorca oziroma opazovanja X_i je definiran kot razlika $\left(X_i - \bar{X}\right)$, kjer je $\bar{X}$ srednja vrednost vzorca.

Odklon srednje vrednosti vzorca je povprečje absolutnih vrednosti odklonov vseh komponent vzorca:

Odklon srednje vrednosti vzorca $= \frac{1}{n}\sum_{i=1}^{n}\left|\left(X_i - \bar{X}\right)\right|$

3. Varianca vzorca S_x^2

Varianco vzorca lahko razumemo tudi kot varianco posameznega opazovanja (elementa) v vzorcu.

Določena je glede na to ali je srednja vrednost populacije μ znana ali ne oziroma ali je znana le srednja vrednost vzorca $\bar{X}$:

- če μ ni znana: $S_x^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2$

- če je μ znana: $S_x^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$

$\bar{X}$ je srednja vrednost vzorca. Zakaj uporabljamo v imenovalcu $(n-1)$ namesto n bomo videli kasneje.

4. Standardni odklon vzorca S_x

Definiran je kot pozitivni kvadratni koren variance vzorca S^2:

$$S_x = +\sqrt{S_x^2}$$

5. Kovarianca vzorca S_{xy}

Če je slučajni vzorec izbran iz dvorazsežne populacije, tako da z opazovanji vedno pridobivamo pare opazovanj, je mogoče določiti kovarianco vzorca.

Če slučajni vzorec sestavljajo pari opazovanj (X_1, Y_1), (X_2, Y_2),…,(X_n, Y_n) je kovarianca vzorca definirana kot:

$$S_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})$$

kjer je $\bar{X}$ srednja vrednost spremenljivke X in $\bar{Y}$ srednja vrednost spremenljivke Y.

6. Varianca $S_{\overline{x}}^2$ in standardni odklon $S_{\overline{x}}$ srednje vrednosti vzorca $\overline{X}$

Varianca srednje vrednosti vzorca: $S_{\overline{x}}^2 = \frac{S_x^2}{n}$

Standardni odklon srednje vrednosti vzorca: $S_{\overline{x}} = \frac{S_x}{\sqrt{n}}$

Standardni odklon S_x in varianca S_x^2 posameznega opazovanja X sta merili kakovosti opravljenih meritev.

Standardni odklon $S_{\overline{x}}$ in varianca $S_{\overline{x}}^2$ srednje vrednosti vzorca $\overline{X}$ sta meri kakovosti srednje vrednosti meritev.

Komentar gornjih izrazov:

S povečevanjem števila meritev zmanjšujemo standardni odklon srednje vrednosti meritev.
Pri tem pa moramo upoštevati tudi omejitve glede točnosti in natančnosti merskega instrumenta in pribora.
Z neprimernim instrumentom in priborom pridobimo pri velikem številu meritev, kljub formalno visoki natančnosti, nenatančen rezultat, ki bo tudi nepravilen (posledično ne bo najbolj točen). Obstaja torej neko razumno končno število opazovanj, ki je odvisno od vrste meritev, s katerim natančnosti, pravilnosti in točnosti srednje vrednosti opazovanj ne moremo več bistveno izboljšati.
V splošnem s ponavljanjem opazovanj, ki niso dovolj kakovostna za odkrivanje sistematičnih pogreškov, ne pridobimo ničesar.
Znatno povečanje števila meritev zato znatno ne zmanjša kakovosti srednje vrednosti opravljenih meritev.
Iz enačbe za izračun standardnega odklona si lahko vnaprej izračunamo, kolikokrat moramo ponoviti opazovanje, da dosežemo želeno natančnost (odgovor poišči sam, glej tudi poglavje o potrebni natančnosti opazovanj).

Skupna varianca in skupni standardni odklon

V geodeziji je pogosto v uporabi tudi t. i. skupna varianca in skupni standardni odklon, ki ju izračunamo:

$$S^2 = \frac{\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2 + \sum_{i=1}^{n}\left(Y_i - \bar{Y}\right)^2 + \sum_{i=1}^{n}\left(Z_i - \bar{Z}\right)^2}{(n_x - 1) + (n_y - 1) + (n_z - 1)}$$

Skupni standardni odklon je zopet:

$$S = +\sqrt{S^2}$$

Skupna varianca je primerna za izračun standardnih odklonov več merjenih količin X, Y in Z, ki so izmerjene različno mnogokrat oziroma n_x, n_y in n_z – krat.

Skupno število opazovanj je v tem primeru $n = n_x + n_y + n_z$ in število neznank (srednjih vrednosti) $u = 3$.

Če je srednja (prava) vrednost katere od količin znana, je število u ustrezno zmanjšano.

Standardni odklon zaradi zaokroževanja odčitkov meritev

V primeru zaokroževanja odčitkov na določeno decimalno mesto (vrednost) izračunamo standardni odklon meritev zaradi zaokroževanja:

$$S_a = \frac{a}{\sqrt{12}} = 0.29a$$

kjer je a enota ([cm], [mm],…), ki smo jo zaokroževali
V primeru na mm zaokroženih vrednosti, odčitanih na cm razdelbi je $a = 1\ \mathrm{cm}$
(Pri tem moramo vedeti, da je dejanski standardni odklon meritev lahko drugačen zaradi drugih vplivov).

Nekorelirana opazovanja različne natančnosti

V primeru različnih uteži p_i opazovanj X_i se gornji izrazi nekoliko spremenijo.

Splošna aritmetična sredina: $\bar{X} = \dfrac{\sum_{i=1}^{n} p_i X_i}{\sum_{i=1}^{n} p_i}$

Varianca opazovanja z utežjo $p_i = 1$: $S_{X_i}^2 = \dfrac{\sum_{i=1}^{n} \left(X_i - \bar{X} \right)^2}{n-1}$

Varianca opazovanja z utežjo p_i: $S_{X_i}^2 = \dfrac{S_{X_i}^2}{p_i}$

Varianca splošne aritmetične sredine: $S_{\bar{X}}^2 = \dfrac{S_{X_i}^2}{\sum_{i=1}^{n} p_i}$

Standardni odkloni gornjih količin so enaki pozitivnim korenom odgovarjajočih varianc.
V gornjih enačbah seštevamo elemente od 1 do n, kjer je n število uteženih opazovanj, ki ni nujno enako številu vseh opazovanj.
Standardni odklon splošne aritmetične sredine je praviloma manjši od standardnega odklona posameznih opazovanj.
Lahko pa se pojavi primer, ko to ni slučaj – v takem primeru je primerneje uporabiti navadno aritmetično sredino.
V primeru koreliranih opazovanj pa vedno uporabljamo za določitev standardnega odklona zakon o prenosu varianc in kovarianc.

OCENA SREDINE

Statistika, ki jo uporabljamo za oceno vrednosti parametra porazdelitve verjetnosti, imenujemo točkovna cenilka ali cenilka.

Ker je cenilka statistika, je slučajna spremenljivka.

Numerično vrednost cenilke, določene iz konkretnega vzorca, imenujemo ocena.

Če je parameter porazdelitve verjetnosti predstavljen z Θ, je cenilka tega parametra predstavljena z oznako $\hat{\Theta}$.

Če je parameter, ki nas zanima srednja vrednost porazdelitve verjetnosti (populacije) μ je cenilka za srednjo vrednost $\hat{\mu}$.

Kot cenilke srednje vrednosti populacije je mogoče uporabiti več statistik, kot so na primer: srednja vrednost vzorca, mediana vzorca,…

Izbira določene statistike je odvisna od želenih lastnostih izbrane statistike, kot so na primer: nepristranskost, skladnost, učinkovitost, zadostnost pa tudi enostavnost za izračun.

Izbira primerne statistike zahteva kar nekaj diskusije.

Dve lastnosti cenilk predstavimo podrobneje.

Nepristranskost

Če je $\hat{\Theta}$ cenilka parametra Θ porazdelitve verjetnosti, tako da je pričakovana vrednost cenilke $\hat{\Theta}$ enaka Θ, to je, da velja:

$$E(\hat{\Theta}) = \Theta$$

tedaj trdimo, da je $\hat{\Theta}$ nepristranska cenilka za Θ.

Skladnost: Če je $\hat{\Theta}$ nepristranska cenilka parametra Θ in se varianca cenilke $\hat{\Theta}$ približuje vrednosti 0, ko se velikost vzorca povečuje, trdimo, da je cenilka $\hat{\Theta}$ skladna s Θ.

Najbolj splošna cenilka srednje vrednosti porazdelitve (populacije) μ je srednja vrednost vzorca $\overline{X}$.

Srednja vrednost vzorca je določena z:

$$\overline{X} = \frac{1}{n}X_1 + \frac{1}{n}X_2 + ... + \frac{1}{n}X_n$$

Če vemo, da je $E(X_1) = E(X_2) = E(X_3) = ... = E(X_n) = \mu$ in $\sigma_{x_1}^2 = \sigma_{x_2}^2 = ... = \sigma_{x_n}^2 = \sigma^2$ dobimo sredino in varianco srednje vrednosti vzorca $\overline{X}$:

$$E(\overline{X}) = \frac{1}{n}\mu + \frac{1}{n}\mu + ... + \frac{1}{n}\mu = n\left(\frac{1}{n}\right)\mu = \mu$$

$$\sigma_{\overline{x}}{}^2 = \left(\frac{1}{n}\right)^2\sigma^2 + \left(\frac{1}{n}\right)^2\sigma^2 + ... + \left(\frac{1}{n}\right)^2\sigma^2 = n\left(\frac{1}{n}\right)^2\sigma^2 = \frac{\sigma^2}{n}$$

$\overline{X}$ je tako nepristranska cenilka za srednjo vrednost porazdelitve μ, kjer je $E(\overline{X}) = \mu$.

Ker se varianca $\overline{X}$ bliža 0, ko n narašča v neskončnost, je $\overline{X}$ skladna cenilka za srednjo vrednost porazdelitve verjetnosti μ.

Če je slučajni vzorec izbran iz normalno porazdeljene populacije je tudi $\overline{X}$ normalno porazdeljena.

OCENA VARIANCE

Najbolj splošna cenilka variance porazdelitve σ^2 je varianca vzorca S^2 (še enkrat):

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2$$

Za dokaz, da je S^2 nepristranska cenilka za σ^2 je potrebno pokazati, da velja:

$$\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2 = \sum_{i=1}^{n}\left(X_i - \mu\right)^2 - n\left(\bar{X} - \mu\right)^2 \rightarrow \text{dokaži sam!} \qquad \text{(A)}$$

(uporabi $\rightarrow \left(X_i - \bar{X}\right) = (X_i - \mu) - (\bar{X} - \mu)$)

Če določimo pričakovano vrednost za enačbo (A):

$$E\left(\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2\right) = \sum_{i=1}^{n} E\left(\left(X_i - \mu\right)^2\right) - n \cdot E\left(\left(\bar{X} - \mu\right)^2\right)$$

In če vemo, da je: $E\left(\left(X_i - \mu\right)^2\right) = \sigma^2$ ter vemo, da je $E\left(\left(\bar{X} - \mu\right)^2\right) = \frac{\sigma^2}{n}$

imamo:

$$E\left(\sum_{i=1}^{n}\left(X_i-\bar{X}\right)^2\right)=n\sigma^2-n\left(\frac{\sigma^2}{n}\right)=\left(n-1\right)\sigma^2$$

iz česar sledi, da je :

$$E(S^2)=E\left(\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\bar{X}\right)^2\right)=\sigma^2$$

kar kaže, da je S^2 nepristranska cenilka za σ^2.

To je razlog, da imamo v izrazu za izračun variance vzorca v imenovalcu člen $\left(n-1\right)$.

Če bi vsoto kvadratov odstopanj od srednje vrednosti vzorca $\left(X_i-\bar{X}\right)$ delili z n namesto z $\left(n-1\right)$ bi bila cenilka pristranska.

Če je populacija iz katere smo izbrali vzorec normalno porazdeljena, se lahko dokaže, da je S^2 tudi skladna cenilka za σ^2 in da je S^2 porazdeljena po χ^2 porazdelitvi.

Oziroma statistika Y:

$$Y=\frac{n-1}{\sigma^2}S^2$$

Bi imela χ^2 porazdelitev z $\left(n-1\right)$ prostostnimi stopnjami.

INTERVALI ZAUPANJA – orodje za analizo natančnosti majhnega vzorca (majhnega števila meritev)

Uporaba standardnega odklona, kot merila natančnosti je smiselna pri velikem številu meritev.
Kot meja za veliko število meritev je običajno vzeto število meritev, ki je večje od 30.
V večini primerov pa imamo na voljo število meritev posamezne količine, ki je manjše od 30.

Izkaže se, da se v praksi veliko uporabljajo tudi standardni odkloni, izračunani za majhno število meritev.
Tako pridobljeni rezultati so lahko zavajajoči.

Dejstvo je, da se močno pogrešene meritve (prisotni grobi in sistematični pogreški) kažejo kot močno razpršena meritve, ki imajo posledično tudi velike standardne odklone.
Lahko pa, kljub prisotnim napakam v merskem postopku, ob nepravilnem delovanju merskega instrumenta,… slučajno pridobimo kakovostne meritve in posledično tudi izračunane standardne odklone, ki so nerealno majhni → zavajajoči rezultati.

Veliko boljša kot uporaba standardnih odklonov za vrednotenje natančnosti in točnosti meritev, je zato uporaba intervalov zaupanja, kar še posebej velja za majhno število meritev.
V praksi se intervali zaupanja sicer redko uporabljajo, ker je izračun in tolmačenje intervalov zaupanja ni najbolj enostavno.

V primeru statističnega analiziranja podatkov meritev je za vrednosti, ki ležijo v bližini mejnih vrednosti intervalov zaupanja potrebno ugotoviti razloge za to.
Ni modro le preprosto privzeti izračunane vrednosti kot sprejemljive (ali kot nesprejemljive) in na njihovi osnovi podajati zaključke.

INTERVALI ZAUPANJA SREDNJE VREDNOSTI

Če slučajni vzorec, velikosti n izberemo iz normalno porazdeljene populacije s srednjo vrednostjo porazdelitve (populacije) μ in varianco σ^2, je srednja vrednost vzorca $\bar{X}$ normalno porazdeljena s srednjo vrednostjo μ in varianco $\frac{\sigma^2}{n}$.

Slučajna spremenljivka:

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

ima tako standardno normalno porazdelitev s srednjo vrednostjo enako 0 in varianco enako 1. Od tod sledi, da je:

$$P\left(-z < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < z \right) = \underbrace{\Phi(z) - \Phi(-z)}_{\substack{\text{prištejemo in odštejemo } \Phi(z) \\ \Phi(z)+\Phi(z)-\Phi(z)+\Phi(-z)=2\Phi(z)-1 \\ \underbrace{\Phi(z)+\Phi(-z)=1}_{\text{simetrija porazdelitve}}}} = 2\Phi(z) - 1$$

Ker je $\Phi(z)$ vrednost porazdelitvene funkcije standardne normalne porazdelitve za vrednost z.

Če preuredimo izraz v oklepaju, dobimo:

$$P\left(\bar{X} - \frac{z\sigma}{\sqrt{n}} < \mu < \bar{X} + \frac{z\sigma}{\sqrt{n}} \right) = 2\Phi(z) - 1$$

kar pomeni, da je verjetnost, da srednja vrednost populacije μ leži med $\bar{X} - \frac{z\sigma}{\sqrt{n}}$ in $\bar{X} + \frac{z\sigma}{\sqrt{n}}$ enaka $2\Phi(z) - 1$.

Ko imamo za $\overline{X}$ opravka s konkretno numerično vrednostjo $\overline{x}$, imenujemo interval z mejnima vrednostma $\left(\overline{x}-\frac{z\sigma}{\sqrt{n}},\overline{x}+\frac{z\sigma}{\sqrt{n}}\right)$ interval zaupanja in $2\Phi(z)-1$ stopnjo zaupanja.

Ocenjevanje, kjer za določeni parameter populacije μ, σ, ρ,... navedemo interval zaupanja je intervalsko ocenjevanje parametrov.

Primer:

Imamo srednjo vrednost $\overline{X}=110{,}155\ \mathrm{m}$, določeno na osnovi 30 neodvisnih meritev dolžine.

Če je standardni odklon populacije (vsakega opazovanja) znan in znaša $\sigma=0{,}025\mathrm{m}$ določi 95% interval zaupanja za srednjo vrednost populacije μ.

Za: $2\Phi\left(z\right)-1=0{,}95$ imamo $\Phi\left(z\right)=\frac{1{,}95}{2}=0{,}975$

Iz tabel standardne normalne porazdelitve pridobimo za $\Phi\left(z\right)=0{,}975$ vrednost za $z=1{,}96$.

Mejni vrednosti intervala zaupanja sta tako:

$$\overline{x}-\frac{z\sigma}{\sqrt{n}}=110{,}155-\frac{1{,}96\cdot(0{,}025)}{\sqrt{30}}=110{,}146\ \mathrm{m}$$

$$\overline{x}+\frac{z\sigma}{\sqrt{n}}=110{,}155+\frac{1{,}96\cdot(0{,}025)}{\sqrt{30}}=110{,}164\ \mathrm{m}$$

S stopnjo zaupanja $0{,}95$ trdimo, da srednja vrednost populacije μ leži v intervalu med $110{,}146\ \mathrm{m}$ in $110{,}164\ \mathrm{m}$.

V gornjem primeru je bil standardni odklon σ populacije znan.

Običajno pa je σ neznan in ga je treba oceniti. Običajno ga ocenimo s standardnim odklonom vzorca S.

V tem primeru moramo namesto slučajne spremenljivke Z:

$$Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

uporabiti slučajno spremenljivko T:

$$T = \frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}}.$$

Dokazati se da, da ima slučajna spremenljivka T, t–porazdelitev z $(n-1)$ prostostnimi stopnjami.

Uporabimo izraz:

$$P\left(\overline{X} - \frac{t \cdot S}{\sqrt{n}} < \mu < \overline{X} + \frac{t \cdot S}{\sqrt{n}}\right) = 2F(t) - 1$$

Ko imamo za srednjo vrednost vzorca $\overline{X}$ numerično vrednost $\overline{x}$ in za standardno deviacijo vzorca S numerično vrednost s je, ob stopnji zaupanja $2F(t)-1$ interval zaupanja za srednjo vrednost populacije μ določen z mejama $\left(\overline{x} - \frac{t \cdot S}{\sqrt{n}}, \overline{x} + \frac{t \cdot S}{\sqrt{n}}\right)$.

Primer:

Za $2F(t)-1=0.95$ je $F(t)=\frac{1,95}{2}=0,975$

Standardni odklon, določen iz vzorca opazovanj je enak $s=0,027$

Število prostostnih stopenj je $n-1=30-1=29$

Iz tabel t porazdelitve dobimo, $t_{0,975,29}=2,045$

Tako sta mejni vrednosti intervala zaupanja:

$$\overline{x}-\frac{t\cdot s}{\sqrt{n}}=110,155-\frac{2,045\cdot 0,027}{\sqrt{30}}=110,145\ \text{m}$$

$$\overline{x}+\frac{t\cdot s}{\sqrt{n}}=110,155+\frac{2,045\cdot 0,027}{\sqrt{30}}=110,165\ \text{m}$$

Zopet torej trdimo, da s stopnjo zaupanja $0,95$, leži vrednost μ v intervalu med $110,145\ \text{m}$ in $110,165\ \text{m}$.

Ko smo določali intervale zaupanja za srednjo vrednost μ populacije (porazdelitve), smo predpostavljali, da smo slučajni vzorec izbrali iz normalno porazdeljene populacije.

Če populacija ni normalno porazdeljena vzorec pa je velik, bo imela srednja vrednost vzorca $\overline{X}$ porazdelitev, ki bo približno normalna in bosta enačbi, ki smo ju uporabili za izračun mejnih vrednosti intervala zaupanja za praktične potrebe še vedno veljavni.

Omenili smo tudi, da z naraščanjem velikosti vzorca lahko t–porazdelitev dovolj dobro aproksimiramo s standardizirano normalno porazdelitvijo.

INTERVALI ZAUPANJA ZA VARIANCO

Ko slučajni vzorec, velikosti n, izberemo iz normalno porazdeljene populacije ima slučajna spremenljivka Y:

$$Y = \frac{n-1}{\sigma^2} S^2$$

χ^2 porazdelitev z $(n-1)$ prostostnimi stopnjami, ki ga lahko uporabimo za določitev intervala zaupanja za varianco populacije σ^2. Imamo:

$$P\left(\chi^2_{a,n-1} < \frac{(n-1)\cdot S^2}{\sigma^2} < \chi^2_{b,n-1} \right) = b - a$$

Kjer sta $\chi^2_{a,n-1}$ in $\chi^2_{b,n-1}$ a – ti in b – ti centil, χ^2 porazdelitve z $(n-1)$ prostostnimi stopnjami.

Iz gornjega sledi:

$$P\left(\frac{(n-1)\cdot S^2}{\chi^2_{b,n-1}} < \sigma^2 < \frac{(n-1)\cdot S^2}{\chi^2_{a,n-1}} \right) = b - a$$

Ko imamo opravka z numeričnimi vrednostmi s^2 za S^2 sta mejni vrednosti intervala zaupanja $\left(\frac{(n-1)\cdot s^2}{\chi^2_{b,n-1}}, \frac{(n-1)\cdot s^2}{\chi^2_{a,n-1}} \right)$ in stopnja zaupanja $(b-a)$.

Ko sestavljamo interval zaupanja za σ^2 je primerno, če izberemo taka centila a in b, da velja $a + b = 1$.

Če nas zanima interval zaupanja za standardni odklon σ, privzamemo za mejni vrednosti intervala zaupanja za standardni odklon σ pozitivna korena mejnih vrednosti za interval zaupanja za varianco σ^2.

Primer:

Varianca vzorca S^2 je v gornjem primeru določena iz neodvisnih meritev dolžine in znaša $s^2 = 0,000729\ \mathrm{m}^2$.

Določi 95% interval zaupanja za varianco σ^2 in standardni odklon σ populacije.

Za $b - a = 0,95$ in $a + b = 1$, imamo $a = 0,025$ in $b = 0,975$.

Število prostostnih stopenj je $n - 1 = 19$.

Iz tabel χ^2 porazdelitve pridobimo:

$$\chi^2_{0,025,29} = 16,047$$

$$\chi^2_{0,975,29} = 45,722$$

Mejni vrednosti intervala zaupanja za stopnjo zaupanja $0,95$ sta:

$$\frac{(n-1)\cdot S^2}{\chi^2_{0,975,29}} = \frac{29 \cdot 0,000729}{45,722} = 0,000462\ \mathrm{m}^2$$

$$\frac{(n-1)\cdot S^2}{\chi^2_{0,025,29}} = \frac{29 \cdot 0,000729}{16,047} = 0,001317\ \mathrm{m}^2$$

S stopnjo zaupanja $0,95$ trdimo, da σ^2 leži med $0,000462\ \mathrm{m}^2$ in $0,001317\ \mathrm{m}^2$.

Odgovarjajoči mejni vrednosti intervala zaupanja za standardni odklon σ pa sta $0,022\ \mathrm{m}$ in $0,036\ \mathrm{m}$.

STATISTIČNE HIPOTEZE IN STATISTIČNI TESTI

Statistični testi so pripomoček pri sprejemanju odločitev.

Izkušnje lahko včasih nadomestijo testiranje, vendar je za vsakdanjo inženirsko prakso pomembna uporaba statističnih testov.

V praksi uporabljamo parametrične teste *.

Tipične situacije, ki zahtevajo testiranje hipotez s pomočjo statističnih testov:

- so specifikacije instrumenta (točnost instrumenta) ustrezna za določeno delo,
- koliko girusov ali ponovitev meritev je potrebno opraviti,
- je instrument A enako kakovosten kot instrument B,
- ali so opazovanja obremenjena s sistematičnimi in/ali grobimi pogreški,
- če pri določenem opazovanju naredim določeno napako, kako napaka vpliva na celoten matematični model,
- je izbrana metoda meritev ustrezna,
- so opravljene meritve, obdelava meritev in izravnava meritev ustrezne kakovosti glede na predhodno določene specifikacije oz. zahteve.

Po pridobitvi vsake rešitve problema izravnave naj bi za ovrednotenje rezultatov uporabili tudi statistični test.

Izid statističnega testa je pokazatelj ali so opravljene meritve in model pravilna.

Pri tem pa moramo vedeti, da statistični test ničesar absolutno ne dokazuje.

---

* Neparametrična statistika je veja statistike, ki ne temelji samo na parametriziranih družinah verjetnostnih porazdelitev (pogosta primera parametrov sta povprečje in varianca). Neparametrična statistika temelji bodisi na tem, da je obravnavna spremenljivke brez porazdelitve verjetnosti ali pa ima določeno porazdelitev verjetnosti, vendar z nedoločenimi parametri porazdelitve verjetnosti. Neparametrična statistika vključuje deskriptivno statistiko in sprejemanje zaključkov/odločitev na osnovi statističnega sklepanja. Neparametrični testi se pogosto uporabljajo, kadar se ne moremo zanesti na predpostavke o parametrih porazdelitve verjetnosti.

Na podlagi vzorca, ki je edina informacija o populaciji, iz katere smo pridobili vzorec, želimo ugotoviti, kakšne so lastnosti porazdelitve verjetnosti populacije.

Običajen postopek pri tem je, da postavimo trditev o porazdelitvi verjetnosti populacije, nato pa na podlagi vzorca, pridobljenega iz populacije, ugotovimo ali ta trditev drži ali ne.

Trditev, ki jo postavimo o porazdelitvi verjetnosti populacije, se imenuje statistična hipoteza (statistična domneva).

Če hipoteza natanko (v celoti) določa porazdelitev verjetnosti je to enostavna hipoteza, vsaka drugačna hipoteza je sestavljena hipoteza.

Enostavna hipoteza je hipoteza, pri kateri uporabimo vse parametre, ki natanko opisujejo porazdelitev verjetnosti (npr.: ob dani srednji vrednosti μ ugotavljamo kakšna je varianca σ^2 normalne porazdelitve).

Sestavljena hipoteza je hipoteza, ki ni enostavna (npr.: nimamo znanih parametrov porazdelitve in/ali ne vemo za kakšno porazdelitev gre).

Za vsako hipotezo H_0 obstaja nasprotna hipoteza H_1. H_0 običajno imenujemo ničelna hipoteza in H_1 alternativna hipoteza.

Hipotezo preizkusimo z vzorcem, pridobljenim iz populacije, tako da izračunamo vrednosti določenih vzorčnih statistik in se nato odločimo ali hipotezo na osnovi vrednosti statistik zavrnemo ali ne zavrnemo. S testiranjem hipotez dejansko preverjamo, ali lahko zavrnemo ničelno hipotezo.

Statistiko, ki jo uporabimo za preizkušanje hipotez imenujemo testna statistika.

Kot že omenjeno, odločitve na podlagi testiranja statistične hipoteze H_0 niso nezmotljive, ker temeljijo na vzorcu pridobljenem iz populacije in ne na celotni populaciji.

Sestavimo čim bolj enostavne hipoteze, ki jih je enostavno razložiti.

S pomočjo testiranja hipotez lahko torej iz podatkov enega vzorca sklepamo na značilnosti populacije, lahko pa tudi primerjamo med seboj dva ali več vzorcev.

Vloga testiranje hipotez je v praksi nekoliko drugačna kot v statistični teoriji.

Pri statističnem preizkušanju hipotez lahko nastopijo naslednji štirje slučaji:

1. H_0 ne zavrnemo, ko je H_0 pravilna
2. H_0 zavrnemo, ko je H_0 pravilna → napaka I. vrste
3. H_0 ne zavrnemo, ko je H_0 napačna → napaka II. vrste
4. H_0 zavrnemo, ko je H_0 napačna

		ODLOČITEV NA OSNOVI STATISTIČNEGA TESTA	
		H_0 NI ZAVRNJENA	H_0 JE ZAVRNJENA
RESNIČNA TRDITEV	H_0 PRAVILNA	PRAVILNA ODLOČITEV	NAPAKA I. VRSTE
	H_0 NAPAČNA	NAPAKA II. VRSTE	PRAVILNA ODLOČITEV

Če se pojavi 1. ali 4. slučaj nismo napravili napake.

Če se pojavi 2. slučaj → zavrnemo pravilno hipotezo, smo napravili napako I. vrste.

Ko nastopi 3. slučaj → ne zavrnemo napačne hipoteze smo napravili napako II.vrste.

Obe napaki sta seveda nezaželeni. Ker se jima ni mogoče izogniti, si prizadevamo, da bosta čim manj verjetni.

Navadno ravnamo tako, da predpišemo: verjetnost za napako I. vrste naj ne presega primerne verjetnosti α.

Območje napake I. vrste α je definirano kot verjetnost zavrnitve H_0, ko je ta pravilna:

$\alpha = P$ (zavrnitev H_0, ko je H_0 pravilna)

Ko za α postavimo določeno številko vrednost (verjetnost), imenujemo α stopnja značilnosti testa.

Kako veliko vrednost za α predpišemo, je odvisno od okoliščin: čim hujše bi bile posledice napačne odločitve, tem manjšo vrednost za α izberemo.

Najpogostejše stopnje značilnosti so 0,05, 0,01, 0,001, ker v praksi še vedno večinoma uporabljamo tabelirane vrednosti porazdelitev verjetnosti.

Ko s statističnim testom ne moremo sprejeti postavljene hipoteze, so razlogi praviloma v:

1. Funkcionalni model

Predstavljajo ga enačbe in konstante, ki so uporabljene v izravnavi.

Enačbe so napačne ali le približne – za rešitev konkretne naloge niso dovolj točne.

Enačbe funkcionalnega modela naj bi bile najmanj eno stopnjo bolj točne (eksaktne, pravilne) od točnosti opazovanj.

2. Stohastični model

Vhodne variance oz. uteži so napačne, napačna je korelacija med opazovanji, zanemarjena je koreliranost opazovanj ali izračunanih količin.

3. Opazovanja

V opazovanjih so prisotni grobi pogreški.

Napačno, ali ne dovolj kakovostno upoštevani pogoji pri meritvah, kar vodi do sistematičnih pogreškov opazovanj.

4. Izračun

Napaka v računalniškem programu, numerična nestabilnost računalniških programov – uporabljeni so algoritmi, ki ne ustrezajo zahtevam naloge.

Kopičenje pogreškov zaokroževanja.

Vzrok za težave s sprejetjem hipoteze so lahko tudi kombinacije dveh ali več naštetih razlogov.

Uporaba statističnih testov je pri velikem številu podatkov lahko zahtevna naloga.

Nekateri statistični testi npr. zahtevajo celotno kovariančno matriko neznank, ki je lahko zelo velika in nerodna za uporabo.

Nekatere naloge pa niso zelo zahtevne in naj bi bile opravljene vedno, ko želimo pridobiti dobro oceno meritev ali rezultatov izravnave.

TEST SREDINE PORAZDELITVE VERJETNOSTI

Ta test opravimo, ko želimo na podlagi vzorca ugotoviti, kakšna naj bi bila srednja vrednost porazdelitve verjetnosti (populacije).

Postavimo trditev, da je srednja vrednost populacije μ enaka μ_0.

Hipotezo, da velja $\mu = \mu_0$ nato testiramo z vzorcem velikosti n in srednjo vrednostjo vzorca $\bar{X}$ kot testno statistiko.

Zapišemo hipotezi:

$H_0 : \mu = \mu_0$

$H_1 : \mu \neq \mu_0$

Predpostavimo, da smo vzorec pridobili iz normalno porazdeljene populacije $\rightarrow$ $\bar{X}$ je normalno porazdeljena.

Pod predpostavko, da je $\mu = \mu_0$, lahko iz enačbe:

$$P\left(-z < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < z \right) = 2\Phi(z) - 1$$

in ob predpostavki, da je standardni odklon populacije σ znan, zapišemo izraz:

$$P\left((\mu_0 - c) < \bar{X} < (\mu_0 + c) \right) = 2\Phi(z) - 1$$

kjer je $c = \frac{z \cdot \sigma}{\sqrt{n}}$.

Če pa standardni odklon populacije σ ni znan, lahko na osnovi enačbe:

$$P\left(\bar{X}-\frac{t\cdot S}{\sqrt{n}}<\mu<\bar{X}+\frac{t\cdot S}{\sqrt{n}}\right)=2F(t)-1$$

zapišemo izraz:

$$P\left(\left(\mu_0-c\right)<\bar{X}<\left(\mu_0+c\right)\right)=2F(t)-1$$

kjer je:

$$c=\frac{t\cdot S}{\sqrt{n}}.$$

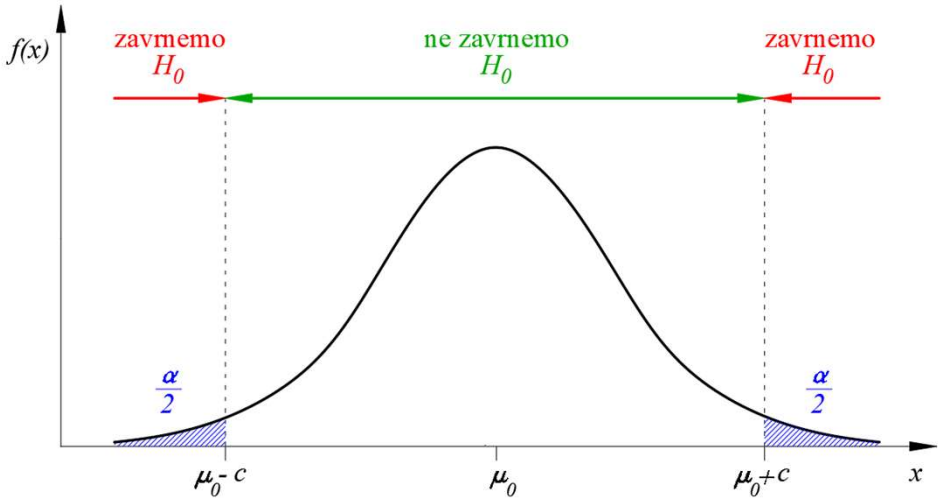

Ničelne hipoteze H_0 ne zavrnemo, če $\bar{x}$ (numerična vrednost za srednjo vrednost vzorca, izračunana iz vrednosti elementov vzorca $\bar{X}$), leži med μ_0-c in μ_0+c; sicer H_0 zavrnemo.

Področja zavrnitve in nezavrnitve H_0 so navedena na sliki.

Če je α verjetnost, da je H_0 zavrnjena, ko je pravilna, je $(1-\alpha)$ verjetnost, da H_0 ni zavrnjena, ko je pravilna.

Iz tega sledi:

$$1-\alpha=2\Phi(z)-1;\quad \text{za znano } \sigma$$
$$=2F(t)-1;\quad \text{za neznano } \sigma$$

Za $\Phi(z)$ in $F(t)$ imamo tako:

$\Phi(z)=1-\frac{\alpha}{2}$ oziroma $F(t)=1-\frac{\alpha}{2}$

Iz tabele standardne normalne porazdelitve dobimo vrednost za z, iz tabele t–porazdelitve pa vrednost za t.

V tabeli t–porazdelitve so tabelirane vrednosti za $t=t_{p,\,n-1}$, kjer je $p=F(t)$.

Primer:

Kot smo izmerili 30 krat.

Vsa opazovanja so neodvisna in opravljena z enako natančnostjo.

30 vrednosti opazovanj tako sestavlja slučajni vzorec velikosti 30.

Srednja vrednost vzorca $\overline{X}$ in standardni odklon vzorca S sta izračunana iz opazovanj (elementov vzorca):

$\overline{x} = 62^\circ 42' 24,6'', \ \ s = 2.5''.$

S 5% stopnjo značilnosti testiraj hipotezo, da je srednja vrednost populacije opazovanj μ enaka $62^\circ 42' 26,0''$ proti alternativni hipotezi, da μ ni enaka $62^\circ 42' 26,0''$.

Obe hipotezi zapišemo:

$H_0 : \mu_0 = 62^\circ 42' 26,0''$

$H_1 : \mu_0 \neq 62^\circ 42' 26,0''$

Za 5% stopnjo značilnosti je $\alpha = 0,05$.

Ker standardnega odklona populacije σ ne poznamo, imamo pa na voljo standardni odklon vzorca ($s = 2,5''$), vemo, da se srednja vrednost vzorca $\overline{X}$ porazdeljuje po t–porazdelitvi.

Imamo torej $p = F(t) = 1 - \frac{\alpha}{2} = 0,975$

Število prostostnih stopenj porazdelitve verjetnosti je $n - 1 = 30 - 1 = 29$

Iz tabele t–porazdelitve pridobimo za $t = t_{0,975,29}$ vrednost $2,042$.

Imamo:

$$c = \frac{t \cdot S}{\sqrt{n}} = \frac{2,042 \cdot 2,5''}{\sqrt{30}} = 0,9''$$

ter tako:

$$\mu_0 - c = 62^\circ 42' 26,0'' - 0.9'' = 62^\circ 42' 25,1''$$

$$\mu_0 + c = 62^\circ 42' 26,0'' + 0.9'' = 62^\circ 42' 26,9''$$

Ker $\overline{x} = 62^\circ 42' 24,6''$ ne leži med $(\mu_0 - c)$ in $(\mu_0 + c)$, hipotezo, da je $\mu_0 = 62^\circ 42' 26,0''$ zavrnemo s 5% stopnjo značilnosti.

TEST VARIANCE PORAZDELITVE VERJETNOSTI

Poleg srednje vrednosti populacije μ nas običajno zanima tudi varianca populacije σ^2.

Spet imamo na voljo vzorec, pridobljen iz normalno porazdeljene populacije.

Sedaj torej testiramo ničelno hipotezo H_0, da je varianca populacije enaka σ^2, proti alternativni hipotezi H_1, da ni enaka σ^2.

Kot testno statistiko uporabimo varianco vzorca S^2.

Omenili smo, da se statistika $\frac{(n-1)S^2}{\sigma^2}$ porazdeljuje s χ^2–porazdelitvijo z $(n-1)$ prostostnimi stopnjami.

Sestavimo lahko izraz:

$$P\left(\chi^2_{a,n-1} < \frac{(n-1)\cdot S^2}{\sigma^2} < \chi^2_{b,n-1}\right) = b - a$$

iz katerega sledi:

$$P\left(\frac{\chi^2_{a,n-1}\cdot\sigma^2}{n-1} < S^2 < \frac{\chi^2_{b,n-1}\cdot\sigma^2}{n-1}\right) = b - a$$

H_0 ne zavrnemo, če s^2 leži med: $\frac{\chi^2_{b,n-1}\cdot\sigma^2}{n-1}$ in $\frac{\chi^2_{a,n-1}\cdot\sigma^2}{n-1}$, sicer H_0 zavrnemo.

Področja zavrnitve in nezavrnitve H_0 so na sosednji sliki.

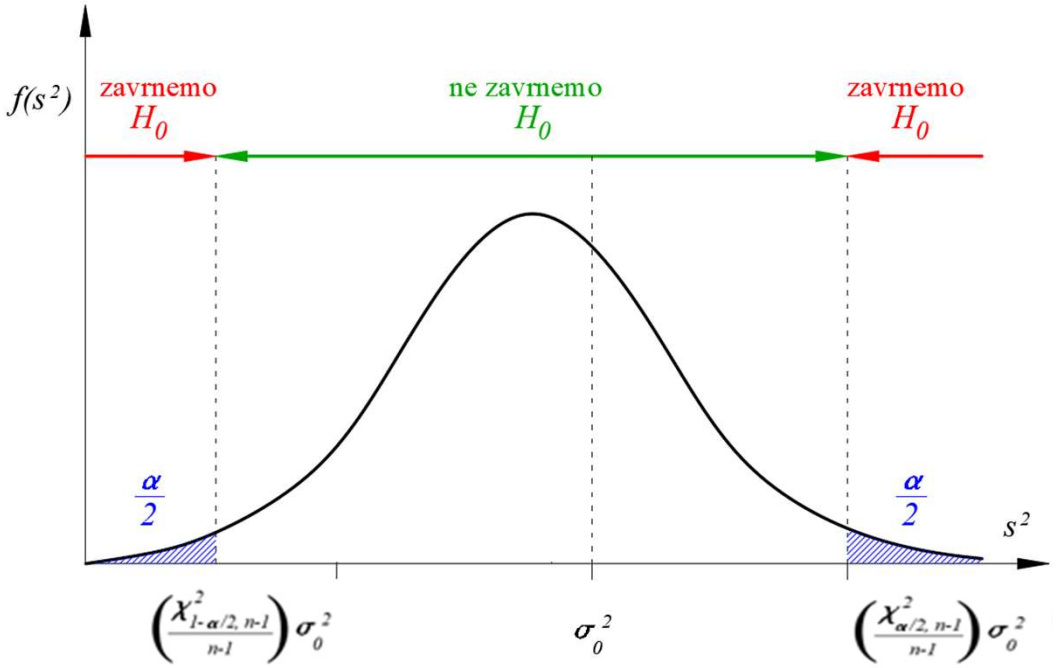

Še enkrat, $(1-\alpha)$ je verjetnost, da H_0 ni zavrnjena, ko je pravilna.

Velja:

- $(1-\alpha)=b-a$.

- izberemo takšna centila a in b, da velja $a+b=1$

Imamo torej:

$$a=\frac{\alpha}{2}$$

$$b=1-\frac{\alpha}{2}$$

Opisani postopek lahko uporabimo tudi za testiranje standardnega odklona σ.

Primer:

Nadaljevanje prejšnjega primera.

S 5% stopnjo značilnosti testiraj hipotezo, da je σ - standardni odklon populacije - enak $2,0"$ proti alternativni hipotezi, da σ ni enak $2,0"$.

Obe trditvi zapišemo v obliki ničelne in alternativne hipoteze:

$H_0 : \sigma = 2,0"$

$H_1 : \sigma \neq 2,0"$

Standardni odklon vzorca (glej prejšnji primer) $s = 2,5"$. Število prostostnih stopenj je $n-1=29$.

Stopnja značilnosti testa $\alpha = 0,05$. Od tod sledi, da je $a = \frac{\alpha}{2} = 0,025$ in $b = 1 - \frac{\alpha}{2} = 0,975$.

Iz tabele χ^2 porazdelitve pridobimo vrednosti $\chi^2_{0,025,29} = 45.722$ in $\chi^2_{0,975,29} = 16.047$ ter dobimo:

$$\frac{\chi^2_{0,025,29} \cdot \sigma^2}{n-1} = \frac{45.722 \cdot (2,0")^2}{29} = 6,31(")^2$$

$$\frac{\chi^2_{0,975,9} \cdot \sigma^2}{n-1} = \frac{16,047 \cdot (2,0")^2}{29} = 2,21(")^2$$

$s^2 = (2,5")^2 = 6,25(")^2 \rightarrow s^2$ leži med $2,21$ in 6.31

Ničelne hipoteze H_0, da je standardni odklon populacije $\sigma = 2,0"$ ne zavrnemo s 5% stopnjo značilnosti.

NORMALNA PORAZDELITEV DVEH SKUPNO PORAZDELJENIH SLUČAJNIH SPREMENLJIVK

Porazdelitev verjetnosti dveh ali več skupno porazdeljenih slučajnih spremenljivk smo omenjali v povezavi s korelacijo in kovarianco.

Porazdelitev verjetnosti dveh slučajnih spremenljivk se pojavi, ko imamo opravka s slučajnimi spremenljivkami, ki nastopajo v parih.

Za geodezijo so pomembni pari slučajnih spremenljivk pari koordinat – ravninske koordinate $(x,y),(n,e),(y,x)$, geografske geodetske in geografske astronomske koordinate $(\varphi,\lambda),(\Phi,\Lambda)$ posamezne točke.

Med porazdelitvami verjetnosti dveh skupno porazdeljenih slučajnih spremenljivk je posebej pomembna normalna porazdelitev.

Funkcija gostote verjetnosti dveh skupno normalno porazdeljenih slučajnih spremenljivk X in Y je dana z izrazom:

$$f(x,y)=\frac{1}{2\pi\ \sigma_x\sigma_y\sqrt{1-\rho^2}}e^{-\left\{\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_x}{\sigma_x}\right)^2-2\rho\left(\frac{x-\mu_x}{\sigma_x}\right)\left(\frac{y-\mu_y}{\sigma_y}\right)+\left(\frac{y-\mu_y}{\sigma_y}\right)^2\right]\right\}}$$

kjer so:

μ_x in σ_x srednja vrednost in standardni odklon slučajne spremenljivke X,

μ_y in σ_y srednja vrednost in standardni odklon slučajne spremenljivke Y,

ρ korelacijski koeficient med X in Y $\rightarrow \rho=\frac{\sigma_{xy}}{\sigma_x\sigma_y}$.

Funkcija gostote verjetnosti $f(x,y)$ dveh skupno normalno porazdeljenih slučajnih spremenljivk ima obliko zvonaste ploskve nad x,y – koordinatno ravnino, s sredino za X v μ_x in za Y v μ_y.

T. i. delni funkciji gostote verjetnosti dveh skupno normalno porazdeljenih slučajnih spremenljivk X in Y sta:

$$f(x)=\frac{1}{\sigma_x\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{x-\mu_x}{\sigma_x}\right)^2}$$

$$f(y)=\frac{1}{\sigma_y\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{y-\mu_y}{\sigma_y}\right)^2}$$

ki sta običajni funkciji gostote verjetnosti za posamezno normalno porazdeljeno slučajno spremenljivko.

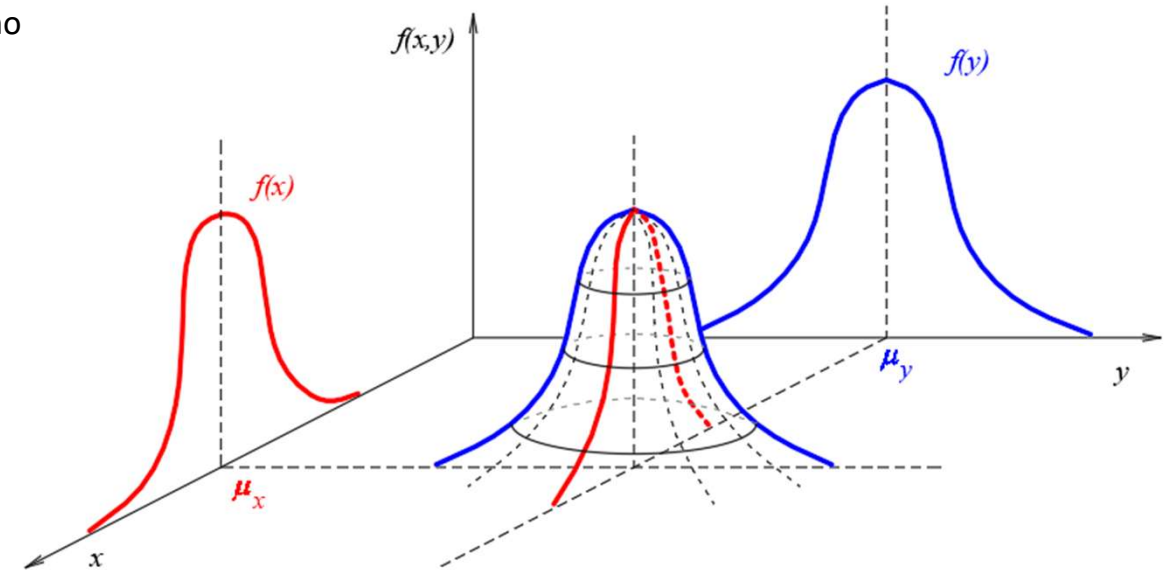

Če presekamo ploskev funkcije gostote verjetnosti dveh skupno normalno porazdeljenih slučajnih spremenljivk $f(x,y)$ z ravnino, vzporedno ravnini x, y, dobimo kot presečno krivuljo elipso.

Enačbo te elipse pridobimo z izenačitvijo izraza za $f(x,y)$ s konstanto k, ki predstavlja oddaljenost (višino) presečne ravnine od (nad) ravnine x, y.

Enačba presečne elipse je oblike:

$$\left(\frac{x-\mu_x}{\sigma_x}\right)^2 - 2\rho\left(\frac{x-\mu_x}{\sigma_x}\right)\left(\frac{y-\mu_y}{\sigma_y}\right) + \left(\frac{y-\mu_y}{\sigma_y}\right)^2 = \left(1-\rho^2\right)c^2$$

V gornji enačbi nastopa druga konstanta c^2, ki je odvisna od konstante-oddaljenosti k.

Konstanta c^2 je obratno sorazmerna z oddaljenostjo k in je dana z izrazom:

$$c^2 = \ln\frac{1}{\left[4\pi^2 k^2 \sigma_x^2 \sigma_y^2 \left(1-\rho^2\right)\right]}$$

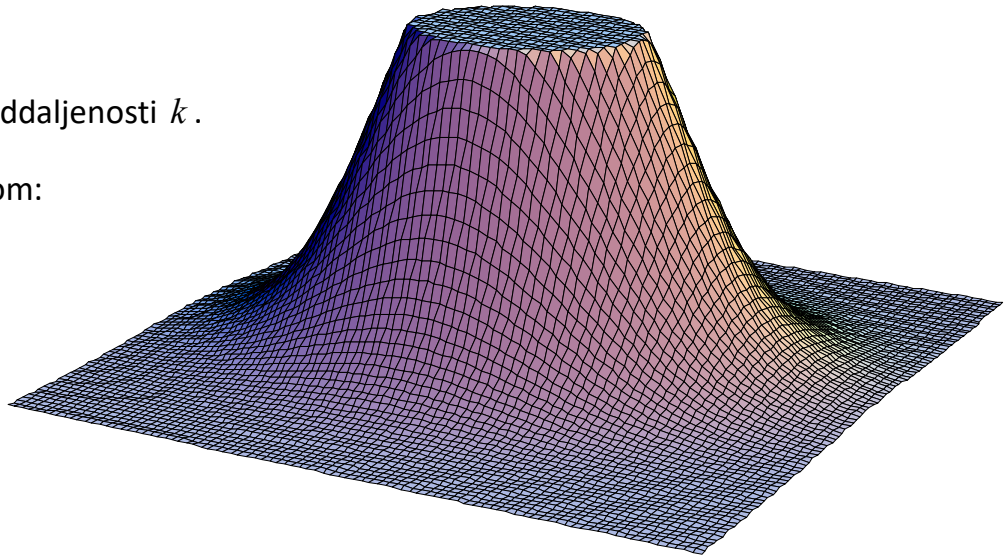

ELIPSE POGREŠKOV (NAPAK)

Če nas zanimata samo komponenti slučajnih pogreškov para koordinat x in y lahko postavimo vrednosti za μ_x in za μ_y, vrednost 0.

S tem funkcijo gostote verjetnosti $f(x,y)$ premaknemo tako, da je njeno središče (vrh) v izhodišču koordinatnega sistema.

S tem se poenostavi izraz za funkcijo gostote verjetnosti $f(x,y)$, kot tudi izraz za presečno elipso med funkcijo gostote verjetnosti $f(x,y)$ in ravnino, vzporedno z ravnino x,y.

Enačba presečne elipse je v tem primeru:

$$\left(\frac{x}{\sigma_x}\right)^2 - 2\rho\left(\frac{x}{\sigma_x}\right)\left(\frac{y}{\sigma_y}\right) + \left(\frac{y}{\sigma_y}\right)^2 = \left(1-\rho^2\right)\cdot c^2$$

Ta enačba predstavlja družino elips pogreškov, postavljenih s središčem v izhodišče x,y koordinatnega sistema.

Za $c=1$ predstavlja gornja enačba t. i. <u>standardno elipso pogreškov</u>.

Elipsa pogreškov je dvorazsežni ekvivalent enorazsežnega intervala zaupanja.

Za dano porazdelitev verjetnosti se je širina intervala zaupanja povečevala, ko se je povečevala stopnja zaupanja.

Enakovredno sedaj velja, da se elipsa pogreškov, za dano porazdelitev verjetnosti, povečuje, ko se povečuje stopnja zaupanja.

Oblika in orientacija standardnih elips pogreškov v odvisnosti od vrednosti parametrov $\sigma_x, \sigma_y, \rho_{xy}$.

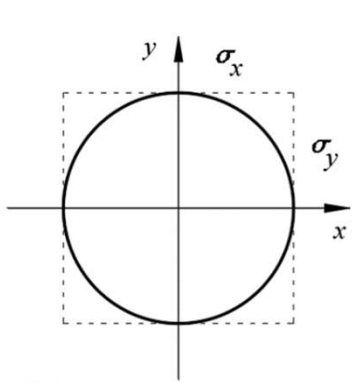

(a) $\sigma_x = \sigma_y$, $\rho_{xy} = 0.$

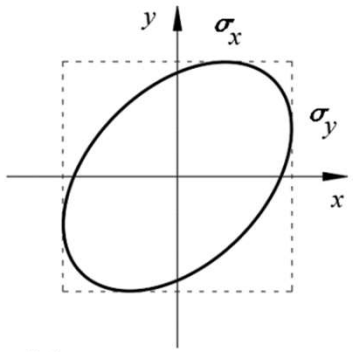

(b) $\sigma_x = \sigma_y$, $\rho_{xy} = 0{,}5.$

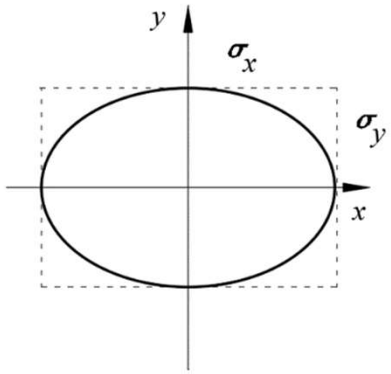

(c) $\sigma_x > \sigma_y$, $\rho_{xy} = 0.$

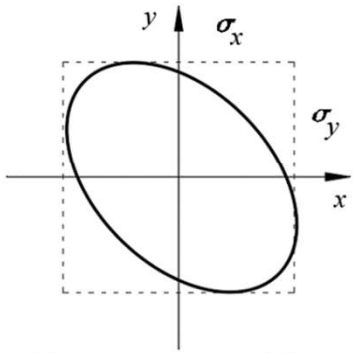

(d) $\sigma_x = \sigma_y$, $\rho_{xy} = -0{,}5.$

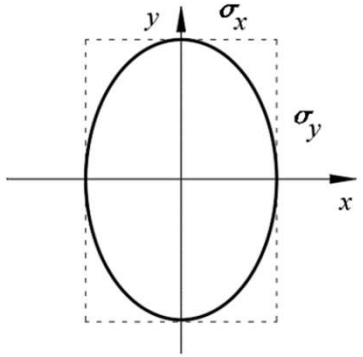

(e) $\sigma_x < \sigma_y$, $\rho_{xy} = 0.$

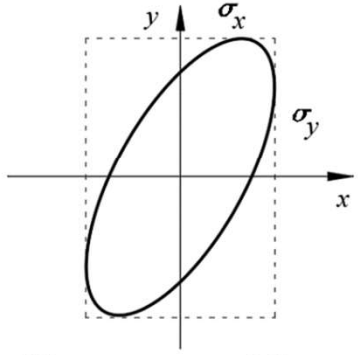

(f) $\sigma_x < \sigma_y$, $\rho_{xy} = 0{,}9.$

Oblika in orientacija standardnih elips pogreškov v odvisnosti od vrednosti parametrov $\sigma_x, \sigma_y, \rho_{xy}$.

$\sigma_x = 1,\ \sigma_y = 2,\ \rho = -0.2$

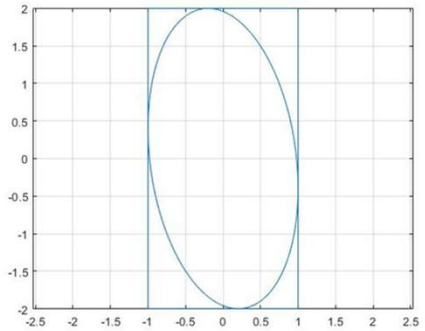

$\sigma_x = 1,\ \sigma_y = 2,\ \rho = -0.5$

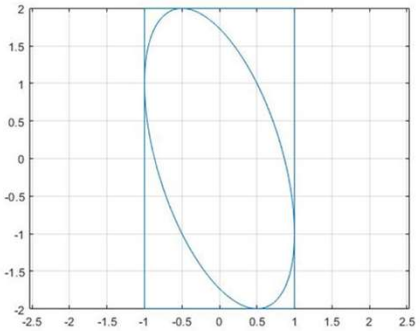

$\sigma_x = 1,\ \sigma_y = 2,\ \rho = -0.8$

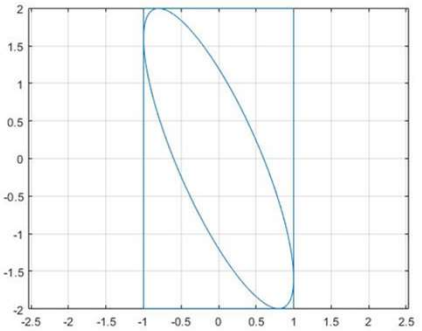

$\sigma_x = 1,\ \sigma_y = 2,\ \rho = 0.3$

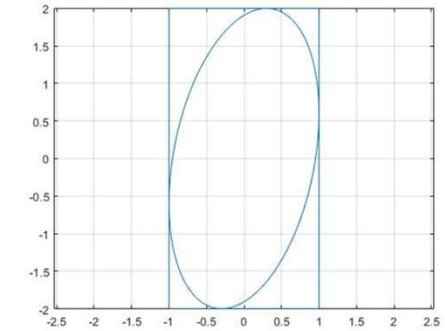

$\sigma_x = 1,\ \sigma_y = 2,\ \rho = 0.99$

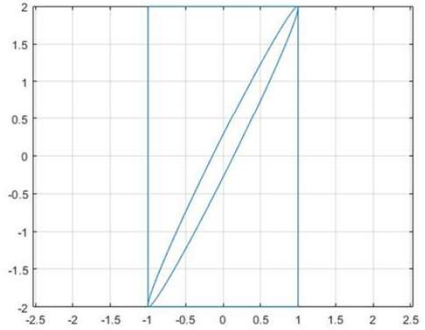

$\sigma_x = 1,\ \sigma_y = 1,\ \rho = 0.999$

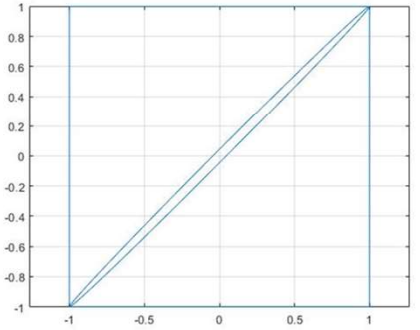

$\sigma_x = 2,\ \sigma_y = 1,\ \rho = 0.999$

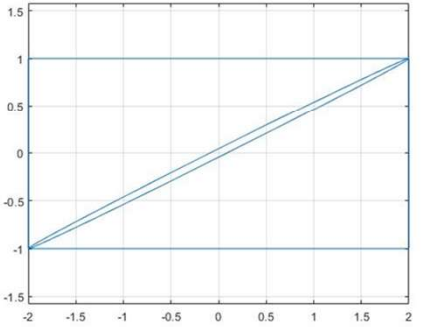

Standardna elipsa pogreškov

Standardna elipsa pogreškov je tista, pri kateri je vrednost konstante $c = 1$.

Velikost in oblika standardne elipse pogreškov določajo parametri $\sigma_x, \sigma_y, \rho_{xy}$ $\left(\sigma_{xy}\right)$.

Standardna elipsa pogreškov je včrtana pravokotniku, velikosti $2\sigma_x \times 2\sigma_y$.

Glavni osi elipse x' in y' v splošnem ne sovpadata s koordinatnima osema x in y.

Glavna os elipse x' je proti pozitivni smeri osi x zasukana za kot θ.

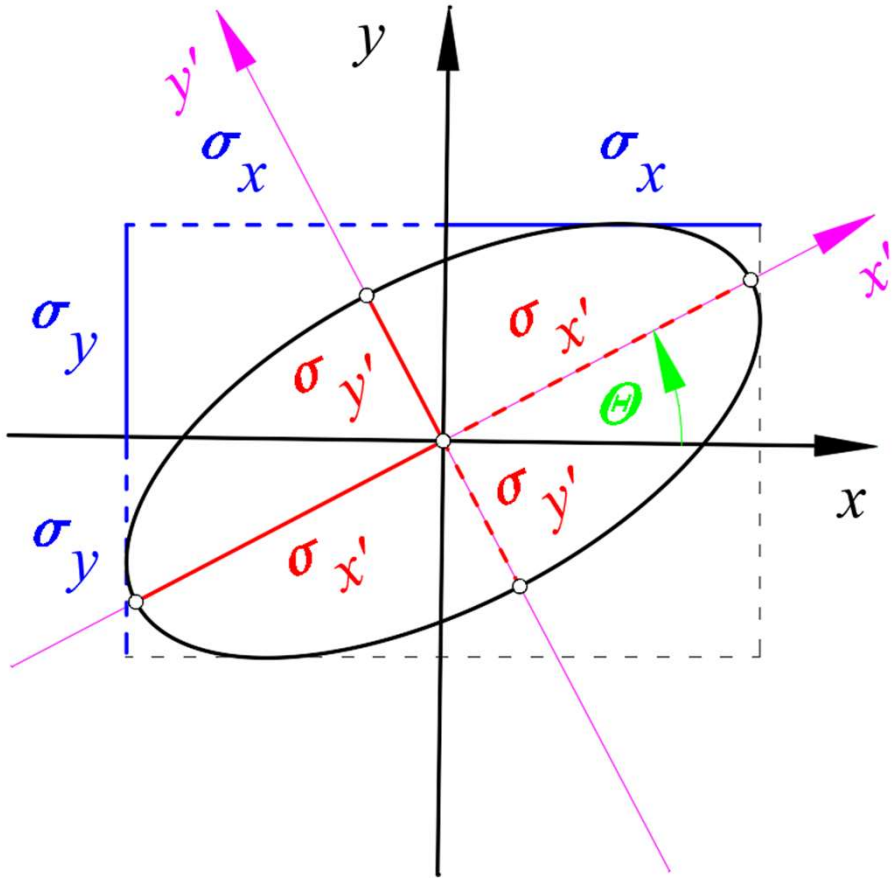

Določitev parametrov standardne elipse pogreškov

(dolžin obeh polosi elipse in kota zasuka velike polosi glede na primarno os k.s.)

Koordinati točke X in Y v koordinatnem sistemu x, y predstavlja slučajni vektor $\mathbf{x} = \begin{bmatrix} X \\ Y \end{bmatrix}$.

Koordinati iste točke X' in Y' v x', y' – koordinatnem sistemu predstavlja slučajni vektor $\mathbf{x}' = \begin{bmatrix} X' \\ Y' \end{bmatrix}$.

Oba slučajna vektorja lahko povežemo z ortogonalno (rotacijsko) transformacijo, ki jo zapišemo:

$$\begin{bmatrix} X' \\ Y' \end{bmatrix} = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} X \\ Y \end{bmatrix}$$

Oziroma:

$$\mathbf{x}' = \mathbf{R}\mathbf{x} \qquad (*)$$

kjer je θ kot zasuka koordinatnega sistema x', y' glede na koordinatni sistem x, y in $\mathbf{R}$ rotacijska matrika.

Rotacijska matrika iz gornje enačbe je torej:

$$\mathbf{R} = \mathbf{R}(\theta) = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix}$$

Kovariančni matriki koordinat X in Y ter X' in Y' oziroma odgovarjajočih slučajnih vektorjev $\mathbf{x}$ in $\mathbf{x}'$ sta:

$$\mathbf{x} = \begin{bmatrix} X \\ Y \end{bmatrix} \rightarrow \boldsymbol{\Sigma}_{\mathbf{xx}} = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix}$$

$$\mathbf{x}' = \begin{bmatrix} X' \\ Y' \end{bmatrix} \rightarrow \boldsymbol{\Sigma}_{\mathbf{x}'\mathbf{x}'} = \begin{bmatrix} \sigma_{x'}^2 & 0 \\ 0 & \sigma_{y'}^2 \end{bmatrix}$$

Izven-diagonalni členi v kovariančni matriki $\boldsymbol{\Sigma}_{\mathbf{x}'\mathbf{x}'}$ slučajnega vektorja $\mathbf{x}'$ so enaki 0, ker sta koordinati X' in Y' v koordinatnem sistemu $x'y'$ nekorelirani (koordinatni osi x' in y' sovpadata z glavnima osema elipse pogreškov).

Če uporabimo zakon o prenosu varianc in kovarianc za izraz (*), lahko zapišemo zvezo med obema kovariančnima matrikama:

$$\boldsymbol{\Sigma}_{\mathbf{x}'\mathbf{x}'} = \mathbf{R}\boldsymbol{\Sigma}_{\mathbf{xx}}\mathbf{R}^T$$

oziroma:

$$\begin{bmatrix} \sigma_{x'}^2 & 0 \\ 0 & \sigma_{y'}^2 \end{bmatrix} = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix} \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

Če matrike v gornjem izrazu pomnožimo med seboj in pridobljene izraze uredimo, pridobimo izraze za izračun parametrov standardne elipse pogreškov: kota zasuka θ velike polosi glede na pozitivno smer x–osi in dolžini obeh polosi $\sigma_{x'}$ in $\sigma_{y'}$.

Izrazi za te parametre so:

$$\tan 2\theta = \frac{2\sigma_{xy}}{\sigma_x^2 - \sigma_y^2}$$

kvadrant kota (2θ) določimo s predznakoma izrazov v števcu in imenovalcu izraza za $\tan 2\theta$:

$$\tan 2\theta = \frac{\sin 2\theta}{\cos 2\theta}$$

- predznak $\sin 2\theta$ ima predznak izraza $2\sigma_{xy}$

- predznak $\cos 2\theta$ ima enak predznak kot $\sigma_x^2 - \sigma_y^2$

Ter:

$$\sigma_{x'}^2 = \frac{\sigma_x^2 + \sigma_y^2}{2} + \sqrt{\frac{\left(\sigma_x^2 - \sigma_y^2\right)^2}{4} + \sigma_{xy}^2}$$

$$\sigma_{y'}^2 = \frac{\sigma_x^2 + \sigma_y^2}{2} - \sqrt{\frac{\left(\sigma_x^2 - \sigma_y^2\right)^2}{4} + \sigma_{xy}^2}$$

Korena gornjih izrazov oziroma $\sigma_{x'}$ in $\sigma_{y'}$ predstavljata dolžino velike in male polosi standardne elipse pogreškov.

Določitev parametrov standardne elipse pogreškov z razcepom kovariančne matrike na lastne vrednosti in lastne vektorje

1. $\sigma_{x'}$ in $\sigma_{y'}$ sta kvadratna korena lastnih vrednosti kovariančne matrike $\mathbf{\Sigma_{xx}}$ koordinat točke

2. Smeri glavnih osi elipse pogreškov sta dani s smerema lastnih vektorjev, ki pripadata lastnima vrednostma.

Imamo slučajni vektor koordinat $\mathbf{x}$ točke ter pripadajočo kovariančno matriko $\mathbf{\Sigma_{xx}}$:

$$\mathbf{x} = \begin{bmatrix} X \\ Y \end{bmatrix} \sim \mathbf{\Sigma_{xx}} = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix}$$

Lastne vrednosti matrike pridobimo z rešitvijo (določitvijo ničel) karakterističnega polinoma matrike $\mathbf{\Sigma_{xx}}$, ki ga zapišemo:

$$(-\lambda)^2 + \mathrm{sled}\left(\mathbf{\Sigma_{xx}}\right)(-\lambda) + \det\left(\mathbf{\Sigma_{xx}}\right) = 0$$

kjer je:

$$\mathrm{sled}\left(\mathbf{\Sigma_{xx}}\right) = \sigma_x^2 + \sigma_y^2$$

$$\det\left(\mathbf{\Sigma_{xx}}\right) = \sigma_x^2\sigma_y^2 - \sigma_{xy}^2$$

Karakteristični polinom je v našem primeru oblike:

$$\lambda^2 - \left(\sigma_x^2 + \sigma_y^2\right)\lambda + \left(\sigma_x^2\sigma_y^2 - \sigma_{xy}^2\right) = 0$$

Rešitvi te enačbe sta gornja izraza za $\sigma_{x'}$ in $\sigma_{y'}$.

Elipsa zaupanja

Določitev verjetnosti, s katero se koordinati X in Y točke nahajata znotraj standardne elipse pogreškov obravnavamo neodvisni (nekorelirani) koordinati X in Y.

Takšni koordinati sta koordinati X' in Y' oz. komponenti slučajnega vektorja $\mathbf{x}' = \begin{bmatrix} X' \\ Y' \end{bmatrix}$ (velika in mala polos elipse sovpadata s koordinatnima osema x' in y' koordinatnega sistema x', y').

Če sta koordinati X in Y korelirani ju vedno lahko transformiramo v nekorelirani z zasukom za kot θ.

Za nekorelirani koordinati X in Y ($\rho = 0$), se splošna enačba elipse pogreškov:

$$\left(\frac{x}{\sigma_x}\right)^2 - 2\rho\left(\frac{x}{\sigma_x}\right)\left(\frac{y}{\sigma_y}\right) + \left(\frac{y}{\sigma_y}\right)^2 = \left(1-\rho^2\right)\cdot c^2$$

preoblikuje v enačbo:

$$\frac{x^2}{\sigma_x^2} + \frac{y^2}{\sigma_y^2} = c^2$$

Koordinati X in Y se bosta nahajali znotraj ali na elipsi pogreškov, ko velja:

$$\frac{x^2}{\sigma_x^2} + \frac{y^2}{\sigma_y^2} \leq c^2$$

Kjer sta x in y slučajna pogreška koordinat X in Y.

Ker sta x in y slučajna pogreška (slučajni spremenljivki) s srednjo vrednostjo enako 0, ima slučajna spremenljivka U :

$$U = \frac{x^2}{\sigma_x^2} + \frac{y^2}{\sigma_y^2}$$

χ^2–porazdelitev z dvema prostostnima stopnjama ($n = 2$).

Izraz za funkcijo gostote verjetnosti slučajne spremenljivke U določimo iz izraza za funkcijo gostote verjetnosti χ^2–porazdelitve:

$$f(y) = \begin{cases} \dfrac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}; \text{ za } y > 0 \\ 0 \quad ; \text{ za } y \le 0 \end{cases}$$

ker je:

$n = 2$

je

$$\Gamma\left(\frac{n}{2}\right) = \Gamma(1) = (1-1)! = 0! = 1$$

In torej:

$$f(u)=\begin{cases}\frac{1}{2}e^{-\frac{u}{2}};\ \text{za } u>0\\ 0;\ \text{za } u\le 0\end{cases}$$

Verjetnost, da bosta slučajna pogreška x in y koordinat X in Y ležala znotraj ali na standardni elipsi pogreškov določimo z:

$$P\left(\frac{x^2}{\sigma_x^2}+\frac{y^2}{\sigma_y^2}\le c^2\right)=P\left(U\le c^2\right)=\int_0^{c^2}\frac{1}{2}e^{-\frac{u}{2}}du=\frac{1}{2}\left(-2e^{-\frac{u}{2}}\right)\Bigg|_0^{c^2}=-e^{-\frac{u}{2}}\Bigg|_0^{c^2}=-e^{-\frac{c^2}{2}}+1=1-e^{-\frac{c^2}{2}}$$

Verjetnost $P\left(U\le c^2\right)$ predstavlja prostornina pod ploskvijo funkcije gostote verjetnosti $f(x,y)$ dveh skupno normalno porazdeljenih slučajnih spremenljivk nad x,y–ravnino in področjem, omejenem z elipso pogreškov.

Za različne vrednosti c^2 so verjetnosti $P\left(U\le c^2\right)$ dane v sosednji tabeli.

c^2	$P\left(U\le c^2\right)$
1,000	0,394
1,177	0,500
1,414	0,632
2,000	0,865
2,146	0,900
2,447	0,950
3,000	0,989
3,035	0,990
3,500	0,998

Verjetnost, da se pravi koordinati X in Y točke nahajata znotraj ali na standardni elipsi pogreškov $(c=1)$ je 0.394.

Z drugimi besedami, verjetnost, da slučajna pogreška x in y koordinat X in Y ležita znotraj ali kvečjemu na standardni elipsi pogreškov je 0.394.

Relativne elipse pogreškov

Z elipso pogreškov praviloma podajamo absolutno natančnost koordinat točke, kakor jo predstavlja absolutna elipsa pogreškov koordinat točke (elipsa pogreškov absolutnih koordinat točke).

Včasih pa je potrebno podati tudi relativno natančnost koordinat dveh točk oziroma natančnost relativnih koordinat dveh točk, ki jo predstavimo z relativno elipso pogreškov (elipsa pogreškov relativnih koordinat dveh točk).

Tudi to elipso pogreškov določimo na osnovi kovariančne matrike koordinat točk.

Če imamo dve točki A in B lahko njune koordinate združeno zapišemo v obliki slučajnega vektorja $\mathbf{x}$:

$$\mathbf{x} = \begin{bmatrix} X_A \\ Y_A \\ X_B \\ Y_B \end{bmatrix}$$

kovariančna matrika koordinat teh dveh točk je:

$$\boldsymbol{\Sigma}_{\mathbf{xx}} = \begin{bmatrix} \sigma_{x_A}^2 & \sigma_{x_A y_A} & \sigma_{x_A x_B} & \sigma_{x_A y_B} \\ \sigma_{x_A y_A} & \sigma_{yA}^2 & \sigma_{y_A x_B} & \sigma_{y_A y_B} \\ \sigma_{x_A x_B} & \sigma_{y_A xB} & \sigma_{x_B}^2 & \sigma_{x_B y_B} \\ \sigma_{x_A y_B} & \sigma_{y_A y_B} & \sigma_{x_B y_B} & \sigma_{y_B}^2 \end{bmatrix}$$

Relativne koordinate (koordinatne razlike) točk A in B so:

$$\Delta X = X_B - X_A$$
$$\Delta Y = Y_B - Y_A$$

Oziroma:

$$\Delta\mathbf{x} = \begin{bmatrix} \Delta X \\ \Delta Y \end{bmatrix} = \begin{bmatrix} -1 & 0 & 1 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_A \\ Y_A \\ X_B \\ Y_B \end{bmatrix} = \mathbf{A}\mathbf{x}$$

Z uporabo zakona o prenosu varianc in kovarianc lahko pridobimo kovariančno matriko koordinatnih razlik (relativnih koordinat):

$$\boldsymbol{\Sigma}_{\mathbf{\Delta x \Delta x}} = \mathbf{A}\boldsymbol{\Sigma}_{\mathbf{xx}}\mathbf{A}^T$$

katere elementi so:

$$\boldsymbol{\Sigma}_{\mathbf{\Delta x \Delta x}} = \begin{bmatrix} \sigma^2_{\Delta x} & \sigma_{\Delta x \Delta y} \\ \sigma_{\Delta x \Delta y} & \sigma^2_{\Delta y} \end{bmatrix}$$

Preverimo lahko, da so elementi kovariančne matrike $\boldsymbol{\Sigma}_{\mathbf{\Delta x \Delta x}}$ dani z zvezami:

$$\sigma^2_{\Delta x} = \sigma^2_{x_A} + \sigma_{x_A x_B} + \sigma^2_{x_B}$$
$$\sigma^2_{\Delta y} = \sigma^2_{y_A} + \sigma_{y_A y_B} + \sigma^2_{y_B}$$
$$\sigma_{\Delta x \Delta y} = \sigma_{x_A y_A} + \sigma_{x_B y_B} - \sigma_{x_A y_B} - \sigma_{x_B y_A}$$

Na osnovi kovariančne matrike $\boldsymbol{\Sigma}_{\mathbf{\Delta x \Delta x}}$ izračunamo elemente relativne elipse pogreškov:

- dolžini obeh polosi $\sigma_{\Delta x'}$ in $\sigma_{\Delta y'}$ ter
- kot zasuka θ daljše polosi elipse glede na pozitivno smer glavne osi koordinatnega sistema

na enak način, kot izračunamo elemente absolutne elipse pogreškov.

KOMENTAR IZRAČUNA KOVARIANČNIH MATRIK TER ELIPS POGREŠKOV

Kot vemo, pridobimo kovariančno matriko na osnovi matrike kofaktorjev $\mathbf{Q}$ in referenčne variance σ_0^2 z zvezo:

$$\mathbf{\Sigma} = \sigma_0^2 \mathbf{Q}$$

Glede na to, da vsebuje matrika kofaktorjev vse informacije o relativni natančnosti komponent slučajnega vektorja, kateremu pripada, lahko uporabimo za predstavitev razmerij natančnosti elementov slučajnega vektorja matriko kofaktorjev.

Ko nas zanimajo natančnosti v absolutnem smislu, moramo uporabiti kovariančno matriko.

V primeru rešitve problema z izravnavo so vse informacije, potrebne za izračun natančnosti neznank (koordinat) in s tem tudi elips pogreškov, so zbrane v kovariančni matriki ocenjenih neznank (koordinat) $\mathbf{\Sigma_{\Delta\Delta}}$.

Če je $\mathbf{x}$ slučajni vektor koordinat je pripadajoča kovariančna matrika $\mathbf{\Sigma_{xx}}$.

Imamo tako:

$$\mathbf{x} = \begin{bmatrix} X \\ Y \end{bmatrix} \text{ in } \mathbf{\Sigma_{xx}} = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix}$$

V nadaljevanju prikazujemo, kako določimo/izračunamo kovariačno matriko koordinat ene ali več točk:

- ko so koordinate določene le na osnovi minimalno potrebnega števila opazovanj (rešitev problema brez izravnave)
- ko imamo za določitev koordinat na voljo nadštevilna opazovanja, ki jih izravnamo in koordinate ocenimo v postopku izravnave.

1. Koordinate in kovariančno matriko koordinat določimo na osnovi opazovanj (brez nadštevilnih opazovanj in brez izravnave)

Matriko kofaktorjev $\mathbf{Q_{xx}}$ (koordinatnih) neznank $\mathbf{x}$ pridobimo s prenosom kofaktorjev opazovanj $\mathbf{l}$ v kofaktorje (koordinatnih) neznank z uporabo zakona o prenosu kofaktorjev (varianc in kovarianc).

Ob dani funkcijski zvezi med opazovanji $\mathbf{l}$ in neznankami $\mathbf{x}$:

$$\mathbf{x} = \mathbf{f}(\mathbf{l})$$

Izračunamo Jacobijevo matriko $\mathbf{J_{xl}}$, to je matriko parcialnih odvodov funkcij $\mathbf{f}(\mathbf{l})$, ki povezujejo vektor opazovanj $\mathbf{l}$ z vektorjem (koordinatnih) neznank $\mathbf{x}$.

Ob dani matriki kofaktorjev opazovanj $\mathbf{Q_{ll}}$ pridobimo matriko kofaktorjev ocenjenih neznank $\mathbf{Q_{xx}}$ z:

$$\mathbf{Q_{xx}} = \mathbf{J_{xl}} \mathbf{Q_{ll}} \mathbf{J_{xl}}^T$$

Na osnovi dane matrike kofaktorjev $\mathbf{Q_{xx}}$ izračunamo kovariančno matriko $\mathbf{\Sigma_{xx}}$:

$$\mathbf{\Sigma_{xx}} = \sigma_0^2 \mathbf{Q_{xx}}$$

Na osnovi tako določene kovarianče matrike določimo elipse pogreškov.

2. Koordinate in kovariančno matriko koordinat določimo na osnovi izravnave opazovanj

V primeru nadštevilnih opazovanj pridobimo ocenjene (koordinatne) neznanke $\hat{\mathbf{x}}$ in matriko kofaktorjev ocenjenih neznank $\mathbf{Q}_{\hat{\mathbf{x}}\hat{\mathbf{x}}} = \mathbf{Q}_{\Delta\Delta}$ kot rezultat izravnave.

Matriko kofaktorjev ocenjenih neznank pridobimo na osnovi matrike koeficientov normalnih enačb $\mathbf{N}$:

$$\mathbf{Q}_{\Delta\Delta} = \mathbf{N}^{-1}$$

Matriko koeficientov normalnih enačb $\mathbf{N}$ pridobimo z uporabo zveze:

$$\mathbf{N} = \mathbf{B}^T \mathbf{P} \mathbf{B}$$

Matrika koeficientov normalnih enačb $\mathbf{N}$ je torej odvisna od matrike koeficientov neznank $\mathbf{B}$ in matrike uteži $\mathbf{P}$.

Elipse pogreškov zopet določimo na osnovi kovariančne matrike neznank $\mathbf{\Sigma}_{\Delta\Delta}$, ki so tokrat določene z izravnavo.

Imamo torej:

$$\mathbf{\Sigma}_{\Delta\Delta} = \sigma_0^2 \mathbf{Q}_{\Delta\Delta}$$

Matrika kofaktorjev $\mathbf{Q}_{\Delta\Delta}$ in kovariančna matrika $\mathbf{\Sigma}_{\Delta\Delta}$, sta torej odvisni od matrike $\mathbf{N}$, ta pa od matrik $\mathbf{B}$ in $\mathbf{P}$.

Od česa pa sta odvisni matriki $\mathbf{B}$ in $\mathbf{P}$?

Za odgovor glej tudi komentar izračuna potrebne natančnosti opazovanj.

Matrika koeficientov neznank $\mathbf{B}$

Matriko koeficientov neznank $\mathbf{B}$ imenujemo matrika konfiguracije matematičnega modela (ang.: configuration, design matrix) in je odvisna od:

- vrste opazovanj v mat. modelu
- geometrijskih lastnosti mat. modela
- razporeditve danih in neznanih količin v mat. modelu

Vrsta opazovanj

Enačbe opazovanj (enačbe, ki povezujejo opazovanja in neznanke) so odvisne od vrste vrste/lastnosti merjene količine.

Različne merjene količine namreč povezujejo neznanke količine z različnimi funkcijskimi zvezami.

Enačba opazovane dolžine povezuje koordinate dveh točk z drugačno funkcijsko zvezo, kot povezuje koordinate dveh točk merjeni horizontalni kot ali horizontalna smer.

(DOMAČA NALOGA: Zapiši enačbi opazovanj med dvema/tremi točkami za vse omenjene vrste merjenih količin).

Izravnava temelji na rešitvi v linearnem oz. lineariziranem mat. modelu.

Če je enačba opazovanja nelinearna jo lineariziramo, na osnovi linearizirane enačbe opazovanja pa sestavimo enačbe popravkov opazovanj.

Ker so, glede na vrsto opazovane količine, različne enačbe opazovanj, so različne tudi enačbe popravkov.

Enačbe, ki predstavljajo elemente matrike $\mathbf{B}$ so torej odvisne od vrste opazovanj oziroma od enačb, ki povezujejo opazovanja in (koordinatne) neznanke (koordinate točk).

Geometrijske lastnosti matematičnega modela

Ko imamo določene linearizirane oblike funkcij, ki povezujejo opazovanja in neznanke, je zanje oziroma za parcialne odvode funkcij po neznankah treba določiti številske vrednosti.

Številske vrednosti parcialnih odvodov so odvisne od razsežnosti (velikosti) merjenih vrednosti, smeri (smernega kota) v kateri poteka npr. dolžina med dvema točkama, velikosti horizontalnega kota… kar združeno obravnavamo kot geometrijo problema.

Razporeditev danih in neznanih količin v matematičnem modelu

Enačbe, ki povezujejo opazovanja, in neznanke sestavimo tako, da v enačbo vključimo vse neznane količine.

Količine, ki so dane (koordinate danih točk) pa pri sestavi enačb opazovanj in nato sestavi enačb popravkov opazovanj pa obravnavamo kot konstante.

Na primer v enačbi opazovane dolžine, ki povezuje dve novi točki v ravninskem koordinatnem sistemu, nastopajo štiri koordinatne neznanke (po dve koordinatni neznanki vsake točke).

Če pa sestavimo enačbo opazovane dolžine med dano in novo točko, v enačbi nastopata le dve koordinatni neznanki.

Enako velja tudi za enačbo opazovanj katere koli druge količine.

Enačba opazovanja je torej odvisna od tega, ali povezuje npr. dano in novo točko ali npr. dve novi točki.

Razporeditev danih in novih točk ter način, kako med seboj te točke povezujejo opazovanja, je tretja vrsta vpliva na enačbe opazovanj in enačbe popravkov opazovanj.

Matrika uteži opazovanj $\mathbf{P}$

Matrika uteži opazovanj $\mathbf{P}$ predstavlja drugo skupino vplivov na matriko koeficientov normalnih enačb $\mathbf{N}$.

Kot vemo, pridobimo matriko uteži $\mathbf{P}$ opazovanj na osnovi kovariančne matrike opazovanj $\boldsymbol{\Sigma}$, zato je v matriki uteži vsebovana informacija o natančnosti opazovanj ter njihovi medsebojni koreliranosti.

Kot smo že omenili pri določitvi potrebne natančnosti opazovanj, je pri sestavi kovariančne matrike opazovanj potrebno poskrbeti, da bodo natančnosti merjenih količin zagotovile želeno oziroma predvideno natančnost računanih količin.

Pri tem je treba paziti tudi, da bodo neznane količine v matematičnem modelu določene s približno enako natančnostjo.

Za dosego tega cilja ni enostavnih navodil, v splošnem pa je treba poskrbeti, da so natančnosti merjenih količin medsebojno usklajene oziroma je vpliv natančnosti merjenih količin na ocenjene neznanke približno enak.

Kovariančna matrika $\boldsymbol{\Sigma}_{\Delta\Delta}$ koordinatnih neznank $\boldsymbol{\Delta}$ vsebuje naštete informacije in mora biti vsaj približno določena že pred samo izvedbo terenske izmere.

Omeniti je treba, da se v obeh primerih (ko nimamo ali imamo nadštevilna opazovanja) koordinate novih točk ter njihova natančnost določitve obnaša na podoben način.

Primeri:

Na osnovi danih koordinat dveh točk ter merjenih horizontalnih kotov (smeri) in dolžin določamo koordinate novih točk. Zanima nas vpliv števila in natančnosti opazovanj na natančnost določitve koordinat oziroma elips pogreškov. Določamo koordinate istih točk, spreminjamo število in natančnost merjenih količin.

1. Izvedba le nujno potrebnega števila opazovanj za določitev koordinat novih točk (ni nadštevilnih opazovanj in ni izravnave opazovanj)

Natančnosti merjenih količin: $\sigma_\alpha = 15"$, $\sigma_d = 5mm$

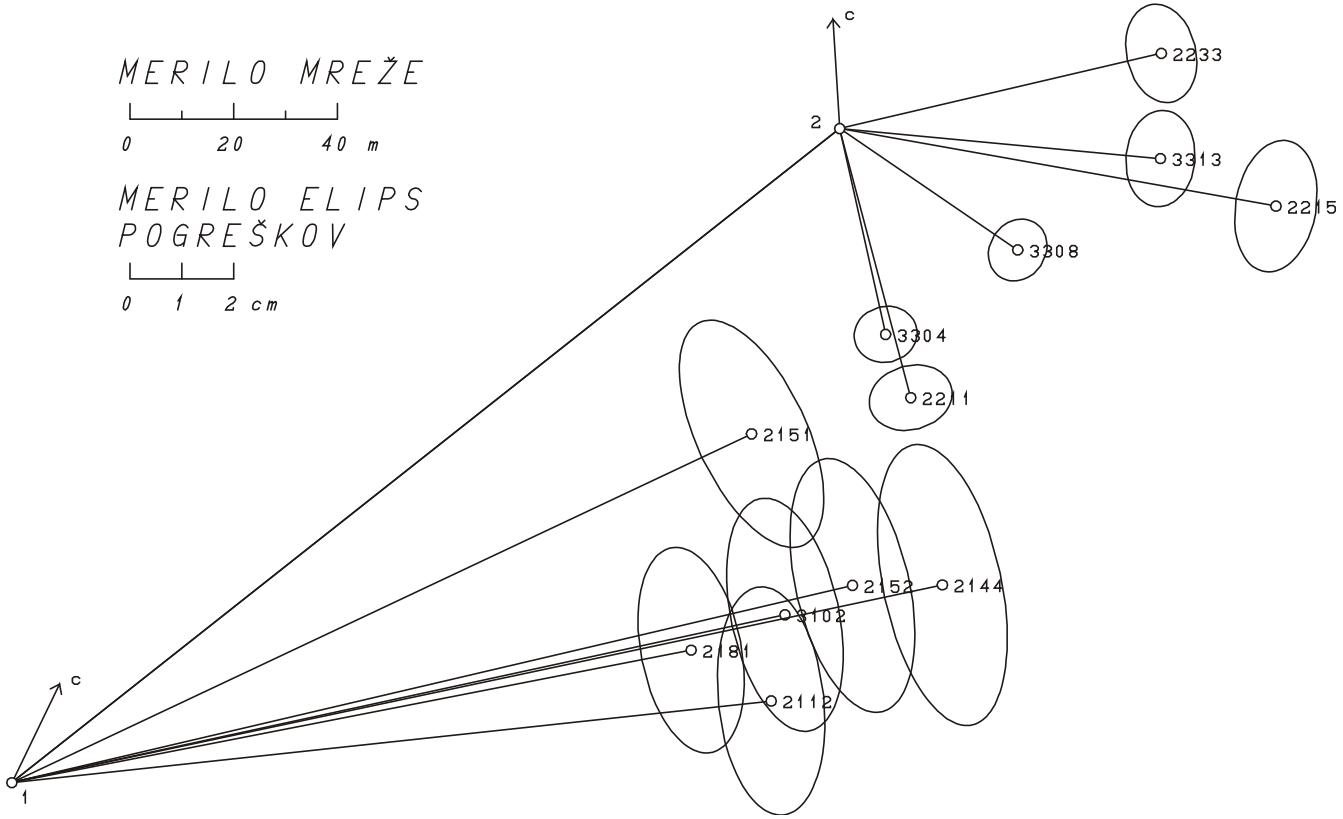

2. Izvedba le nujno potrebnega števila opazovanj za določitev koordinat novih točk (ni nadštevilnih opazovanj in ni izravnave opazovanj)

Natančnosti merjenih količin: $\sigma_\alpha = 5"$, $\sigma_d = 5mm$

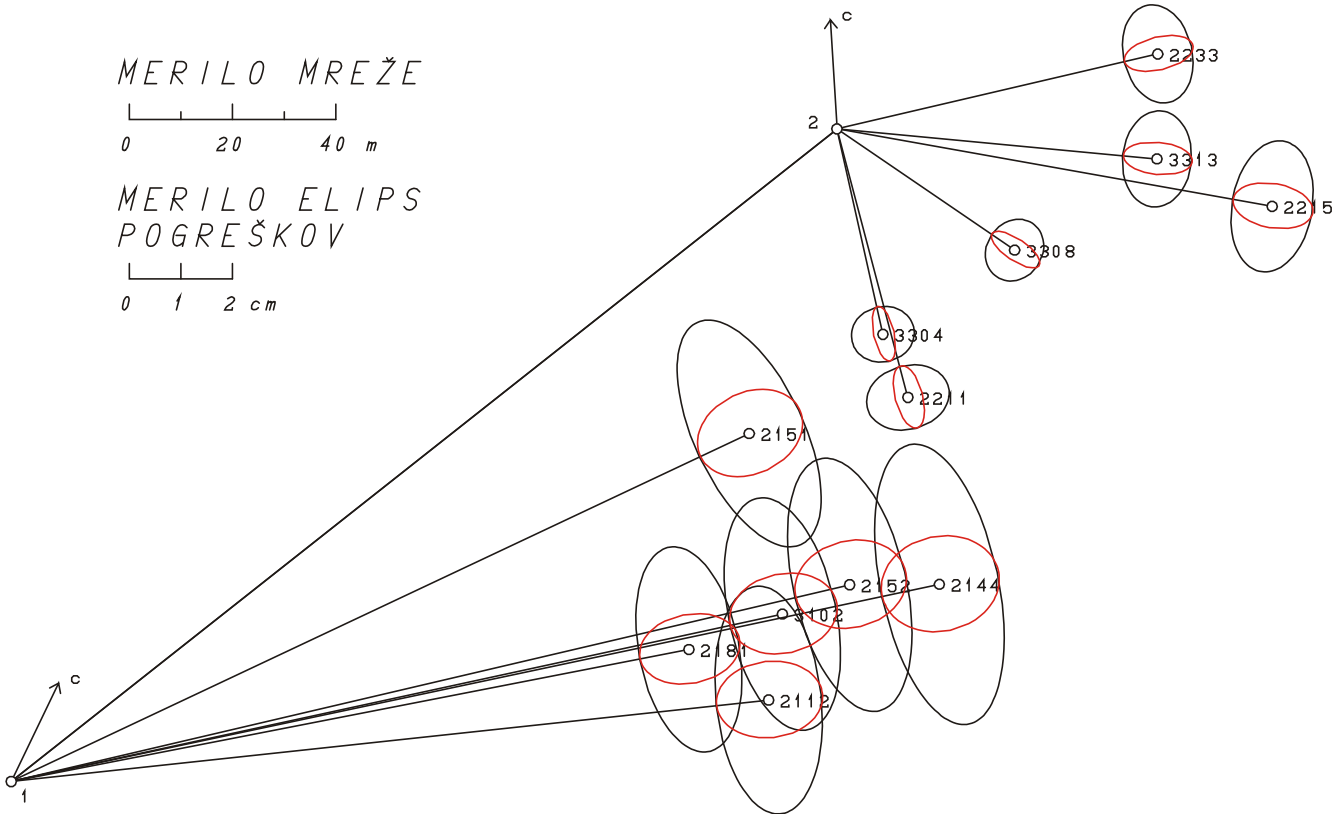

3. Izvedba nadštevilnih opazovanj za določitev koordinat vseh novih točk (nadštevilna opazovanja in izravnava opazovanj)

Natančnosti merjenih količin: $\sigma_\alpha = 15"$, $\sigma_d = 5mm$ (enake kot v 1. primeru)

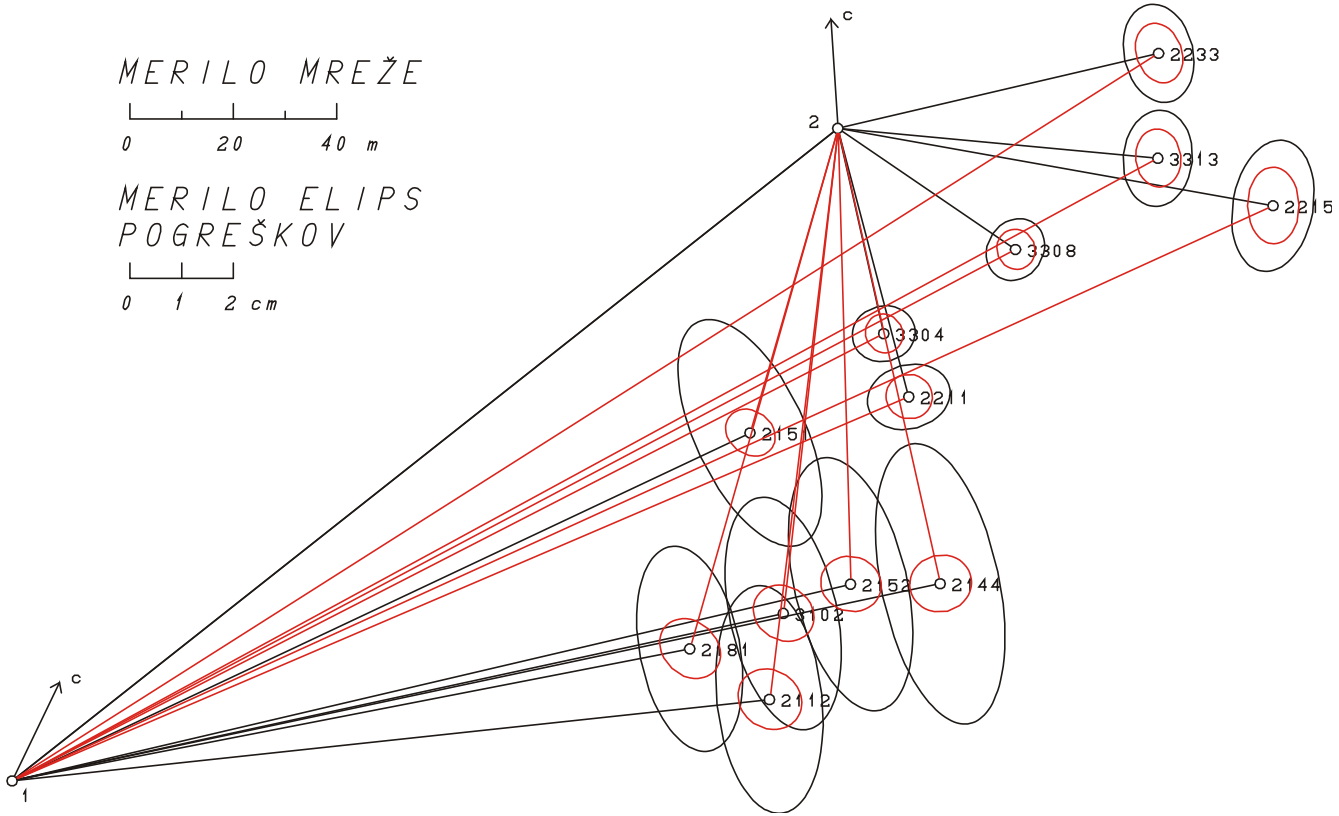

4. Izvedba nadštevilnih opazovanj za določitev koordinat vseh novih točk (nadštevilna opazovanja in izravnava opazovanj)

Natančnosti merjenih količin: $\sigma_\alpha = 5"$, $\sigma_d = 5mm$ (enake kot v 2. primeru)

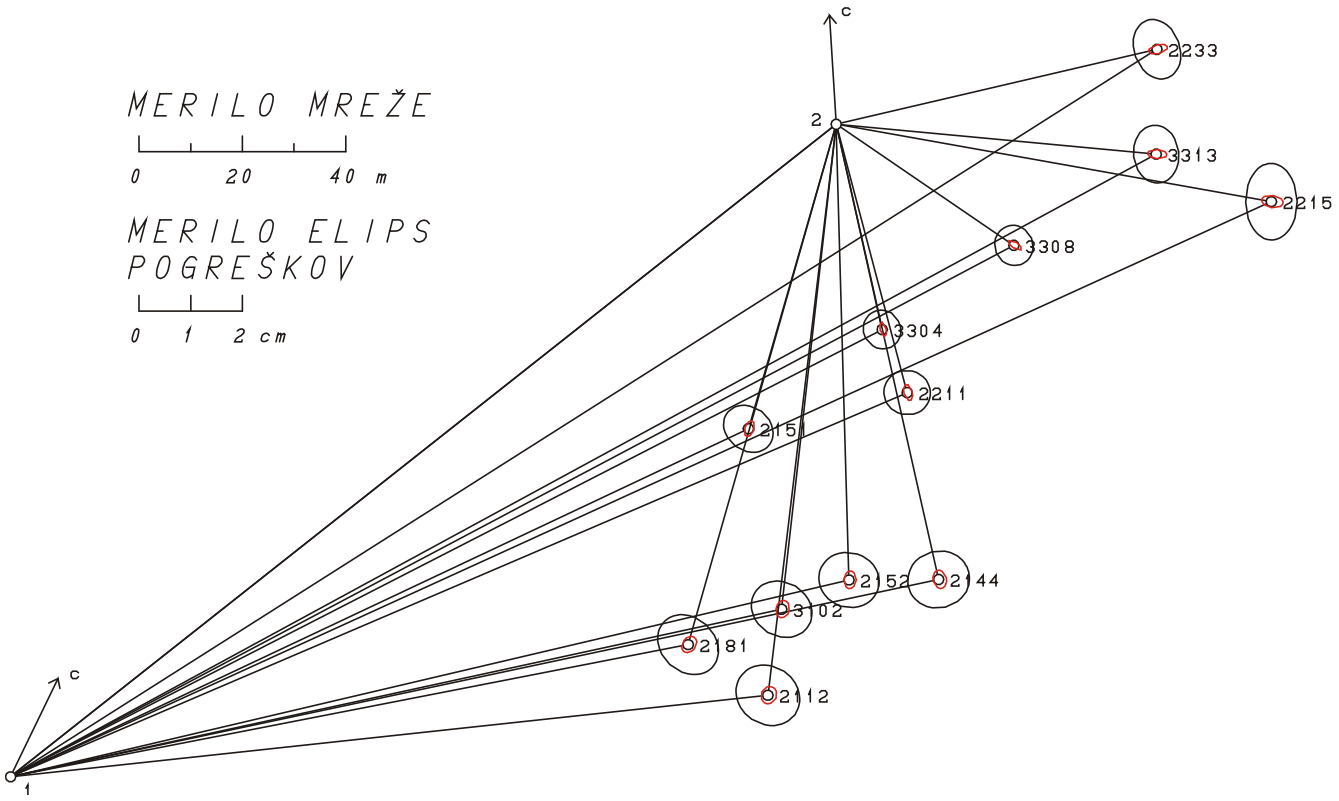

Primeri kažejo, kako lahko z izvedbo nadštevilnih opazovanj povečamo natančnost natančnost določitve koordinat točk.

Primeri določitve koordinat točk v geodetski mreži in njihovih natančnosti (elips pogreškov):

- Elipse pogreškov naraščajo z naraščanjem oddaljenosti od danih točk
- Dane točke na več delih geodetske mreže povečajo natančnost koordinat ovih točk
- Vpliv grobo pogrešenih opazovanj na natančnost določitve koordinat ni »viden« v matrikah **kofaktorjev** in v elipsah pogreškov.

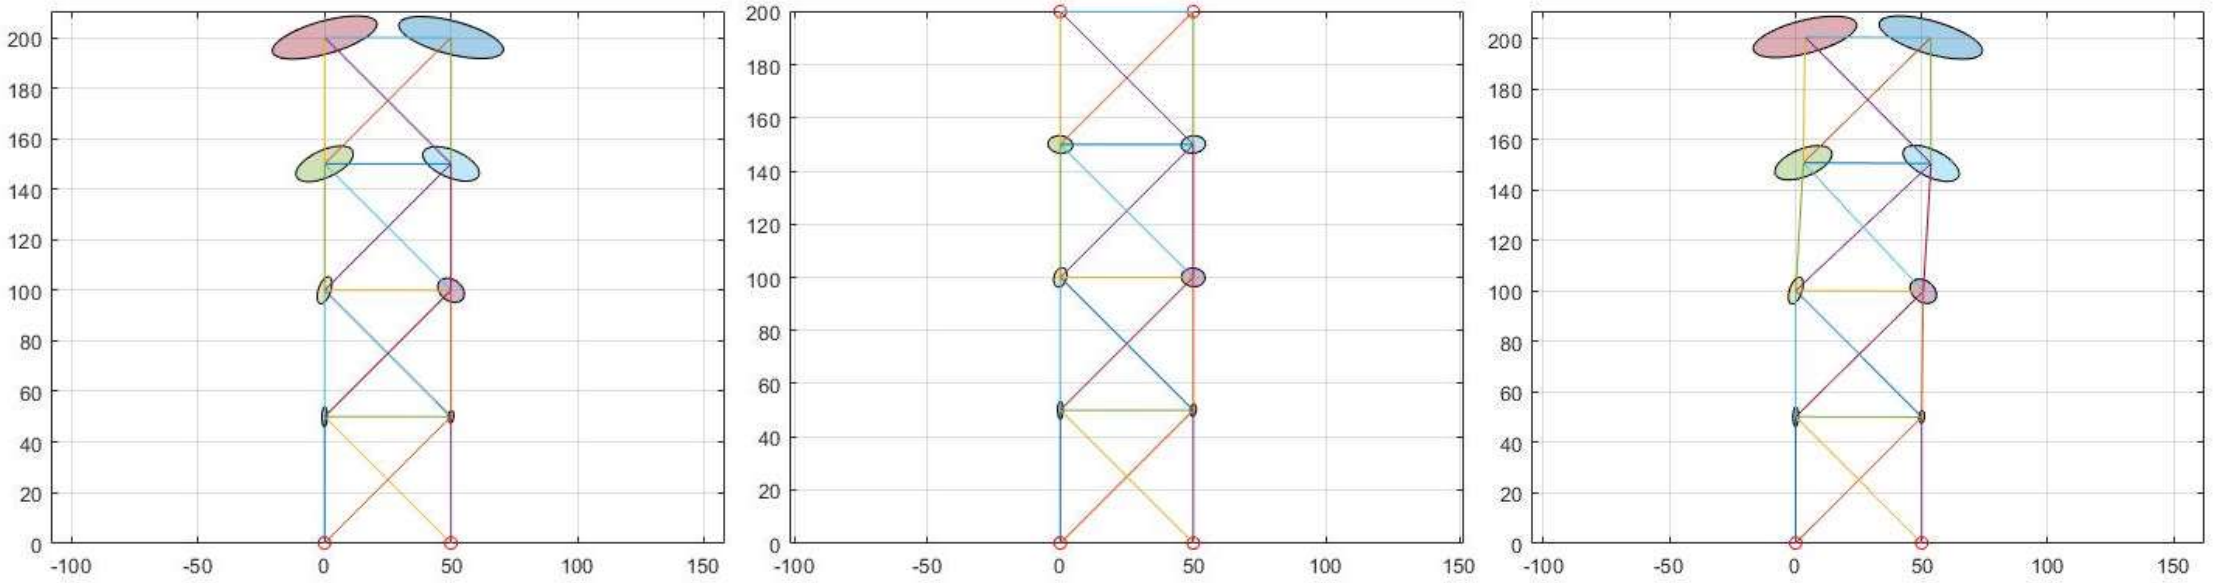

Tako kot koordinate novih točk so tudi natančnosti koordinat (kovariančne matrike) t.i. **<u>datumsko odvisne količine</u>**.

To dejstvo zahteva previdnost pri interpretaciji izračunanih koordinat novih točk in natančnosti in elips pogreškov le-teh.

SPLOŠNI MODEL IZRAVNAVE PO MNK

Lani smo za izpeljavo enačb za rešitev problema posredne izravnave uporabili primer, v katerem premico prilagodili trem točkam.

Pri tem smo obravnavali:

- y –koordinate točk kot opazovanja
- x –koordinate kot konstante.

Na osnovi enačbe premice:

$$y - ax - b = 0$$

smo nato sestavili enačbe popravkov v obliki:

$$\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$$

Elementa vektorja neznank $\boldsymbol{\Delta}$ sta bila a –naklonski koeficient premice in b –sečišče premice z y –osjo.

Popravki opazovanj so se nanašali na opazovanja, to je na koordinate y .

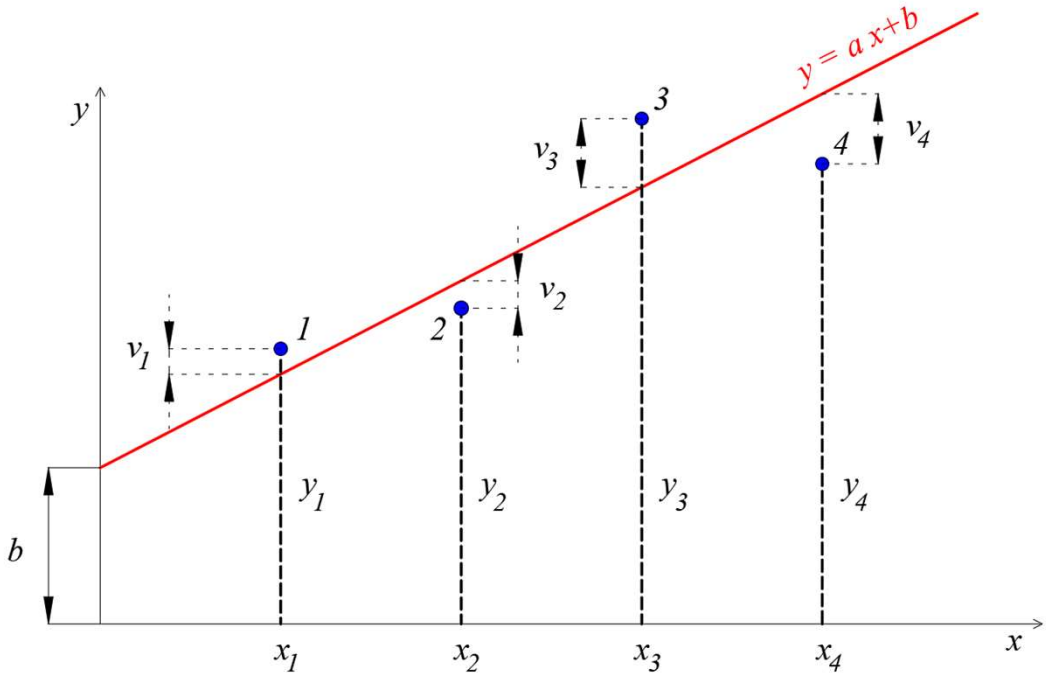

Lahko trdimo, da se bo identična situacija, kot v gornjem primeru (aproksimacija krivulje) v praksi le izjemoma pojavila.

Običajno namreč nimamo razlogov, da bi posamezne koordinate ene entitete obravnavali na različne načine – eno skupino kot konstante, drugo kot opazovanja…

Obravnavajmo sedaj primer, ko ne opazujemo samo koordinat y, ampak tudi koordinate x vsake točke.

Enačba premice v obliki $y - ax - b = 0$ sedaj vsebuje za vsako točko z opazovanima obema koordinatama dve opazovanji x in y ter dve neznanki a in b.

Za rešitev problema izravnave v tem primeru ne moremo uporabiti nobene od do sedaj znanih tehnik izravnave po MNK.

V posredni izravnavi, kjer so enačbe popravkov dane v obliki $\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$, sme v vsaka enačbi popravka nastopati le eno opazovanje.

V primeru pogojne izravnave imamo pogojne enačbe oblike $\mathbf{A}\mathbf{v} = \mathbf{f}$, v katerih pa neznanke niso vključene.

Vidimo, da potrebujemo za skupno obravnavo opazovanj in neznank bolj splošno tehniko izravnave, ki bo omogočala skupno obravnavo opazovanj in neznank brez omejitev, da sme nastopati v vsaki enačbi samo eno opazovanje.

Taka tehnika je splošni model izravnave.

Za splošno rešitev problema izravnave prav tako ne sme biti nobenih omejitev glede strukture kovariančne matrike $\boldsymbol{\Sigma}$, matrike kofaktorjev $\mathbf{Q}$ in matrike uteži $\mathbf{P}$ vektorja opazovanj $\mathbf{l}$.

Korelirana in nekorelirana opazovanja, ki so enake ali različne natančnosti, morajo biti obravnavana enakovredno.

PRIMER:

Imamo spet tri točke, z opazovanimi koordinatami x in y, ki jim želimo prilagoditi premico oblike $y - ax - b = 0$.

Opazovane koordinate x in y točk ter variance teh koordinat so:

TOČKA	$x[\mathrm{cm}]$	$y[\mathrm{cm}]$	$\sigma_x^2\left[\mathrm{cm}^2\right]$	$\sigma_y^2\left[\mathrm{cm}^2\right]$
1	5,00	10,20	0,01	0,10
2	10,00	20,00	0,04	0,08
3	15,00	30,00	0,04	0,08
4	20,00	40,00	0,04	0,08

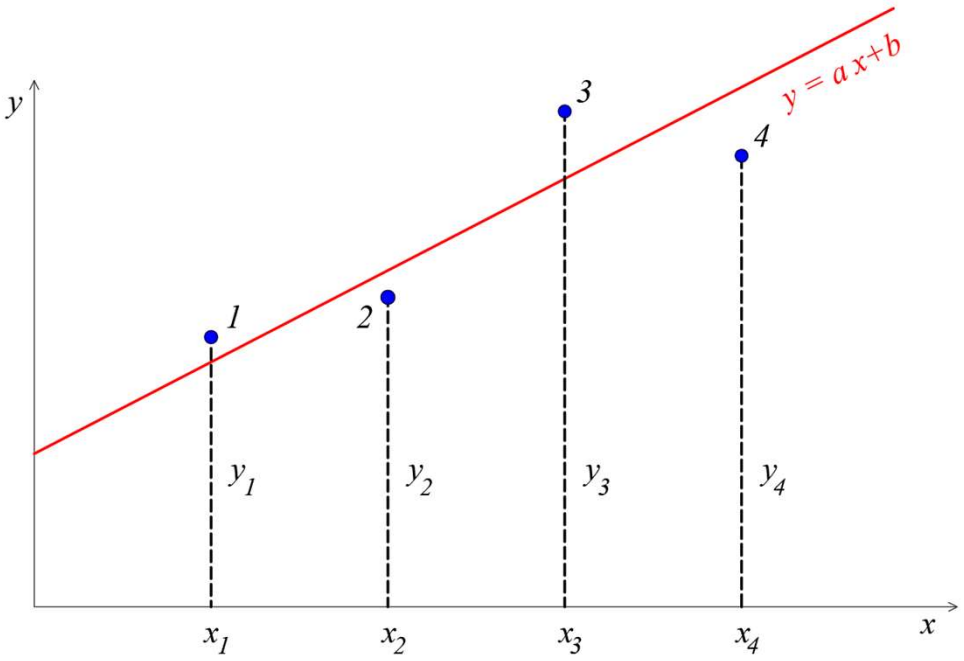

Podatki so enaki, kot v prejšnjih primerih, z variancami, dodanimi tudi za koordinato x.

Opazovanja so nekorelirana.

Zanima nas ocena po MNK za koeficienta premice a in b.

Enačbo premice, za opazovani koordinati x in y ter pripadajoča popravka v_x in v_y, zapišemo v obliki:

$$(y + v_y) - a(x + v_x) - b = 0$$

Ker sta a in v_x neznani spremenljivki, je enačba nelinearna za neznanke.

Enačbe premice torej ne moremo uporabiti neposredno, kot smo to storili v primeru posredne izravnave, moramo jo linearizirati.

Enačbo premice zapišemo v obliki:

$$F = y - ax - b = 0$$

Linearizirana oblika enačba premice je:

$$F = F_0 + \left(\frac{\partial F}{\partial x}\right)_{(a_0,b_0)} v_x + \left(\frac{\partial F}{\partial y}\right)_{(a_0,b_0)} v_y + \left(\frac{\partial F}{\partial a}\right)_{(a_0,b_0)} \delta a + \left(\frac{\partial F}{\partial b}\right)_{(a_0,b_0)} \delta b = 0$$

kjer je:

$$F_0 = F_{(a_0,b_0)} = \left(y - a_0 x - b_0\right);\ \left(\frac{\partial F}{\partial x}\right)_{(a_0,b_0)} = -a_0;\ \left(\frac{\partial F}{\partial y}\right)_{(a_0,b_0)} = 1;\ \left(\frac{\partial F}{\partial a}\right)_{(a_0,b_0)} = -x;\ \left(\frac{\partial F}{\partial b}\right)_{(a_0,b_0)} = -1$$

Kar vodi do:

$$\left(-a_0\right) v_x + \left(1\right) v_y + \left(-x\right) \delta a + \left(-1\right) \delta b = \left(-y + a_0 x + b_0\right)$$

kjer sta a_0 in b_0 približni vrednosti neznank a in b.

Če združimo člene ob popravkih opazovanj in popravkov približnih vrednosti neznank v odgovarjajočih matrikah, zapišemo linearizirano enačbo:

$$\begin{bmatrix} -a_0 & 1 \end{bmatrix} \cdot \begin{bmatrix} v_x \\ v_y \end{bmatrix} + \begin{bmatrix} -x & -1 \end{bmatrix} \cdot \begin{bmatrix} \delta a \\ \delta b \end{bmatrix} = \begin{bmatrix} -y + a_0 x + b_0 \end{bmatrix}$$

Linearizirane enačbe za tri točke zapišemo:

$$\begin{bmatrix} -a_0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -a_0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -a_0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -a_0 & 1 \end{bmatrix} \begin{bmatrix} v_{x1} \\ v_{y1} \\ v_{x2} \\ v_{y2} \\ v_{x3} \\ v_{y3} \\ v_{x4} \\ v_{y4} \end{bmatrix} + \begin{bmatrix} -x_1 & -1 \\ -x_2 & -1 \\ -x_3 & -1 \\ -x_4 & -1 \end{bmatrix} \begin{bmatrix} \delta a \\ \delta b \end{bmatrix} = \begin{bmatrix} -y_1 + a_0 x_1 + b_0 \\ -y_2 + a_0 x_2 + b_0 \\ -y_3 + a_0 x_3 + b_0 \\ -y_4 + a_0 x_4 + b_0 \end{bmatrix}$$

oziroma:

$$\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$$

Kjer je:

$$\mathbf{A}_{ij} = \left(\frac{\partial \mathbf{F}_i}{\partial \mathbf{l}_j} \right)_{\mathbf{x}_0} , \ \mathbf{B}_{ij} = \left(\frac{\partial \mathbf{F}_i}{\partial \mathbf{x}_j} \right)_{\mathbf{x}_0} , \ \mathbf{f}_i = -\mathbf{F}_i \left(\mathbf{l}, \mathbf{x} \right)_{\mathbf{x}_0}$$

Za numerično rešitev problema je treba določiti numerične vrednosti elementov matrik $\mathbf{A}$ in $\mathbf{B}$ ter vektorja $\mathbf{f}$, za kar pa, poleg vrednosti opazovanih koordinat x_i in y_i potrebujemo približne vrednosti neznank a_0 in b_0.

Določimo ju iz enačbe premice, ki poteka skozi kateri koli dve točki.

Če izberemo na primer točki 2 in 3 imamo:

$$y_2 = a_0 x_2 + b_0$$
$$y_3 = a_0 x_3 + b_0$$

Za a_0 in b_0 dobimo:

$$a_0 = \frac{y_3 - y_2}{x_3 - x_2} = \frac{30-20}{15-10} = 2\,,\; b_0 = y_2 - a_0 x_2 = 20 - 2\cdot 10 = 0$$

Ter:

$$\mathbf{A} = \begin{bmatrix} -2 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -2 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -2 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} -5 & -1 \\ -10 & -1 \\ -15 & -1 \\ -20 & -1 \end{bmatrix}, \quad \mathbf{f} = \begin{bmatrix} 0,20 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Ker obravnavamo koordinati x in y kot opazovanji, in ker imamo skupno opazovanih 8 koordinat, je kovariančna matrika opazovanj $\mathbf{\Sigma}$ velikosti 8×8. Ker so opazovanja nekorelirana, je kovariančna matrika diagonalna:

$$\mathbf{\Sigma} = \begin{bmatrix} \sigma_{x_1}^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma_{y_1}^2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_{x_2}^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_{y_2}^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_{x_3}^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma_{y_3}^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{x_4}^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{y_4}^2 \end{bmatrix} = \begin{bmatrix} 0,01 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0,10 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0,04 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0,08 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0,04 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0,08 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0,04 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0,08 \end{bmatrix} \left[\mathrm{cm}^2\right]$$

Vektor opazovanj $\mathbf{l}$ in vektor popravkov $\mathbf{v}$ sta:

$$\mathbf{l} = \begin{bmatrix} x_1 \\ y_1 \\ x_2 \\ y_2 \\ x_3 \\ y_3 \\ x_4 \\ y_4 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} v_{x_1} \\ v_{y_1} \\ v_{x_2} \\ v_{y_2} \\ v_{x_3} \\ v_{y_3} \\ v_{x_4} \\ v_{y_4} \end{bmatrix}$$

Vektor $\mathbf{f}$ pa zapišemo kot:

$$\mathbf{f} = -\begin{bmatrix} -a_0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -a_0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -a_0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -a_0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \\ x_2 \\ y_2 \\ x_3 \\ y_3 \\ x_4 \\ y_4 \end{bmatrix} + \begin{bmatrix} b_0 \\ b_0 \\ b_0 \\ b_0 \end{bmatrix}$$

oziroma:

$$\mathbf{f} = -\mathbf{A}\mathbf{l} + \mathbf{d}$$

kjer je $\mathbf{d}$ vektor konstant: $\mathbf{d} = \begin{bmatrix} b_0 \\ b_0 \\ b_0 \\ b_0 \end{bmatrix}$.

S tem smo dobili enačbo splošnega modela izravnave, ki je oblike:

$$\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f} = \mathbf{d} - \mathbf{A}\mathbf{l}$$

Za rešitev problema splošnega modela izravnave moramo vektor opazovanj $\mathbf{l}$ transformirati v vektor t.i. ekvivalentnih opazovanj $\mathbf{l}_e$ in vektor popravkov opazovanj $\mathbf{v}$ v vektor popravkov t.i. ekvivalentnih opazovanj $\mathbf{v}_e$.

Vektor opazovanj $\mathbf{l}$ transformiramo v vektor ekvivalentnih opazovanj $\mathbf{l}_e$ z zvezo:

$$\mathbf{l}_e = \mathbf{A}\mathbf{l}$$

in vektor popravkov $\mathbf{v}$ v vektor popravkov ekvivalentnih opazovanj $\mathbf{v}_e$ z zvezo:

$$\mathbf{v}_e = \mathbf{A}\mathbf{v}$$

Po uvedbi vektorjev ekvivalentnih opazovanj $\mathbf{l}_e$ dobimo tudi:

$$\mathbf{f} = -\mathbf{l}_e + \mathbf{d}$$

Za ekvivalentna opazovanja $\mathbf{l}_e$ in njim pripadajoče popravke $\mathbf{v}_e$ lahko zdaj zapišemo:

$$\mathbf{v}_e + \mathbf{B}\boldsymbol{\Delta} = -\mathbf{l}_e + \mathbf{d} = \mathbf{f}$$

Vidimo, da gre za identično obliko enačb popravkov opazovanj kot v primeru posredne izravnave, s tem, da tokrat uporabljamo ekvivalentna opazovanja $\mathbf{l}_e$ in popravke ekvivalentnih opazovanj $\mathbf{v}_e \rightarrow$ enačbe popravkov za ekvivalentna opazovanja.

Za upoštevanje natančnosti opazovanj v izravnavi moramo za ekvivalentna opazovanja $\mathbf{l}_e$, izračunati še kovariančno matriko $\boldsymbol{\Sigma}_e$:

$$\boldsymbol{\Sigma}_e = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = \begin{bmatrix} 0.1400 & 0 & 0 & 0 \\ 0 & 0.2400 & 0 & 0 \\ 0 & 0 & 0.2400 & 0 \\ 0 & 0 & 0 & 0.2400 \end{bmatrix} \left[\mathrm{cm}^2\right]$$

(Kovariančno matriko $\boldsymbol{\Sigma}_e = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T$ izračunamo z zakonom o prenosu varianc za funkcijo $\mathbf{l}_e = \mathbf{A}\mathbf{l}$, ob dani kovariančni matriki $\boldsymbol{\Sigma}$ sl. vektorja $\mathbf{l}$.)

Če izberemo $\sigma_0^2 = 0,0100\ \mathrm{cm}^2$ je matrika uteži $\mathbf{P}_e$ ekvivalentnih opazovanj $\mathbf{l}_e$:

$$\mathbf{P}_e = {\sigma_0}^2 \boldsymbol{\Sigma}_e^{-1} = \begin{bmatrix} 0.0714 & 0 & 0 & 0 \\ 0 & 0.0417 & 0 & 0 \\ 0 & 0 & 0.0417 & 0 \\ 0 & 0 & 0 & 0.0417 \end{bmatrix}$$

Rešitev problema po metodi najmanjših kvadratov pridobimo z uporabo istih enačb kot v primeru posredne izravnave.

Razlika je le to, da vektor opazovanj $\mathbf{l}$ nadomešča vektor ekvivalentnih opazovanj $\mathbf{l}_e$ in matriko uteži opazovanj $\mathbf{P}$ nadomešča matrika uteži ekvivalentnih opazovanj $\mathbf{P}_e$.

Imamo torej:

$$\mathbf{N} = \mathbf{B}^T \mathbf{P}_e \mathbf{B} = \begin{bmatrix} 31.9940 & 2.2321 \\ 2.2321 & 0.1964 \end{bmatrix}$$

$$\mathbf{t} = \mathbf{B}^T \mathbf{P}_e \mathbf{f} = \begin{bmatrix} 0.0714 \\ 0.0143 \end{bmatrix}$$

$$\mathbf{N}^{-1} = \begin{bmatrix} 0.1509 & -1.7143 \\ -1.7143 & 24.5714 \end{bmatrix}$$

$$\boldsymbol{\Delta} = \mathbf{N}^{-1}\mathbf{t} = \begin{bmatrix} -0.0137 \\ 0.2286 \end{bmatrix} = \begin{bmatrix} \delta a \\ \delta b \end{bmatrix}$$

Popravljeni vrednosti neznank sta:

$$a_1 = a_0 + \delta a = 2 - 0,0137 = 1,9863$$
$$b_1 = b_0 + \delta b = 0 + 0,2286 = 0,2286$$

Popravljeni vrednosti neznank a_1 in b_1, določeni v prvem iteracijskem koraku, uporabimo v drugem iteracijskem koraku kot novi približni vrednosti za neznanki a in b.

Z rešitvijo problema v drugem iteracijskem koraku pridobimo nov vektor popravkov približnih vrednosti neznank in postopek nadaljujemo dokler ne dosežemo konvergence rešitve.

Kot smo omenili že lani, uporabimo za pridobitev numerično točne rešitve originalno nelinearnih enačb opazovanj oziroma v tem primeru enačb splošnega modela izravnave z iterativnim postopkom reševanja lineariziranih enačb.

Imamo torej:

$$\mathbf{A}_1 = \begin{bmatrix} -1,9863 & 1,0000 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1,9863 & 1,0000 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1,9863 & 1,0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -1,9863 & 1,0000 \end{bmatrix},\ \mathbf{B}_1 = \begin{bmatrix} -5 & -1 \\ -10 & -1 \\ -15 & -1 \\ -20 & -1 \end{bmatrix},\ \mathbf{f}_1 = \begin{bmatrix} -0,0400 \\ 0,0914 \\ 0,0229 \\ -0,0457 \end{bmatrix}$$

$$\mathbf{\Sigma}_{e_1} = \mathbf{A}_1 \mathbf{\Sigma} \mathbf{A}_1{}^T = \begin{bmatrix} 0,1395 & 0 & 0 & 0 \\ 0 & 0,2378 & 0 & 0 \\ 0 & 0 & 0,2378 & 0 \\ 0 & 0 & 0 & 0,2378 \end{bmatrix}$$

Ob vrednosti za referenčno varianco $\sigma_0^2 = 0{,}0100$ je:

$$\mathbf{P}_{e_1} = {\sigma_0}^2 \boldsymbol{\Sigma}_{e_1}^{-1} = \begin{bmatrix} 0.0717 & 0 & 0 & 0 \\ 0 & 0.0420 & 0 & 0 \\ 0 & 0 & 0.0420 & 0 \\ 0 & 0 & 0 & 0.0420 \end{bmatrix}$$

$$\mathbf{N}_1 = \mathbf{B}_1{}^T \mathbf{P}_{e_1} \mathbf{B}_1 = \begin{bmatrix} 32.2788 & 2.2508 \\ 2.2508 & 0.1979 \end{bmatrix}$$

$$\mathbf{t}_1 = \mathbf{B}_1{}^T \mathbf{P}_{e_1} \mathbf{f}_1 = \begin{bmatrix} -0.7536 \cdot 10^{-4} \\ -0.1507 \cdot 10^{-4} \end{bmatrix}$$

$$\mathbf{N}_1{}^{-1} = \begin{bmatrix} 0.1498 & -1.7044 \\ -1.7044 & 24.4427 \end{bmatrix}$$

$$\boldsymbol{\Delta}_1 = \mathbf{N}_1{}^{-1} \mathbf{t}_1 = \begin{bmatrix} 0.0144 \cdot 10^{-3} \\ -0{,}2400 \cdot 10^{-3} \end{bmatrix}$$

Ker sta elementa $\boldsymbol{\Delta}_1$ želeno majhna, zaustavimo iterativni postopek reševanja lineariziranega problema.

Končni vrednosti za ocenjeni vrednosti neznank sta tako:

$\hat{a} = 1{,}9863$ in $\hat{b} = 0{,}2283$ cm

Kot smo videli, je nekatere probleme izravnave možno rešiti s splošnim modelom izravnave, z uporabo enačb oblike $\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$.

Čeprav je načeloma možno rešiti vsak problem s katerokoli tehniko izravnave po MNK pa je pogosto lažje in bolj učinkovito reševati določene probleme z določeno tehniko.

Splošni model izravnave se tako uporablja v nalogah, ko koordinate točk obravnavamo kot opazovanja.

Takšni primeri so v geodeziji aproksimacija krivulj in ploskev ter transformacija koordinat.

Izkaže se, da je uporaba splošnega modela izravnave v teh nalogah tudi najlažja pot za rešitev problema.

IZPELJAVA REŠITVE SPLOŠNEGA MODELA IZRAVNAVE PO MNK

Za rešitev problema izravnave moramo najprej določiti parametre problema.

Na voljo imamo n opazovanj, minimalno število opazovanj, potrebno za enolično rešitev problema je n_0.

Ko je $n > n_0$ imamo na voljo nadštevilna opazovanja → izravnava.

Število nadštevilnih opazovanj r je zopet:

$r = n - n_0$

Kot vemo, med n–opazovanji obstaja r–neodvisnih pogojev.

Teh r–neodvisnih pogojev lahko zapišemo v obliki r–pogojnih enačb.

Če želimo v izravnavo vpeljati tudi neznanke, moramo za vsako neznanko zapisati dodatno enačbo.

Do sedaj smo n_0 enačili s številom neznank u.

Za u–neznank, vključenih v izravnavo in r nadštevilnih opazovanj bo <u>število enačb za rešitev problema</u> c, določeno z:

$c = r + u$

Komentar gornje enačbe:

1. Spodnja vrednost za število neznank u je očitno 0. V tem primeru v izravnavi nimamo neznank in velja:

$c = r$

Število enačb v izravnavi je tedaj enako številu pogojev r med opazovanji.

2. Zgornja meja za število neznank je $u = n_0$. V tem primeru je:

$c = r + n_0 = n$

To pomeni, da ne moremo sestaviti več enačb, kot je skupno število opazovanj (n).

Velja torej:

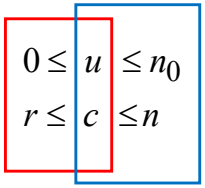

Spodnji meji za število neznank u in število enačb c določata pogojno izravnavo, gornji meji pa posredno izravnavo.

V mnogih primerih pa število neznank v funkcijskem modelu izravnave ni niti 0 niti n_0 .

V teh primerih nobena od že znanih tehnik izravnave (pogojna, posredna) ne bo primerna.

Namesto r –pogojnih enačb ali n –enačb opazovanj, sestavimo sedaj c –enačb splošnega modela izravnave v obliki:

$$\mathbf{A}\left(\mathbf{l}+\mathbf{v}\right)+\mathbf{B}\boldsymbol{\Delta}=\mathbf{d}$$

kjer je:

$\mathbf{A}$ = matrika numeričnih koeficientov opazovanj, $c\times n$ ($c\le n$)

$\mathbf{B}$ = matrika numeričnih koeficientov neznank, $c\times u$ ($c>u$)

$\mathbf{l}$ = vektor opazovanj, $n\times 1$

$\mathbf{v}$ = vektor popravkov opazovanj, $n\times 1$

$\boldsymbol{\Delta}$ = vektor neznank, $u\times 1$

$\mathbf{d}$ = vektor numeričnih konstant, $c\times 1$

Natančnost opazovanj predstavimo s kovariančno matriko $\boldsymbol{\Sigma}$, matriko kofaktorjev $\mathbf{Q}$ ali matriko uteži $\mathbf{P}$.

Obstajata dva načina/postopka izpeljave rešitve problema splošnega modela izravnave po MNK.

<u>Izpeljava rešitve splošnega modela izravnave – uvedba ekvivalentnih opazovanj</u>

To izpeljavo smo dejansko že opravili s pomočjo praktičnega primera.

Imamo c –enačb oblike:

$$\mathbf{Av} + \mathbf{B\Delta} = \mathbf{f}$$

Naj bo:

$$\mathbf{l}_e = \mathbf{Al}$$

vektor c –ekvivalentnih opazovanj $\mathbf{l}_e$.

Vektor c –ekvivalentnih opazovanj $\mathbf{l}_e$ je linearna kombinacija n –opazovanj $\mathbf{l}$.

Vektor popravkov ekvivalentnih opazovanj $\mathbf{v}_e$ je določen z:

$$\mathbf{v}_e = \mathbf{Av}$$

Vektor c –popravkov ekvivalentnih opazovanj $\mathbf{v}_e$ je prav tako linearna kombinacija n – popravkov opazovanj $\mathbf{v}$.

Dana je matrika kofaktorjev opazovanj $\mathbf{Q}$.

Za ekvivalentna opazovanja je treba določiti pripadajočo matriko kofaktorjev ekvivalentnih opazovanj $\mathbf{Q}_e$.

Določena je z uporabo zakona o prenosu kofaktorjev:

$$\underset{c\times c}{\mathbf{Q}_e} = \underset{c\times n}{\mathbf{A}}\ \underset{n\times n}{\mathbf{Q}}\ \underset{n\times c}{\mathbf{A}^T}$$

Enačbe popravkov za ekvivalentna opazovanja so:

$$\mathbf{l}_e + \mathbf{v}_e + \mathbf{B}\boldsymbol{\Delta} = \mathbf{d}$$

$$\mathbf{v}_e + \mathbf{B}\boldsymbol{\Delta} = \mathbf{d} - \mathbf{l}_e = \mathbf{f}$$

Matrika uteži ekvivalentnih opazovanj $\mathbf{l}_e$ je $\mathbf{P}_e$:

$$\mathbf{P}_e = \mathbf{Q}_e^{-1} = \left(\mathbf{A}\mathbf{Q}\mathbf{A}^T\right)^{-1}$$

Matrika normalnih enačb $\mathbf{N}$ je:

$$\mathbf{N} = \mathbf{B}^T\mathbf{P}_e\mathbf{B} = \mathbf{B}^T\left(\mathbf{A}\mathbf{Q}\mathbf{A}^T\right)^{-1}\mathbf{B}$$

vektor $\mathbf{t}$ je:

$$\mathbf{t} = \mathbf{B}^T\mathbf{P}_e\ \mathbf{f} = \mathbf{B}^T\left(\mathbf{A}\mathbf{Q}\mathbf{A}^T\right)^{-1}\mathbf{f}$$

Vektor neznank $\boldsymbol{\Delta}$ je:

$$\boldsymbol{\Delta} = \mathbf{N}^{-1}\mathbf{t}$$

Izpeljane enačbe enakovredne enačbam za rešitev problema posredne izravnave, ko uporabljamo ekvivalentna opazovanja.

Izpeljava – splošno

Metoda najmanjših kvadratov zahteva minimiziranje utežne funkcije Φ.

Za opazovanja različne natančnosti (opazovanja imajo matriko uteži $\mathbf{P}$) to zahtevo zapišemo:

$$\Phi = \mathbf{v}^T\mathbf{P}\mathbf{v} \quad \rightarrow \quad \min.$$

Ta enačba velja za kakršno koli obliko matrike uteži (za opazovanja enake ali različne natančnosti ter za nekorelirana in korelirana opazovanja).

Zopet imamo c–enačb splošnega modela izravnave:

$$\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f} \qquad (1)$$

ter:

$$\mathbf{f} = \mathbf{d} - \mathbf{A}\mathbf{l} \qquad (2)$$

V splošnem imamo opravka s c–nelinearnimi funkcijami $\mathbf{F}$, ki povezujejo opazovanja in neznanke:

$$\mathbf{F} = \mathbf{F}\left(\mathbf{l}, \mathbf{x}\right) = \mathbf{0} \qquad (3)$$

kjer je $\mathbf{l}$ vektor n–opazovanj in $\mathbf{x}$ vektor u–neznank.

Linearizacija enačbe (3) vodi do enačbe (1), kjer so:

$$\mathbf{A}_{ij} = \frac{\partial \mathbf{F}_i}{\partial \mathbf{l}_j}, \quad \mathbf{B}_{ij} = \frac{\partial \mathbf{F}_i}{\partial \mathbf{x}_j}, \quad \mathbf{f}_i = -\mathbf{F}_i(\mathbf{l}, \mathbf{x}_0) \tag{4}$$

Kjer so numerične vrednosti elementov matrik $\mathbf{A}$ in $\mathbf{B}$ ter vektorja $\mathbf{f}$ določene za vrednosti opazovanj $\mathbf{l}$ in približne vrednosti neznank $\mathbf{x}_0$.

Na podoben način, kot pri pogojni izravnavi, uvedemo tudi sedaj vektor c–Lagrangejevih multiplikatorjev oziroma vektor korelat $\mathbf{k}$.

Utežno funkcijo Φ nadomestimo z utežno funkcijo Φ':

$$\Phi' = \mathbf{v}^T\mathbf{P}\mathbf{v} - 2\mathbf{k}^T(\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} - \mathbf{f}) \;\rightarrow\; \text{minimum} \tag{5}$$

Za določitev minimuma funkcije Φ' parcialne odvode Φ' po neznanih vektorjih $\mathbf{v}$ in $\boldsymbol{\Delta}$ izenačimo z 0:

$$\frac{\partial \Phi'}{\partial \mathbf{v}} = 2\mathbf{v}^T\mathbf{P} - 2\mathbf{k}^T\mathbf{A} = \mathbf{0}$$

$$\frac{\partial \Phi'}{\partial \boldsymbol{\Delta}} = -2\mathbf{k}^T\mathbf{B} = \mathbf{0}$$

kar preuredimo in zapišemo:

$$\mathbf{P}\mathbf{v} = \mathbf{A}^T\mathbf{k} \tag{6}$$

$$\mathbf{B}^T\mathbf{k} = \mathbf{0} \tag{7}$$

Če iz enačbe (6) izrazimo vektor popravkov $\mathbf{v}$, imamo:

$$\mathbf{v} = \mathbf{P}^{-1}\mathbf{A}^T\mathbf{k} = \mathbf{Q}\mathbf{A}^T\mathbf{k} \tag{8}$$

Če vstavimo izraz za $\mathbf{v}$ v enačbo (1) dobimo:

$$\left(\mathbf{A}\mathbf{Q}\mathbf{A}^T\right)\mathbf{k} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$$

kar zapišemo:

$$\mathbf{Q}_e\mathbf{k} = \mathbf{f} - \mathbf{B}\boldsymbol{\Delta} \tag{9}$$

Če iz enačbe (9) izrazimo vektor $\mathbf{k}$, dobimo:

$$\mathbf{k} = \mathbf{Q}_e^{-1}(\mathbf{f} - \mathbf{B}\boldsymbol{\Delta}) = \mathbf{P}_e(\mathbf{f} - \mathbf{B}\boldsymbol{\Delta}) \tag{10}$$

Če enačbo (10) vstavimo v enačbo (7) dobimo:

$$\mathbf{B}^T\mathbf{P}_e(\mathbf{f} - \mathbf{B}\boldsymbol{\Delta}) = \mathbf{0}$$

kar preuredimo v:

$$\mathbf{B}^T\mathbf{P}_e\mathbf{B}\boldsymbol{\Delta} = \mathbf{B}^T\mathbf{P}_e\mathbf{f} \tag{11}$$

Kočno dobimo:

$$\mathbf{N}\boldsymbol{\Delta} = \mathbf{t} \tag{12}$$

kjer je:

$$\mathbf{N} = \mathbf{B}^T \mathbf{P}_e \ \mathbf{B} = \mathbf{B}^T (\mathbf{A}\mathbf{Q}\mathbf{A}^T)^{-1}\mathbf{B}$$

in

$$\mathbf{t} = \mathbf{B}^T \mathbf{P}_e \ \mathbf{f} = \mathbf{B}^T (\mathbf{A}\mathbf{Q}\mathbf{A}^T)^{-1}\mathbf{f}$$

Gornji enačbi sta enaki kot v primeru uvedbe ekvivalentnih opazovanj in uporabe ekvivalentnih enačb popravkov.

Če so enačbe splošnega modela izravnave nelinearne, pridobimo vektor ocenjenih vrednosti neznank z:

$$\hat{\mathbf{x}} = \mathbf{x}_0 + \boldsymbol{\Delta} \qquad (13)$$

Vektor popravkov opazovanj $\mathbf{v}$ dobimo, če vstavimo izraz za $\mathbf{k}$ iz enačbe (10) v enačbo (8):

$$\mathbf{v} = \mathbf{Q}\mathbf{A}^T\mathbf{k} = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{f} - \mathbf{B}\boldsymbol{\Delta}) \qquad (14)$$

Vektor popravljenih opazovanj $\hat{\mathbf{l}}$ dobimo z zvezo:

$$\hat{\mathbf{l}} = \mathbf{l} + \mathbf{v} \qquad (15)$$

S tem smo pridobili izraze za rešitev funkcijskega modela splošnega modela izravnave.

Primer:

(Nadaljevanje gornjega primera)

Izračunaj izravnane vrednosti koordinat treh točk na premici.

Imeli smo kovariančno matriko opazovanj:

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0,01 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0,10 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0,04 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0,08 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0,04 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0,08 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0,04 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0,08 \end{bmatrix} \left[\mathrm{cm}^2\right]$$

Izberemo vrednost referenčne variance $\sigma_0^2 = 0,0100$.

Matrika kofaktorjev $\mathbf{Q}$ je:

$$\mathbf{Q} = \frac{1}{\sigma_0^2}\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 10 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 4 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 8 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 8 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 8 \end{bmatrix}$$

V zadnji iteraciji smo imeli:

$$\mathbf{A}_1 = \begin{bmatrix} -1{,}9863 & 1{,}0000 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1{,}9863 & 1{,}0000 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1{,}9863 & 1{,}0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -1{,}9863 & 1{,}0000 \end{bmatrix},\ \mathbf{B}_1 = \begin{bmatrix} -5 & -1 \\ -10 & -1 \\ -15 & -1 \\ -20 & -1 \end{bmatrix},\ \mathbf{f}_1 = \begin{bmatrix} -0{,}0400 \\ 0{,}0914 \\ 0{,}0229 \\ -0{,}0457 \end{bmatrix}$$

$$\mathbf{\Sigma}_{e_1} = \mathbf{A}_1 \mathbf{\Sigma} \mathbf{A}_1{}^T = \begin{bmatrix} 0{,}1395 & 0 & 0 & 0 \\ 0 & 0{,}2378 & 0 & 0 \\ 0 & 0 & 0{,}2378 & 0 \\ 0 & 0 & 0 & 0{,}2378 \end{bmatrix}$$

Pri izpeljavi enačb za rešitev problema splošnega modela izravnave s pomočjo primera smo za referenčno varianco izbrali vrednost $\sigma_0^2 = 0{,}0100$ in dobili matriko uteži ekvivalentnih opazovanj $\mathbf{P}_e$:

$$\mathbf{P}_{e_1} = \sigma_0{}^2 \mathbf{\Sigma}_{e_1}^{-1} = \begin{bmatrix} 0{,}0717 & 0 & 0 & 0 \\ 0 & 0{,}0420 & 0 & 0 \\ 0 & 0 & 0{,}0420 & 0 \\ 0 & 0 & 0 & 0{,}0420 \end{bmatrix}$$

Popravki približnih vrednosti neznank so bili v zadnji iteraciji zanemarljivo majhni:

$$\mathbf{\Delta} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Vektor popravkov opazovanj izračunamo z uporabo zveze (14),

ki se ob upoštevnju gornje vrednosti za vektor $\boldsymbol{\Delta}$ preoblikuje v:

$$\mathbf{v} = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{f} - \mathbf{B}\boldsymbol{\Delta}) = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{f} = \begin{bmatrix} 0.0057 \\ -0.0288 \\ -0.0305 \\ 0.0307 \\ -0.0076 \\ 0.0077 \\ 0.0153 \\ -0.0154 \end{bmatrix} [\mathrm{cm}]$$

vektor izravnanih opazovanj pa je:

$$\hat{\mathbf{l}} = \mathbf{l} + \mathbf{v} = \begin{bmatrix} x_1 \\ y_1 \\ x_2 \\ y_2 \\ x_3 \\ y_3 \\ x_4 \\ y_4 \end{bmatrix} + \begin{bmatrix} v_{x1} \\ v_{y1} \\ v_{x2} \\ v_{y2} \\ v_{x3} \\ v_{y3} \\ v_{x4} \\ v_{y4} \end{bmatrix} = \begin{bmatrix} 5{,}0000 \\ 10{,}2000 \\ 10{,}0000 \\ 20{,}0000 \\ 15{,}0000 \\ 30{,}0000 \\ 20{,}0000 \\ 40{,}0000 \end{bmatrix} + \begin{bmatrix} 0{,}0057 \\ -0{,}0288 \\ -0{,}0305 \\ 0{,}0307 \\ -0{,}0076 \\ 0{,}0077 \\ 0{,}0153 \\ -0{,}0154 \end{bmatrix} = \begin{bmatrix} 5{,}0057 \\ 10{,}1712 \\ 9{,}9695 \\ 20{,}0307 \\ 14{,}9924 \\ 30{,}0077 \\ 20{,}0153 \\ 39{,}9846 \end{bmatrix} [\mathrm{cm}]$$

Izravnane koordinate štirih točk so tako:

TOČKA	$\hat{x}[cm]$	$\hat{y}[cm]$
1	5,0057	10,1712
2	9,9695	20,0307
3	14,9924	30,0077
4	20,0153	39,9846

Preveri, ali točke tudi zares ležijo na premici z enačbo
$y = 1{,}9863x + 0{,}2283$.

Primerjaj te rezultate z lanskoletnimi rezultati posredne izravnave.

NATANČNOST OCENE SPLOŠNEGA MODELA IZRAVNAVE

Poleg izračuna ocenjenih vrednosti neznank $\boldsymbol{\Delta}$ in popravkov $\mathbf{v}$ ter izravnanih opazovanj $\hat{\mathbf{l}}$ (rešitev funkcijskega modela) je treba izračunati tudi natančnost ocenjenih vrednosti (rešitev stohastičnega modela).

Zanimajo nas torej matrike kofaktorjev $\mathbf{Q}_{\Delta\Delta}$, $\mathbf{Q}_{\mathbf{vv}}$ in $\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$.

Za pridobitev rešitve stohastičnega modela izravnave uporabimo zakon o prenosu kofaktorjev.

Dano imamo kovariančno matriko opazovanj $\boldsymbol{\Sigma}$.

Na njeni osnovi določimo matriko kofaktorjev opazovanj $\mathbf{Q}$ in matriko uteži opazovanj $\mathbf{P}$.

Uporabimo zaporedni prenos kofaktorjev, pri čemer uporabimo enačbe rešitve funkcijskega modela izravnave (glej izpeljavo).

Za določitev matrike kofaktorjev ocenjenih vrednosti neznank $\mathbf{Q}_{\Delta\Delta}$ vstavimo izraz:

$$\mathbf{t} = \mathbf{B}^T \mathbf{P}_e \mathbf{f}$$

v izraz:

$$\boldsymbol{\Delta} = \mathbf{N}^{-1}\mathbf{t}$$

in dobimo:

$$\boldsymbol{\Delta} = \mathbf{N}^{-1}\mathbf{B}^T \mathbf{P}_e \mathbf{f} \qquad (16)$$

Vektor $\mathbf{f}$ zapišemo:

$$\mathbf{f} = \mathbf{d} - \mathbf{A}\mathbf{l}$$

in dobimo:

$$\boldsymbol{\Delta} = \mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e(\mathbf{d} - \mathbf{A}\,\mathbf{l}) \qquad (17)$$

Edini slučajni vektor v (17) je vektor opazovanj $\mathbf{l}$, njegova matrika kofaktorjev je $\mathbf{Q}$.

Prenos kofaktorjev za nelinearno in linearno funkcijsko zvezo zahteva določitev Jacobijeve matrike.

Jacobijevo matriko v našem primeru določajo parcialnimi odvodi funkcij (vektorja $\boldsymbol{\Delta}$) po opazovanjih (vektorju $\mathbf{l}$):

$$\mathbf{J}_{\boldsymbol{\Delta}\mathbf{l}} = \frac{\partial \boldsymbol{\Delta}}{\partial \mathbf{l}} = -\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\ \mathbf{A} \qquad (18)$$

Iz izraza za prenos varianc in kovarianc oziroma kofaktorjev za nelinearno funkcijo $\mathbf{Q}_{\mathbf{yy}} = \mathbf{J}_{\mathbf{yx}}\mathbf{Q}_{\mathbf{xx}}\mathbf{J}_{\mathbf{yx}}{}^T$ imamo:

$$\begin{aligned}
\mathbf{Q}_{\boldsymbol{\Delta}\boldsymbol{\Delta}} &= \mathbf{J}_{\boldsymbol{\Delta}\mathbf{l}}\mathbf{Q}\mathbf{J}_{\boldsymbol{\Delta}\mathbf{l}}{}^T \\
&= \left(-\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\ \mathbf{A}\right)\mathbf{Q}\left(-\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\ \mathbf{A}\right)^T \\
&= \mathbf{N}^{-1}\mathbf{B}^T\ \mathbf{P}_e\ \underbrace{\underbrace{\mathbf{A}\mathbf{Q}\mathbf{A}^T}_{=\mathbf{P}_e^{-1}}\mathbf{P}_e}_{=\mathbf{I}}\mathbf{B}\mathbf{N}^{-1} \\
&= \mathbf{N}^{-1}\underbrace{\mathbf{B}^T\mathbf{P}_e\,\mathbf{B}}_{=\mathbf{N}}\mathbf{N}^{-1}
\end{aligned}$$

Oziroma:

$$\mathbf{Q}_{\Delta\Delta} = \mathbf{N}^{-1} \qquad (19)$$

Kjer sta $\mathbf{N}$ ter tako tudi $\mathbf{N}^{-1}$ simetrični matriki.

Enačbe, ki povezujejo opazovanja in neznanke, so v splošnem nelinearne, zato jih lineariziramo z razvojem v Taylorjevo vrsto.

V tem primeru predstavlja $\mathbf{\Delta}$ vektor popravkov vektorja približnih vrednosti neznank $\mathbf{x}_0$.

Določiti moramo pa matriko kofaktorjev $\mathbf{Q}_{\hat{\mathbf{x}}\hat{\mathbf{x}}}$ končnega vektorja ocenjenih vrednosti neznank $\hat{\mathbf{x}}$.

V kakšni relaciji sta matrika kofaktorjev popravkov približnih vrednosti neznank in matrika kofaktorjev $\mathbf{Q}_{\hat{\mathbf{x}}\hat{\mathbf{x}}}$ končnega vektorja ocenjenih neznank $\hat{\mathbf{x}}$?

Iz enačbe $\hat{\mathbf{x}} = \mathbf{x}_0 + \mathbf{\Delta}$ vidimo, da je končna vrednost ocenjenega vektorja neznank vsota vektorjev $\mathbf{x}_0$ in $\mathbf{\Delta}$.

Če je $\mathbf{x}_0$ vektor neznank na začetku zadnje iteracije rešitve po MNK in $\mathbf{\Delta}$ vektor končnih popravkov približnih vrednosti neznank, je:

$$\mathbf{Q}_{\hat{\mathbf{x}}\hat{\mathbf{x}}} = \mathbf{Q}_{\Delta\Delta} = \mathbf{N}^{-1} \qquad (20)$$

ker lahko v tem primeru obravnavamo $\mathbf{x}_0$ kot vektor numeričnih konstant, ki smo ga določili pred zadnjo iteracijo.

Enačba (20) kaže tudi, da je matrika kofaktorjev ocenjenih vrednosti neznank zopet inverzna matrika matrike koeficientov normalnih enačb $\mathbf{N}$.

Natančnost ocene vrednosti neznank je torej stranski produkt izračuna ocenjenih vrednosti neznank samih.

Ker je enačba (5) enačba za izračun matrike kofaktorjev, celovita informacija o natančnosti ocenjenega vektorja neznank pa je zbrana v kovariančni matriki $\mathbf{\Sigma}_{\Delta\Delta}$.

Če je referenčna varianca $\sigma_0{}^2$ a–priori znana izračunamo $\mathbf{\Sigma_{\Delta\Delta}}$ oz. $\mathbf{\Sigma_{\hat{x}\hat{x}}}$:

$$\mathbf{\Sigma_{\hat{x}\hat{x}}} = \mathbf{\Sigma_{\Delta\Delta}} = \sigma_0^2 \mathbf{Q_{\Delta\Delta}} = \sigma_0^2 \mathbf{N}^{-1} \qquad (21)$$

Kako ravnamo, če referenčna varianca a–priori ($\sigma_0{}^2$) ni znana, bomo videli kasneje.

<u>Primer:</u>

Za gornji primer izračunaj matriko kofaktorjev $\mathbf{Q_{\Delta\Delta}}$ in kovariančno matriko $\mathbf{\Sigma_{\hat{x}\hat{x}}} = \mathbf{\Sigma_{\Delta\Delta}}$ ocenjenih neznank $\mathbf{\Delta}$.

V zadnji iteraciji je bila inverzna matrika $\mathbf{N}^{-1}$:

$$\mathbf{Q_{\hat{x}\hat{x}}} = \mathbf{Q_{\Delta\Delta}} = \mathbf{N}^{-1} = \begin{bmatrix} 0{,}1498 & -1{,}7044 \\ -1{,}7044 & 24{,}4427 \end{bmatrix}$$

Za referenčno varianco smo na začetku reševanja problema izbrali vrednost $\sigma_0^2 = 0{,}0100$.

Za to vrednost referenčne variance je kovariančna matrika ocenjenih neznank $\mathbf{\Sigma_{\Delta\Delta}}$:

$$\mathbf{\Sigma_{\hat{x}\hat{x}}} = \mathbf{\Sigma_{\Delta\Delta}} = \begin{bmatrix} 0{,}0015 & -0{,}0170 \\ -0{,}0170 & 0{,}2444 \end{bmatrix}$$

Standardna odklona $\sigma_{\hat{a}}$ in $\sigma_{\hat{b}}$ koeficientov premice $\hat{a}$ in $\hat{b}$ sta tako:

$\sigma_{\hat{a}} = 0{,}0387$ in $\sigma_{\hat{b}} = 0{,}4944$.

Zanimata nas še dve matriki kofaktorjev, in sicer matrika kofaktorjev popravkov opazovanj $\mathbf{Q_{vv}}$ in matrika kofaktorjev izravnanih opazovanj $\mathbf{Q_{\hat{l}\hat{l}}}$.

Za določitev $\mathbf{Q_{vv}}$ imamo:

$$\begin{aligned}\mathbf{k} &= \mathbf{P}_e(\mathbf{f} - \mathbf{B}\mathbf{N}^{-1}\mathbf{t}) \\ &= \mathbf{P}_e(\mathbf{f} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\mathbf{f}) \\ &= \mathbf{P}_e(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)(\mathbf{d} - \mathbf{A}\mathbf{l})\end{aligned} \qquad (22)$$

Vemo, da je tudi:

$$\mathbf{v} = \mathbf{Q}\mathbf{A}^T\mathbf{k} \qquad (23)$$

Če uporabimo splošni zakon o prenosu varianc in kovarianc za enačbo (22) in če vemo, da je $\mathbf{d}$ vektor konstant, imamo:

$$\mathbf{Q_{kk}} = (-\mathbf{P}_e(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{A})\mathbf{Q}(-\mathbf{P}_e(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{A})^T$$

kar preuredimo v:

$$\mathbf{Q_{kk}} = \mathbf{P}_e(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e) \qquad (24)$$

Omenimo lahko, da je matrika $\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e$ idempotentna.

Če sedaj uporabimo splošni zakon o prenosu kofaktorjev za (23), imamo:

$$\begin{aligned}\mathbf{Q_{vv}} &= \mathbf{Q}\mathbf{A}^T\mathbf{Q_{kk}}(\mathbf{Q}\mathbf{A}^T)^T \\ &= \mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{A}\mathbf{Q}\end{aligned} \tag{25}$$

Za določitev $\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$ pa iz (15), (14) in (16) sledi:

$$\begin{aligned}\hat{\mathbf{l}} &= \mathbf{l}+\mathbf{v} \\ &= \mathbf{l}+\mathbf{Q}\mathbf{A}^T\mathbf{P}_e\left(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\right)(\mathbf{d}-\mathbf{A}\mathbf{l}) \\ &= \left(\mathbf{I}-\mathbf{Q}\mathbf{A}^T\mathbf{P}_e\left(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\right)\mathbf{A}\right)\mathbf{l}+\mathbf{c}\end{aligned} \tag{26}$$

kjer je $\mathbf{c}=\mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{d}$ vektor konstant.

Z uporabo splošnega zakona o prenosu kofaktorjev za enačbo (26) imamo:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}=\left(\mathbf{I}-\mathbf{Q}\mathbf{A}^T\mathbf{P}_e\left(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\right)\mathbf{A}\right)\mathbf{Q}\left(\mathbf{I}-\mathbf{Q}\mathbf{A}^T\mathbf{P}_e\left(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e\right)\mathbf{A}\right)^T \tag{27}$$

kar po preurejanju vodi do:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}=\mathbf{Q}-\underbrace{\mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{I}-\mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{A}\mathbf{Q}}_{=\mathbf{Q_{vv}}} \tag{28}$$

Iz enačb (28) in (25) vidimo, da tudi tokrat veljajo enake zveze med $\mathbf{Q}$, $\mathbf{Q_{vv}}$ in $\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}$ kot v primeru posredne in pogojne izravnave:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}}=\mathbf{Q}-\mathbf{Q_{vv}} \tag{29}$$

Primer:

Izračunaj matriki kofaktorjev $\mathbf{Q_{vv}}$ in $\mathbf{Q_{\hat{l}\hat{l}}}$ za gornji primer.

Matrika kofaktorjev opazovanj je:

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 10 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 4 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 8 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 8 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 8 \end{bmatrix}$$

V zadnji iteraciji sta bili matriki $\mathbf{A}$ in $\mathbf{B}$:

$$\mathbf{A}_1 = \begin{bmatrix} -1{,}9863 & 1{,}0000 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1{,}9863 & 1{,}0000 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1{,}9863 & 1{,}0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -1{,}9863 & 1{,}0000 \end{bmatrix}, \quad \mathbf{B}_1 = \begin{bmatrix} -5 & -1 \\ -10 & -1 \\ -15 & -1 \\ -20 & -1 \end{bmatrix}$$

ter matriki $\mathbf{P}_e$ in $\mathbf{N}^{-1}$:

$$\mathbf{P}_{e_1} = \begin{bmatrix} 0{,}0717 & 0 & 0 & 0 \\ 0 & 0{,}0420 & 0 & 0 \\ 0 & 0 & 0{,}0420 & 0 \\ 0 & 0 & 0 & 0{,}0420 \end{bmatrix} \text{ in } \mathbf{N}^{-1} = \begin{bmatrix} 0{,}1498 & -1{,}7044 \\ -1{,}7044 & 24{,}4427 \end{bmatrix}$$

$\mathbf{Q_{vv}}$ je dana z izrazom (25):

$$\mathbf{Q_{vv}} = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e(\mathbf{I} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T\mathbf{P}_e)\mathbf{A}\mathbf{Q} =$$

$$= \begin{bmatrix} 0{,}0568 & -0{,}2861 & -0{,}3030 & 0{,}3051 & -0{,}0758 & 0{,}0763 & 0{,}1515 & -0{,}1526 \\ -0{,}2861 & 1{,}4402 & 1{,}5257 & -1{,}5362 & 0{,}3814 & -0{,}3841 & -0{,}7628 & 0{,}7681 \\ -0{,}3030 & 1{,}5257 & 2{,}0586 & -2{,}0728 & -0{,}4807 & 0{,}4841 & -0{,}3657 & 0{,}3682 \\ 0{,}3051 & -1{,}5362 & -2{,}0728 & 2{,}0872 & 0{,}4841 & -0{,}4874 & 0{,}3682 & -0{,}3708 \\ -0{,}0758 & 0{,}3814 & -0{,}4807 & 0{,}4841 & 1{,}8706 & -1{,}8835 & -1.0868 & 1{,}0943 \\ 0{,}0763 & -0{,}3841 & 0{,}4841 & -0{,}4874 & -1{,}8835 & 1{,}8965 & 1{,}0943 & -1{,}1019 \\ 0{,}1515 & -0{,}7628 & -0{,}3657 & 0{,}3682 & -1{,}0868 & 1{,}0943 & 0{,}8465 & -0{,}8523 \\ -0{,}1526 & 0{,}7681 & 0{,}3682 & -0{,}3708 & 1{,}0943 & -1{,}1019 & -0{,}8523 & 0{,}8582 \end{bmatrix}$$

Matrika kofaktorjev izravnanih opazovanj $\mathbf{Q_{\hat{l}\hat{l}}}$ pa je:

$$\mathbf{Q_{\hat{l}\hat{l}}} = \mathbf{Q} - \mathbf{Q_{vv}} =$$

$$= \begin{bmatrix} 0{,}9432 & 0{,}2861 & 0{,}3030 & -0{,}3051 & 0{,}0758 & -0{,}0763 & -0{,}1515 & 0{,}1526 \\ 0{,}2861 & 8{,}5598 & -1{,}5257 & 1{,}5362 & -0{,}3814 & 0{,}3841 & 0{,}7628 & -0{,}7681 \\ 0{,}3030 & -1{,}5257 & 1{,}9414 & 2{,}0728 & 0{,}4807 & -0{,}4841 & 0{,}3657 & -0{,}3682 \\ -0{,}3051 & 1{,}5362 & 2{,}0728 & 5{,}9128 & -0{,}4841 & 0{,}4874 & -0{,}3682 & 0{,}3708 \\ 0{,}0758 & -0{,}3814 & 0{,}4807 & -0{,}4841 & 2{,}1294 & 1{,}8835 & 1{,}0868 & -1{,}0943 \\ -0{,}0763 & 0{,}3841 & -0{,}4841 & 0{,}4874 & 1{,}8835 & 6{,}1035 & -1{,}0943 & 1{,}1019 \\ -0{,}1515 & 0{,}7628 & 0{,}3657 & -0{,}3682 & 1{,}0868 & -1{,}0943 & 3{,}1535 & 0{,}8523 \\ 0{,}1526 & -0{,}7681 & -0{,}3682 & 0{,}3708 & -1{,}0943 & 1{,}1019 & 0{,}8523 & 7{,}1418 \end{bmatrix}$$

Kovariančna matrika izravnanih koordinat treh točk je $\left(\sigma_0^2 = 0,0100\right)$:

$$\mathbf{\Sigma}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \sigma_0^2 \mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \begin{bmatrix} 0,0094 & 0,0029 & 0,0030 & -0,0031 & 0,0008 & -0,0008 & -0,0015 & 0,0015 \\ 0,0029 & 0,0856 & -0,0153 & 0,0154 & -0,0038 & 0,0038 & 0,0076 & -0,0077 \\ 0,0030 & -0,0153 & 0,0194 & 0,0207 & 0,0048 & -0,0048 & 0,0037 & -0,0037 \\ -0,0031 & 0,0154 & 0,0207 & 0,0591 & -0,0048 & 0,0049 & -0,0037 & 0,0037 \\ 0,0008 & -0,0038 & 0,0048 & -0,0048 & 0,0213 & 0,0188 & 0,0109 & -0,0109 \\ -0,0008 & 0,0038 & -0,0048 & 0,0049 & 0,0188 & 0,0610 & -0,0109 & 0,0110 \\ -0,0015 & 0,0076 & 0,0037 & -0,0037 & 0,0109 & -0,0109 & 0,0315 & 0,0085 \\ 0,0015 & -0,0077 & -0,0037 & 0,0037 & -0,0109 & 0,0110 & 0,0085 & 0,0714 \end{bmatrix}$$

Izračunaj standardne odklone izravnanih koordinat točk (izravnanih opazovanj).

Primerjaj jih s standardnimi odkloni koordinat (podatki opazovanj).

POSEBNA PRIMERA SPLOŠNEGA MODELA IZRAVNAVE

Pred splošnim modelom izravnave smo obravnavali dve tehniki izravnave po MNK, in sicer:

- posredno izravnavo
- pogojno izravnavo

Izkaže, da sta obe posebna primera splošnega modela izravnave.

POSREDNA IZRAVNAVA

Ta posebni primer nastopa, ko je u (število neznank, vključenih v izravnavo) enako svoji gornji meji n_0 (minimalno število opazovanj, potrebnih za enolično rešitev) in je tudi c (število enačb) enako svoji gornji meji, n (številu opazovanj).

Začetni sistem enačb splošnega modela izravnave zapišemo:

$$\mathbf{A}_0\mathbf{v} + \mathbf{B}_0\boldsymbol{\Delta} = \mathbf{f}_0 \qquad (1)$$

Kjer so $\mathbf{A}_0, \mathbf{B}_0$ in $\mathbf{f}_0$ začetne vrednosti matrik $\mathbf{A}$ in $\mathbf{B}$ ter vektorja $\mathbf{f}$.

Ko je $c = n$ je $\mathbf{A}_0$ kvadratna matrika, velikosti $n \times n$.

Enačbe splošnega modela izravnave morajo biti med seboj linearno neodvisne, zato je $\mathbf{A}_0$ nesingularna, kar pomeni, da obstaja tudi njena inverzna matrika $\mathbf{A}_0^{-1}$.

Izraz (1) pomnožimo z leve stani z $\mathbf{A}_0^{-1}$ in dobimo:

$\mathbf{A}_0^{-1}\mathbf{B}_0 = \mathbf{B}$ ter $\mathbf{A}_0^{-1}\mathbf{f}_0 = \mathbf{f}$.

Enačbe splošnega modela izravnave lahko sedaj zapišemo:

$$\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f} \qquad (2)$$

Kar je oblika enačb popravkov posredne izravnave.

Razlika med enačbo $\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$ in enačbo $\mathbf{A}\mathbf{v} + \mathbf{B}\boldsymbol{\Delta} = \mathbf{f}$ je v tem, da je v primeru enačb popravkov matrika $\mathbf{A}$ enotska matrika.

Če zamenjamo matriko $\mathbf{A}$ v izrazih za rešitev splošnega modela izravnave z enotsko matriko $\mathbf{I}$, imamo:

$$\mathbf{Q}_e = \mathbf{IQI} = \mathbf{Q} \qquad (3)$$

$$\mathbf{P}_e = \mathbf{Q}_e^{-1} = \mathbf{Q}^{-1} = \mathbf{P} \qquad (4)$$

$$\mathbf{N} = \mathbf{B}^T\mathbf{P}_e\mathbf{B}^T = \mathbf{B}^T\mathbf{PB} \qquad (5)$$

$$\mathbf{t} = \mathbf{B}^T\mathbf{P}_e\mathbf{f} = \mathbf{B}^T\mathbf{Pf} \qquad (6)$$

Gornje enačbe so enake enačbam za rešitev posredne izravnave.

Ko je $\mathbf{A} = \mathbf{I}$ in $\mathbf{P}_e = \mathbf{Q}^{-1}$, imamo:

$$\mathbf{v} = \mathbf{f} - \mathbf{B}\boldsymbol{\Delta} \tag{7}$$

Če je $\mathbf{N}$ določena z izrazom (5) je:

$$\mathbf{Q}_{\boldsymbol{\Delta}\boldsymbol{\Delta}} = \mathbf{N}^{-1}$$

Iz enačbe (25) sledi:

$$\mathbf{Q}_{\mathbf{vv}} = \mathbf{Q} - \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T \tag{8}$$

Enačba (28) pa se reducira v:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{B}\mathbf{N}^{-1}\mathbf{B}^T \tag{9}$$

kar je enako izrazom za rešitev posredne izravnave.

Velja pa tudi:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{Q} - \mathbf{Q}_{\mathbf{vv}} \tag{10}$$

POGOJNA IZRAVNAVA

Ta posebni primer nastopi, ko je u enak svoji spodnji meji (0) in, ko je število enačb c enako svoji spodnji meji (r) številu nadštevilnih opazovanj.

Brez neznank v izrazu člen $\mathbf{B\Delta}$ odpade in ostane samo:

$$\mathbf{Av} = \mathbf{f} \tag{1}$$

kar je oblika pogojnih enačb.

Da zagotovimo, da bo člen $\mathbf{B\Delta}$ mora biti $\mathbf{B} = \mathbf{0}$.

Matrika $\mathbf{B}$ bo ničelna matrika, ko v enačbah, ki povezujejo opazovanja in neznanke, neznanke ne bodo prisotne.

V tem primeru se enačba:

$$\mathbf{k} = \mathbf{P}_e\left(\mathbf{f} - \mathbf{B\Delta}\right)$$

reducira v:

$$\mathbf{k} = \mathbf{P}_e\mathbf{f} \tag{2}$$

kar je izraz za vektor korelat pri pogojni izravnavi.

Enačba:

$$\mathbf{v} = \mathbf{QA}^T\mathbf{k} \tag{3}$$

je že enaka enačbi za izračun vektorja popravkov pri pogojni izravnavi.

Ko je $\mathbf{B} = \mathbf{0}$ se enačba (25) reducira v:

$$\mathbf{Q_{vv}} = \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\mathbf{Q} \qquad (4)$$

in enačba (28) v:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{Q} - \mathbf{Q}\mathbf{A}^T\mathbf{P}_e\mathbf{A}\mathbf{Q} \qquad (5)$$

Vidimo, da ponovno velja:

$$\mathbf{Q}_{\hat{\mathbf{l}}\hat{\mathbf{l}}} = \mathbf{Q} - \mathbf{Q_{vv}} \qquad (6)$$

kar tudi na osnovi teh izrazov kaže, da je pogojna izravnava poseben primer splošnega modela izravnave.

V splošnem, lahko vsak problem, ki ga lahko rešimo s splošnim modelom izravnave, rešimo tudi s posebnima primeroma, če uporabimo ustrezne transformacije.

Te transformacije so lahko dokaj komplicirane in jih v praksi ne uporabljamo.

Namesto tega uporabimo določeno tehniko izravnave za rešitev določenega problema.

Izbira najprimernejše tehnike izravnave za rešitev danega problema temelji na izkušnjah.

VHODNI PODATKI V IZRAVNAVO PO MNK

V izravnavo naj bi vključiti samo opazovanja, za katera zanesljivo poznamo njihove vrednosti in pripadajočo natančnost.

Vrednotenje kakovosti opazovanj opravimo pred in po izravnavi, s postopkoma:

- predhodne (a-priori) analize opazovanj
- naknadne (a-posteriori) analize opazovanj

Predhodna analiza opazovanj je opravljena pred izravnavo opazovanj z namenom ugotovitve/določitve vplivov na opazovano količino.

Naknadna analiza opazovanj je opravljena z namenom ugotovitve dejansko dosežene kakovosti opazovanj. Določena je na osnovi nadštevilnih opazovanj, ob upoštevanju vrednosti opazovanj in geometrije matematičnega modela.

V obeh primerih nas poleg določitve natančnosti opazovanj zanimajo tudi pogreški v opazovanjih → odstranitev vseh znanih pogreškov.

Tradicionalno pogreške (kot vemo) delimo na slučajne, sistematične in grobe.

Slučajni pogreški se pojavljajo povsem slučajno.

Študij slučajnih pogreškov dobro pripravljenih in opravljenih meritev kaže, da ti sledijo naslednjim empiričnim pravilom:

- pojav majhnih slučajnih pogreškov je bolj verjeten kot pojav večjih slučajnih pogreškov,
- slučajni pogrešek ne preseže določene velikosti,
- frekvenci pojava slučajnih pozitivnega in negativnega predznaka sta enaki,
- ko število opazovanj narašča, se srednja vrednost slučajnih pogreškov približuje vrednosti 0.

Gornje empirične ugotovitve v matematični statistiki povzema normalna porazdelitev verjetnosti slučajnih pogreškov.

Vpliv slučajnih pogreškov na opazovanja in funkcije opazovanj lahko strogo ovrednotimo tudi po opravljeni izravnavi.

Grobi pogreški so običajno pogreški, ki so po svoji velikosti veliki in so v glavnem posledica napak operaterja, nepravilnega delovanja merskega instrumenta, napačne interpretacije situacije v kateri izvajamo meritve, napačnih oznak, zapisov…

Grobi pogreški se običajno pojavljajo povsem lokalno (vezani na specifično situacijo).

V izogib grobim pogreškom so vzpostavljeni ustrezni postopki izvedbe meritev ter postopki nadzora nad opravljenimi meritvami.

Ti postopki v glavnem vključujejo ponavljanje meritev in izkoriščanje različnih geometrijskih pogojev, ki jim morajo meritve zadostiti.

V splošnem grobi pogreški niso po svoji velikosti le veliki, so tudi srednje veliki in majhni.

Vrednotenje grobih pogreškov poteka v primerjavah morebitnega grobega pogreška z natančnostjo meritev.

Na voljo je nekaj (malo) statističnih postopkov, s katerimi vrednotimo prisotnost grobih pogreškov v meritvah.

Sistematični pogreški se pojavljajo v skladu z določenimi pravili.

Lahko so konstantni, konstantni z nasprotnim predznakom, linearna ali drugačna funkcija nekega vpliva na opazovanja…

Opazovanja naj bi bila prosta sistematičnih pogreškov, zato izvedemo meritve s kalibriranim merskim instrumentom in priborom, upoštevamo vse znane vplive na opazovanjs, primerjamo merjene vrednosti s predhodno določenimi količinami…

Pri zmanjševanju sistematičnih pogreškov je ključno dobro poznavanje merskega instrumentarija, metode meritev oz. merskega procesa in funkcijskega modela, na osnovi katerega bomo pridobili količine, ki nas zanimajo.

Razumeti treba, da sistematičnih pogreškov ne moremo v celoti odstraniti, zato po odstranitvi znanih sistematičnih vplivov in pogreškov obravnavamo preostale sistematične pogreške s postopki naknadnega vrednotenja rezultatov izravnave.

Dejstvo: v teoriji ni na voljo orodij za ločevanje slučajnih pogreškov, majhnih sistematičnih pogreškov in majhnih grobih pogreškov.

Predhodna analiza opazovanj

Pred izravnavo ocenimo opazovanja s t. i. predhodno analizo opazovanj, katere cilji so:

- odstranitev grobo pogrešenih opazovanj,
- upoštevanje vseh znanih vplivov na opazovanja (odstranitev sistematičnih pogreškov),
- določitev natančnosti opazovanj (določitev velikosti slučajnih pogreškov).

Nepristransko oceno za vse spremenljivke v modelu pridobimo le v primeru, ko so pravi pogreški opazovanj slučajno porazdeljeni.

Glede na dejstvo, da so v opazovanjih vedno prisotni tudi grobi pogreški, ki neposredno vplivajo na kakovost pridobljenih rezultatov, je potrebno prisotnosti grobih in/ali sistematičnih pogreškov v opazovanjih posvetiti ustrezno pozornost.

Pri tem je pomembno obravnavati prisotnost grobih in/ali sistematičnih pogreškov v opazovanjih na osnovi predhodne ocene/analize opazovanj, kot tudi na osnovi rezultatov izravnave opazovanj.

Potrebnost predhodne analize opazovanj izhaja iz dejstva, da izravnava po MNK zmanjša možnost odkritja grobih pogreškov v opazovanjih.

Grobo pogrešena opazovanja se v postopku izravnave »razlijejo« na vsa opazovanja, kar otežuje ugotavljanje njihove prisotnosti in lociranje.

Pogosta posledica je odstranitev napačnih opazovanj.

Z večjim številom poskusnih izravnav, v katere vključimo različne podmnožice celotne množice opazovanj, lahko sicer odkrijemo grobo pogrešena opazovanja, kar pa ni vedno slučaj.

Druga težava, ki včasih onemogoča pridobitev rešitve problema izravnave pa izhaja iz dejstva, da enačbe, ki povezujejo opazovanja in neznanke (če so te nelinearne) linearizirramo.

Za pridobitev točne rešitve v tem primeru uporabimo iterativni postopek.

Pri reševanju takšnih problemov se lahko pojavijo težave s konvergenco rešitve.

Predhodni analizi opazovanj je zato treba posvetiti ustrezno pozornost.

Odkrivanje grobo pogrešenih opazovanj po izravnavi je praviloma težje kot v okviru predhodne analize opazovanj.

Predhodna analiza opazovanj temelji na izpolnjevanju pogojev, ki jih morajo izpolniti opazovanja.

Pri ponovljenih opazovanjih iste količine gre za ugotavljanje medsebojne skladnosti ponovljenih opazovanj.

Pri ugotavljanju izpolnjevanja pogojev, ki jih morajo izpolniti opazovanja uporabljamo enostavne kontrole, kot so npr.: vsota kotov v mnogokotniku, vsota niveliranih višinskih razlik v zaključenem nivelmanskem vlaku ipd.

Običajno lahko velika odstopanja v primeru ponovljenih opazovanj, odstopanja v pogojnih enačbah ali odstopanja opazovanih vrednosti glede na predhodno pridobljene rezultate, obravnavamo kot grobo pogrešena opazovanja.

Osnova za vse postopke ugotavljanja prisotnosti grobih pogreškov v opazovanjih so statistični testi.

Statistični testi, ki jih uporabljamo, so povezani z dejansko porazdelitvijo verjetnosti popravkov opazovanj in njihovo skladnostjo s predpostavljeno porazdelitvijo le-teh.

S predhodno analizo opazovanj želimo določiti tudi prave vrednosti opazovanj.

Ker pa prave vrednosti opazovanj ne poznamo, skušamo določiti njihovo najboljšo oceno.

Pravi vrednosti opazovanj se približamo, če iz opazovanj odstranimo grobe in sistematične pogreške.

Po odstranitvi grobih in sistematičnih pogreškov primerjamo opazovanja med seboj in z danimi količinami.

Med posameznimi opazovanji naj bi bile razlike praviloma (nekajkrat) manjše od standardnega odklona opazovanj.

Uspešnost odstranitve sistematičnih vplivov in grobo pogrešenih opazovanj vrednotimo tudi z izračunom približnih vrednosti neznank, ki jih določimo večkrat iz različnih kombinacij opazovanj.

Ob odstranjevanju grobo pogrešenih opazovanj moramo paziti, da števila opazovanj preveč ne zmanjšamo oziroma da imamo po odstranitvi »sumljivih« opazovanj še vedno na dovolj nadštevilnih opazovanj.

Poskrbeti moramo, da, po odstranitvi »sumljivih« opazovanj, velja $n > n_0$ oziroma $r > 0$.

V nasprotnem je potrebno opraviti dodatna opazovanja ključnih količin za rešitev problema.

Vedeti je treba, da v matematičnem modelu lahko odkrijemo kvečjemu r –grobo pogrešenih opazovanj.

Postopki predhodne analize opazovanj

1. Ugotavljanje medsebojne skladnosti ponovljenih opazovanj

V primerih, ko imamo na voljo ponovljena opazovanja iste količine, lahko ugotavljamo skladnost posameznega opazovanja z drugimi opazovanji v istem nizu.

V splošnem definiramo ničelno hipotezo H_0 kot:

H_0 : l_i je skladno z drugimi opazovanji

Možne testne statistike za testiranje ničelne hipoteze so dane v sosednji tabeli.

Testno statistiko izberemo glede na to, ali poznamo srednjo vrednost (μ) in varianco (σ^2) populacije ali ne.

Velja:

- če poznamo pravo vrednost opazovane količine, poznamo tudi srednjo vrednost populacije,

- če poznamo natančnost uporabljenega instrumentarija, metode izmere… lahko trdimo, da poznamo varianco populacije in obratno.

	μ –znana	μ –neznana
σ –znana	$Y_1 = \frac{l_i - \mu}{\sigma}$	$Y_2 = \frac{l_i - \overline{l}}{\sigma\sqrt{\frac{n-1}{n}}}$
σ –neznana	$Y_3 = \frac{l_i - \mu}{s}$	$Y_4 = \frac{l_i - \overline{l}}{s\sqrt{\frac{n-1}{n}}}$

V gornji tabeli je $\overline{l}$ –srednja vrednost vzorca in s^2 –varianca vzorca, ki sta določeni:

$$\overline{l} = \frac{1}{n}\sum_{i=1}^{n} l_i$$

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(l_i - \overline{l}\right)^2$$

Ko je varianca populacije σ^2 znana (natančnost opazovanj je znana), testni statistiki Y_1 in Y_2 pripadata standardni normalni porazdelitvi $N(0,1)$.

Ob dani stopnji značilnosti testa α opazovanje l_i $(i=1,...,n)$ obravnavamo kot skladno z drugimi opazovanji l_j $(j \neq i, j=1,...,n)$, če velja:

$|Y_1|$ ali $|Y_2| \leq N(01,)_{(1-\alpha/2)}$

Statistiko Y_1 uporabimo, ko je srednja vrednost populacije μ znana, v nasprotnem primeru uporabimo testno statistiko Y_2.

Ko variance populacije ne poznamo, uporabimo testno statistiko Y_3 ali Y_4, v odvisnosti ali poznamo srednjo vrednost populacije μ ali ne.

Teoretično vzeto, če varianco s^2 *ocenimo iz neodvisnih podatkov*, se obe statistiki Y_3 in Y_4 porazdeljujeta s $t-$ porazdelitvijo z $(n-1)$ prostostnimi stopnjami.

V tem primeru ničelne hipoteze H_0 ne zavrnemo ob stopnji značilnosti α, če velja:

$$|Y_3| \text{ali } |Y_4| \leq t(n-1)_{(1-\alpha/2)}$$

Testno statistiko Y_3 uporabimo, če poznamo srednjo vrednost populacije μ, sicer uporabimo testno statistiko Y_4.

Če variance populacije σ^2 ne poznamo in ocenimo varianco vzorca s^2 *iz podatkov vzorca*, se obe statistiki Y_3 in Y_4 porazdeljujeta s $\tau-$ porazdelitvijo z $(n-1)$ prostostnimi stopnjami.

Ničelne hipoteze H_0 v tem primeru ne zavrnemo ob stopnji značilnosti α, če velja:

$$|Y_3| \text{ ali } |Y_4| \leq \tau(n-1)_{(1-\alpha/2)}$$

Tipične kritične vrednosti za standardno normalno porazdelitev $N(0,1)_{(1-\alpha/2)}$, $t(r)_{(1-\alpha/2)}$ in $\tau(r)_{(1-\alpha/2)}$ porazdelitev za stopnjo značilnosti $\alpha = 5\%$ in različne vrednosti r, so dane v tabeli (glej nadaljevanje).

2. Odkrivanje grobih pogreškov v opazovanjih na osnovi pogojev med opazovanji

Ko imamo na razpolago nadštevilna opazovanja, lahko ugotavljamo skladnost opazovanj s pogoji, ki jih morajo opazovanja izpolniti.

Pogoji, ki jih pri tem lahko uporabimo, izhajajo iz geometrijskih ali fizikalnih lastnosti problema.

Ker so opazovanja obremenjena s slučajnimi pogreški je pričakovana vrednost pravega pogreška v pogojno enačbo vključenih opazovanj enaka 0.

To dejstvo izkoristimo pri pripravi statističnega testa za ugotovitev prisotnosti grobih pogreškov v opazovanjih.

Če je pogojna enačba, ki jo morajo izpolniti opazovanja, linearna funkcija opazovanj, zapišemo odstopanje f_i v i–ti pogojni enačbi, kot:

$$f_i = d_i - \sum_{j=1}^{n} a_j l_j = d_i - \mathbf{a}^T \mathbf{l}$$

kjer je:

$\mathbf{a}^T = \begin{bmatrix} a_1 & a_2 & \dots & a_n \end{bmatrix}$ vektor koeficientov (konstant), $\mathbf{l} = \begin{bmatrix} l_1 & l_2 & \dots & l_n \end{bmatrix}^T$ vektor opazovanj, d_i konstanta, $l_j, (j = 1,\dots,n)$ n–opazovanj in $a_j, (j = 1,\dots,n)$ n–koeficientov $i-$ te pogojne enačbe.

Ko je pogojna enačba $g_i = g_i(l_1, l_2, ..., l_n)$ nelinearna funkcija opazovanj, je odstopanje f_i v i – ti pogojni enačbi dano z:

$$f_i = d_i - \sum_{j=1}^{n} \frac{\partial g_i}{\partial l_j} l_j = d_i - \mathbf{a}^T \mathbf{l}$$

kjer je sedaj:

$\mathbf{a}^T = \left[\frac{\partial g_i}{\partial l_1} \quad \frac{\partial g_i}{\partial l_2} \quad ... \quad \frac{\partial g_i}{\partial l_m} \right]$ vektor parcialnih odvodov nelinearnih funkcij g_i, $\mathbf{l} = \left[l_1 \quad l_2 \quad ... \quad l_n \right]^T$.

Za testiranje ali je odstopanje (pravi pogrešek) f_i v i – ti pogojni enačbi normalno porazdeljeno s srednjo vrednostjo enako 0 sestavimo ničelno hipotezo H_0:

$$H_0 : \; E\{f_i\} = 0$$

Testno statistiko Y_i za testiranje pravega pogreška (odstopanja) f_i v i –pogojni enačbi sestavimo kot:

$$Y_i = \frac{f_i}{\sigma_{f_i}}$$

Standardni odklon pravega pogreška σ_{f_i} je določen z uporabo zakona o prenosu varianc in kovarianc:

$$\sigma_{f_i} = \sqrt{\mathbf{a}^T \mathbf{\Sigma}_{ll} \mathbf{a}}$$

$\mathbf{\Sigma}_{ll} = \mathbf{\Sigma}$ je kovariančna matrika opazovanj.

Ko je a-priori kovariančna matrika opazovanj $\boldsymbol{\Sigma}_{ll}$ znana, se testna statistika Y_i porazdeljuje s standardno normalno porazdelitvijo $Y_i \sim N(0,1)$.

Ob stopnji značilnosti testa α obravnavamo odstopanje f_i kot statistično značilno preveliko (zavrnemo ničelno hipotezo H_0) s stopnjo značilnosti α, če velja:

$$|Y_i| > N(0,1)_{(1-\alpha/2)}$$

kjer je $N(0,1)_{(1-\alpha/2)}$ kritična vrednost.

Če a-priori kovariančna matrika opazovanj ni znana, jo ocenimo na osnovi opazovanj.

Izračunamo jo na osnovi matrike kofaktorjev in z uporabo referenčnega standardnega odklona opazovanj a-posteriori $\hat{\sigma}_0$, ki ga določimo na osnovi opazovanj.

V tem primeru je standardni odklon pravega pogreška $\hat{\sigma}_{f_i}$ določen z:

$$\hat{\sigma}_{f_i} = \hat{\sigma}_0 \sqrt{\mathbf{a}^T \mathbf{Q}_{ll} \mathbf{a}}$$

kjer je $\mathbf{Q}_{ll}$ matrika kofaktorjev opazovanj in $\hat{\sigma}_0$ referenčni standardni odklon a-posteriori.

Referenčni standardni odklon a-posteriori $\hat{\sigma}_0$ lahko določimo na osnovi istega niza opazovanj, ki je predmet obravnave ali iz neodvisnih podatkov.

V prvem primeru se testna statistika Y_i porazdeljuje s τ –porazdelitvijo, v drugem primeru pa s $t-$ porazdelitvijo.

Ničelno hipotezo sedaj zavrnemo, odvisno od načina določitve referenčnega standardnega odklona a-posteriori $\hat{\sigma}_0$, če velja:

$$|Y_i| > \tau(r)_{(1-\alpha/2)}$$

ali

$$|Y_i| > t(r)_{(1-\alpha/2)}$$

kjer je r –število nadštevilnih opazovanj ($r = n - n_0$), s katerim je bila določena referenčna varianca a-posteriori $\hat{\sigma}_0^2$.

Referenčno varianco a-posteriori $\hat{\sigma}_0^2$ določimo z izrazom:

$$\hat{\sigma}_0^2 = \frac{\mathbf{v}^T \mathbf{P} \mathbf{v}}{n - n_0}$$

Več o referenčni varianci a-posteriori $\hat{\sigma}_0^2$ še sledi.

Numerične vrednosti τ -porazdelitve pridobimo na osnovi t – porazdelitve iz izraza:

$$\tau(r)_{(1-\alpha/2)} = \frac{\sqrt{r} \cdot t(r-1)_{(1-\alpha/2)}}{\sqrt{r - 1 + \left(t(r-1)_{(1-\alpha/2)}\right)^2}}$$

Kritične vrednosti za porazdelitve $N(0,1)_{(1-\alpha/2)}$, $t(r)_{(1-\alpha/2)}$ in $\tau(r)_{(1-\alpha/2)}$ ob dani stopnji zaupanja $(1-\alpha)$ pridobimo analitično ali iz tabel.

r	$N(0,1)_{(1-\alpha/2)}$	$t(r)_{(1-\alpha/2)}$	$\tau(r)_{(1-\alpha/2)}$
2	1.96	1.41	4.30
3	1.96	1.64	3.18
4	1.96	1.76	2.78
5	1.96	1.81	2.57
6	1.96	1.85	2.45
7	1.96	1.87	2.37
8	1.96	1.88	2.31
9	1.96	1.90	2.26
10	1.96	1.90	2.23
15	1.96	1.93	2.13
20	1.96	1.94	2.09
25	1.96	1.94	2.06
30	1.96	1.94	2.04
35	1.96	1.95	2.03
40	1.96	1.95	2.02
50	1.96	1.95	2.01
60	1.96	1.95	2.00
80	1.96	1.96	1.99
100	1.96	1.96	1.98

Kritične vrednosti za $\tau(r)$, $t(r)$ in $N(0,1)$ porazdelitve za stopnjo značilnosti $\alpha = 5\%$

V praksi pogosto uporabljamo približno oceno prisotnosti grobih pogreškov v opazovanjih.

Ta ocena temelji na kriteriju, da je vsako odstopanje v pogojni enačbi (pravi pogrešek), ki je dvakrat večje od pripadajočega standardnega odklona tega odstopanja potrebno obravnavati glede prisotnosti grobih pogreškov.

Za različne vrste meritev v geodeziji je na osnovi praktičnih izkušenj pridobljenih tudi nekaj drugih pravil za ocenjevanje prisotnosti grobih pogreškov v opazovanjih.

Tako obstajajo pravila za ocenjevanje prisotnosti grobih pogreškov v zaključenem nivelmanu, v zaključenih figurah v geodetskih mrež GNSS, odstopanja v trilateraciji in triangulaciji,...

Za ugotavljanje prisotnosti grobih pogreškov v opazovanjih je torej treba preveriti izpolnjevanje vseh možnih pogojev med opazovanji v obravnavani nalogi, kar pa zahteva sistematičen postopek obravnave opazovanj.

Tovrstni postopki so bili v primerih različnih vrst opazovanj, vključenih v večje matematične modele za človeka, skoraj neobvladljivi.

S pojavom elektronskih računalnikov je postal problem obvladljiv, čeprav zelo učinkovitih algoritmov za odkrivanje grobih pogreškov pred izravnavo opazovanj v matematičnem modelu ni ravno na pretek.

Določitev natančnosti podatkov meritev (vhodnih podatkov v izravnavo)

Za pridobitev optimalnih rezultatov izravnave moramo sestaviti tudi ustrezen stohastični model izravnave.

Stohastični model predstavljajo vhodni standardni odkloni opazovanj in korelacije med opazovanji (dejanska natančnost opazovanj).

Za pravilno oceno natančnosti opazovanj imamo pred izravnavo naslednje možnosti:

1. Določitev standardnega odklona opazovanj na osnovi ponovljenih opazovanj iste količine. Tako določen standardni odklon opazovanj je praviloma slabo določen, ker je vzorec opazovanj običajno majhen.
2. Za standardni odklon opazovanj iste vrste uporabimo enako vrednost (predpostavimo npr. enako natančnost kotnih količin).
3. Za standardni odklon posameznega opazovanja uporabimo podatek proizvajalca geodetskega instrumenta.
4. Uporabimo zakon o prenosu varianc in kovarianc in tako upoštevamo vplive, ki v standardnem odklonu, danem od proizvajalca geodetskega instrumenta, niso upoštevani (centriranje, refrakcija, signalizacija, operater,…).
5. Sestavimo matriko kofaktorjev opazovanj in matriko uteži opazovanj.
6. S primerno izbrano vrednostjo referenčne variance a-priori sestavimo ustrezno kovariančno matriko opazovanj.

Pravilen funkcijski in stohastični model izravnave → pravilna rešitev problema

VREDNOTENJE REZULTATOV IZRAVNAVE PO MNK

Rezultat izravnave po MNK je vektor popravkov opazovanj $\mathbf{v}$, vektor izravnanih opazovanj $\hat{\mathbf{l}}$ in vektor ocenjenih neznank $\boldsymbol{\Delta}$ ter pripadajoče kovariančne matrike.

Pred izravnavo naj bi opazovanja popravili za vrednosti sistematičnih vplivov ter odstranili grobo pogrešena opazovanja.

Kljub temu pa moramo pred nadaljnjo uporabo rezultatov izravnave ugotoviti, ali so ti ustrezne kakovosti.

To je glavna naloga ocenjevanja rezultatov izravnave.

Pri vrednotenju kakovosti rezultatov izravnave ocenjujemo:

- popravke opazovanj,
- ocenjene vrednosti neznank,
- kovariančne matrike neznank, popravkov opazovanj, izravnanih opazovanj,
- vrednost referenčne variance $\hat{\sigma}_0^2$ a-posteriori.

Ocenjevanje rezultatov izravnave je v glavnem omejeno na ugotavljanje in odstranjevanje grobo pogrešenih opazovanj, ki so po velikosti pogreškov »malo grobo pogrešena«.

Pri tem predpostavljamo, da smo »močno grobo pogrešena« opazovanja odstranili med samo izmero, s predhodno analizo opazovanj ali v okviru obeh postopkov.

Izravnava po metodi najmanjših kvadratov teži k prenosu vpliva grobo pogrešenega opazovanja na vse rezultate izravnave.

Tako se veliki popravki opazovanj lahko pojavijo za opazovanja v bližini grobo pogrešenega opazovanja, in ne samo za grobo pogrešena opazovanja.

Zaradi lokalnega vpliva, ki ga imajo grobo pogrešena opazovanja v izravnavi, laže odkrijemo »močno grobo pogrešena« opazovanja.

Včasih grobo pogrešeno opazovanje vodi do težav s konvergenco rešitve.

Ocenjevanje rezultatov izravnave vključuje statistično testiranje z izravnavo ocenjenih količin.

V glavnem je omejeno na vrednotenje popravkov opazovanj.

Popravki opazovanj so merilo kakovosti opazovanj kot tudi merilo kakovosti matematičnega modela.

Slaba opazovanja ter slab matematični model izravnave imata podoben vpliv na rezultate izravnave.

Zato je težko, včasih celo nemogoče, ločiti oba možna vzroka za slabe rezultate izravnave.

Ocenjevanje rezultatov izravnave tako vključuje hkratno testiranje modela izravnave in opazovanj.

V okviru reševanja najpogostejših nalog v geodeziji je matematični model običajno enostaven, ker temelji na enostavnih geometrijskih in fizikalnih zakonih.

To pomeni, da smo praviloma sposobni sestaviti ustrezen matematični model za rešitev problema izravnave.

V taki situaciji pa lahko odkrivamo opazovanja, ki so obremenjena z grobimi pogreški.

Popravki opazovanj in grobi pogreški

Ključna količina v vrednotenju rezultatov izravnave so z izravnavo ocenjeni popravki opazovanj:

$$\mathbf{v} = \hat{\mathbf{l}} - \mathbf{l} \qquad (1a)$$

Vektor popravkov opazovanj $\mathbf{v}$ je za posredno izravnavo:

$$\mathbf{v} = \mathbf{f} - \mathbf{B}\boldsymbol{\Delta} = \left[\mathbf{I} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T\mathbf{P} \right] \mathbf{f} = \mathbf{R}\mathbf{f} \qquad (1b)$$

Kjer je vektor $\mathbf{f}$ določen:

$$\mathbf{f} = -\mathbf{F}(\boldsymbol{\Delta}_0, \mathbf{l}) \qquad (1c)$$

Iz izrazov (1a) in (1b) sledi:

$$\mathbf{v} = \hat{\mathbf{l}} - \mathbf{l} = \mathbf{R}\mathbf{f} \qquad (1d)$$

oziroma:

$$\mathbf{v} = \mathbf{R}\mathbf{f} = \mathbf{R}\left(\mathbf{d} - \mathbf{l}\right) \qquad (1e)$$

Ko je zveza med opazovanji in neznankami nelinearna, problem linearizíramo. Linearizacijo izvedemo v okolici približnih vrednosti neznank $\boldsymbol{\Delta}_0$. Vektorja $\mathbf{d}$ in $\mathbf{f}$ sta za linearizíran nelinearen problem odvisna od približnih vrednosti neznank $\boldsymbol{\Delta}_0$.

V gornjih izrazih je: $\mathbf{B}$ matrika koeficientov neznank, $\mathbf{P}$ matrika uteži, $\mathbf{l}$ vektor opazovanj, $\hat{\mathbf{l}}$ vektor ocenjenih opazovanj, $\mathbf{v}$ vektor popravkov opazovanj, $\mathbf{f}$ vektor »odstopanj« v enačbah popravkov opazovanj, $\boldsymbol{\Delta}_0$ je vektor približnih vrednosti neznank, $\boldsymbol{\Delta}$ vektor popravkov približnih vrednosti neznank in $\mathbf{R}$ matrika nadštevilnosti (angl: redundancy matrix).

Matrika nadštevilnosti $\mathbf{R}$ je določena z zvezo:

$$\mathbf{R} = \mathbf{I} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T\mathbf{P} \tag{2}$$

Zapišemo jo lahko kot:

$$\mathbf{R} = \begin{bmatrix} r_1 & r_{12} & \cdots & r_{1i} & \cdots & r_{1n} \\ r_{21} & r_2 & \cdots & r_{2i} & \cdots & r_{2n} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ r_{i1} & r_{i2} & \cdots & r_i & \cdots & r_{in} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ r_{n1} & r_{n2} & \cdots & r_{ni} & \cdots & r_n \end{bmatrix} \tag{3}$$

kjer so $r_i \ (i = 1,...,n)$ diagonalni in $r_{ij} \ (i \neq j)$ izven-diagonalni členi matrike $\mathbf{R}$.

Posamezen popravek $v_i \ (i = 1,...,n)$, glede na enačbo (1b), zapišemo kot:

$$v_i = \sum_{j=1}^{n} r_{ij} f_j \quad (i = 1,...,n) \tag{4}$$

Ugotovimo lahko, da je matrika kofaktorjev $\mathbf{Q_{vv}}$ vektorja popravkov $\mathbf{v}$ določena z zvezo:

$$\mathbf{Q_{vv}} = \mathbf{RP} \tag{5}$$

Izraz (5) preveri sam.

Vzrok za pojav popravkov opazovanj naj bi (teoretično) bili slučajni pogreški opazovanj.

Grobi pogrešek je pogrešek, ki predstavlja večje odstopanje v opazovanjih.

Predpostavimo, da vektor opazovanj $\mathbf{l}$ vsebuje vektor grobo pogrešenih opazovanj $\nabla\mathbf{l}$.

Vpliv grobo pogrešenih opazovanj $\nabla\mathbf{l}$ na vektor popravkov opazovanj $\mathbf{v}$ je dan z:

$$\nabla\mathbf{v} = -\mathbf{R}\nabla\mathbf{l} \qquad (6)$$

Enačba (6) velja kljub temu, da velja $\mathbf{v} = \mathbf{Rf}$ (grobo pogrešena opazovanja $\nabla\mathbf{l}$ imajo vpliv na popravke, vektor $\mathbf{d}$ ga nima).

Vpliv vektorja grobo pogrešenih opazovanj $\nabla\mathbf{l}$ na popravek i–tega opazovanja ∇v_i, je tako:

$$\nabla v_i = -\sum_{j=1}^{n} r_{ij}\nabla l_j \quad (i = 1,...,n) \qquad (7)$$

Popravek, ki vsebuje vpliv slučajnih in grobih pogreškov opazovanj lahko zapišemo:

$$\breve{v}_i = v_i + \nabla v_i \quad (i = 1,...,n) \qquad (8)$$

Prisotnost grobih pogreškov, praviloma, poveča velikost popravkov opazovanj.

Popravek opazovanja, ki preseže določene mejne vrednosti, ki temeljijo na privzetih statističnih lastnostih opazovanj imenujemo »popravek verjetno grobo pogrešenega opazovanja« (angl.: »outlier«).

Kot smo omenili, je popravek opazovanja določen kot posledica različnih pogreškov opazovanj od slučajnih in sistematičnih do grobih.

Iz matrike kofaktorjev popravkov opazovanj $\mathbf{Q_{vv}}$ (5) izhaja, da so popravki med seboj korelirani ($\mathbf{Q_{vv}}$ je polna matrika) tudi, ko so opazovanja nekorelirana (diagonalna matrika uteži $\mathbf{P}$), ker je matrika $\mathbf{R}$ v splošnem polna matrika.

Iz enačb (4) in (7) izhaja, da je popravek vsakega opazovanja linearna kombinacija vseh opazovanj.

Večja, kot je koreliranost popravkov, bolj zapletena je linearna odvisnost popravkov od opazovanj.

Spreminjanje vrednosti posameznega opazovanja (grobi pogrešek v enem opazovanju) se izraža na večjem številu popravkov.

Velja tudi obratno, da se spreminjanje vrednosti večjega števila opazovanj lahko izraža v samo enem popravku.

Bolj verjetna je sicer prva situacija.

V primeru, ko popravki med seboj niso korelirani, to je v primeru, ko je matrika $\mathbf{R}$ diagonalna, bo tudi matrika $\mathbf{Q_{vv}}$ diagonalna.

Takrat bo sprememba vrednosti enega opazovanja vplivala na opazovanju pripadajoč popravek.

Zaradi koreliranosti popravkov je težko ugotoviti, v katerem opazovanju je prisoten grobi pogrešek (katero opazovanje je povzročilo povečanje popravka).

Koreliranost popravkov in dejstvo, da je vsak popravek linearna kombinacija vseh opazovanj sta razloga, da ločimo:

- odkrivanje prisotnosti verjetno grobo pogrešenih opazovanj
- lociranje grobo pogrešenih opazovanj.

Predpostavimo, da imamo med opazovanji $l_i \quad (\mathrm{i}=1,...,n)$ prisoten en grobi pogrešek ∇l_i.

Uvedemo vektor $\nabla_i \mathbf{l}$:

$$\nabla_i \mathbf{l} = \begin{bmatrix} 0 & 0 & \dots & 0 & \nabla l_i & 0 & \dots & 0 \end{bmatrix}^T \qquad (9)$$

ki vsebuje na mestu grobo pogrešenega opazovanja grobi pogrešek ∇l_i, ostali elementi so enaki 0.

Vpliv vektorja grobo pogrešenih opazovanj $\nabla_i \mathbf{l}$ (oziroma grobega pogreška ∇l_i) na vektor popravkov je določen z enačbo (6) in ga predstavlja vektor $\nabla \mathbf{v}$:

$$\nabla \mathbf{v} = -\mathbf{R} \nabla_i \mathbf{l} \qquad (10)$$

Vpliv grobega pogreška ∇l_i na temu opazovanju pripadajoč popravek $\nabla_i v_i$ izhaja iz enačbe (7).

Ta vpliv je določen z odgovarjajočim diagonalnim elementom matrike $\mathbf{R}$, kar lahko zapišemo kot:

$$\nabla_i v_i = -r_i \nabla l_i \qquad (11)$$

kjer je:

$$r_i = (\mathbf{R})_{ii} \qquad (12)$$

Diagonalni element $r_i = (\mathbf{R})_{ii}$ matrike $\mathbf{R}$ imenujemo število nadštevilnosti (angl. redundancy number).

Dokazati se da, da je vrednost števila nadštevilnosti r_i vedno med 0 in 1:

$$0 \le r_i \le 1 \qquad (13)$$

ter, da je vsota števil nadštevilnosti r_i posameznih opazovanj l_i enaka številu nadštevilnih opazovanj $-r$ matematičnega modela:

$$\sum_{i=1}^{n} r_i = r = n - n_0 \qquad (14)$$

Vpliv $\nabla_i v_j \quad (j \neq i)$ grobega pogreška ∇l_i v opazovanju l_i na druge popravke $v_j \quad (j \neq i, j = 1,...,n)$ pa je dan z izven-diagonalnimi elementi matrike $\mathbf{R}$:

$$\nabla_i v_j = -r_{ji} \nabla l_i \quad (j \neq i,\ j = 1,...,n) \qquad (15)$$

kjer je:

$$r_{ji} = (\mathbf{R})_{ji} \quad (j \neq i,\ j = 1,...,n) \qquad (16)$$

Ker je število nadštevilnosti vedno v mejah $0 \le r_i \le 1$, je samo del grobega pogreška vključen v popravke.

Preostali del grobo pogrešenega opazovanja se prenese v neznanke.

Grobi pogrešek ∇l_i opazovanja, ki ima veliko število nadštevilnosti r_i bo imel velik vpliv na temu opazovanju pripadajoči popravek v_i .

To pomeni, da večje število nadštevilnosti r_i omogoča boljši nadzor nad opazovanji.

Po drugi strani pa iz enačbe (15) izhaja, da se lahko grobi pogrešek ∇l_i opazovanja l_i prenese na vse popravke.

Za ugotovitev, katero opazovanje je grobo pogrešeno na osnovi analize popravka grobo pogrešenega opazovanja v_i , mora biti absolutna vrednost $\nabla_i v_i$ večja od $\nabla_i v_j \quad (j \neq i,\ j = 1,...,n)$, oziroma glede na enačbi (11) in (15):

$$r_i > \left| r_{ji} \right| \quad (j \neq i,\ j = 1,...,n) \tag{17}$$

V takem primeru, lahko ob sumu, da je opazovanje l_i grobo pogrešeno tudi ocenimo velikost grobega pogreška ∇l_i , in sicer na osnovi izračunanega popravka $\nabla_i v_i$ tega opazovanja.

Iz (11) izhaja:

$$\nabla l_i = -\frac{\nabla_i v_i}{r_i} \tag{18}$$

Kar pa vodi do smiselnega rezultata (ocene velikosti grobega pogreška) le pod pogojem, da je izpolnjena zahteva (17).

V primeru, ko velja:

$$r_i \leq \max\left\{\left|r_{ij}\right| \ (j \neq i, \ \ j = 1,...,n)\right\} \qquad (19)$$

pa je ugotavljanje prisotnosti grobih pogreškov oteženo.

Glede števila nadštevilnosti r_i obstajata dve skrajni situaciji.

Prvi in tudi idealni primer nastopi, ko je $r_i = 1$.

Ta slučaj nastopi za opazovanja danih količin.

V tem primeru bo verjetnost ugotovitve prisotnosti grobega pogreška ∇l_i v opazovanju opazovanja l_i enaka 100%.

Druga in tudi slaba možnost nastopi, ko je $r_i = 0$.

Grobi pogrešek takšnega opazovanja ne bo vplival na nobenega od popravkov opazovanj, zato tudi ne bo mogel biti odkrit in bo v celoti prešel v neznanke.

Povprečno število nadštevilnosti matematičnega modela je dano z:

$$\overline{r} = \frac{r}{n} \qquad (20)$$

Če je matematični model slabo sestavljen, se število nadštevilnosti r_i posameznih opazovanj močno spreminja, ne ostaja v bližini $\overline{r}$.

To pomeni, da imamo v matematičnem modelu različen nadzor nad opazovanji.

S primerjavo števil nadštevilnosti posameznih opazovanj v matematičnem modelu ali z ugotavljanjem števil nadštevilnosti v posameznih delih matematičnega modela ugotavljamo »čvrstost« posameznih delov matematičnega modela.

V praksi stremimo za tem, da je nadštevilnost posameznih delov matematičnega modela približno enaka, kar zagotavlja enake možnosti odkrivanja grobo pogrešenih opazovanj na celotnem območju matematičnega modela.

Število nadštevilnosti je v celoti odvisno od geometrije problema in ni odvisno od dejanskih vrednosti opazovanj.

Zato ga lahko določimo pred izvedbo meritev in tako poskrbimo za enakomerno kakovost (preko enakomernega nadzora nad morebiti prisotnimi grobimi pogreški) vseh delov matematičnega modela.

Lahko rečemo, da s tem poskrbimo za enakomerno zanesljivost rezultatov v vseh delih matematičnega modela.

PRIMER:

Imamo kocko, v kateri smo opazovali dolžino stranice – l_1, dolžino diagonale osnovne ploskve – l_2, dolžino telesne diagonale – l_3, obseg osnovne ploskve – l_4, ploščino odnovne ploskve – l_5 in prostornino – l_6.

<u>1. Opazovanja so nekorelirana in enake natačnosti.</u>

1.1. Sestavi matriko $\mathbf{R}$ in jo komentiraj.

1.2. Za različna števila in kombinacije opazovanj sestavi matrike $\mathbf{R}$ in jih primerjaj med seboj.

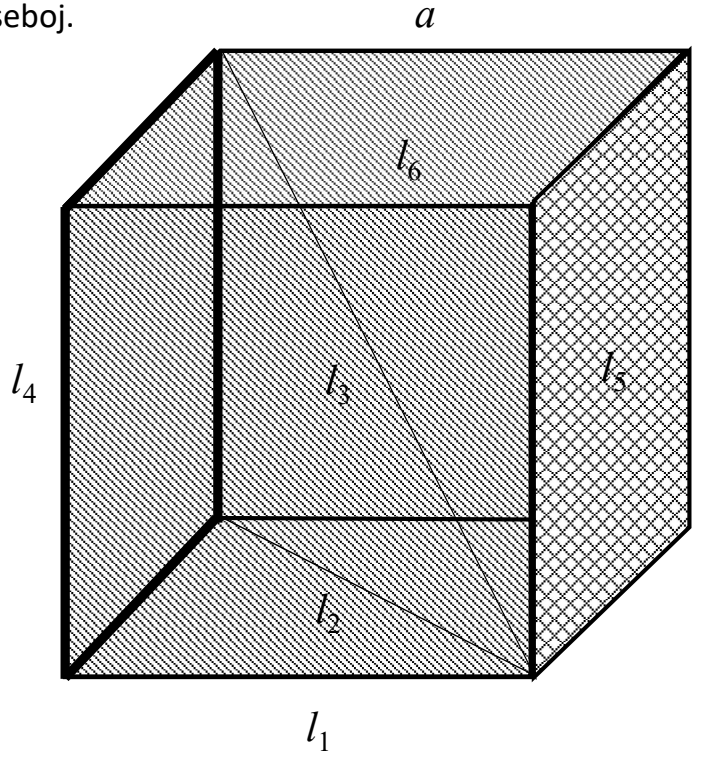

Podatki:

$l_1 = 10\text{m}$
$l_2 = 14.4\text{m}$
$l_3 = 17.3\text{m}$
$l_4 = 40.1\text{m}$
$l_5 = 101\text{m}^2$
$l_6 = 1000\text{m}^3$

Parametri problema:

$n = 6$
$n_0 = 1$
$u = 1$
$r = 5$

Za $u = 1$ neznanko izberemo dolžino stranice kocke a.

Enačbe, ki povezujejo opazovanja $l_1 - l_6$ in dolžino stranice a so:

$$F_1 = l_1 - a = 0$$
$$F_2 = l_2 - a\sqrt{2} = 0$$
$$F_3 = l_3 - a\sqrt{3} = 0$$
$$F_4 = l_4 - 4a = 0$$
$$F_5 = l_5 - a^2 = 0$$
$$F_6 = l_6 - a^3 = 0$$

Enačbe so nelinearne za neznanko $\rightarrow$ linearizacija.

Linearizirane enačbe popravkov opazovanj so:

$$v_1 - 1 \cdot \delta a = a_0 - l_1$$
$$v_2 - \sqrt{2} \cdot \delta a = \sqrt{2} \cdot a_0 - l_2$$
$$v_3 - \sqrt{3} \cdot \delta a = \sqrt{3} \cdot a_0 - l_3$$
$$v_4 - 4 \cdot \delta a = 4 \cdot a_0 - l_4$$
$$v_5 - 2 \cdot a \cdot \delta a = a_0^2 - l_5$$
$$v_6 - 3 \cdot a^2 \cdot \delta a = a_0^3 - l_6$$

Izberemo približno vrednost za a, $a_0 = 10\mathrm{m}$.

Matrika $\mathbf{B}$ in vektor $\mathbf{f}$ sta:

$$\mathbf{B} = \begin{bmatrix} -1 \\ -\sqrt{2} \\ -\sqrt{3} \\ -4 \\ -2 \cdot a_0 \\ -3 \cdot a_0^2 \end{bmatrix}; \quad \mathbf{f} = \begin{bmatrix} 0 \\ -0.2579 \\ 0.0205 \\ -0.1000 \\ -1 \\ 0 \end{bmatrix}$$

Matrika uteži $\mathbf{P}$ je enotska matrika

1.1. Matrika $\mathbf{R}$ je (vrednosti so zaokrožene na 4 decimalna mesta):

$$\mathbf{R} = \mathbf{I} - \mathbf{B}\left(\mathbf{B}^T\mathbf{B}\right)^{-1}\mathbf{B}^T = \begin{bmatrix} 1.0000 & -0.0000 & -0.0000 & -0.0000 & -0.0002 & -0.0033 \\ -0.0000 & 1.0000 & -0.0000 & -0.0001 & -0.0003 & -0.0047 \\ -0.0000 & -0.0000 & 1.0000 & -0.0001 & -0.0004 & -0.0057 \\ -0.0000 & -0.0001 & -0.0001 & 0.9998 & -0.0009 & -0.0133 \\ -0.0002 & -0.0003 & -0.0004 & -0.0009 & 0.9956 & -0.0664 \\ -0.0033 & -0.0047 & -0.0057 & -0.0133 & -0.0664 & 0.0047 \end{bmatrix}$$

Vsota diagonalnih elementov je 5.

1.2. Sestavimo matriko $\mathbf{R}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

Matrika $\mathbf{R} = \begin{bmatrix} 0.6667 & -0.4714 \\ -0.4714 & 0.3333 \end{bmatrix}$

b.) Opazovanja l_1, l_2 in l_3:

Matrika $\mathbf{R} = \begin{bmatrix} 0.8333 & -0.2357 & -0.2887 \\ -0.2357 & 0.6667 & -0.4082 \\ -0.2887 & -0.4082 & 0.5000 \end{bmatrix}$

c.) Opazovanja l_1, l_2, l_3 in l_4:

Matrika $\mathbf{R} = \begin{bmatrix} 0.9545 & -0.0643 & -0.0787 & -0.1818 \\ -0.0643 & 0.9091 & -0.1113 & -0.2571 \\ -0.0787 & -0.1113 & 0.8636 & -0.3149 \\ -0.1818 & -0.2571 & -0.3149 & 0.2727 \end{bmatrix}$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

Matrika $\mathbf{R} = \begin{bmatrix} 0.9976 & -0.0034 & -0.0041 & -0.0095 & -0.0474 \\ -0.0034 & 0.9953 & -0.0058 & -0.0134 & -0.0670 \\ -0.0041 & -0.0058 & 0.9929 & -0.0164 & -0.0821 \\ -0.0095 & -0.0134 & -0.0164 & 0.9621 & -0.1896 \\ -0.0474 & -0.0670 & -0.0821 & -0.1896 & 0.0521 \end{bmatrix}$

2. Opazovanja so nekorelirana in različne natačnosti

Standardni odkloni opazovanj so sedaj:

$$\sigma_1 = 0.2\text{m}$$
$$\sigma_2 = 0.24\text{m}$$
$$\sigma_3 = 0.27\text{m}$$
$$\sigma_4 = 0.5\text{m}$$
$$\sigma_5 = 1\text{m}^2$$
$$\sigma_6 = 5\text{m}^3$$

Kovariančna matrika opazovanj $\boldsymbol{\Sigma}$ je:

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0.0040 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.0576 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.0729 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.2500 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 25.000 \end{bmatrix}$$

Matrika uteži opazovanj $\mathbf{P}$ je:

$$\mathbf{P} = \begin{bmatrix} 25.0000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 17.3611 & 0 & 0 & 0 & 0 \\ 0 & 0 & 13.7174 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4.0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.0400 \end{bmatrix}$$

2.1. Ponovno sestavi matriko $\mathbf{R}$ in jo komentiraj.

$$\mathbf{R} = \mathbf{I} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T\mathbf{P} = \begin{bmatrix} 0.9940 & -0.0059 & -0.0057 & -0.0038 & -0.0048 & -0.0029 \\ -0.0085 & 0.9917 & -0.0081 & -0.0054 & -0.0068 & -0.0041 \\ -0.0104 & -0.0102 & 0.9901 & -0.0067 & -0.0083 & -0.0050 \\ -0.0240 & -0.0236 & -0.0228 & 0.9846 & -0.0192 & -0.0115 \\ -0.1201 & -0.1179 & -0.1141 & -0.0768 & 0.9040 & -0.0576 \\ -1.8008 & -1.7685 & -1.7114 & -1.1525 & -1.4406 & 0.1356 \end{bmatrix}$$

Vsota diagonalnih elementov je zopet 5.

2.2. Spet sestavimo matriko $\mathbf{R}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

Matrika $\mathbf{R} = \begin{bmatrix} 0.5814 & -0.4111 \\ -0.5920 & 0.4186 \end{bmatrix}$

b.) Opazovanja l_1, l_2 in l_3:

Matrika $\mathbf{R} = \begin{bmatrix} 0.7522 & -0.2434 & -0.2355 \\ -0.3505 & 0.6558 & -0.3331 \\ -0.4293 & -0.4216 & 0.5920 \end{bmatrix}$

c.) Opazovanja l_1, l_2, l_3 in l_4:

Matrika $\mathbf{R} = \begin{bmatrix} 0.8484 & -0.1489 & -0.1441 & -0.0970 \\ -0.2144 & 0.7894 & -0.2038 & -0.1372 \\ -0.2626 & -0.2579 & 0.7504 & -0.1681 \\ -0.6065 & -0.5957 & -0.5764 & 0.6118 \end{bmatrix}$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

Matrika $\mathbf{R} = \begin{bmatrix} 0.9557 & -0.0435 & -0.0421 & -0.0283 & -0.0354 \\ -0.0626 & 0.9385 & -0.0595 & -0.0401 & -0.0501 \\ -0.0767 & -0.0753 & 0.9271 & -0.0491 & -0.0613 \\ -0.1770 & -0.1739 & -0.1682 & 0.8867 & -0.1416 \\ -0.8852 & -0.8693 & -0.8412 & -0.5665 & 0.2919 \end{bmatrix}$

3. Opazovanja so nekorelirana in različne natačnosti

Standardni odkloni opazovanj so sedaj:

$$\sigma_1 = 0.010\text{m}$$
$$\sigma_2 = 0.014\text{m}$$
$$\sigma_3 = 0.017\text{m}$$
$$\sigma_4 = 0.040\text{m}$$
$$\sigma_5 = 0.200\text{m}^2$$
$$\sigma_6 = 3.000\text{m}^3$$

Kovariančna matrika opazovanj $\boldsymbol{\Sigma}$ je:

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0.0001 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.0002 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.0003 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.0016 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.0400 & 0 \\ 0 & 0 & 0 & 0 & 0 & 9.0000 \end{bmatrix}$$

Matrika uteži opazovanj $\mathbf{P}$ je:

$$\mathbf{P} = \begin{bmatrix} 10000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 5102 & 0 & 0 & 0 & 0 \\ 0 & 0 & 3460 & 0 & 0 & 0 \\ 0 & 0 & 0 & 625 & 0 & 0 \\ 0 & 0 & 0 & 0 & 25 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.1111 \end{bmatrix}$$

3.1. Sestavi matriko $\mathbf{R}$ in jo ponovno komentiraj.

$$\mathbf{R} = \mathbf{I} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T\mathbf{P} = \begin{bmatrix} 0.8349 & -0.1191 & -0.0989 & -0.0413 & -0.0083 & -0.0006 \\ -0.2334 & 0.8316 & -0.1399 & -0.0584 & -0.0117 & -0.0008 \\ -0.2859 & -0.2063 & 0.8287 & -0.0715 & -0.0143 & -0.0010 \\ -0.6602 & -0.4764 & -0.3957 & 0.8349 & -0.0330 & -0.0022 \\ -3.3012 & -2.3819 & -1.9785 & -0.8253 & 0.8349 & -0.0110 \\ -49.5174 & -35.7287 & -29.6771 & -12.3794 & -2.4759 & 0.8349 \end{bmatrix}$$

Vsota diagonalnih elementov je zopet 5.

3.2 Spet sestavimo matriko $\mathbf{R}$ za različne kombinacije opazovanj:

a.) Opazovanji l_1 in l_2:

Matrika $\mathbf{R} = \begin{bmatrix} 0.5051 & -0.3571 \\ -0.7000 & 0.4949 \end{bmatrix}$

b.) Opazovanja l_1, l_2 in l_3:

Matrika $\mathbf{R} = \begin{bmatrix} 0.6730 & -0.2359 & -0.1960 \\ -0.4624 & 0.6664 & -0.2771 \\ -0.5663 & -0.4086 & 0.6606 \end{bmatrix}$

c.) Opazovanja l_1, l_2, l_3 in l_4:

Matrika $\mathbf{R} = \begin{bmatrix} 0.7536 & -0.1778 & -0.1477 & -0.0616 \\ -0.3485 & 0.7486 & -0.2088 & -0.0871 \\ -0.4268 & -0.3079 & 0.7442 & -0.1067 \\ -0.9856 & -0.7111 & -0.5907 & 0.7536 \end{bmatrix}$

d.) Opazovanja l_1, l_2, l_3, l_4 in l_5:

Matrika $\mathbf{R} = \begin{bmatrix} 0.8023 & -0.1426 & -0.1185 & -0.0494 & -0.0099 \\ -0.2796 & 0.7983 & -0.1676 & -0.0699 & -0.0140 \\ -0.3424 & -0.2471 & 0.7948 & -0.0856 & -0.0171 \\ -0.7908 & -0.5706 & -0.4739 & 0.8023 & -0.0395 \\ -3.9538 & -2.8528 & -2.3696 & -0.9884 & 0.8023 \end{bmatrix}$

Statistične hipoteze v odkrivanju grobih pogreškov opazovanj

V primeru izravnave opazovanj po MNK so opazovanja lahko poljubno porazdeljena.

Morajo pa biti normalno porazdeljena za uporabo navedenih parametričnih statističnih testov (testov, s katerimi testiramo parametre porazdelitve).

To zahtevo oblikujemo kot:

- opazovanja so normalno porazdeljena s pričakovano vrednostjo $\mathbf{d}-\mathbf{B}\boldsymbol{\Delta}$ in
- kovariančna matrika opazovanj je $\boldsymbol{\Sigma}_{\mathbf{ll}}=\boldsymbol{\Sigma}=\sigma_0^2\mathbf{P}^{-1}$.

Ničelno hipotezo lahko zapišemo kot:

$$H_0:\ \mathbf{l}\in N\left(\mathbf{d}-\mathbf{B}\boldsymbol{\Delta},\sigma_0^2\mathbf{P}^{-1}\right) \qquad (1)$$

Za vsako ničelno hipotezo obstaja neskončno alternativnih hipotez.

Za naš primer lahko sestavimo prvo alternativno hipotezo H_1, s katero trdimo da opazovanja ne izvirajo iz normalno porazdeljene populacije:

$$H_1:\ \mathbf{l}\notin N\left(\mathbf{d}-\mathbf{B}\boldsymbol{\Delta},\sigma_0^2\mathbf{P}^{-1}\right) \qquad (2)$$

Test ničelne glede na alternativno hipotezo izvedemo s t.i. χ^2 testom prileganja (angl.: »goodness of fit test«), s katerim skušamo ugotoviti ali je histogram popravkov opazovanj skladen z normalno porazdelitvijo.

Praksa kaže, da so tipična opazovanja v geodeziji normalno porazdeljena, zato se omejimo na takšne primere.

Srednja vrednost in varianca normalno porazdeljene populacije sta lahko drugačni od podane v ničelni hipotezi.

To vodi do štirih možnih alternativnih hipotez:

$H_{1-1}: \mathbf{l} \in N\left(\mathbf{d}-\mathbf{B}\boldsymbol{\Delta}, \tilde{\sigma}_0^2\mathbf{P}^{-1}\right)$ … napačen stohastični model (3)

$H_{1-2}: \mathbf{l} \in N\left(\mathbf{d}-\mathbf{B}\boldsymbol{\Delta}-\nabla\mathbf{l}, \sigma_0^2\mathbf{P}^{-1}\right)$ … grobi pogreški v opazovanjih (4)

$H_{1-3}: \mathbf{l} \in N\left(\mathbf{A}\mathbf{y}, \sigma_0^2\mathbf{P}^{-1}\right)$ … napačen funkcijski model (5)

$H_{1-4}: \mathbf{l} \in N\left(\mathbf{A}\mathbf{y}, \tilde{\sigma}_0^2\mathbf{P}^{-1}\right)$ … napačen funkcijski in stohastični model (6)

Dodatni komentar alternativnih hipotez:

- H_{1-1} pomeni, da smo uporabili napačne uteži opazovanj $\tilde{\sigma}_0^2 \neq \sigma_0^2$
- H_{1-2} predstavlja možnost, da je med opazovanji prisoten grobi pogrešek ($\nabla\mathbf{l} \neq 0$)
- H_{1-3} pomeni, da je funkcijski model napačen ($\mathbf{d}-\mathbf{B}\Delta \neq \mathbf{A}\mathbf{y}$).
- H_{1-4} predstavlja možnost v celoti napačnega matematičnega modela.

Ko ničelno hipotezo H_0 zavrnemo, imamo torej na voljo več možnih alternativnih hipotez.

Izbira pravilne alternativne hipoteze je lahko dokaj težavna in zahteva dobro poznavanje postopkov meritev in analize rezultatov.

V primeru, ko ničelno hipotezo zavrnemo, imamo najpogosteje opravka z alternativnima hipotezama H_{1-1} in H_{1-2}.

Najpomembnejše količine v vrednotenju rezultatov izravnave so popravki opazovanj.

Zato sestavimo primerno ničelno in alternativne hipoteze, ki se naslanjajo na porazdelitev verjetnosti popravkov opazovanj.

Ustrezne hipoteze so:

$$H_0 : \mathbf{v} \in N(\mathbf{0}, \mathbf{\Sigma_{vv}}) \tag{7}$$

$$H_{1-1} : \mathbf{v} \in N(\mathbf{0}, \tilde{\mathbf{\Sigma}}_{\mathbf{vv}}) \tag{8}$$

$$H_{1-2} : \mathbf{v} \in N(\nabla\mathbf{v}, \mathbf{\Sigma_{vv}}) \tag{9}$$

kjer so:

$$\Sigma_{\mathbf{vv}} = \sigma_0^2 \left[\mathbf{P}^{-1} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T \right] \tag{10}$$

$$\tilde{\Sigma}_{\mathbf{vv}} = \tilde{\sigma}_0^2 \left[\mathbf{P}^{-1} - \mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T \right] \tag{11}$$

$$\nabla\mathbf{v} = -\mathbf{R}\nabla\mathbf{l} = \left[\mathbf{B}\left(\mathbf{B}^T\mathbf{P}\mathbf{B}\right)^{-1}\mathbf{B}^T\mathbf{P} - \mathbf{I} \right]\nabla\mathbf{l} \tag{12}$$

Enačba (7) podaja situacijo v kateri naj bi bila opazovanja $\mathbf{l}$ obremenjena samo s slučajnimi pogreški, s srednjo vrednostjo enako 0.

V tem primeru naj bi bil vektor popravkov opazovanj slučajni vektor s srednjo vrednostjo enako 0.

Namen vrednotenja rezultatov izravnave je ocenjevanje popravkov opazovanj z uporabo statističnega testiranja hipotez.

Ugotoviti torej želimo ali popravki opazovanj izpolnjujejo gornjo domnevo (7), to je ali so opazovanja obremenjena z grobimi pogreški.

V osnovi imamo dva postopka testiranja ničelne hipoteze na osnovi popravkov opazovanj, glede na to ali je referenčna varianca (a-priori) σ_0^2 znana ali ne.

Prvi postopek t. i. globalni test modela ter pregled podatkov opazovanj je predlagal nizozemski geodet Baarda (1968) in vključuje:

- ugotovitev morebiti prisotnih grobih pogreškov opazovanj s t. i. globalnim testom modela
- lociranje grobih pogreškov s postopkom t. i. pregleda podatkov opazovanj oz. postopkom »data snooping«

Postopek uporabimo, ko je referenčna varianca (a-priori) σ_0^2 znana.

Drugi postopek t. i. τ –test je predlagal ameriški geodet Pope (1976), v primeru, ko referenčna varianca (a-priori) σ_0^2 ni znana.

Globalni test modela in pregled opazovanj

Globalni test modela in pregled opazovanj (angl.: »Data snooping«) sta (je) najpogosteje uporabljana postopka za ocenjevanje rezultatov izravnave na osnovi popravkov opazovanj.

Z globalnim testom modela ugotovimo prisotnost grobih pogreškov v opazovanjih, s postopkom pregleda opazovanj – »data snooping«-om nato lociramo grobo pogrešena opazovanja.

Po izravnavi najprej izvedemo globalni test modela, s katerim testiramo skladnost referenčne variance a-posteriori $\hat{\sigma}_0^2$ z referenčno varianco a-priori σ_0^2.

Če je globalni test modela neuspešen, imamo težave s potrjevanjem ničelne hipoteze (7), zato je v tem primeru potreben drugi korak – pregled opazovanj.

Očitno je, da moramo v tem primeru zanesljivo poznati natančnost opazovanj, poznati moramo referenčno varianco a-priori σ_0^2.

V nasprotnem je smiselna interpretacija rezultatov testov precej težavna (praktično neizvedljiva).

Globalni test modela (testiranje skladnosti referenčne variance a-priori in referenčne variance a-posteriori)

Referenčno varianco a-posteriori $\hat{\sigma}_0^2$ določimo na osnovi rezultatov izravnave z izrazom:

$$\hat{\sigma}_0{}^2 = \frac{\mathbf{v}^T\mathbf{P}\mathbf{v}}{n-n_0} = \frac{\mathbf{v}^T\mathbf{P}\mathbf{v}}{r} \tag{1}$$

Po definiciji relacij med $\mathbf{P}$, $\mathbf{Q}$ in $\boldsymbol{\Sigma}$, velja:

$$\mathbf{P} = \mathbf{Q}^{-1} = \sigma_0{}^2\boldsymbol{\Sigma}^{-1} \tag{2}$$

in lahko zapišemo:

$$\mathbf{v}^T\mathbf{P}\mathbf{v} = \sigma_0{}^2(\mathbf{v}^T\boldsymbol{\Sigma}^{-1}\mathbf{v}) \tag{3}$$

Dokazati se da, da je pričakovana vrednost izraza:

$$E(\mathbf{v}^T\boldsymbol{\Sigma}^{-1}\mathbf{v}) = n - n_0 = r \tag{4}$$

V skladu z enačbama (3) in (4) je:

$$E(\mathbf{v}^T\mathbf{P}\,\mathbf{v}) = \sigma_0{}^2E(\mathbf{v}^T\boldsymbol{\Sigma}^{-1}\mathbf{v}) = \sigma_0{}^2r \tag{5}$$

oziroma:

$$\sigma_0^2 = \frac{E(\mathbf{v}^T\mathbf{P}\,\mathbf{v})}{r} \tag{6}$$

Če predpostavimo za a-priori vrednost referenčne variance $\sigma_0^2 = 1$, imamo:

$$\sigma_0^2 = 1 = \frac{E\left(\mathbf{v}^T \mathbf{P}\, \mathbf{v}\right)}{r} \rightarrow E\left(\mathbf{v}^T \mathbf{P}\, \mathbf{v}\right) = r \qquad (7)$$

Od tod sledi vrednost za nepristransko oceno za referenčno varianco a-posteriori $\hat{\sigma}_0^2$:

$$\hat{\sigma}_0^2 = \frac{E\left(\mathbf{v}^T \mathbf{P}\, \mathbf{v}\right)}{r} = \frac{r}{r} = 1 \qquad (8)$$

Kar pomeni, da naj bi bila referenčna varianca a-posteriori $\hat{\sigma}_0^2$ enaka (statistično skladna) z referenčno varianco a-priori σ_0^2.

Skladnost referenčne variance a-posteriori $\hat{\sigma}_0^2$ z referenčno varianco a-priori σ_0^2 ugotavljamo z globalnim testom modela.

Uporabimo testno statistiko:

$$Y = \frac{r \cdot \hat{\sigma}_0^2}{\sigma_0^2} \qquad (9)$$

Pokazati se da, da se pod ničelno hipotezo H_0 (en (7)↑), testna statistika Y porazdeljuje s χ^2–porazdelitvijo z r–prostostnimi stopnjami.

Glede porazdelitve testne statistike Y lahko tako zapišemo:

$$Y \left| H_0 \in \chi^2(r) \right. \qquad (10)$$

Pričakovana vrednost za $\chi^2(r)$ je r, torej velja:

$$E\left\{Y \middle| H_0\right\} = r \tag{11}$$

iz česar izhaja $\left(\frac{Y}{r} = \frac{\hat{\sigma}_0^2}{\sigma_0^2}\right)$:

$$E\left\{\frac{\hat{\sigma}_0^2}{\sigma_0^2} \middle| H_0\right\} = 1 \tag{12}$$

oziroma:

$$E\left\{\hat{\sigma}_0^2 \middle| H_0\right\} = \sigma_0^2 \tag{13}$$

V povezavi z ničelno hipotezo H_0 (en. (7)↑) naj bi torej bila pričakovana vrednost referenčne variance a-posteriori $\hat{\sigma}_0^2$ skladna z referenčno varianco a-priori σ_0^2.

Ob dani stopnji značilnosti testa α, v povezavi z dvostranskimi statističnimi testi, ničelno hipotezo H_0 (en. (7)↑) zavrnemo, če velja:

$$Y < \chi^2_{\alpha/2}(r) \text{ ali } Y > \chi^2_{1-\alpha/2}(r) \tag{14}$$

Ničelne hipoteze pa ne zavrnemo, če velja:

$$\chi^2_{\alpha/2}(r) \leq Y \leq \chi^2_{1-\alpha/2}(r) \tag{15}$$

Če ničelno hipotezo zavrnemo, lahko sprejmemo (ne zavrnemo) neskončno mnogo alternativnih hipotez.

Kot smo omenili, se omejimo na dve izmed njih:

H_{1-1} … nepravilne uteži opazovanj,

H_{1-2} … prisotnost grobih pogreškov v opazovanjih

V začetni fazi ne vemo, s katero možnostjo imamo opravka, zato rešujemo problem postopoma.

Najprej preverimo prvo možnost ali smo opazovanjem dodelili pravilne uteži.

Vrednost testne statistike Y izračunamo z izrazom:

$$Y = \frac{r \cdot \hat{\sigma}_0^2}{\sigma_0^2} = \mathbf{v}^T \frac{\mathbf{P}}{\sigma_0^2} \mathbf{v} = \mathbf{v}^T \boldsymbol{\Sigma}^{-1} \mathbf{v} \qquad (16)$$

ker velja $\mathbf{P} = \sigma_0^2 \boldsymbol{\Sigma}^{-1}$.

Iz enačbe (16) izhaja, da je testna statistika Y neodvisna od izbire referenčne variance a-priori σ_0^2.

Odvisna je samo od popravkov opazovanj $\mathbf{v}$ in kovariančne matrike opazovanj $\boldsymbol{\Sigma}$.

Tudi pod alternativno hipotezo H_{1-1} je pričakovana vrednost vektorja popravkov $\mathbf{v}$ enaka 0.

Vrednost testne statistike Y lahko obravnavamo kot obratno sorazmerno s kovariančno matriko opazovanj $\boldsymbol{\Sigma}$.

A-priori podcenjena natančnost opazovanj (glede na dejansko natančnost) vodi v premajhno vrednost testne statistike (glede na spodnjo kritično vrednost) in a-priori precenjena natančnost opazovanj v preveliko vrednost testne statistike (glede na gornjo kritično vrednost).

Ničelno hipotezo H_0 v obeh primerih zavrnemo.

Iz zveze (9) med statistiko Y in referenčno varianco a-posteriori $\hat{\sigma}_0^2$ izhaja:

$$\hat{\sigma}_0^2 = \left(\frac{Y}{r}\right)\sigma_0^2 \qquad (17)$$

V primeru a-priori podcenjene natančnosti opazovanj, bo torej referenčna varianca a-posteriori $\hat{\sigma}_0^2$ manjša od referenčne variance a-priori σ_0^2 in obratno.

Tudi če zavrnemo ničelno hipotezo zaradi a-priori slabo ocenjene natančnosti opazovanj pa so popravki še vedno (lahko) normalno porazdeljeni.

V primeru, ko so popravki po svoji velikosti, glede na natančnost uporabljenega instrumenta, primerno veliki in je referenčna varianca a-posteriori $\hat{\sigma}_0^2$ glede na referenčno varianco a-priori σ_0^2 prevelika, je možen vzrok za zavrnitev ničelne hipoteze slabo sestavljena kovariančna matrika opazovanj $\boldsymbol{\Sigma}$, ki jo je potrebno sestaviti na novo.

V praksi jo običajno spremenimo tako, da prvotno kovariančno matriko $\boldsymbol{\Sigma}$ množimo z referenčno varianco a-posteriori $\hat{\sigma}_0^2$:

$$\tilde{\boldsymbol{\Sigma}} = \hat{\sigma}_0^2\boldsymbol{\Sigma} \qquad (18)$$

Sedaj ponovno izvedemo izravnavo z uporabo na novo sestavljene kovariančne matrike $\tilde{\boldsymbol{\Sigma}}$.

Ničelne hipoteze naj sedaj ne bi zavrnili.

Če pa so v prvem koraku analize prisotni tudi popravki opazovanj, ki so preveliki, glede na natančnost uporabljenega instrumenta in metode meritev, moramo opazovanja testirati glede na prisotnost grobih pogreškov.

Uporabimo tehniko pregleda opazovanj-data snooping.

Pregled opazovanj (data snooping)

Postopek pregleda opazovanj oz. »data snooping« je kombiniran postopek:

1. Odkrivanja »popravkov verjetno grobo pogrešenih opazovanj« (angl.: outlier)

2. Lociranja (in odstranitve) grobo pogrešenih opazovanj.

1. Odkrivanje »popravkov verjetno grobo pogrešenih opazovanj«

Čeprav so popravki opazovanj po izravnavi znani, pa grobi pogreški $\nabla\mathbf{l}$ niso, kar pomeni, da ne moremo trditi, katera opazovanja so grobo pogrešena.

Če imamo razloge za prepričanje, da je bila ničelna hipoteza H_0 (en. (7) $\uparrow$) zavrnjena zaradi prisotnosti grobih pogreškov v opazovanjih (H_{1-2} (en. (9) $\uparrow$ je pravilna), je ključna naloga lociranje in odstranitev grobih pogreškov iz podatkov opazovanj.

Hipoteza H_{1-2} je še vedno preveč splošna, ker ne podaja nobene informacije glede posameznih komponent vektorja grobih pogreškov, ki se nanaša na celoten model.

Potrebujemo torej enostavno in podrobno definirano alternativno hipotezo H_{1-2i}, ki podaja zvezo med popravki opazovanj $\mathbf{v}$ in grobimi pogreški $\nabla\mathbf{l}$.

V okviru tehnike pregleda opazovanj (postopka »data snooping«) predpostavljamo, da je v vektorju opazovanj samo eno ($i-$to) opazovanje grobo pogrešeno.

Alternativno hipotezo H_{1-2i} torej sestavimo kot:

$$H_{1-2i}: \nabla_i \mathbf{l} = \mathbf{c}_i \cdot \nabla l_i \neq 0 \quad (i=1,...,n) \tag{19}$$

kjer je $\mathbf{c}_i = \begin{bmatrix} 0 & 0 & ... & 0 & 1 & 0 & ... & 0 \end{bmatrix}^T$ vektor ničel z eno enico na $i-$tem mestu, ∇l_i je grobi pogrešek na $i-$tem mestu v vektorju $\mathbf{l}$.

Kot testno statistiko za testiranje ničelne hipoteze H_0 (en. (7) ↑) uporabimo:

$$w_i = \frac{\mathbf{c}_i^T \mathbf{P}\mathbf{v}}{\sigma_0^2 \sqrt{\mathbf{c}_i^T \mathbf{P}\mathbf{Q}_{vv}\mathbf{P}\mathbf{c}_i}} \tag{20}$$

ki se za nekorelirana opazovanja (matrika uteži $\mathbf{P}$ je diagonalna matrika) reducira v t. i. standardizirani popravek:

$$w_i = \frac{v_i}{\sqrt{r_i}\sigma_{l_i}} = \frac{v_i}{\sigma_{v_i}} \tag{21}$$

kjer je:

$$\sigma_{v_i} = \sqrt{r_i}\sigma_{l_i} \tag{22}$$

Dokazati se da, da je pod ničelno hipotezo H_0 (en. (7) ↑) statistika w_i porazdeljena po standardni normalni porazdelitvi:

$$w_i \,|\, H_0 \in N(0,1) \tag{23}$$

Ob dani stopnji značilnosti α_0, ob uporabi dvostranskega testa, ničelno hipotezo H_0 (en. (7) ↑) zavrnemo, če velja:

$$w_i < N(0,1)_{(\alpha_0/2)} \text{ ali } w_i > N(0,1)_{(1-\alpha_0/2)} \tag{24}$$

Ničelne hipoteze H_0 ne zavrnemo, če velja:

$$N(0,1)_{(\alpha_0/2)} \le w_i \le N(0,1)_{(1-\alpha_0/2)} \tag{25}$$

kjer sta $N(0,1)_{(\alpha_0/2)}$ in $N(0,1)_{(1-\alpha_0/2)}$ spodnja in gornja kritična vrednost testne statistike w_i, izračunane iz standardne normalne porazdelitve za dano stopnjo značilnosti α_0.

α_0 je stopnja značilnosti testa za izračun mejnih vrednosti kritičnega intervala (24) in (25) za testno statistiko w_i.

Termin »data snooping« se nanaša na enodimenzionalni test, s katerim preiskujemo naenkrat samo en standardizirani popravek (predpostavimo, da imamo v vektorju opazovanj prisotno le eno grobo pogrešeno opazovanje).

Če imamo opravka z več kot enim grobim pogreškom, postopek zaporedoma ponavljamo.

Kot stopnjo značilnosti testa običajno izberemo vrednost $\alpha_0 = 0.001$, ki ji pripada vrednost standardne normalne porazdelitve $N(0,1)$ enaka 3.29.

Ničelno hipotezo H_0 (en. (7) $\uparrow$) zavrnemo in $i-$ ti popravek označimo kot popravek verjetno grobo pogrešenega opazovanja, če velja:

$$|w_i| > 3.29 \qquad (26)$$

oziroma

$$|v_i| > 3.29\sigma_{v_i} \qquad (27)$$

Vrednost testne statistike w_i je izračunana na osnovi znane standardne deviacije opazovanja σ_{l_i}.

Postopek »data snooping« je torej zanesljiv samo v primeru dobro znanih statističnih lastnosti opazovanj.

To je tudi razlog, da je v primeru, ko z globalnim testom modela ničelno hipotezo zavrnemo, potrebno najprej raziskati razloge za to.

2. Lociranje in odstranitev grobih pogreškov

Ko smo odkrili popravke verjetno grobo pogrešenih opazovanj, je naslednji korak lociranje grobih pogreškov.

To pomeni, da je potrebno ugotoviti ali so odkriti popravki verjetno grobo pogrešenih opazovanj posledica grobega pogreška ∇l_i v opazovanju l_i .

V splošnem je uspešnost lociranja grobih pogreškov odvisna od geometrije problema, natančnosti in vrste opazovanj ter od števila in velikosti grobih pogreškov v opazovanjih.

Splošna zahteva je, da so opazovanja med seboj statistično skladna (uravnotežene natančnosti-glej poglavji »potrebna natančnost opazovanj« in primere matrike $\mathbf{R}$).

Očitna je tudi zahteva, da mora biti število grobih pogreškov v opazovanjih manjše kot je skupno število nadštevilnih opazovanj v danem problemu izravnave.

Ker imamo opravka z grobimi pogreški majhne velikosti, je pravilno lociranje grobih pogreškov na osnovi popravkov verjetno grobo pogrešenih opazovanj močno odvisno od lastnosti matematičnega modela (matrike $\mathbf{R}$).

V primeru, da med opazovanji obstaja samo eno grobo pogrešeno opazovanje, lahko, zaradi koreliranosti popravkov opazovanj, popravek verjetno grobo pogrešenega opazovanja dejansko kaže na prisotnost grobega pogreška ∇l_i v opazovanju l_i , samo, če ima to opazovanje dominantno število nadštevilnosti r_i :

$$r_i > \left| r_{ji} \right| \quad (j \neq i, j = 1,...,n) \tag{28}$$

kjer je $r_i \quad (i = 1,...,n)$ diagonalni element in so $r_{ij} \quad (i, j = 1,...n;\ i \neq j)$ izven-diagonalni elementi matrike $\mathbf{R}$.

Tau-test

Globalni test modela in »data snooping« zahtevata, da sta natančnost opazovanj in referenčna varianca a-priori σ_0^2 znana, kar praktično pomeni, da smo sposobni določiti variance opazovanj v pravilnem razmerju ter določiti tudi dejansko (absolutno) natančnost opazovanj.

Če referenčne variance a-priori σ_0^2 ne poznamo, ali se na natančnost opazovanj ne moremo zanesti, uporabimo na mestu referenčne variance a-priori σ_0^2 referenčno varianco a-posteriori $\hat{\sigma}_0^2$.

V tem primeru globalnega testa modela ne izvajamo in tehniko pregleda opazovanj »data snooping« modificiramo z uporabo nove testne statistike τ_i:

$$\tau_i = \frac{v_i}{\hat{\sigma}_{v_i}} = \frac{v_i}{\hat{\sigma}_0 \sqrt{q_{v_i v_i}}} \qquad (1)$$

ki se pod ničelno hipotezo H_0 (en (7) $\uparrow$) porazdeljuje po τ–porazdelitvi z $r-$ prostostnimi stopnjami:

$$\tau_i \,|H_0 \in \tau(r) \qquad (2)$$

Ob dani stopnji značilnosti testa α_0, bo sedaj vrednost τ_i označena kot prevelika, če velja:

$$|\tau_i| > \tau(r)_{(1-\alpha_0/2)} \qquad (3)$$

kjer je $\tau(r)_{(1-\alpha_0/2)}$ kritična vrednost.

Test uporabimo zaporedoma za vse standardizirane popravke.

Težava pri uporabi τ –testa je, da je referenčna varianca a-posteriori $\hat{\sigma}_0^2$ obremenjena s prisotnostjo grobih pogreškov v opazovanjih.

Večji kot so grobi pogreški, večja bo vrednost referenčne variance a-posteriori $\hat{\sigma}_0^2$, ki bo posledično zmanjševala vrednost testne statistike τ_i, dane z izrazom (1).

To tudi pomeni, da lahko, po uporabi tau-testa, ostanejo nekateri grobi pogreški neodkriti, še posebno, ko so majhni po svoji velikosti.

Ko so določeni popravki označeni kot preveliki, je postopek lociranja in odstranitve grobih pogreškov iz opazovanj enak, kot pri tehniki pregleda opazovanj »data snooping«.

POVZETEK STRATEGIJE ODKRIVANJA GROBIH POGREŠKOV

Vrednotenje rezultatov izravnave vključuje tudi ugotavljanje morebitne prisotnosti grobih pogreškov v opazovanjih.

V tej fazi ugotavljamo prisotnost grobih pogreškov, ki so majhni po svoji velikosti.

Velike in srednje velike grobe pogreške naj bi odkrili med izmero, pred izravnavo ali s predhodno analizo opazovanj.

Pri vrednotenju morebitne prisotnosti grobih pogreškov v rezultatih izravnave imamo na razpolago dve tehniki vrednotenja rezultatov:

- globalni test modela in pregled popravkov opazovanj (»data snooping«) in
- »tau-test«

Za uporabo prvega postopka moramo zanesljivo poznati natančnost opazovanj → izvedba globalnega testa modela.

V nasprotnem globalnega testa modela ne moremo izvesti, postopek »data snooping« nadomestimo s postopkom »tau-test«.

Za ustrezno vrednotenje rezultatov izravnave moramo poznati merske postopke, dejansko natančnost meritev, možnosti in načine pojavljanja grobih pogreškov, kot tudi postopke in ozadje tehnik odkrivanja grobih pogreškov v opazovanjih.

Osnovni količini pri postopkih ugotavljanja prisotnosti grobih pogreškov v opazovanjih:

- popravki opazovanj $\mathbf{v}$ in
- referenčna varianca a-posteriori $\hat{\sigma}_0^2$

1. Globalni test modela in pregled popravkov opazovanj (»data snooping«)

Ko je natančnost opazovanj zanesljivo znana, najprej izvedemo globalni test modela.

Če ugotovimo, da referenčno varianco a-posteriori $\hat{\sigma}_0^2$ lahko obravnavamo, kot statistično skladno z referenčno varianco a-priori σ_0^2 trdimo, da so opazovanja prosta grobih pogreškov ter da je stohastični model izravnave pravilno sestavljen.

Reševanje problema izravnave v tem primeru zaključimo.

Priporočljivo pa je, da opravimo tudi postopek pregleda opazovanj – »data snooping«, s katerim preverimo prisotnost grobih pogreškov v opazovanjih.

Ko, na osnovi standardiziranih popravkov, ugotovimo, da nobenega od popravkov opazovanj ne moremo ovrednotiti, kot »popravka verjetno grobo pogrešenega opazovanja« (»outlier«) zaključimo s postopkom vrednotenja rezultatov izravnave.

Če z globalnim testom modela ne moremo trditi, da je referenčna varianca a-posteriori $\hat{\sigma}_0^2$ statistično skladna z referenčno varianco a-priori σ_0^2 sta za to dva možna razloga:

- opazovanjem nismo dodelili pravilnih uteži (napačen je stohastični model izravnave)
- med opazovanji so prisotna (malo) grobo pogrešena opazovanja, ki jih do sedaj nismo odkrili

Če z globalnim testom modela ugotovimo, da referenčne variance a-posteriori $\hat{\sigma}_0^2$ ne moremo obravnavati kot statistično skladne z referenčno varianco a-priori σ_0^2, najprej ponovno ovrednotimo natančnost opazovanj.

Ko menimo, da natančnosti opazovanj ni ustrezna najprej preverimo popravke opazovanj.

Če ti po velikosti ustrezajo natančnosti merskega instrumenta, metodi izmere, okoliščinam meritev… in torej ne moremo trditi, da imamo med popravki takšne, ki jih lahko obravnavamo kot »popravke verjetno grobo pogrešenih opazovanj«, izračunamo referenčno varianco a-posteriori $\hat{\sigma}_0^2$

Z referenčno varianco a-posteriori $\hat{\sigma}_0^2$ pomnožimo prvotno kovariančno matriko opazovanj in ponovimo izravnavo.

Z globalnim testom modela naj bi sedaj ugotovili skladnost referenčne variance a-posteriori $\hat{\sigma}_0^2$ in referenčne variance a-priori σ_0^2.

Enako kot v primeru, ko z globalnim testom modela ugotovimo skladnost referenčne variance a-posteriori $\hat{\sigma}_0^2$ z referenčno varianco a-priori σ_0^2 je tudi v tem primeru priporočljivo nadaljevati s postopkom pregleda opazovanj.

Ko ugotovimo, da nobenega od popravkov ne moremo opredeliti kot »popravka verjetno grobo pogrešenega opazovanja«, zaključimo z izravnavo.

Če z globalnim testom modela ne moremo ugotoviti skladnosti referenčne variance a-posteriori $\hat{\sigma}_0^2$ in referenčne variance a-priori σ_0^2 in ne moremo trditi, da je za to neskladnost razlog v slabo sestavljenem stohastičnem modelu nadaljujemo s pregledom opazovanj.

Če tudi sedaj ne ugotovimo prisotnosti grobih pogreškov, postopek pregleda opazovanj zaključimo.

Če pa ugotovimo prisotnost grobih pogreškov, jih skušamo locirati in grobo pogrešena opazovanja odstraniti iz vektorja opazovanj.

Izravnavo in ves postopek, vključno z globalnim testom modela in postopkom pregleda opazovanj, ponavljamo, dokler ne pridemo v situacijo, ko ugotovljenih (ugotovljivih) grobih pogreškov ni več med opazovanji.

2. Tau–test

V primeru, ko natančnosti opazovanj zanesljivo ne poznamo, opravimo »tau-test«, s katerim testiramo posamezne standardizirane popravke z namenom ugotovitve ali gre za »popravke verjetno grobo pogrešenih opazovanj« (»outlier«).

Postopek ugotavljanja prisotnosti grobih pogreškov med opazovanji s tau-testom je podoben, kot v primeru uporabe postopka »data snooping«.

Zanesljivost odkrivanja »popravkov verjetno grobo pogrešenih opazovanj« s postopkom »tau–test« otežuje dejstvo, da je v tem primeru standardizirani popravek določen na osnovi referenčne variance a-posteriori.

Ta je ob prisotnosti grobih pogreškov praviloma večja od pričakovane, kar povzroči zmanjšanje vrednost testne statistike τ .

Nekateri, predvsem majhni grobi pogreški, lahko pri tem ostanejo neodkriti.

Zaključek

Pri odstranitvi vsakega opazovanja iz vektorja opazovanj na osnovi opazovanju pripadajočega popravka je potrebna previdnost.

Zaradi koreliranosti popravkov je lahko kot »popravek vejretno grobo pogrešenega opazovanja« (»outlier«) opredeljen tudi popravek opazovanja, ki ni grobo pogrešeno.

Dogaja se, da kot grobo pogrešeno odstranimo napačno opazovanje.

Če v taki situaciji ponovimo izravnavo brez (grobo pogrešenega) odstranjenega opazovanja, bodo popravki opazovanj zelo podobni popravkom iz predhodne izravnave.

V takem primeru odstranjeno opazovanje vrnemo ter odstranimo kot verjetno grobo pogrešeno drugo opazovanje.

Pri tem odstranimo tisto opazovanje, ki ima drugo največjo vrednost standardiziranega popravka w_i.

Postopek izvajamo iterativno in sistematično, tako da odstranjujemo opazovanja, ki naj bi bila grobo pogrešena, glede na v izravnavi pridobljene popravke, ki jih ovrednotimo, kot »popravke verjetno grobo pogrešenih opazovanj«.

Postopek je uspešen, če popravki opazovanj med seboj niso močno korelirani (glej matriko nadštevilnosti $\mathbf{R}$).

Do težav lahko pride v primeru, ko imamo veliko grobo pogrešenih opazovanj ter močno koreliranost popravkov opazovanj.

Težave so še večje v primeru majhnih grobih pogreškov.

V postopkih ocenjevanja prisotnosti grobih pogreškov verjetno grobo pogrešenih opazovanj ne odstranjujemo samodejno.

Prvi razlog je cena opravljenega opazovanja, drugi pa zmanjševanje števila nadštevilnih opazovanj ob odstranjevanju opazovanj.

Z vsakim odstranjenim opazovanjem postajajo postopki lociranja grobo pogrešenih opazovanj manj zanesljivi (število nadštevilnih opazovanj se zmanjšuje).

To dejstvo postane posebej problematično v matematičnih modelih z majhnim številom nadštevilnih opazovanj.

Pri vrednotenju rezultatov izravnave moramo vedeti, da imamo praviloma na voljo le majhno (omejeno) število opazovanj in statistične teste, ki jih moramo interpretirati zelo previdno.

Končne odločitve sprejemamo na osnovi poznavanja konceptov in postopkov meritev, merskih tehnologij, izravnalnega računa, izkušenj ter logičnega odločanja.

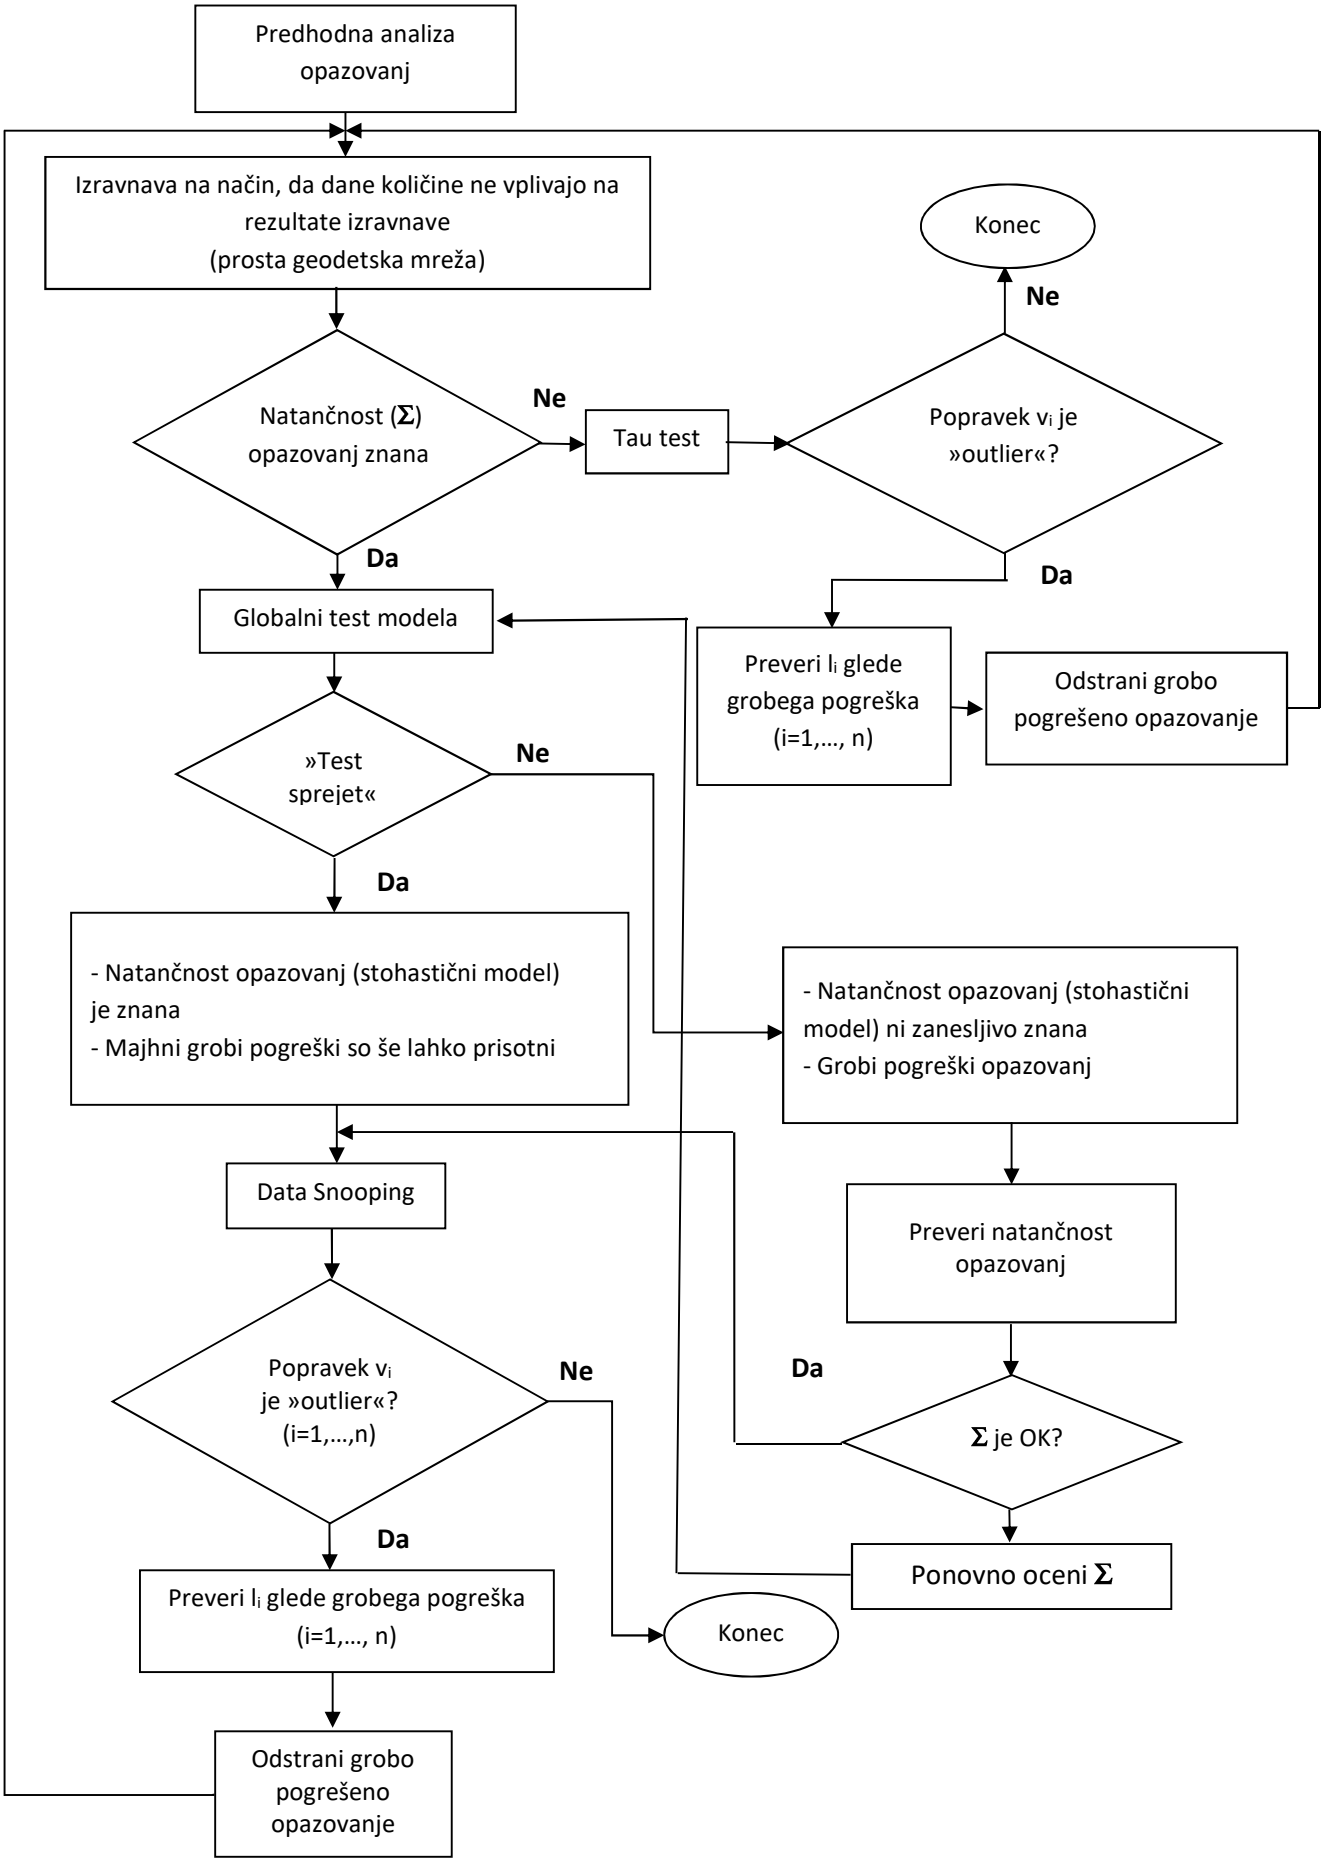
Predhodna analiza opazovanj
Izravnava na način, da dane količine ne vplivajo na rezultate izravnave (prosta geodetska mreža)
Natančnost (Σ) opazovanj znana
Ne
Tau test
Popravek v_i je »outlier«?
Konec
Ne
Da
Da
Globalni test modela
Preveri l_i glede grobega pogreška (i=1,…, n)
Odstrani grobo pogrešeno opazovanje
»Test sprejet«
Ne
Da
- Natančnost opazovanj (stohastični model) je znana
- Majhni grobi pogreški so še lahko prisotni
- Natančnost opazovanj (stohastični model) ni zanesljivo znana
- Grobi pogreški opazovanj
Data Snooping
Preveri natančnost opazovanj
Popravek v_i je »outlier«? (i=1,…,n)
Ne
Da
Σ je OK?
Da
Ponovno oceni Σ
Preveri l_i glede grobega pogreška (i=1,…, n)
Konec
Odstrani grobo pogrešeno opazovanje